

Sleep-Time Compute Conference Appendix

Samsung SAIT Neural Memory Study

Source freeze: 2026-08-05

Appendix scope

이 부록은 conference main 의 page budget 때문에 생략한 evidence chronology, evidence-maturity audit, scaling derivation, infrastructure transaction, benchmark design, negative evidence 와 canonical public claim ledger 를 보존한다. 각 장은 Full Study 와 동일한 frozen source/figure ID 를 사용한다. During the preparation of this work the authors used Codex GPT-5.6 for evidence synthesis, LaTeX drafting, and artifact QA. All content was reviewed and edited by the authors, who take full responsibility for the accuracy and integrity of the work.

Contents

Appendix scope	i
1 계보: biological replay 에서 multi-rate neural memory 까지	1
1.1 1995: complementary learning systems	1
1.2 2017: continual-learning baselines 가 먼저 만든 consolidation 문제	1
1.3 2020 – 2022: NREM/REM analogy 를 계산 mechanism 으로 만든 연구	2
1.4 2023 – 2025: external hierarchy 와 wake-time neural memory	2
1.5 2026: 명시적 parametric sleep 과 product synthesis 의 분기	2
2 Evidence trajectory: 무엇이 실제로 성숙하고 있는가	4
2.1 Date-frozen corpus 와 재현 가능한 경계	4
2.2 Evidence maturity 와 expected value 는 다른 축이다	4
2.3 Industry 와 academia 의 서로 다른 수렴	6
2.4 번역 corpus 가 담당하는 역할	6
3 Scaling law: 법칙이 아니라 측정 가능한 가설부터	7
3.1 State 와 lifecycle work 를 먼저 닫는 identity	7
3.2 Valid reuse 가 만드는 compile break-even	8
3.3 Finite state 가 만드는 capacity knee	8
3.4 Cadence 와 queue 의 내부 optimum	9
3.5 Fit candidate 와 법칙 승격 조건	10
4 System infrastructure: wake, sleep, memory 를 어떻게 잇는가	12
4.1 세 plane 과 하나의 publication transaction	12
4.2 Source-of-record 와 heterogeneous materialized views	12
4.3 Scheduler: operator, destination, cadence 를 분리한다	12
4.4 State migration roofline	13
4.5 네 가지 physical placement	13
4.6 운영 계약	14
5 Falsifiable benchmark 와 experiment roadmap	16
5.1 독립 단위와 cycle	16
5.2 Observable 과 oracle 을 물리적으로 분리한다	16
5.3 Event 와 query family	17
5.4 Confirmatory methods 와 resource envelope	17
5.5 Metric stack	17
5.6 통계 · 재현성과 claim-down rule	18

6	Limitations, negative evidence 와 falsifiers	19
6.1	문헌 자체의 한계	19
6.2	Negative evidence 가 가리키는 구조적 위험	19
6.3	결론을 뒤집거나 좁힐 구체적 falsifier	20
6.4	Coverage 와 saturation 의 한계	20
6.5	본 논문이 주장하지 않는 것	21
	Canonical claim – evidence ledger	22
	참고문헌	25

계보: biological replay 에서 multi-rate neural memory 까지

Sleep-time compute 는 2026 년에 갑자기 생긴 단일 논문 계열이 아니다. Fast/slow learning theory, continual learning, generative replay, external agent memory, test-time neural memory, asynchronous memory agents 가 서로 다른 문제를 풀다가 하나의 lifecycle 로 수렴한다.

1995–2026: 이름보다 먼저 존재한 계보



Figure 1.1: 1995 – 2026 evidence chronology. 연도는 공개 source 의 최초 publication/release 기준이며, 같은 시기의 방법이 동일 maturity 라는 뜻은 아니다.

[STC-F003]

출처/제작: Original synthesis; SRC-STC-0001–SRC-STC-0063 대체 설명: 1995 CLS 에서 2017 continual learning, 2020 PAD, 2023 MemGPT, 2025 Titans/HOPE, 2026 parametric sleep 과 product dreaming 으로 이어지는 시간축.

1.1 1995: complementary learning systems

CLS 는 hippocampus 의 빠른 episodic acquisition 과 neocortex 의 느린 interleaved learning 을 분리했다 (McClelland et al. 1995). 이 관점이 제공하는 basis 는 “새 기억을 빠르게 받는 store” 와 “기존 구조를 보존하며 천천히 통합하는 learner” 를 한 update rule 로 강제하지 않는다는 점이다. 오늘의 system 으로 번역하면 wake log/episodic memory 와 sleep consolidation model 의 역할 분리다.

그러나 biology 에서 production architecture 를 곧바로 도출할 수는 없다. Biological model 은 user scope, exact delete, source attribution, model release compatibility 를 다루지 않는다. 따라서 계보는 mechanism inspiration 이지 deployment evidence 가 아니다.

1.2 2017: continual-learning baselines 가 먼저 만든 consolidation 문제

Deep Generative Replay 는 generator 의 pseudo-data 와 새 data 를 함께 학습해 과거 task forgetting 을 줄이는 강한 non-sleep-named baseline 이다. [STC-C019] (Shin et al. 2017) EWC 는 이전 task 에 중요한 parameter 를 Fisher-weighted quadratic penalty 로 보호해 stability 와 plasticity 를 trade-off 한다. [STC-C020] (Kirkpatrick et al. 2016) GEM 은 stored examples 의 gradient 를 constraint 로 사용해 이전 task loss 가 국소적으로 증가하지 않게 update 를 투영한다. [STC-C021] (Lopez-Paz and Ranzato 2017)

Progress & Compress 는 active column 에서 새 task 를 배우고 consolidation phase 에서 knowledge base 로 압축하는 periodic-refresh 대안을 제시했다. [STC-C022] (Schwarz et al. 2018) 이 계열은 중요한 교훈을 준다. “Sleep” 이라는 이름 없이도 progress/online phase 와 compress/offline phase 를 나눌 수 있으며, 새 term 의 가치는 matched resource 에서 기존 periodic consolidation 보다 나아야 한다.

1.3 2020 – 2022: NREM/REM analogy 를 계산 mechanism 으로 만든 연구

PAD(Perturbed and Adversarial Dreaming) 는 wake, NREM-like perturbed replay, REM-like adversarial dreaming 을 분리해 cortical representation learning 을 연구했다.^[STC-C018] (Deperrois et al. 2022) Hippocampus-neocortex computational model 은 autonomous offline dynamics 와 alternating NREM/REM regime 로 새 정보 통합과 old knowledge 보호를 함께 탐구했다.^[STC-C017] (Singh et al. 2022)

2022 년 PLOS Computational Biology 의 spiking-network 연구는 두 task 설정에서 interleaved sleep-like replay 가 joint synaptic representation 을 형성하고 catastrophic forgetting 을 줄였다고 보고했다.^[STC-C016] (Golden et al. 2022) 이것은 user-scale LLM deployment 증거가 아니라, online data 없이 autonomous replay 가 consolidation 을 도울 수 있다는 mechanism evidence 다. Task 수, modality, network scale, governance 의 외삽을 분리해야 한다.

1.4 2023 – 2025: external hierarchy 와 wake-time neural memory

MemGPT 는 제한된 context 와 external storage 사이에서 information 을 paging 하는 OS-style hierarchy 로 long-term agent memory 를 framing 했다.^[STC-C011] (Packer et al. 2023) 여기서 중요한 변화는 “모델이 모든 것을 weights 에 기억해야 한다” 에서 “virtual memory 처럼 context 와 archival memory 를 관리한다” 로의 이동이다.

Titans 는 surprise-driven update 로 test time 에 neural memory state 를 학습하지만, 그 자체는 wake-path fast-state learning 이지 deferred cross-session sleep 은 아니다.^[STC-C023] (Behrouz et al. 2024) 이 구분은 user framing 의 핵심이다. Test-time learning 은 current/near-current stream 에 적응하고, sleep-time learning 은 더 넓은 replay 와 검증을 거쳐 longer-lived state 를 publish 한다.

Nested Learning/HOPE 는 optimization process 를 여러 update frequency 의 nested memory level 로 보아 cadence 를 분석하는 유용한 틀을 제공하지만, 공개 evidence 는 deployed asynchronous sleep consolidation 을 입증하지 않는다.^[STC-C024] (Behrouz et al. 2025) HOPE 의 CMS 처럼 서로 다른 frequency 로 갱신되는 state 는 wake/sleep scheduler 에 자연스럽게 매핑되지만, frequency hierarchy 와 lifecycle publication 은 별개 요구다.

1.5 2026: 명시적 parametric sleep 과 product synthesis 의 분기

2026 년 계보는 둘로 갈라진다. 한쪽은 Language Models Need Sleep 처럼 self-modification 과 replay-like training 으로 parametric memory 를 통합하는 연구다. 다른 쪽은 Dreaming, Mem0 Dream, Letta 처럼 external memory 를 background 에서 합성하는 product lifecycle 이다. 두 방향은 같은 sleep boundary 를 공유하지만 state medium 과 evidence maturity 가 다르다.

Table 1.1: 계보별 evidence 가 실제로 지지하는 범위

계보	지지하는 것	아직 지지하지 않는 것
biological/computational sleep	autonomous replay 와 multi-phase integration 가능성	LLM fleet economics, delete/rollback
continual learning	forgetting 을 줄이는 replay-constraint-isolation mechanism	무한 capacity, task-free production stability
external agent memory	bounded context 밖 persistent state 와 hierarchy	parametric skill acquisition
neural/test-time memory	forward path 에서 learned state update 가 능성	deferred multi-session publication
explicit parametric sleep	self-modification+consolidation research proof	broad per-user production deployment
product dreaming	scheduled external background synthesis	foundation-weight training 공개 증거

핵심 계보의 종합

새로운 것은 replay 자체가 아니라, persistent agent product 가 wake-derived state 를 background 에서 계속변환하며 serving lifecycle 로 운영하기 시작했다는 점이다. 과학적 novelty 는 matched alternative 대비 효과와 scaling surface 에서, 산업적 novelty 는 publication-rollback-memory plane 의 지속 운영에서 평가

한다.

Evidence trajectory: 무엇이 실제로 성숙하고 있는가

이 장의 목적은 논문 수를 세어 momentum 을 선언하는 것이 아니라, 서로 다른 종류의 증거가 어떤주장을 허용하는지 분리하는 것이다. 연구용 알고리즘의 controlled experiment, 공개 code, 공식 product documentation, production trace, independent incident report 는 같은 무게가 아니다. 또한 “sleep” 이라는 단어가 없는 continual learning, external memory, state caching 연구도 lifecycle 의 일부를 직접 다룰 수 있고, 반대로 생물학적 은유만 사용하는 연구는 operational STC 의 증거가 아닐 수 있다.

2.1 Date-frozen corpus 와 재현 가능한 경계

본 연구는 2026-08-05 를 source freeze 로 고정했다. Registry 에는 paper, official release, documentation, tagged repository 를 합쳐 73 개의 primary/official source 가 들어 있다. [STC-C001] 각 source 는 stable ID, canonical URL, 공개일, 접근일, source type 을 가지며, 본문의 claim 은 prose citation 이 아니라 마지막 ledger 의 exact locator 로 다시 연결된다. 이 수는 검색 결과의 개수가 아니라 중복 제거와 source-kind 판정을 마친 audit surface 다.

동결 시점에 명시적 background memory synthesis 를 설명한 공개 production lineage 는 적어도 OpenAI Dreaming 과 Mem0 Dream 두 개였다. [STC-C002] (OpenAI 2026; Mem0 2026) Letta 의 tagged sleeptime code 와 Zep/Graphiti 의 temporal provenance 는 같은 lifecycle 을 다른 component 에서 보강하지만, product-scale comparative effectiveness 를 대신하지 않는다. 공식 release 는 “기능이 존재한다” 를 지지할 수 있어도 “strongest baseline 보다 우월하다” 를 지지하지 못한다.

검색은 saturation 을 과장하지 않는다. 12 개 cluster 중 2 개만 bounded closure, 5 개는 active frontier, 5 개는 measurement gap 으로 단혔다. [STC-C003] 특히 utility-sleep compute, utility-memory budget, retention-update count, bytes moved-placement curve 가 없는 cluster 는 source 가 많아도 “saturated” 로 부르지는 않았다. 이 규칙은 2026-08-05 이후의 발견이 결론을 바꿀 수 있음을 문서 구조에 남긴다.

2.2 Evidence maturity 와 expected value 는 다른 축이다

Table 2.1: 본문에서 사용하는 evidence maturity ladder

Level	최소 근거	허용되는 문장	허용되지 않는 확대 해석
E0	아이디어 · 명칭	제안되었다	작동한다
E1	단일 synthetic/offline 실험	제한된 setting 에서 관측됐다	일반화된다
E2	다중 task/model 또는 code	조건부로 지지된다	production-ready 다
E3	strong baseline, ablation, long horizon	평가 범위에서 경쟁력 있다	fleet economics 가 성립한다
E4	공식 production lifecycle	공개 제품에서 동작한다	scientific optimum 이다
E5	independent deployment trace-incident	운영 성질이 독립 확인됐다	다른 workload 에도 보편적이다

Expected value 가 높아도 evidence 가 E1 이면 high-upside research bet 이다. 반대로 E5 인 query-time retrieval 이 특정 high-reuse procedural workload 에서 가장 값싼 해답이라는 뜻도 아니다. 본 논문은 problem severity, quality advantage, cost advantage, evidence maturity, deployment fit, governance, industry momentum, academic momentum 을 각각 기록하고 평균 점수 하나로 숨기지 않는다.




Figure 2.1: Source freeze 시점의 industry-academia landscape. Industry 는 external synthesis 와 temporal provenance 에, academia 는 continual learning, neural memory, learned writer 와 capacity theory 에 더 넓게 분포한다. 좌표는 corpus 의 정성적 audit 를 시각화한 것이며 시장 규모가 아니다.

[STC-F014]

출처/제작: Original synthesis; SRC-STC-0054, SRC-STC-0056, SRC-STC-0057 대체 설명: 제품과 연구 lineages 를 external lifecycle, learned memory policy, parametric consolidation, benchmark/theory 축에 배치한 지도.

2.3 Industry 와 academia 의 서로 다른 수렵

Industry 에서 가장 분명한 경로는 episode 보존 → contradiction/dedup → scheduled pattern synthesis → future retrieval → user control/provenance 다. Academia 의 경로는 더 넓다. Replay 와 continual-learning regularization, test-time neural memory, memory writer/router RL, rate-distortion compaction, self-evolving strategy memory, sequential fact reachability 가 서로 다른 이름으로 같은 admission-transform-destination-validation 문제를 만든다. (Behrouz et al. 2025; Behrouz et al. 2026a; Colaco and Lahjouji 2026; Ouyang et al. 2025; Unknown organization 2026a)

따라서 momentum 에 대한 정확한 표현은 “external background transformation 은 I3/E4 에 도달했고, learned external policy 는 빠른 E2-E3 frontier 이며, broad per-user parametric sleep 은 E1-E2” 다. 이 세 문장을 하나의 “STC 가 뜬다” 로 합치면 투자 방향과 실험 설계가 모두 왜곡된다.

2.4 번역 corpus 가 담당하는 역할

전체 source 를 모두 번역하는 대신, explicit sleep, biological/computational precursor, continual learning, external memory, neural memory, capacity, negative evidence 를 가로지르는 15 편을 balanced translation corpus 로 고정했다.^[STC-C004] 번역본은 의견을 추가하는 secondary review 가 아니라 원문의 section-figure-limitation 을 보존하는 독해 보조물이다. 반면 이 Study 는 그 source 들을 problem 과 lifecycle 기준으로 재조합하는 분석이다. 두 산출물을 분리해야 번역자의 해석이 원저자의 주장처럼 보이지 않는다.

핵심 Evidence trajectory 의 결론


새로운 축의 가장 강한 증거는 하나의 breakthrough paper 가 아니다. Continual-learning mechanism, external-memory product, asynchronous implementation, temporal provenance, realistic benchmark 가 서로다른 층에서 같은 lifecycle boundary 를 채우기 시작했다는 점이다. 다만 parametric destination 의 장기 retention·delete·rollback·fleet cost 를 동시에 보여 주는 공개 증거는 아직 비어 있다.

Scaling law: 법칙이 아니라 측정 가능한 가설부터

Pre-training scaling 은 통제된 data, parameter, compute 와 loss 의 관계를 다룬다. STC 에는 previous state, wake evidence, admission policy, memory medium, cycle count, future query reuse, validation 과 publication 이 추가되어 path-dependent 하다. 따라서 “accuracy versus sleep FLOPs” 한 곡선은 state 가증가했는지, data 가 좋아졌는지, future reuse 가 달랐는지 구분하지 못한다.

동결 corpus 의 어느 source 도 보편적인 sleep-time scaling law 를 확립하지 않는다.^[STC-C041] (Morris et al. 2025; Colaco and Lahjouji 2026; Unknown organization 2026b) 아래 식은 MEASURED accounting identity, ANALYTICAL break-even, FIT CANDIDATE, HYPOTHESIS 의 네 등급으로 분리한다. 관측 전 가설을 “law” 라고 부르지 않는 것이 이 장의 가장 중요한 결과다.

수식의 지위를 섞지 않는다



universal ‘more sleep FLOPs → better memory’ law: not established

Figure 3.1: Scaling statement 의 네 등급. Identity 는 장부를 담고, break-even 은 제한된 가정 아래경계를 계산하며, fit candidate 는 sweep 에 맞추고, hypothesis 는 반증 실험을 기다린다.

^[STC-F007]

출처/제작: Original synthesis; SRC-STC-0035, SRC-STC-0050 **대체 설명:** 측정식에서 보편 법칙으로 갈수록 필요한 가정과 검증 범위가 증가하는 네 단계 사다리.

3.1 State 와 lifecycle work 를 먼저 달는 identity

Answer-bearing retained state 를 destination 하나로 축소하면 안 된다.

$$B_{retained} = B_r + B_e + B_l + B_p + B_a + B_v, \quad (3.1)$$

여기서 B_r 은 canonical/raw evidence, B_e 는 text/vector/graph/index, B_l 은 latent·KV·recurrent state, B_p 는 adapter/expert/weight delta, B_a 는 optimizer·importance-router-teacher support, B_v 는 lineage·predecessor-rollback state 다. Active summary bytes 만 보고 “압축률” 을 계산하면 archive 와 recovery copy 가 사라진 것처럼 보이는 오류가 생긴다.

동시에 존재하는 candidate, pinned predecessor, migration, workspace, replica 까지 더한 peak 는

$$B_{peak,state}(t) = B_{retained}(t) + B_{candidate}(t) + B_{pinned}(t) + B_{migration}(t) + B_{workspace}(t) + B_{replica}(t), \quad (3.2)$$

$$B_{peak,physical}(t) = B_{base,resident}(t) + B_{peak,state}(t) + B_{execution}(t). \quad (3.3)$$

Physical maximum 은 각 항의 서로 다른 시간대 high-water mark 를 더하지 않고 같은 timestamp 에서평가한다. Separate wake/sleep fleet 가 contention 을 줄이면서 base model replica 를 늘릴 수 있으므로 incremental state 와 physical placement 를 둘 다 보고해야 한다.

Full-history replay 는 특히 위험하다. Cycle t 에서 이전 task 의 m_i 개를 모두 replay 하면

$$W_T = \sum_{t=1}^T \sum_{i=1}^t m_i = \sum_{i=1}^T m_i(T - i + 1). \quad (3.4)$$

$m_i = m > 0$ 이면 $W_T = mT(T + 1)/2 = \Theta(T^2)$ 다. Admission fraction 을 일정 비율 줄이는 것만으로는계수만 줄고 차수가 바뀌지 않는다. Bounded memory 를 주장하려면 expire, compaction, coreset, generated replay 또 는 selective revisit 가 실제로 lifetime work 와 retained state 를 제한하는지 보여야 한다.

3.2 Valid reuse 가 만드는 compile break-even

Sleep artifact i 의 가치에서 raw memory count 나 sleep FLOPs 보다 유용한 후보 변수는 valid reusable evidence per lifecycle cost 다.^[STC-C043](Colaco and Lahjouji 2026; Ouyang et al. 2025; Unknown organization 2026a) 그 이유는 compile 이 한 번 비싸도 미래에 반복 사용되면 이득이고, 수천 개 memory 를 만들었어도 다시쓰이지 않으면 이득이 0 이기 때문이다.

Stationary 하고 quality 가 같다는 제한된 가정에서 reuse break-even 은

$$n^* = \frac{C_{compile} + C_{maint}}{\Delta C_{use}}. \quad (3.5)$$

Validity survival 과 discount 를 넣으면 horizon H 의 expected valid reuse 는

$$R_i(H) = \int_0^H \lambda_i(t) S_i(t) e^{-\omega t} dt. \quad (3.6)$$

Promotion 은 $R_i(H) \Delta U_{ij}$ 가 compile, serve, governance, risk cost 의 합보다 클 때만 후보가 된다. Future reuse 를 oracle 로 쓰지 않기 위해 실제 router 는 past-only feature 로 $\hat{R}_i$ 를 예측하고, calibration error 도 lifecycle cost 에 넣는다.

측정용 efficiency 는 scalar 를 강제하지 않고 먼저 Pareto vector 로 보고한다.

$$\eta_i = \frac{\Delta U_{later,i} R_{valid,i}}{C_{life,i}}, \quad (3.7)$$

$$C_{life} = C_{ingest} + C_{transform} + C_{train} + C_{validate} + C_{publish} + C_{serve} + C_{maint} + C_{delete/rollback}. \quad (3.8)$$

Dollar, joule, byte, second 를 임의의 환율로 합치지 않는다. Utility floor 를 통과한 뒤 비용을 비교하거나, cost cap 아래 utility 를 비교하는 방식이 더 재현 가능하다.

3.3 Finite state 가 만드는 capacity knee

고정된 finite state 는 positive-entropy stream 을 같은 distortion 으로 영원히 보존할 수 없다. Mutable state 가 $b_{mutable}$ bits 이고 conditionally independent answer family 의 rate-distortion cost 가 $R_{Y_i|Q_i, \theta_0}(D_i)$ 라면 제한된 조건 아래




Figure 3.2: One-time sleep cost 와 future valid reuse 의 analytical crossover. Break-even 왼쪽은 external retrieval 이, 오른쪽은 compiled artifact 가 유리할 수 있다. Quality-governance 차이가 있으면 경계가 이동한다.

[STC-F008]

출처/제작: Original analytical redraw; SRC-STC-0027, SRC-STC-0052 대체 설명: 초기 compile 비용을 수평선으로, reuse 에 따라 누적되는 per-use saving 을 상승선으로 나타낸 교차 그래프.

$$\sum_{i=1}^n R_{Y_i|Q_i, \Theta_0}(D_i) \leq H(M_n | \Theta_0) \leq b_{mutable}. \quad (3.9)$$

이는 facts-per-parameter 보편 상수가 아니다. 하지만 계속 들어오는 novel evidence 에 대해 state growth, distortion 증가, forgetting, external offload 중 적어도 하나가 필요하다는 점은 분명히 한다.

Finite memory 에서는 marginal consolidation utility 가 떨어지고 interference, compaction 또는 delete cost 가 급증하는 capacity knee 가 나타날 것으로 예상된다. [STC-C045] (Morris et al. 2025; Colaco and Lahjouji 2026; O'Neill 2026) Physical storage knee, normal-query reachability knee, retrieval index knee, new-task plasticity knee, governance knee, hot-state residency knee 는 서로 다른 위치에 있을 수 있다. 따라서 “parameter 가 아직 남았다” 는 말은 behavioral capacity 의 반증이 아니다.

Controlled sweep 에서는 retention threshold τ_{ret} 을 먼저 고정하고

$$\text{logit } p_{ret}(N_a) = \text{logit } \tau_{ret} - \kappa \log(N_a / K_{eff}) \quad (3.10)$$

같은 segmented knee candidate 와 generalized mean, min-bottleneck, monotone nonparametric competitor 를 함께 맞춘다. 전 구간 power law 하나를 강제하지 않는다.

3.4 Cadence 와 queue 의 내부 optimum

Optimal cadence 는 staleness, batching efficiency, interference 와 wake-SLA impact 를 균형시켜야 한다. Continuous update 나 무한히 긴 batch 어느 쪽도 일반적으로 최적이지 않다. [STC-C044] (Behrouz et al. 2025; Behrouz et al. 2026b; Mem0 2026)

Run cost C_s , interval τ , smooth staleness penalty $a\tau^p$ 라는 제한에서




Figure 3.3: Finite-memory capacity knee 의 가설적 형태. Physical occupancy 가 한계에 닿기 전에 behavioral reachability 또는 plasticity 가 임계값 아래로 내려갈 수 있다. 곡선은 설명용이며 측정 결과가 아니다.

[STC-F009]

출처/제작: Original hypothesis redraw; SRC-STC-0034, SRC-STC-0036 대체 설명: Evidence load 가 증가할 때 retention 과 plasticity 가 서로 다른 knee 에서 감소하는 두 곡선.

$$\bar{C}(\tau) = \frac{C_s}{\tau} + a\tau^p, \quad \tau^* = \left(\frac{C_s}{ap} \right)^{1/(p+1)}. \quad (3.11)$$

Event rate r_e , fixed job cost F , linear delay harm h 이면 $\tau^* = \sqrt{2F/(hr_e)}$ 다. Burst arrival, hard deadline, multi-resource blocking, capacity-triggered regime change 에서는 이 closed form 이 깨진다. 이때 queue recursion $Q_{t+1} = \max\{0, Q_t + A_t - S_t\}$ 와 P99 job age 를 직접 시뮬레이션해야 한다.

3.5 Fit candidate 와 법칙 승격 조건

첫 fit candidate 는 saturating return 에 interference, staleness, risk penalty 를 분리한다.

$$\Delta U = A \left[1 - \exp \left(-k F_s^\alpha E_{eff}^\beta R_v^\gamma \right) \right] - \Phi_{int} - \Phi_{stale} - \Phi_{risk}. \quad (3.12)$$

E_{eff} 는 authorization, confidence, diversity 를 통과한 canonical evidence 이고 R_v 는 valid future reuse 다. Competitor 는 log-linear, floor 가 있는 power law, segmented knee, generalized mean, nonparametric monotone surface 다. Sign change 나 knee 가 보이면 global power law 를 기각한다.

진짜 STC scaling law 라 부르려면 (1) unit 과 state boundary 를 고정하고, (2) model size·workload·medium·hardware 를 둘 이상 포함하며, (3) strongest alternative 와 total lifecycle cost 를 맞추고, (4) held-out condition 을 예측하고, (5) knee 를 숨기지 않으며, (6) contamination·recursive depth·capacity·cycle control 을 통과하고, (7) 실패한 형태를 공개해야 한다. 그 전까지의 정직한 산출물은 identity, restricted break-even, workload-conditioned empirical surface 와 falsifiable hypothesis 다.




Figure 3.4: Cadence frontier. 너무 잦은 sleep 은 fixed overhead 와 interference 가 크고, 너무 늦은 sleep 은 staleness 와 queue age 가 크다. 내부 optimum 의 위치는 workload 와 resource vector 에 따라 변한다.

[STC-F010]

출처/제작: Original analytical redraw; SRC-STC-0020, SRC-STC-0063 대체 설명: 짧은 interval 의 batching 비용과 긴 interval 의 staleness 비용이 합쳐져 U 자 total cost 를 만드는 그래프.

System infrastructure: wake, sleep, memory 를 어떻게 잇는가

세 개의 logical plane 이 곧 세 개의 physical cluster 를 뜻하지 않는다. 필요한 것은 latency-critical wake execution, throughput-oriented candidate construction, transactional publication 의 책임 분리다. Load 와 state locality 가 허용하면 같은 accelerator pool 을 time-partition 할 수 있고, contention 또는 privacy 가크면 분리할 수 있다. 배치는 brain analogy 가 아니라 bytes, queue, SLO 측정으로 결정한다.

4.1 세 plane 과 하나의 publication transaction

1. **Wake plane:** inference, retrieval, optional fast learning, event append 를 latency SLO 안에서 수행하고, 하나의 authorized serving head 를 pin 한다.
2. **Sleep plane:** immutable wake snapshot 을 읽어 extract, compact, graph update, replay, distill, adapter tune, policy update, rebuild, verify job 을 수행한다. 결과는 candidate 일 뿐 live state 가 아니다.
3. **Memory/control plane:** raw evidence 와 derived views 의 lineage, version, authorization, capacity, atomic publish, rollback 을 관리한다.

Sleep transaction 은 다음처럼 표현할 수 있다.

$$T(X_v, M_v, B, P) \rightarrow \widehat{M}_{v+1} \xrightarrow[\text{compare-and-swap}]{\text{validate}} M_{v+1}. \quad (4.1)$$

X_v 는 immutable event range, M_v 는 published manifest, B 는 resource budget, P 는 frozen policy 다. Candidate 는 old/new/safety/delete/poison/system canary 를 통과한 뒤에만 manifest-last 로 publish 된다. Reader 는 요청 중 한 version 을 보며 partial vector/metadata/adaptor state 를 섞어 보지 않는다.

4.2 Source-of-record 와 heterogeneous materialized views

Derived memory 의 governance basis 로는 updated weights 하나보다 external source-of-record 와 provenance graph 가 강하다.^[STC-C046](OpenAI 2025; Mem0 2026; Zep 2026) Raw event 도 retention policy 가 허용하는 동안만 canonical 이다. Text summary, vector, graph, latent/KV, adaptor, shared weight 는 모두 source lineage 를 가진 materialized view 로 취급한다.

삭제는 tombstone 한 번이 아니다. Immediate access deny, online artifact invalidation, derived lineage rebuild, backup/key expiry, behavioral residual test 를 서로 다른 deadline 으로 기록한다. Old checkpoint 전체를 되살리는 rollback 은 그 사이의 delete/consent epoch 를 되돌릴 수 있으므로, authorized sub-root 만 새 generation 으로 재조합해야 한다.

4.3 Scheduler: operator, destination, cadence 를 분리한다

하나의 evidence region 에 대한 action space 는 NO_OP, RETAIN_EXACT, EXPIRE, DEDUP, MERGE, ABSTRACT, GRAPH_UPDATE, LATENT_COMPILE, ADAPTER_COMPILE, PARAMETRIC_PROMOTE, DEMOTE, REBUILD, QUARANTINE 를 포함한다. Learned policy 가 action 을 제안해도 privacy, tenant boundary, capacity, deadline, promotion gate 는 hard constraint 로 남긴다.

Batching key 는 base model/tokenizer 와 adaptor shape, embedding/index version, privacy zone, deadline, operator, source shard 다. 같은 batch 가 효율적이라는 이유로 tenant security domain 을 합치지 않는다.

Table 4.1: Memory medium 별 serving path 와 rollback contract

Medium	Wake path	Update/validation	Rollback basis
raw episode	selective retrieval	append, redact, expire	event/version log
semantic text	prompt injection	rewrite, faithfulness	source span + predecessor
vector/graph	ANN/traversal	re-embed, edge validity	index generation + episode
latent/recurrent	accelerator state read	compatibility, semantic probe	checkpoint or source rebuild
adapter/expert	model forward/router	train, merge, old/new canary	base digest + delta version
shared weight	model forward	full regression/unlearning	checkpoint + training lineage

Preemption 은 uncommitted candidate 를 버릴 수 있어야 하고, wake saturation 시 sleep 보다 wake 가 우선한다.

Sleep service 는 scalar FLOP queue 가 아니라 resource vector queue 다.

$$\mathbf{c}_j = (c_{GPU-s}, c_{CPU-s}, c_{HBM-byte-s}, c_{RAM-byte-s}, c_{IO-byte}, c_{net-byte}). \quad (4.2)$$

Mean GPU utilization 이 낮아도 source affinity, validation model, index lock, network link 때문에 P99 job age 가발산할 수 있다. Queue 안정성은 utilization 한 숫자뿐 아니라 privacy deadline 과 tenant starvation 으로판정한다.

4.4 State migration rooeline

Separate sleep cluster 는 training accelerator utilization 을 높일 수 있지만 source episode, base model, optimizer, adapter candidate, validation trace 를 이동시킨다. Link ℓ 마다 이동 bytes B_ℓ , transfer price/energy p_ℓ , delay T_ℓ , delay value v_{delay} 를 두면

$$C_{move} = \sum_{\ell} (B_\ell p_\ell + T_\ell v_{delay}). \quad (4.3)$$

추가 local execution 과 replication cost 가 C_{move} 보다 작을 때만 compute 를 data 쪽으로 옮긴다. Model/optimizer residency 가 source 보다 훨씬 크면 centralized GPU 가, source-to-delta ratio 와 privacy locality 가크면 shard-local preprocessing 이 유리할 수 있다.

4.5 네 가지 physical placement

Table 4.2: Physical placement option 과 측정해야 할 trade-off

Placement	장점	비용/위험	적합 조건
shared priority fleet	base/model copy 최소, pooling	wake tail contention	sleep 가 작고 preemptible
time-partitioned fleet	idle window 활용	burst 와 timezone mismatch	predictable diurnal load
separate wake/sleep	isolation, training batch 효율	base replica 와 network movement	sustained sleep demand

Placement	장점	비용/위험	적합 조건
regional/shard-local hybrid	source locality, privacy	낮은 local compute efficiency, fragmentation	source-to-delta ratio 가 큼

4.6 운영 계약

Minimum viable system 은 (1) append-only event log, (2) exact snapshot, (3) copy-on-write candidate, (4) signed validation result, (5) atomic serving-head swap, (6) delete epoch 와 deny root, (7) version-pinned read, (8) bounded rollback 과 GC owner 를 가져야 한다. Algorithm quality 가 좋아도 이 계약이 없으면 wake request 가 half-published state 를 읽고, deleted source 가 predecessor 에서 부활하며, sleep retry 가 duplicate update 를 만들 수 있다.

핵심 Infra 결론

필요한 분리는 cluster 의 개수가 아니라 responsibility 와 transaction boundary 다. Wake 는 응답과 event capture, sleep 은 candidate construction, memory/control 은 authoritative lineage 와 publication 을 담당한다. Data 이동을 최소화한다는 말은 source 만 보는 것이 아니라 base, optimizer, candidate, validation, predecessor 까지 같은 timestamp 와 link 에서 계측한다는 뜻이다.




Figure 4.1: Wake/sleep placement 의 state-migration roofline. Arithmetic intensity 가 아니라 유용한 sleep work 대비 이동 state 의 비율과 link bandwidth 가 placement crossover 를 정한다. 표시된 영역은 설계공간이며 특정 GPU 의 측정 결과가 아니다.

[STC-F011]

출처/제작: Original systems synthesis; SRC-STC-0022, SRC-STC-0059 대체 설명: Shared, separate, shard-local 배치를 state movement 와 compute efficiency 측에서 비교한 roofline 형 지도.

Falsifiable benchmark 와 experiment roadmap

이 분야에 필요한 다음 산출물은 더 큰 metaphor 가 아니라 matched lifecycle experiment 다. 같은 wake events 와 future queries 를 주고, exact external retention, external compaction, latent/KV compilation, user-local adapter, deliberate forgetting, past-only hybrid routing 중 무엇이 가장 나은지를 측정해야 한다. Null result 와 boundary 를 계획에 포함해야 negative paper 도 가치가 있다.

반증 가능한 research → system → device agenda




Figure 5.1: Falsifiable research agenda. Evidence stream, candidate construction, lifecycle validation, repeated-cycle evaluation, scaling fit 을 하나의 provenance chain 으로 연결한다.

[STC-F015]

출처/제작: Original synthesis; SRC-STC-0036, SRC-STC-0050, SRC-STC-0056 대체 설명: Matched methods, cycle probes, systems/governance metrics, held-out scaling test 가 순차적으로 이어지는 roadmap.

5.1 독립 단위와 cycle

최상위 independent unit 은 user/stream 이다. Cycle 과 probe 를 독립 sample 처럼 세어 significance 를 부풀리지 않는다. 한 cycle 은 다음 순서를 가진다.

wake capture → pre-sleep probe → immutable snapshot → candidate
→ validate/publish → post-sleep probe → delayed next-wake probe.

Default horizon 은 128 cycles, sensitivity 는 $C \in \{8, 32, 128, 512\}$, retrieval lag 는 가능한 경우 $\{1, 8, 32, 128\}$ cycles 로 둔다. 단일 sleep 후 정확도는 lifelong behavior 를 지지하지 못한다.

5.2 Observable 과 oracle 을 물리적으로 분리한다

Method 가 보는 observable stream 에는 event payload, 현재 confidence, privacy scope, 알려진 supersession/delete, past reuse, resource/queue state 만 있다. True future reuse, future contradiction, future deletion, poison truth, ground-truth dependency, clairvoyant destination 은 oracle ledger 에 따로 둔다. 파일, schema, API permission 과 process boundary 로 누출을 막는다.

Train 은 learned router/compiler 를 fit 하고, CALIBRATION 은 threshold, cadence, baseline hyperparameter 를한 번 선택하며, TEST 는 G2 freeze 뒤 한 번만 실행한다. TEST family identity 나 future reuse 로 configuration 을바꾸는 mutation test 가 통과해야 한다. Dream-generated probe 도 evaluation query 가 아니라 derived training artifact 이므로 generator/prompt/input/output/filter digest 를 남긴다.

5.3 Event 와 query family

Table 5.1: 독립적으로 변화시킬 event factor 와 주요 failure

Family	Controlled variables	잡아야 할 failure
stable exact fact	entropy, surface length, reuse, lag	semantic compression 이 exact detail 을 지움
volatile fact/preference procedure/skill	validity interval, correction hazard reusable/one-off, environment version	stale overwrite, historical loss vague summary, non-executable memory
relation/graph failure feedback	alias, temporal edge, hop count wrong action, correction, avoidance	entity collision, invalid edge success-only bias
privacy/delete poison/adversarial	consent expiry, dependency fan-out injection, conflicting frequency, delayed label	tombstone-only delete poison amplification
one-off distractor	salience, payload size, zero reuse	unnecessary consolidation

Reuse, volatility, poison, deletion, payload size 와 memory pressure 는 서로 독립적으로 변화시킨다. Query 는 exact, semantic, temporal, relational, procedural, negative/failure, calibration, deletion family 로 나눈다. Acquisition query, exact repeat, held-out paraphrase, held-out composition, correction probe, unrelated control 을동일 지표로 합치지 않는다. “기억한 문장을 그대로 다시 답했다” 와 “새 상황에 procedure 를 적용했다” 는다른 능력이다.

5.4 Confirmatory methods 와 resource envelope

Primary deployable family 는 raw external, compressed external, latent/KV compiler, user-parametric LoRA, static mixture, past-only hybrid router 여섯 개다. Clairvoyant oracle 은 heterogeneity 의 upper bound 일 뿐 deployable method 가 아니다. Long-context no-memory lower bound 와 unbounded full-history upper bound 는 diagnostic 으로 남긴다.

모든 method 는 다음 upper bound 를 공유한다.

- live token, active byte, durable byte, total incremental peak-state byte,
- physical HBM/fleet peak, sleep FLOPs, peak accelerator,
- 동일한 information cutoff, privacy 와 delete contract.

Search/tuning, router, judge, embedding, synthetic data, optimizer, answer-reachable KV/recurrent state, index rebuild, raw archive, lineage, rollback reserve 와 transient workspace 를 모두 charge 한다. 사용하지 않은 budget 은낭비하도록 강제하지 않고 그대로 보고한다.

Reuse $R \in \{0, 1, 4, 16\}$ 와 active-capacity ratio $\phi \in \{1, 1/4, 1/16\}$ 을 교차한다. Schedule/operator factorial 은 inline versus deferred 와 identity versus semantic consolidation 을 destination external 로 고정해, execution timing 의 효과와 추가 정보를 더본 효과를 분리한다.

5.5 Metric stack

Table 5.2: 한 결과표에 함께 있어야 할 metric stack

Layer	Required metrics
learning	lifetime utility AUC, current utility, acquisition, retention/forgetting, forward transfer, memory half-life
semantic	exact/semantic/temporal/relational/procedural, composition, relevance, calibration, false memory
memory path	writer/retriever/reader error, route/merge compatibility, coverage, faithfulness, detail loss, stale conflict
robustness	poison amplification, cross-user/task interference, rare-tail survival, recursive-depth distortion
governance	access deny, physical removal, lineage invalidation, key expiry, behavioral residual, rollback success/time
serving	TTFT/ITL/task P50/P95/P99, throughput, cache/adaptor hit, load/swap, fallback
sleep service	throughput, queue age, deadline miss, retry, validation/publish/rollback cost
resources	pre/post/wake/sleep/validation FLOPs, retained/peak bytes, bytes moved by link, write amplification, energy
compatibility	base/tokenizer/embedding version, artifact route, rebase and rebuild cost

Primary quality endpoint 은 cycle 과 pre/post/delayed probe block 에 동일 가중치를 주는 lifetime utility AUC 다. Energy-per-correct 는 frozen accuracy floor 위에서만 계산한다. Delete score 는 access denial 과 physical removal, derived invalidation, behavioral residual 을 한 binary 로 합치지 않는다.

5.6 통계 · 재현성과 claim-down rule

모든 method 는 같은 stream, event order, query order, resource tuple 을 받는다. User/stream 을 paired resampling unit 로 사용하고 workload-family×seed-family block 을 유지한다. Hardware placement 와 method order 는 randomize 또는 block 한다. Outcome 을 본 뒤 stopping point, comparator, hypothesis family 를 바꾸지 않는다.

Run artifact 는 source/version → question/hypothesis → config/data/code/environment → raw checksum → result → claim → figure/table → manuscript sentence 를 연결한다. Timeout, OOM, deadline miss, cap violation 은 missing data 가 아니라 consumed work 를 charge 한 RESOURCE_FAILURE 로 처리한다.

다음 경우 claim 을 낮춘다: effect 가 materiality margin 보다 작음, equivalence interval 이 margin 을 걸침, simulation 으로 absolute hardware latency 를 말함, archive 를 남기고 total compression 이라 함, behavioral forgetting 을 physical deletion 이라 함, post-hoc arm 을 추가함. Minimum publishable result 는 hybrid 가실패 해도 deterministic leakage-tested stream, matched methods, complete resource ledger, retention/acquisition 분리와 잘 추정된 crossover·knee·null 중 하나를 남기는 것이다.

핵심 실험의 최종 질문

“Sleep 이 정확도를 높였는가?” 가 아니라 “동일한 evidence 와 lifetime budget 에서, 어떤 admission, operator, destination, cadence 가 later-wake utility 와 governance 의 Pareto frontier 를 움직였는가?” 를 묻는다.

Limitations, negative evidence 와 falsifiers

이 Study 의 결론은 2026-08-05 공개 evidence 에 대한 조건부 synthesis 다. Product 내부 trace, 비공개 deployment incident, 실제 device workload 가 없으며, 논문 간 model-task-budget 이 달라 meta-analysis 를 수행하지 않았다. Original figure 의 좌표와 scenario 는 측정 결과가 아니라 reasoning aid 다.

6.1 문헌 자체의 한계

명시적 parametric sleep 연구는 direct mechanism evidence 지만 model scale, task diversity, cycle count 와 production governance 가 제한된다. Product documentation 은 background phase 의 존재를 보여도 strongest alternative 대비 causal advantage 를 보여 주지 않는다. Continual-learning precursor 는 forgetting 을 줄이는 방법을 제공하지만 LLM agent 의 deletion, state migration, future reuse economics 를 직접 측정하지 않는다.

DANN/SSRN record 는 동결 source 에서 independent verification 에 필요한 method 와 result 를 충분히 공개하지 않아 load-bearing evidence 로 사용하지 않았다.^[STC-C047](Tutuncuoglu 2025) 제목이나 abstract 가 “zero forgetting” 을 말해도 full method, data, comparator, statistics, artifact 가 없으면 central claim 을 지탱할 수 없다. 이 판단은 논문이 틀렸다는 결론이 아니라 증거 접근성에 대한 claim-down 이다.

6.2 Negative evidence 가 가리키는 구조적 위험

Table 6.1: 실패 mode 와 필요한 control

Risk	관찰/이론적 근거	필요한 control
behavioral unreachability	sequential fact 가 weights 에 남아 도 normal query 에서 접근 불가	direct, prompted, compositional reachability 를 분리
catastrophic interference	new update 가 old task 와 plasticity 를 손상	old/new/safety slice, replay/regularization/isolation ablation
recursive-data collapse	synthetic-only generations 가 rare tail 을 잃을 수 있음	canonical anchor, recursive depth, common/tail distortion
false merge/compaction	summary 가 exact, temporal, negative detail 을 지움	source spans, faithfulness, exact/temporal query, rebuild
memory poisoning	persistent record 가 후속 behavior 를 조종	provenance, quarantine, poison canary, least privilege
delete illusion	tombstone 뒤 summary, index, cache, adapter 에 영향 잔존	lineage fan-out, deny root, physical removal, residual probe
state fan-out	user/cohort artifact 와 catalog 가 base saving 을 상쇄	total state, hot residency, route/load latency
queue/SLA failure	평균 utilization 전에도 affinity-validation 이 P99 age 를 악화	multi-resource queue, deadline, wake preemption
version churn	base/tokenizer/embedding 변경 이 artifact 를 무효화	compatibility digest, rebase/rebuild cost

Failure mode마다 lifecycle control을 붙인다




Figure 6.1: Wake capture 에서 deletion 까지 이어지는 주요 failure mode 와 lifecycle control. 한 단계의 accuracy gate 만으로는 poison, stale publish, rollback resurrection, residual delete 를 막을 수 없다.

[STC-F013]

출처/제작: Original synthesis; SRC-STC-0042, SRC-STC-0053 대체 설명: Admission, candidate, publish, serve, delete 단계마다 poison-interference-race-residual 과 대응 control 을 연결한 흐름도.

6.3 결론을 뒤집거나 줄힐 구체적 falsifier

F1—새 phase claim. 동일 transformation, information cutoff, destination, total resource 를 맞췄을 때 deferred 와 synchronous 실행의 later-wake quality, wake-SLA, batching 차이가 모두 사라지면 “새 scientific axis” 는 scheduling label 로 좁혀야 한다.

F2—hybrid recommendation. External-only 또는 direct parametric-only 가 stable skill 과 volatile fact 모두에서 utility, cost, deletion, rollback, portability 를 지배하면 hybrid default 를 폐기한다.

F3—valid-reuse hypothesis. Reuse 와 query predictability 를 넓게 sweep 해도 STC gain 과 interaction 이 없거나 predictor error 가 top- k yield 를 없애면 reuse-based promotion 이론을 기각한다.

F4—capacity knee. Repeated stream 에서 behavioral retention/plasticity 가 physical occupancy 와 같이 부드럽게 변하고 앞선 knee 가 재현되지 않으면 별도 behavioral knee hypothesis 를 기각한다.

F5—canonical anchoring. Synthetic/summary replay 와 source-anchored replay 의 rare-tail survival 이 matched cost 에서 차이가 없으면 canonical anchor 의 안정성 주장을 낮춘다.

F6—dedicated sleep infra. Shared priority fleet 가 모든 realistic trace 에서 더 낮은 physical peak, 이동 bytes, P99 wake latency 와 job age 를 동시에 보이면 separate sleep cluster 필요성을 기각한다.

F7—device relevance. Background memory job 이 commodity CPU/object-store metadata 수준에 머물고 retained bytes, rewrite, movement, tail-SLA 가 장치 선택에 영향을 주지 않으면 새로운 memory workload 라는 주장을 좁힌다.

6.4 Coverage 와 saturation 의 한계

Search cluster 는 date-bounded snapshot 이며 five active frontier 와 five measurement gap 을 명시적으로 남겼다. 특히 Google, Meta, Microsoft 의 research output 은 넓지만 public production per-user weight sleep 의 부재를 “그 회사가 하지 않는다” 는 negative fact 로 바꾸지 않는다. 공개하지 않았을 가능성과 아직 측정하지 않은 possibility 가 있기 때문이다.

Figure 는 권리 검토된 original redraw 만 사용했으며 source paper figure 를 직접 복제하지 않았다. 이 선택은 copyright risk 를 줄이지만 원 실험 plot 의 numeric fidelity 를 대신하지 않는다. 독자는 claim ledger 와 primary source 로 수치를 확인해야 한다.

6.5 본 논문이 주장하지 않는 것

- Biological NREM/REM stage 가 AI operator 에 one-to-one 으로 대응한다는 주장,
- 더 많은 sleep FLOPs 가 항상 utility 를 높인다는 universal monotone law,
- weights 가 external memory 보다 본질적으로 더 장기적이라는 주장,
- 공개 product lifecycle 가 comparative scientific optimality 를 입증한다는 주장,
- simulation 이 특정 GPU-memory device 의 latency, energy, endurance 를 측정했다는 주장,
- P3-held device hypothesis 가 publication 또는 patent review 를 통과했다는 주장.

주의 가장 중요한 한계

현재 논문은 measurement program 과 conditional strategy 를 제시한다. STC 의 universal dominance 나 broad parametric deployment 를 관측한 논문이 아니다. 이 구분을 유지해야 향후 negative result 가 연구 실패가 아니라 이론의 경계를 좁히는 결과가 된다.

Canonical claim – evidence ledger

본문의 파란 claim ID 는 이 표의 canonical English statement 와 source locator 로 연결된다. 이 표는 번역문이 아니라 Veridraft gate 를 통과한 frozen assertion surface 다.

Table 2: Veridraft-gated public claims (source freeze 2026-08-05)

ID	Type / confidence	Canonical claim	Evidence locator
STC-C001	direct fact high	The date-frozen evidence audit contains 73 primary papers, official releases, documentation pages, and tagged repositories.	SRC-STC-0014: source registry audit; entry SRC-STC-0014
STC-C002	direct fact high	By 2026-08-05, at least two public production systems described explicit background memory synthesis: OpenAI Dreaming and Mem0 Dream.	SRC-STC-0052: official release, opening and How dreaming works SRC-STC-0063: official docs, Overview and How Dream works
STC-C003	direct fact high	The 12-cluster search closes only as a bounded date snapshot: 2 clusters are bounded, 5 remain active frontiers, and 5 retain measurement gaps.	SRC-STC-0036: paper abstract and §5 limitations
STC-C004	direct fact high	A balanced 15-paper translation corpus spans explicit sleep, biological and computational precursors, continual learning, external memory, neural memory, capacity, and negative evidence.	SRC-STC-0011: full paper, title through Discussion
STC-C005	synthesis high	Sleep-time compute is best defined by lifecycle, not by metaphor: computation is deferred beyond the latency-critical response and changes reusable state for later wake episodes.	SRC-STC-0014: abstract; §1; Fig. 1 SRC-STC-0052: official release, How dreaming works SRC-STC-0063: official docs, Synthesis mode
STC-C006	synthesis high	Update timing and memory medium are orthogonal axes: a sleep phase may update weights, adapters, recurrent state, text/vector stores, graphs, or mixtures.	SRC-STC-0014: §2, sleep-time agent architecture SRC-STC-0021: §2-§3, self-modification and consolidation SRC-STC-0016: §2-§3, temporal graph memory
STC-C007	direct fact high	OpenAI Dreaming is production background synthesis over external user memory, not disclosed per-user foundation-weight training.	SRC-STC-0052: official release, opening through How dreaming works
STC-C008	direct fact high	Mem0 Dream performs scheduled background synthesis with provenance-preserving, additive outputs; merge and supersede are distinct ingest-time operations.	SRC-STC-0063: official docs, Overview; Modes; Operational behavior SRC-STC-0064: tag v2.0.13, dream-gate.ts
STC-C009	direct fact high	Letta’s tagged sleeptime group schedules an asynchronous post-response agent that revises durable memory outside the response-critical path.	SRC-STC-0059: tag 0.16.8, sleep-time_multi_agent_v4.py
STC-C010	direct fact high	Zep and Graphiti represent external memory as temporally versioned episodes, entities, and relations rather than as user-specific model-weight updates.	SRC-STC-0016: abstract; §2 Architecture; §3 Temporal KG SRC-STC-0065: commit aab852d, README overview SRC-STC-0066: official docs, Episodes
STC-C011	author claim high	MemGPT frames long-term agent memory as an operating-system-style hierarchy that pages information between constrained context and external storage.	SRC-STC-0013: abstract; §2 Virtual Context Management; Fig. 1
STC-C012	direct fact high	ReasoningBank stores reusable reasoning strategies extracted from experience; the public method is an external strategy memory rather than broad online weight consolidation.	SRC-STC-0043: abstract; §2-§3 SRC-STC-0054: official Google Research post, Method
STC-C013	synthesis medium	Meta’s personalized-agent and HyperAgents work emphasizes feedback-conditioned agent behavior, program memory, and archives; public evidence does not establish fleet-scale per-user sleep updates to foundation weights.	SRC-STC-0057: official Meta paper page, abstract SRC-STC-0058: official Meta paper page, abstract
STC-C014	direct fact high	Microsoft STATE-Bench evaluates agent memory across state tracking, adaptation, and efficiency, but is a benchmark rather than a disclosed sleep-training product.	SRC-STC-0056: official Microsoft post, benchmark dimensions SRC-STC-0067: commit 4efcbf2, README tasks and metrics
STC-C015	synthesis high	Language Models Need Sleep is direct evidence for parametric sleep: the model learns to self-modify and consolidate memories using replay-like training, but the reported regime remains research-scale rather than production deployment proof.	SRC-STC-0021: abstract; §2 Method; §4 Experiments; §6 Limitations
STC-C016	author claim high	In a two-task spiking-network setting, interleaved sleep-like replay formed a joint synaptic representation and reduced catastrophic forgetting.	SRC-STC-0011: abstract; Results, Figs. 2-7; Discussion
STC-C017	author claim high	A hippocampus-neocortex model used autonomous offline dynamics and alternating NREM/REM regimes to integrate new information while protecting older knowledge.	SRC-STC-0010: abstract; Fig. 1; Simulation 2; Fig. 4
STC-C018	author claim high	Perturbed and Adversarial Dreaming separates wake, NREM-like perturbed replay, and REM-like adversarial dreaming to learn cortical representations.	SRC-STC-0009: abstract; Results; Figs. 1-9; Discussion
STC-C019	author claim high	Deep generative replay is a strong non-sleep-named baseline: a generator replays pseudo-data while the solver learns new data, reducing catastrophic forgetting.	SRC-STC-0003: abstract; §2 Deep Generative Replay; Algorithm 1

다음 쪽에 계속

ID	Type / confidence	Canonical claim	Evidence locator
STC-C020	author claim high	Elastic Weight Consolidation protects parameters judged important to earlier tasks through a Fisher-weighted quadratic penalty, trading plasticity for stability.	SRC-STC-0002: §2; Eq. 3; experiments
STC-C021	author claim high	Gradient Episodic Memory constrains updates using stored examples so that loss on prior tasks does not increase under the local constraint.	SRC-STC-0004: §2; Eqs. 3-10; Algorithm 1
STC-C022	author claim high	Progress & Compress alternates an active column with a consolidation phase that compresses knowledge into a reusable knowledge base, providing a direct periodic-refresh alternative to explicit sleep framing.	SRC-STC-0007: abstract; §2 Progress; §3 Compress; Fig. 1
STC-C023	synthesis high	Titans learns a neural memory state at test time using surprise-driven updates; this is wake-path fast-state learning, not by itself deferred cross-session sleep.	SRC-STC-0017: §2 Neural Long-Term Memory; Eqs. 7-13; Fig. 1
STC-C024	synthesis high	Nested Learning/HOPE treats optimization processes at multiple update frequencies as nested memory levels, supplying a useful cadence model but not public evidence of deployed asynchronous sleep consolidation.	SRC-STC-0020: §2 Nested Learning; §4 HOPE; CMS frequency schedule
STC-C025	author claim high	Memory Caching identifies a serving problem for recurrent memory models: reusable state has to be materialized, keyed, cached, and shared to recover prefix-cache-like efficiency.	SRC-STC-0022: abstract; §2 Memory Caching; §4 Serving Experiments
STC-C026	author claim high	Retrieval-augmented generation keeps mutable knowledge outside model weights and conditions generation on retrieved passages, making it a strong update-cost and governance baseline.	SRC-STC-0031: abstract; §2 Method; Fig. 1
STC-C027	synthesis high	LoRA constrains adaptation to low-rank weight deltas, reducing trainable parameter and optimizer-state cost but not eliminating sequential interference or lifecycle governance.	SRC-STC-0030: abstract; §4 Method; Eq. 3 SRC-STC-0036: §3 sequential fact-learning results
STC-C028	synthesis high	ROME localizes and edits factual associations in transformer MLP weights, showing targeted parametric change is possible but not proving stable unbounded continual accumulation.	SRC-STC-0032: abstract; §3 Causal Tracing; §4 ROME
STC-C029	synthesis high	MEMIT extends model editing to many memories, but mass editing remains a bounded batch intervention rather than a demonstrated lifelong sleep loop.	SRC-STC-0033: abstract; §3 MEMIT; scaling experiments
STC-C030	synthesis high	Generative Adapter compiles context into parameters in one forward pass, suggesting a latent-memory path whose value depends on reuse amortizing compilation and version-management cost.	SRC-STC-0027: abstract; §3 Generative Adapter; experiments
STC-C031	synthesis high	Self-Adapting Language Models generate their own adaptation data and update rules, bridging wake-time learning and later consolidation while introducing recursive-data quality risks.	SRC-STC-0029: abstract; §2-§3 self-edits SRC-STC-0041: model-collapse results
STC-C032	author claim high	Sequentially learned facts can remain encoded in weights yet become behaviorally unreachable; retention must therefore be measured by access and composition, not only by parameter storage.	SRC-STC-0036: abstract; §4 Results; §5 Discussion
STC-C033	synthesis high	Static memorization capacity measurements do not directly determine safe continual-learning capacity because sequential access, interference, and governance add independent constraints.	SRC-STC-0034: abstract; capacity experiments SRC-STC-0036: §4-§5
STC-C034	synthesis high	A rate-distortion view makes memory compaction an explicit utility-budget tradeoff, but its proposed frontier is not yet a universal empirical scaling law for agents.	SRC-STC-0035: abstract; §2 Rate-Distortion Formulation; limitations
STC-C035	author claim high	Recursive training on generated data can collapse distribution tails when real-data support is lost, so sleep-generated replay cannot be treated as costless fresh data.	SRC-STC-0041: main results; Figs. 1-3; Methods
STC-C036	author claim high	Model collapse is not inevitable when real and synthetic data are accumulated under appropriate conditions; the relevant scaling variable is recursive depth and real-data anchoring, not a binary synthetic-data flag.	SRC-STC-0069: abstract; theoretical results; experiments
STC-C037	synthesis high	External memories create an attack surface: poisoned records can steer agent behavior while remaining hard to notice, making provenance and revocation first-class design requirements.	SRC-STC-0042: abstract; threat model; attack results
STC-C038	synthesis high	As of the freeze date, public industry evidence is strongest for external-memory sleep and background synthesis, not broad per-user foundation-weight sleep.	SRC-STC-0052: official OpenAI Dreaming release SRC-STC-0063: official Mem0 Dream docs SRC-STC-0059: tagged Letta sleeptime implementation SRC-STC-0065: tagged Graphiti repository
STC-C039	synthesis medium	Broad per-user parametric sleep remains technically immature because public evidence does not jointly establish continual retention, rollback, deletion, security, and fleet-level serving economics.	SRC-STC-0021: §4 experiments and §6 limitations SRC-STC-0036: §4-§5 sequential-learning limits SRC-STC-0042: memory-poisoning threat model
STC-C040	synthesis medium	The most credible medium-term architecture is hybrid: keep an auditable external system of record, then selectively promote high-reuse, stable knowledge into reversible adapters or bounded parametric state.	SRC-STC-0052: external synthesis lifecycle SRC-STC-0027: parameter compilation method SRC-STC-0030: low-rank adapter method SRC-STC-0066: episode provenance

다음 쪽에 계속

ID	Type / confidence	Canonical claim	Evidence locator
STC-C041	synthesis high	No source in the frozen corpus establishes a universal sleep-time scaling law; current equations should be labeled accounting identities, break-even models, fit candidates, or untested hypotheses.	SRC-STC-0034: static memorization-capacity experiments SRC-STC-0035: rate-distortion proposal SRC-STC-0050: memory-statistics tradeoff theory
STC-C042	synthesis high	The lifecycle may become mainstream without the term ‘sleep-time compute’ becoming the dominant label; current systems use dreaming, reflection, synthesis, memory, self-evolution, and consolidation language.	SRC-STC-0052: title and product terminology SRC-STC-0054: title and product terminology SRC-STC-0060: reflection-launcher terminology SRC-STC-0063: Dream terminology
STC-C043	hypothesis medium	A useful candidate scaling variable is valid reusable evidence per unit sleep cost, not raw memories processed or raw sleep FLOPs.	SRC-STC-0043: strategy selection and reuse results SRC-STC-0051: RL over memory objective SRC-STC-0035: utility-budget formulation
STC-C044	hypothesis medium	The optimal sleep cadence should balance staleness, batching efficiency, interference, and wake-SLA impact; neither continuous updating nor arbitrarily long batching is generally optimal.	SRC-STC-0020: multi-frequency update framework SRC-STC-0063: scheduled synthesis cadence SRC-STC-0022: serving and state-reuse costs
STC-C045	hypothesis medium	Finite memory systems should exhibit a capacity knee where marginal consolidation utility falls and interference, compaction, or deletion cost rises sharply.	SRC-STC-0034: memorization-capacity curves SRC-STC-0035: rate-distortion frontier SRC-STC-0036: sequential reachability degradation
STC-C046	synthesis high	For derived memory, the external source-of-record plus provenance graph is a stronger governance basis than treating updated weights as the sole authoritative record.	SRC-STC-0053: official memory controls SRC-STC-0063: provenance and non-destructive behavior SRC-STC-0066: episode provenance and temporal facts
STC-C047	direct fact high	The DANN/SSRN record is not load-bearing evidence because the frozen source exposes insufficient methods and results for independent verification.	SRC-STC-0039: SSRN abstract and meta-data landing page

참고문헌

- Behrouz, Ali, Farnoosh Hashemi, Adel Javanmard, and Vahab Mirrokni (2026a). *Language Models Need Sleep: Learning to Self-Modify and Consolidate Memories*. Frozen source SRC-STC-0021; type=paper; accessed=2026-08-05. arXiv: 2606.03979. URL: <https://arxiv.org/abs/2606.03979v2> (visited on 08/05/2026).
- Behrouz, Ali, Zeman Li, Yuan Deng, Peilin Zhong, Meisam Razaviyayn, and Vahab Mirrokni (2026b). *Memory Caching: RNNs with Growing Memory*. Frozen source SRC-STC-0022; type=paper; accessed=2026-08-05. arXiv: 2602.24281. URL: <https://arxiv.org/abs/2602.24281v1> (visited on 08/05/2026).
- Behrouz, Ali, Meisam Razaviyayn, Peilin Zhong, and Vahab Mirrokni (2025). *Nested Learning: The Illusion of Deep Learning Architectures*. Frozen source SRC-STC-0020; type=paper; accessed=2026-08-05. arXiv: 2512.24695. URL: <https://arxiv.org/abs/2512.24695v1> (visited on 08/05/2026).
- Behrouz, Ali, Peilin Zhong, and Vahab Mirrokni (2024). *Titans: Learning to Memorize at Test Time*. Frozen source SRC-STC-0017; type=paper; accessed=2026-08-05. arXiv: 2501.00663. URL: <https://arxiv.org/abs/2501.00663v1> (visited on 08/05/2026).
- Colaco, Ashwin Gerard and Nada Lahjouji (2026). *What to Keep, What to Forget: A Rate-Distortion View of Memory Compaction in LLMs and Agents*. Frozen source SRC-STC-0035; type=paper; accessed=2026-08-05. arXiv: 2607.08032. URL: <https://arxiv.org/abs/2607.08032v1> (visited on 08/05/2026).
- Deperrois, Nicolas, Mihai A Petrovici, Walter Senn, and Jakob Jordan (2022). *Learning Cortical Representations through Perturbed and Adversarial Dreaming*. Frozen source SRC-STC-0009; type=paper; accessed=2026-08-05. DOI: 10.7554/eLife.76384. URL: <https://doi.org/10.7554/eLife.76384> (visited on 08/05/2026).
- Golden, Ryan, Jean Erik Delanois, Pavel Sanda, and Maxim Bazhenov (2022). *Sleep Prevents Catastrophic Forgetting in Spiking Neural Networks by Forming a Joint Synaptic Weight Representation*. Frozen source SRC-STC-0011; type=paper; accessed=2026-08-05. DOI: 10.1371/journal.pcbi.1010628. URL: <https://doi.org/10.1371/journal.pcbi.1010628> (visited on 08/05/2026).
- Kirkpatrick, James, Razvan Pascanu, Neil Rabinowitz, Joel Veness, Guillaume Desjardins, Andrei A. Rusu, Kieran Milan, John Quan, Tiago Ramalho, Agnieszka Grabska-Barwinska, Demis Hassabis, Claudia Clopath, Dharshan Kumaran, and Raia Hadsell (2016). *Overcoming catastrophic forgetting in neural networks*. Frozen source SRC-STC-0002; type=paper; accessed=2026-08-05. DOI: 10.1073/pnas.1611835114. arXiv: 1612.00796. URL: <https://arxiv.org/abs/1612.00796v2> (visited on 08/05/2026).
- Lopez-Paz, David and Marc'Aurelio Ranzato (2017). *Gradient Episodic Memory for Continual Learning*. Frozen source SRC-STC-0004; type=paper; accessed=2026-08-05. arXiv: 1706.08840. URL: <https://arxiv.org/abs/1706.08840v6> (visited on 08/05/2026).
- McClelland, James L., Bruce L. McNaughton, and Randall C. O'Reilly (1995). *Why There Are Complementary Learning Systems in the Hippocampus and Neocortex*. Frozen source SRC-STC-0001; type=paper; accessed=2026-08-05. DOI: 10.1037/0033-295X.102.3.419. URL: <https://doi.org/10.1037/0033-295X.102.3.419> (visited on 08/05/2026).
- Mem0 (2026). *Mem0 Dream*. Version web-capture:2026-08-05. Frozen source SRC-STC-0063; type=official documentation; accessed=2026-08-05. URL: <https://docs.mem0.ai/platform/features/dream> (visited on 08/05/2026).
- Morris, John X., Chawin Sitawarin, Chuan Guo, Narine Kokhlikyan, G. Edward Suh, Alexander M. Rush, Kamalika Chaudhuri, and Saeed Mahloujifar (2025). *How much do language models memorize?* Frozen source SRC-STC-0034; type=paper; accessed=2026-08-05. arXiv: 2505.24832. URL: <https://arxiv.org/abs/2505.24832v3> (visited on 08/05/2026).
- O'Neill, Charles (2026). *Can a Language Model Learn Facts Continually in Its Weights?* Frozen source SRC-STC-0036; type=paper; accessed=2026-08-05. arXiv: 2607.11020. URL: <https://arxiv.org/abs/2607.11020v2> (visited on 08/05/2026).
- OpenAI (2025). *Memory and New Controls for ChatGPT*. Version web-capture:2026-08-05. Frozen source SRC-STC-0053; type=official release note; accessed=2026-08-05. URL: <https://openai.com/index/memory-and-new-controls-for-chatgpt/> (visited on 08/05/2026).
- (2026). *Dreaming: Better Memory for a More Helpful ChatGPT*. Version web-capture:2026-08-05. Frozen source SRC-STC-0052; type=official release note; accessed=2026-08-05. URL: <https://openai.com/index/chatgpt-memory-dreaming/> (visited on 08/05/2026).
- Ouyang, Siru, Jun Yan, I-Hung Hsu, Yanfei Chen, Ke Jiang, Zifeng Wang, Rujun Han, Long T. Le, Samira Daruki, Xiangru Tang, Vishy Tirumalashetty, George Lee, Mahsan Rofouei, Hangfei Lin, Jiawei Han, Chen-Yu Lee, and Tomas Pfister (2025). *ReasoningBank: Scaling Agent Self-Evolving with*

- Reasoning Memory*. Frozen source SRC-STC-0043; type=paper; accessed=2026-08-05. arXiv: 2509.25140. URL: <https://arxiv.org/abs/2509.25140v2> (visited on 08/05/2026).
- Packer, Charles, Sarah Wooders, Kevin Lin, Vivian Fang, Shishir G. Patil, Ion Stoica, and Joseph E. Gonzalez (2023). *MemGPT: Towards LLMs as Operating Systems*. Frozen source SRC-STC-0013; type=paper; accessed=2026-08-05. arXiv: 2310.08560. URL: <https://arxiv.org/abs/2310.08560v2> (visited on 08/05/2026).
- Schwarz, Jonathan, Jelena Luketina, Wojciech M. Czarnecki, Agnieszka Grabska-Barwinska, Yee Whye Teh, Razvan Pascanu, and Raia Hadsell (2018). *Progress & Compress: A scalable framework for continual learning*. Frozen source SRC-STC-0007; type=paper; accessed=2026-08-05. arXiv: 1805.06370. URL: <https://arxiv.org/abs/1805.06370v2> (visited on 08/05/2026).
- Shin, Hanul, Jung Kwon Lee, Jaehong Kim, and Jiwon Kim (2017). *Continual Learning with Deep Generative Replay*. Frozen source SRC-STC-0003; type=paper; accessed=2026-08-05. arXiv: 1705.08690. URL: <https://arxiv.org/abs/1705.08690v3> (visited on 08/05/2026).
- Singh, Dhairyya, Kenneth A. Norman, and Anna C. Schapiro (2022). *A Model of Autonomous Interactions between Hippocampus and Neocortex Driving Sleep-Dependent Memory Consolidation*. Frozen source SRC-STC-0010; type=paper; accessed=2026-08-05. doi: 10.1073/pnas.2123432119. URL: <https://doi.org/10.1073/pnas.2123432119> (visited on 08/05/2026).
- Tutuncuoglu, Bekir Tolga (2025). *Dream-Augmented Neural Networks: Harnessing Synthetic Sleep for Continual Learning and Zero Forgetting*. Frozen source SRC-STC-0039; type=paper; accessed=2026-08-05. doi: 10.2139/ssrn.5402490. URL: <https://doi.org/10.2139/ssrn.5402490> (visited on 08/05/2026).
- Unknown organization (2026a). *From Player to Master: Enhancing Test-Time Learning of LLM Agents via Reinforcement Learning over Memory*. Version web-capture:2026-08-05. Frozen source SRC-STC-0051; type=paper; accessed=2026-08-05. URL: <https://openreview.net/forum?id=gNWNtstp3r> (visited on 08/05/2026).
- (2026b). *Memory-Statistics Tradeoff in Continual Learning with Structural Regularization*. Version web-capture:2026-08-05. Frozen source SRC-STC-0050; type=paper; accessed=2026-08-05. URL: <https://openreview.net/forum?id=qfEqXJn1B4> (visited on 08/05/2026).
- Zep (2026). *Zep Episodes*. Version web-capture:2026-08-05. Frozen source SRC-STC-0066; type=official documentation; accessed=2026-08-05. URL: <https://help.getzep.com/episodes> (visited on 08/05/2026).