

SLEEP-TIME COMPUTE


기억 생애주기의 다음 인프라

판별식 하나, 자 두 개, 감사 하나, 최소모형 하나

판별



회계



판정



반증



답은 하나가 아니라 경로마다 다르다

이 발표가 답할 질문 — 일곱 개 더하기 하나

질문 지도

- | | | | |
|----|--|----|---|
| 01 | Q1 무슨 문제를 푸는가 · 경로마다 다르다 — § 4 에서 셋으로 갈라 답한다 | 08 | Q8 무엇이 이를 뒤집는가 · 반증 불가능한 판정은 쓰지 않는다 |
| 02 | Q2 무엇이 이 범주인가 · 이 발표가 스스로 더한 질문 · 나머지의 전제 | 09 | 답이 놓인 자리 ① · ch11 · 판별식과 corpus 29 편 전수 분류 |
| 03 | Q3 비용은 비교 가능한가 · 통일 회계를 세워야 비교가 성립한다 | 10 | 답이 놓인 자리 ② · ch24 · 대상 확정과 간격의 구조성 판정 |
| 04 | Q4 유망한가 · 최선인가 · 경로별 판정 · 판정 불가로 남는 칸이 있다 | 11 | 답이 놓인 자리 ③ · ch25·ch26 · 시간의 자와 바이트의 자 |
| 05 | Q5 주류가 될까 · 조건으로만 답한다 · 조건 없는 예측은 쓰지 않는다 | 12 | 답이 놓인 자리 ④ · ch27 · 경로별 판정과 판정 불가 칸 |
| 06 | Q6 scaling law 가 있는가 · B_s 를 축으로 놓을 수 있는지부터 감사한다 | 13 | 답이 놓인 자리 ⑤ · ch28·ch29 · 예산 축 감사와 device 좌표 |
| 07 | Q7 device 기회가 있는가 · 상태 바이트가 회계되어야 성립하는 논의 | 14 | 답이 놓인 자리 ⑥ · ch30 · 판정 32 개와 각각의 반증 관측 |

경로마다 다르다 — § 4 에서 셋으로 갈라 답한다

같은 이름 아래 세 개의 다른 대상이 있다

문제 제기

대화
요약

질의 전 요약을 벡터 DB 에 적재한다 — 모델 밖

저랭크
쓰기

배포 가중치에 저랭크 expert 를 덧붙인다

재귀
추가

KV cache 를 비우기 전 recurrence 를 더 돈다

셋 다 자기 절차를 sleep 이라 부르고, 셋을 같은 자로 댜 사람은 없다

이 발표를 지탱하는 장치 넷

방법

판별식

네 조건

네 조건 ·
갱신식과 시계만 본다

통일 회계

네 값

네 값 · $B_s, L_w,$
 C_{cap}, ρ 로 환산한다

정직성 규칙

불리한 사실

불리한 사실 ·
완곡화와 누락을
결함으로 본다

등급화

자기 실험

자기 실험 · 무엇을
단정 못 하는지 먼저
적는다

넷 다 앞 모노그래프에서 부족했거나 없었던 것이고, 넷 다 반증 가능하게 설계했다

척추 논지 — 이름이 기제보다 넓다

척추 논지 —

이름

기제

인용

비용



'sleep-time
compute' 은...
Memory fabric 이 version 을 보유하고
Control plane 이 publish 와 undo 를 결정한다

하나 . 생물학에서 왔고 논증은 오지 않았다


두 시간의 지도 — 여섯 걸음

발표 지도



청중과의 계약 — 무엇을 단정하고 무엇을 안 하는가

계약



비율 · 순서 · 자릿수 · crossover 는 단정한다 . 절대치는 하한 또는 방향성으로만 쓴다

비율 · 순서 · 자릿수 · crossover 는 단정한다 . 절대치는 하한 또는 방향성으로만 쓴다

앞 모노그래프에서 무엇을 그대로 가져오는가

승계

식

(U-W) 는 NM 의 master equation (M) 과 같은 식이다

기호

$\Theta \cdot W \cdot S_t \cdot \eta_t \cdot \beta_t \cdot \alpha_t$ 의 의미를 재정의하지 않는다

규율

등급 계약과 ' 억지 통합 금지 ' 를 그대로 가져온다

두 책은 겹치지 않고 이어진다 — 결론을 억지로 하나로 잇지 않는 규율도 승계한다

오늘 쓸 기호 세 개 — Θ , W , E

정의

Θ

slow weights · 배포 아티팩트를 이루는 가중치

W

fast weights · 요청 · 세션에 붙는 가중치 형태 상태

E

external store · 모델 밖의 텍스트 · 벡터 · 그래프

세 층의 결정적 차이는 크기가 아니라 누가 소유하고 언제 사라지는가이다

왜 세 층으로 나누는가 — 서빙 질문 넷

정의

네 질문의 답은 전부 '무엇이 바뀌었는가'에 달려 있고, 그 무엇이 정확히 셋뿐이다

evict 가능한가

레코드면
정책, 가중치면 롤백

배치에 섞이는가

사용자별
delta가 생기면
깨진다

롤백 단위는

행인가
세션인가
아티팩트인가

evict
가능한가

01

배치에 섞이는가

롤백 단위는

소유와 수명이 나머지를 전부 정한다

정의

E 레코드

요청과 독립 . 임의 시점에 삭제 가능

W 상태

들고 있는 주체가 사라지면 함께 사라진다

Θ 가중치

지우는 연산이 없다 . 새 아티팩트가 필요

롤백 단위

행 삭제 · 세션 종료 · 체크포인트 교체

batching

E 는 온전 , W 는 부분 파
손 , Θ 는 delta 단위
파손

요청과 독립 . 임의 시점에 삭제 가능

읽기는 하나 — 세 층을 모두 통과한다

식 (R) —



$\hat{y}=f(q;\Theta,W,E) \longrightarrow \Rightarrow$ 세 층을 모두 읽는다

질의 q

$ret(E,q)$ 는 여러분 어휘로 vector DB 조회 한 번이고 , 비용도 그렇게 회계한다

$ret(E,q)$ 는 vector DB 조회 한 번 . L_w 에만 잡힌다

쓰기 ① — fast weights 에 쓴다

식 (U-W) —



$$W = \alpha W + S \longrightarrow \Rightarrow \text{시계는 토큰}$$

α 남김비율

이 식은 앞 모노그래프의 master equation 과 글자 그대로 같다 . 재정의하지 않는다

NM 의 master equation (M) 과 글자 그대로 같다

쓰기 ② — slow weights 에 쓴다

식 (U-Θ) —



$$\Theta \leftarrow \Theta - \eta \nabla L(R \longrightarrow \Rightarrow \text{시계는 라운드})$$

R_k
학습집합

R_k 를 어떻게 만드느냐가 Θ- 경로 설계의 절반이고 , Part I 의 절반이 그 이야기다

η_Θ 는 inner η 와 다르다 . 섞어 쓰면 논리가 무너진다

쓰기 ③ — 모델 밖에 쓴다

식 (U-E) —



$E \leftarrow wr(E, \hat{c}) \longrightarrow \Rightarrow$ 시계는 세션

$\hat{c} = S(c; B_s)$

wr 의 형태 — 덮어쓰기인가 합집합인가 판단인가 — 가 E- 경로 논문들을 가르치는
축이다

S 에 추론이 들어 있는지가 조건 (2) 의 내용이다

읽는 규칙 하나 — 좌변을 적어라

규칙

좌변

무엇이 바뀌는가 — Θ 인가 W 인가 E 인가

참자

언제 바뀌는가 — 토큰 t 인가 라운드 k 인가

소비자

누가 읽는가 — 같은 질의인가 이후 질의인가

좌변을 못 적으면 그 절차는 아직 이해되지 않은 것이다

세 경로 — 실행하는 식과 배포의 변화

정의

E- 경로

레코드

레코드 ·
(U-E) 만 실행, 배포
불변

W- 경로

텐서

텐서 · (U-W) 를
오프라인에 추가 실행

 Θ - 경로

delta

delta · (U- Θ)
실행, 배포가 바뀐다

합성

순서

순서 · 어느 식을
먼저 도는지 밝힌다

경로를 걸치는 절차는 순서를 밝힌다 — 예 : (U-E) 로 $\hat{c}$ 를 만든 뒤 그것을 R 로 삼아 (U- Θ) 를 돈다

training 어휘 ① — 무엇이 언제 움직이는가

training
배경

pre-train

대량

대량 · 일반
코퍼스로 θ 전체를
만든다

SFT

지시

지시 · 라벨된
응답으로 θ 를 맞춘다

RL

보상

보상 · 선호나
검증 신호로 θ 를 민다

continual

지속

지속 · 배포
후에도 θ 를 계속
움긴다

네 레짐의 차이는 데이터의 출처와 갱신의 시계이지 optimizer 가 아니다

training 어휘 ② — fine-tuning 과 PEFT, 그리고 rank

training
배경



training 어휘 ③ — distillation, 그리고 교사가 누구인가

training
배경

logit

교사의 출력
분포를 학생이
따라 배운다

feature

중간
표현을 맞춘다

self

교사가 자기
자신 .
라운드마다
갱신된다

frozen

교사를
 θ_0 에
고정한다

교사

4
stages
2 refs

logit

logit · feature

feature

self-distillation 은 교사가 자기 자신

LIMI
T

sleep 라운드의 교사가 누구인가 — 이
질문이 뒤에서 반복 열화의 부호를
정한다

training 어휘 ④ — RL 과 보상 , 그리고 reward hacking

training
배경

RLHF

선호

선호 · 사람
비교로 보상 모델을
만든다

DPO

직접

직접 · 보상 모델
없이 선호로 바로 민다

RLVR

검증

검증 · 정답이 기계
검증되는 과제에 쓴다

hacking


보상

보상 · 지표를
속이는 해로 수렴한다

Θ- 경로 sleep 논문 둘 다 쓰기 검증이 외부 신호에 의존하고, 그 신호가 실질 병목이다

training 어휘 ⑤ — 데이터를 만드는 법과 model collapse

training
배경



gen(H;B_s)

replace

replace-mult

accumulate

2 차 모멘트

경험에서 학습 집합을 만드는 절차

합성으로 원본을 갈아치운다 — 위험 $\sim k$

합성만 늘린다 — 위험 $\sim \log k$

원본을 남기고 쌓는다 — 유계

정리가 볼 수 없는 좌표 . 여기서 죽는다

합성만 늘리는 것은 발산을 선형에서 로그로 낮출 뿐 유계로 만들지 못한다

training 어휘 ⑥ — 망각과 replay, 그리고 ρ 의 정체

training
배경



training 어휘 ⑦ — CLS 와 생물학적 sleep, 그리고 은유의 담보

training
배경

CLS

replay

왜 오프라인

담보



두 층

4
stages
2 refs

CLS

해마 ↔ 신피질

replay


빠른 학습기와 느린 통합기의 분업

LIMIT

이름은 생물학에서 왔고 논증은 오지 않았다 — 담보 확인은 뒤에서 다시 한다

training 어휘 ⑧ — 기억 용량 , 그리고 그 값이 하한이라는 사실

논문 수치



bits/param 3.64

- bits/param 3.64
- 밴드 2.86–4.23
- bf16 3.51
- fp32 3.83
- 명시된 하한

3.64 는 하한이다 . 상한으로 쓰면 뒤집힌다

training 어휘 ⑨ — 외부 기억과 검색 비용

training
배경

청킹 · 인코딩

문서를 잘라 벡터로 만든다 . 추론 없음

인덱스

corpus 당 수십 GB. host DRAM 에 산다

$\text{ret}(E, q)$

질의당 1 회 조회 . L_w 에만 잡힌다

프롬프트 증가

회수된 문서가 prefill 을 늘린다

단위 문제

corpus 당 바이트이지
사용자당이 아니다

문서를 잘라 벡터로 만든다 . 추론 없음

비용 4 종 — 오늘 모든 절차를 이 네 값으로 환산한다

정의

 B_s

예산

예산 · 유휴 시간 배치
job 의 비용 (FLOPs ·
토큰)

 L_w

지연

지연 · SLA
항목 (ms, TTFT/ITL)

 C_{cap}

용량

용량 · 저장
sizing (bytes/ 사용
자)

 ρ

열화

열화 · 반복 실행의
지속가능성 (라운드
당)

값이 논문에 없으면 ' 논문에 없음 ' 이라고 쓴다 . 추정치를 본문 수치로 올리지 않는다

상각식 (A) — 오늘 가장 자주 나올 도구

식 (A) —



$$C = C_w + C_s / N_q \longrightarrow \text{매 질의}$$


C_wake

식 (A) 는 N_q 를 안다고 가정한다 . 실서빙 N_q 분포를 보고한 논문은 corpus 에 0 편이다

N_q 분포를 보고한 논문이 corpus 에 0 편이다

손으로 한 번 굴러 본다 — 손익분기 3.64

예시 (본서
산술)



baseline: 10,000 prefill + 30...

- baseline: 10,000 prefill + 30...
- sleep: $10,000 + 3,000 \times 10 = 40...$
- wake: $500 + 150 \times 10 = 2,000$
- $N_q^* = 40,000 / 11,000 = 3.64$
- 손익분기는 네 번째 질의 근처

이 산수는 발표의 예시다

Rosetta 사전 — 서빙 어휘로 옮기면 이렇게 된다

Rosetta

- | | | | |
|----|---|----|--|
| 01 | prefix cache · ⚠️ $\hat{c}$ 는 같은 계산 재사용이 아니라 새 추론의 선행 | 08 | reuse distance · N_q — 같은 회계, 새 이름. 상각의 분모 |
| 02 | KV cache · W — append-only 무손실 대 고정 크기 손실 압축 | 09 | write amplification · $B_s \div$ 늘어난 C_{cap} — 1 바이트를 만드는 계산 |
| 03 | vector DB 조회 · $ret(E, q)$ — 동일. 비용도 동일하게 회계 | 10 | LSM compaction · GC · E 의 감쇠 · 병합 · 삭제. 유무가 설계를 가른다 |
| 04 | 모델 재배포 · $(U - \Theta)$ 1 회 — 배포 아티팩트가 바뀐다 | 11 | 카나리 · 롤백 · ⚠️ 사용자별이면 롤백 대상이 사용자 수만큼 |
| 05 | shared batching · ⚠️ 사용자별 δ 가 생기면 성립하지 않는다 | 12 | dtype 선택 · C_{cap} 의 정보 밀도 — 같은 도구, 새 대상 |
| 06 | warm-up · 사전컴파일 · sleep 라운드 — 단 sleep 은 품질을 바꾼다 | 13 | SLA(TTFT/ITL) · L_w — sleep 은 여기에 0 을 기여해야 한다 |
| 07 | checkpoint 크기 · $C_{cap} - \Theta$ 상태량은 여기서 직접 읽힌다 | 14 | GEMM shape · δ 단위 라우팅이 실패하면 grouped-GEMM |

⚠️ $\hat{c}$ 는 같은 계산 재사용이 아니라 새 추론의 선행

판별식 — 네 조건을 모두 만족해야 한다

판정 도구 —————

(1) 시계

질의 전

질의 전 · 상태 변경이
q 도착 전에
실행되는가

(2) 예산

$B_s > 0$

$B_s > 0$ · 추가
계산을 실제로
소비하는가

(3) 대상

총

총 · $\Theta \cdot W \cdot E$ 중
하나의
상태를 실제로
바꾸는가

(4) 소비자

이후 질의

이후 질의 · 그
변화를 다른 질의가
쓰는가

판별식은 논문의 자기 규정도 성능도 묻지 않는다 . 보는 것은 갱신식과 시계의 쌍뿐이다

판별식이 묻지 않는 것 둘

규칙

자기
규정

성능

재량

제목 · 초록 · 저자의 명명은 입력이 아니다

이득의 유무와 크기는 소속과 무관하다

다섯 단계를 같은 순서로 돌아 제거한다

이득이 있는지는 이 범주에 속하는지와 무관하다 — 이득의 크기는 판정 절이
다룬다


적용 절차 — 다섯 단계를 같은 순서로 돈다

절차



조건 (1) 을 빼면 — 모든 쓰기가 sleep 이 된다


확립




조건 (2) 를 빼면 — 저장에 추론으로 승격된다

확립


조건 (2) 가 없으면 색인 구축이 전부 sleep-time compute 이 되고 상각식의 분자가 정의를 잃는다




$B_s = 0$



MemTrans




원문




조건 (3) 을 빼면 — 읽기를 바꾼 논문이 쓰기 논문으로 둔갑한다

확립


조건 (3) 이 없으면 식 (R) 을 고친 논문과 (U-*) 를 고친 논문이 섞이고 경로 구분이 무너진다



읽기식



바뀐 것



경계에서

갱신
경로

조건 (4) 를 빼면 — test-time compute 전체가 들어온다

확립

이 라인을 만든 논문이 test-time 예산의 대안으로 자신을 제시했다는 점에서 이 조건은 양보할 수 없다

CoT·scratchpad

상태를 만들고
읽지만 질의와 함께
사라진다

같은 질의

Nested Learning

' 문맥이 제거되면
in-context 지식은
존속 안 함 '

Nested Learning

CMS 블록


일정 step 뒤
초기값으로
되돌아간다

CMS 블록

CoT·scrat
chpad
LEDGER

전수 분류 결과 — 29 편이 9 + 1 + 19 로 갈린다

전수 확인



A 군 통과 9 편

- A 군 통과 9 편
- 경계 1 편
- B 군 불충족 9 편
- C 군 배경 10 편
- E 6 / Θ 2 / W 1

경계 사례는 통과군에 세지 않는다

A 군 — 판별식을 통과한 아홉 편과 경계 사례 하나

전수 확인

- | | | | |
|----|--|----|--|
| 01 | Letta STC 2504.13171 · E · 질의 전 1 회 . 이 라인의 이름을 만든 논문 | 08 | Do LMs Need Sleep? 2605.26099 · W · KV 비우기 전 N 회 재귀 . 유일한 정면 사례 |
| 02 | MemGPT 2310.08560 · E · 대화 중 — 경계 사례 , (1) 불충족 | 09 | SEAL 2506.10943 · Θ · 두 시간척도 . 자기 생성 self-edit |
| 03 | Mem0 2504.19413 · E · 메시지쌍마다 ADD/UPDATE/DELETE 판단 | 10 | LM Need Sleep 2606.03979 · $\Theta \leftarrow W$ · sleep 라운드 k 마다 이송 |
| 04 | Zep 2501.13956 · E · 에피소드마다 + 주기적 community refresh | 11 | 층 분포 · E 6 편 · Θ 2 편 · W 1 편 . 경계 사례를 더하면 E 가 7 |
| 05 | ReasoningBank 2509.25140 · E · 과제 종료 후 . wr 이 순수 합집합 | 12 | 시계 분포 · 질의 전 1 회부터 메시지쌍마다까지 주기가 다르다 |
| 06 | SCM 2604.20943 · E · 대화 후 . 제목은 consolidation, 가중치 불변 | 13 | 상각의 분모 · N_q 가 세는 대상이 논문마다 달라진다 |
| 07 | Multi-Timescale 2605.05097 · E · 이벤트마다 . 유일 실험에서 LLM 미사용 | 14 | W- 경로 표본 · 1. 그 하나마저 자기 주류 계보와 접점이 없다 |

E · 질의 전 1 회 . 이 라인의 이름을 만든 논문

B 군 — 불충족 아홉 편과 걸린 조건

전수 확인

- | | | | |
|----|--|----|--|
| 01 | Nested Learning · (1)(4) · 시계가 토큰, 문맥 끝나면 소멸 | 08 | RAG · (2) · $\hat{c}$ 가 항등사상 · 저장 전 추론 없음 |
| 02 | Memory Caching · (2)(3) · B_s=0, 읽기식을 바꿨다 | 09 | Memorizing Transformers · (1)(2) · forward 중 (k,v) 캐시 적재 |
| 03 | Memory Layers · (1)(3) · pre-training 1 회, 배포 후 정지 | 10 | 시계 부재 셋 · LoRA·ROME·MEMIT — 쓰기 primitive 의 지위를 준다 |
| 04 | Generative Adapter · (1) · 갱신은 (U-W), 시계는 wake | 11 | 탈락 (1) 최다 · 질의 전이 아니라는 이유가 가장 많다 |
| 05 | LoRA · (1) 시계 부재 · 쓰기 primitive 이지 절차 아님 | 12 | 탈락 (2) · 저장 전에 추론이 없는 두 편 |
| 06 | ROME · (1) 시계 부재 · 저자가 실용 목적 아니라 명시 | 13 | 탈락 (3) · 상태가 아니라 읽기를 바꾼 두 편 |
| 07 | MEMIT · (1) 시계 부재 · 같은 편집의 대량 확장판 | 14 | 쓸모 · 용량 실측 · 천장 차수 · 반증 축을 공급한다 |

(1)(4) · 시계가 토큰, 문맥 끝나면 소멸

C 군 — 판정 대상이 아니지만 증거가 되는 열 편

배경 문헌

- | | | | |
|----|---|----|--|
| 01 | EWC · 지속학습 일반 · 망각 대응의 원형 | 08 | Can a LM Learn Facts Continually · Θ - 경로의 반증 후보 |
| 02 | Deep Generative Replay · replay 의 원형 | 09 | Sleep prevents forgetting (PLOS) · 생물 실증 |
| 03 | GEM · 성능행렬 Π 의 출처 | 10 | PAD (eLife) · 생물 실증 · dreaming |
| 04 | model collapse · 자기생성 데이터일 때 걸리는 제약 | 11 | 어디에 쓰이나 ① · 3.64 bits/param $\rightarrow \Theta$ 용량 회계의 분자 |
| 05 | How much do LMs memorize · 용량 상한 이론 . 3.64 bits/param | 12 | 어디에 쓰이나 ② · model collapse $\rightarrow$ 반복 열화의 함수형 |
| 06 | LoRA as Knowledge Memory · 저랭크 쓰기의 용량 실측 | 13 | 어디에 쓰이나 ③ · Continual Facts $\rightarrow$ 유일한 다라운드 증거 |
| 07 | Rate-Distortion Compaction · 무엇을 버릴 것인가의 이론 | 14 | 어디에 쓰이나 ④ · 생물 두 편 $\rightarrow$ 은유의 담보 확인 |

지속학습 일반 · 망각 대응의 원형

이름과 실체가 갈리는 다섯 사례

본서 판정



SCM

→ 제목은 consolidation, 좌변은 전부 그래프다

MEMCACHING

→ 갱신식이 아니라 읽기식을 바꿨다 .
B_s=0

NESTEDLEARN

→ 연속체는 표기의 다리이지 기제의 다리가 아니다

MEMLAYERS

→ 배포 후 정지 . 볼 시계가 없다


GENADAPTER

→ 산출물은 LoRA 모양 , 시계는 wake
다

분류는 산출물의 모양이 아니라 (갱신식 , 시계) 의 쌍으로 한다

SCM 한 편을 다섯 단계로 실제로 밟아 본다

본서 판정



1 연산자

— hebb · downscale · transfer · dream · prune

2 좌변

— 전부 그래프와 텍스트 버퍼
— 모델 밖

3 시계

— 대화 후 . 트리거가 상태
의존이다

4 예산

— 0 보다 크되 LLM 호출이
하나도 없다

5 소비자

— 이후 턴의 검색이 읽는다
— 통과

연산자가 같아도 좌변이 다르면 다른 총이고, 비용 ·
용량 · 롤백 단위가 전부 달라진다

경계 사례 규칙 — MemGPT 는 되고 RAG 는 안 되는 이유

규칙

조건

네 조건 중 셋을 만족하고, 통과군이 조상으로 지목

의무

탈락 조건 명시 + 통과군으로 세지 않기

RAG

탈락 조건 하나지만 조상 지목이 없다 — 배경

경계 사례 자격은 탈락 조건의 개수만으로 주어지지 않는다

침묵 지도 — 연대가 강제한 침묵과 선택된 침묵

전수 확인

정의

뒤에 온 논문이 앞선 논문을 인용했는가만 묻는다

Memory Layers

MemGPT·LoRA·ROME·EWC 넷 다 미인용

Nested Learning

8 개월 선행한 Letta STC 를 인용하지 않는다

Letta STC

W·Θ· 생물 세 방향 모두에 침묵한다

ReasoningBank

'sleep' 이 논문 전체에 한
번도 안 나온다

뒤에 온 논문이 앞선 논문을 인용했는가만 묻는다

같은 경로 안에서도 창시 논문이 인용되지 않는다

본서 판정 ———

E- 경로

W- 경로

상속

예외



같은
연산을
하는
논문이 그 연산에 이...

ReasoningBank 는 5 개월 뒤에 나왔다

E- 경로 — 모델 밖에 쓰고 프롬프트로 읽는다

경로 개요

좌변

레코드

레코드 ·
텍스트 · 벡터 ·
그래프 · θ 와 W 는
불변

시계

세션

세션 · 대화 후,
과제 후,
에피소드마다

읽기

검색

검색 · $\text{ret}(E, q)$
한 번 + 프롬프트 증가

이점

배칭

배칭 ·
shared-weight
batching 이 온전하다

통과 9 편 중 6 편이 여기 있고, 이 라인의 이름도 여기서 나왔다

가장 이른 조상 — Memorizing Transformers 는 왜 이 범주가 아닌가

명제

미분 불가 저장소를 attention 으로 읽는 것이 낫다

쓰기

forward 가 만든 (k,v) 그대로 . S 가 항등사상

읽기

12 층 중 layer 9 에서 top-32 회수 후 attention

탈락

조건 (1)(2). 쓰기가 wake pass 안에 있다

비용 4 중

값이 든 칸이 없다 . C_cap
은 개수로만


미분 불가 저장소를 attention 으로 읽는 것이 낫다

RAG 에서 MemGPT 로 — 단위가 corpus 당에서 사용자당으로 바뀐다—



Letta `Sleep-time Compute` — 이름을 만든 논문

확립



공백 제조

계보

번호 수식

sleep 의 뜻

생물 인용

test-time scaling 에
stateless 가정을 부여

OS prefetching 유비
하나 . 문제 상속 아님

논문에 번호 붙은 수식이
하나도 없다

consolidation 이 아니라
유휴 시간

CLS 도 replay 도 0 편

상속받은 open question 이 없다 . 참고문헌 22 개에
계보 진술은 유비 하나뿐이다

Letta STC 의 기제 — (U-E) 하나가 네 겹으로 특수화된다

확립



'learned' 는 gradient 를 뜻하지 않는다 — 논문 자신이 그렇게 쓴다

논문 원문

learned

공간

귀결

근거



표현이
형성되는
공간이
paramete...

gradient 아님

비용모델 — 생성 토큰만 세고 prefill 항이 없다

논문의 식 —



$C = \kappa B_t \text{ only} \longrightarrow \kappa = 10 \text{ wake}$

생성 토큰

빠진 항의 방향과 방법이 작동하는 방향이 같다 — 이 방법은 프롬프트를 늘린다

이 방법의 기제가 프롬프트를 늘리는 방향으로 작동한다

5× · 13% · 2.5× 는 어디서 나온 수인가

본서 판정

05

본서
판정 FINDINGS

GSM-Sym
AIME
Multi-Q
SWE-Feat

GSM-SYM

→ 저자 제작 변형 . GSM8K 에 문맥 몇 문장을 붙였다

AIME

→ 60 문항 . 문맥이 빈 인스턴스가 개수 미상 포함

MULTI-Q

→ 90.9% 가 모델 생성 문항 . 생성 답 검증 미보고

SWE-FEAT

→ 형제 PR 묶음 . 절감이 약 1.5× 로 작다


K_COST=10

→ 벤더 문서 인용 한 줄 . 민감도 분석 없음

네 벤치마크가 전부 저자 제작 변형이고 , 기존 *stateful reasoning* 벤치가 하나도 없다

이득은 높은 예산에서 역전하고, sleep 스케일링은 비단조다

논문 수치



GSM 에서 역전

- GSM 에서 역전
- SWE 에서 역전
- 병렬 5 벌 > 10 벌
- 기제 제시 없음
- 논문 자신의 보고

둘 다 논문 안에 있다

프로덕션 넷 — Mem0 · Zep · ReasoningBank · SCM

확립



쓰기 연산자의 네 형태 — 그리고 수축 가능한 것은 둘뿐

확립

네 연산 문법

판단

판단 · Mem0 의
ADD/UPDATE/
DELETE/NOOP

그래프 delta

누적

누적 · Zep 과
Mem0^g.
비파괴적이다

합집합

단조

단조 ·
ReasoningBank.
지우지 않는다

동역학

감쇠

감쇠 ·
SCM · Memini.
prune 이 유일한 수축

수축 가능한 둘 다 삭제 정확도를 측정하지 않는다

E- 경로의 대가 — 품질 1 위가 반복적으로 ' 기억 없음 ' 이다

논문 자기
수치

Mem0

full-context 72.90% 대 Mem0 66.88% (J)

Zep DMR

full-conversation 94.4% 가 MemGPT 93.4% 를 이김

SCM

무망각 그래프 baseline 이 22/22 로 동률

ReasoningBank

검색 항목을 늘리면 성공률이 단조 악화


표준편차

격차가 인쇄된 sd 의 20
배를 넘는다

full-context 72.90% 대 Mem0 66.88% (J)

W- 경로 — 문맥을 접고 원 문맥을 버린다


경로 개요



회계상 가장 유리한 형태를 가진 경로인데 판별식 정면 통과가 한 편뿐이다

경첩 — Generative Adapter 는 왜 Θ - 경로가 아닌가

본서 판정



산출물

갱신식

빈 항 넷

체크포인트

시계

- LoRA. 논문이 그 형태를 명시적으로 유도
- $S_t = S_{t-1} + A_2 H^T H B_1 - (U-W)$ 변종
- α 없음, $\beta \equiv 1$, η 없음, inner loss 없음
- 이전과 바이트 단위로 같다
- wake. 그 자리에서 접고 그 문맥에 답한다

산출물은 LoRA 모양이고 논문이 그 형태를 직접 유도하는데, 갱신식은 $(U-W)$ 이고 시계는 wake 다

모양으로 분류하면 세 판정이 동시에 틀린다

본서 판정

Gen
Adap
ter
SCM

모양으로 보면 Θ , 실제로는 W 이고 시계는 wake

제목으로 보면 Θ , 실제로는 E 다

MemC
aching

문제의식으로 보면 이 범주, 실제로는 읽기 변경

모양은 저장 · 전송 · 롤백 단위를 정하고, 시계와 갱신식이 경로를 정한다

`Do LMs Need Sleep?` — W- 경로의 유일한 정면 사례

확립



판별식 통과가 설정에 달려 있다

본서 판정

같은 논문의 두 설정 중 하나에서는 sleep-time compute 이고 다른 하나에서는 아니다

Depo 설정

consolidation 이
질의보다 앞선다 .
 $N_q=10$

$N_q = 1$

GSM-Infinite

질문이 문맥 앞 .
consolidation 이
질의 조건부

GSM-Infinite

귀결

$N_q=1$ 이라 식
(A) 가 함으로
붕괴한다

귀결

Depo
설정

비용 4 종 전부 부재 , 그리고 계산량을 맞춘 baseline 이 없다

부재 확인

B_s

구조로만 있다 . 수치가 없다

L_w

아키텍처 보장이지 측정이 아니다

C_{cap}

상태 차원 · head 수 · dtype 이 없어 유도 불가

p

관측될 레짐에 논문이 들어가지 않는다


대조군

캐시 유지 full attention
이 어디에도 없다

구조로만 있다 . 수치가 없다

이 경로에서 함께 거론되지만 이 범주가 아닌 둘

본서 판정



둘 다 이 범주는 아니되 뒤에서 용량 천장과 반증 축의 재료를 공급한다

둘 다 이 범주는 아니되 뒤에서 용량 천장과 반증 축의 재료를 공급한다

Θ- 경로 — 배포 아티팩트 자체를 바꾼다

경로 개요

좌변

delta

delta · 가중치 .
배포 아티팩트가
바뀐다

시계

라운드

라운드 ·
sleep 라운드 k 마다

이점

0

0 · 담긴 사실의
질의당 한계 비용이 0
이다

대가


배칭

배칭 ·
shared-weight
batching 이 깨진다

질의당 한계 decode 비용 0 을 사기 위해 배치 효율과 워م 스토리지를 지불한다

쓰기 primitive ① — LoRA, 그리고 그것이 풀지 않은 문제

확립



쓰기 primitive ② — ROME 과 MEMIT, 그리고 저자 자신의 유보

확립

ROME 갱신

등식제약 최소제곱의 닫힌 해 . η_Θ 가 없다

저자 유보

' 실용적 방법으로 의도되지 않았다 '

MEMIT

같은 편집을 대량으로 확장 . 제자리 덧셈

지위

delta 아티팩트를 만들지 않는다


gradient 불필요

Θ 쓰기가 반드시 SGD
여야 하는 건 아니다

등식제약 최소제곱의 닫힌 해 . η_Θ 가 없다

편집 용량 10,000 과 그 대가

논문 수치



GPT-J 6B 10,000 편집

- GPT-J 6B 10,000 편집
- specificity 83.5 → 73.7
- zsRE Specificity 26.6
- 미편집 GPT-J 27.0
- 편집당 2.68 초 (본서 나눗셈)

10,000 은 관측된 하한이다

갈림길 — delta 인가 직접 편집인가

본서 판정

delta

분리 가능한 아티팩트 . 사용자별로 붙였다 떼다

직접
편집

base 에 흡수 . 아무것도 남기지 않는다

귀결

전역이면 편집이 이기고 , 개인화면 delta 여야 한다

직접 편집은 전역 사실 갱신의 도구이고 , delta 는 개인화의 도구다 . 이
구분을 제기한 논문이 없다

SEAL — 모델이 자기 학습 데이터를 쓴다

확립



SEAL — 자기 표가 논지를 세 번 꺾는다

논문 자기
수치

05

논문 자기
수치 FINDINGS

초록
범위 RL
없이 TTT
보상 형식 자율

초록 범위

→ 'GPT-4.1 능가' 는 세 열 중 한 열에서만 성립

RL 없이

→ 프롬프트 둘 (49.3·49.4) 이 RL 헤드라인 47.0 을 넘음

TTT 보상

→ 지워도 45.6 이고 약 72 배 싸다

형식 자율

→ 모델이 형식을 스스로 정하면 18.9 로 무너진다

벤치 구성

→ TTT 가해성으로 필터된 19 과제 — Oracle 100% 는 구성상 참

실제 걸림들은 계산이 아니라 문맥마다 라벨을 요구하는 보상 oracle 이다

`LM Need Sleep` — wake 의 W 에서 sleep 의 Θ 로 이송한다

확립

bridge-in

wake

sleep

확장

상속

(U-W)

이송

성장

상속 · NL 이 범위
밖에
둔 자리를 명시적으로
받는다

(U-W) · 살아 있는
시퀀스에서 fast
weight 에 쌓는다


이송 · 세 단계로
 Θ 에 옮기고 W 를
리셋한다

성장 · $\dim \Theta$ 가
라운드마다 커진다

corpus 에서 bridge-in 이 교과서적으로 성립하는 거의 유일한 사례다

Knowledge Seeding 과 Dreaming — 그리고 그 마진의 출처

확립



Seeding

Dreaming

확장만

예산

부재

- sleep 에 넣을 데이터를 스스로 만든다
- 생성된 것으로 distillation 과 RL 을 돈다
- 76.6→77.9 등 마진 절반이 여기서 나온다
- SFT 대비 step 당 4 배 . 절대값은 없다
- 일곱 실험 중 넷은 숫자가 없다

마진의 절반가량이 Knowledge Seeding 없이 구조적 확장만으로 얻어진다

ablation 역전과 상각식의 퇴화

논문 자기
수치

Semantic Reward

제거하면 AIME-25 가 69.0 에서 69.2 로 오른다

그럼에도

' 모든 구성요소가 긍정적으로 기여한다 '

그 보상

이름도 크기도 없는 외부 frozen reward model

N_q

쓰기가 스케줄별이라 ' 앞으로의 전 트래픽 ' 이 된다


귀결

식 (A) 가 이 경로에서 퇴화한다

제거하면 AIME-25 가 69.0 에서 69.2 로 오른다

반증 축 — 가중치에 사실을 계속 넣을 수 있는가

반증 축



생물학이 실제로 보인 것 — 은유의 담보를 확인한다

생물 실증

PLOS

강한 baseline

결과

PAD

wake 와
sleep 두
시계로 같은
시냅스에 쓴다

과거 데이터를
저장하는 고전
interleaving

sleep
0.70/0.68 대
interleaving
0.68/0.65

제목이 가리키는
성분의 효과를
못 보였다

0.70

4
stages
3 refs

PLOS

0.68 대 0.65

강한 baseline 고전 interleaving 과 표준편차 안에서 같다

LIMIT

실증된 우위는
정확도가 아니라 저장의 제거다

이 발표가 담은 실험 넷 — 어느 것도 GPU 실측이 아니다

등급 계약

X1 비용 회계

회계

회계 · 상각식에 빠진
항을 되살려 닫힌
형태로 푼다

X2 용량 회계

회계

회계 · 구성
파라미터에서
바이트를 복원한다

X3 예산 감사

감사

감사 · 29 편의 B_s
보고 형태를 전수로
센다

X4 반복 열화


모형

모형 · 가우시안과
선형 연상기억 · LLM
아님

이 host 에 NVIDIA GPU 가 없다 . 그래서 이 발표에는 지연 · 처리량 · 전력의 측정값이 하나도 없다

계산해 놓고 본문에 올리지 않은 값 넷

등급 계약



비용 칸이 비어 있는 논문에 '효율적' 이라고 쓰지 않는 규칙은 이 발표의 실험에도 똑같이 적용된다

비용 칸이 비어 있는 논문에 '효율적' 이라고 쓰지 않는 규칙은 이 발표의 실험에도 똑같이 적용된다

X1 설계 — 논문의 비용모델을 열어 빠진 항을 되살린다

회계 (측정
아님)



X1 파생량 ① — 임계 길이 L^*

본서 산술 —



$$L^* = \frac{\kappa \Delta B}{(w \cdot \kappa_{//})} \longrightarrow \text{wake 배수}$$

κ_{cost}

$|\hat{c}|$ 가 L^* 를 넘으면 N_q 를 아무리 키워도 baseline 을 이길 수 없다 . $w_{\text{in}}=0$ 이면 $L^*=\infty$ 이다

논문의 회계에는 이 경계가 존재하지 않는다

X1 파생량 ② — 손익분기는 절벽이 아니라 점근이다

본서 산술 —



$$Nq^* = Bs/w\Delta \longrightarrow \text{한 번}$$


분자 B_s

$|\hat{c}| \rightarrow L^*$ 에서 N_q^* 가 발산한다 . 임계에 닿기 한참 전부터 필요한 질의 수가 도달 불가능해진다

$|\hat{c}|$ 가 L^* 에 가까워질수록 필요한 질의 수가 발산한다

X1 결과 — 단정하는 것은 레짐 간 순서다

회계 ·
순서만



논문 회계

GSM-Sym

AIME

SWE-Feat

단정

세 레짐 모두 '경계 없음'

FLOPs · $\kappa // = 1$ 에서
문맥의 12 배

여유가 크지만 문맥이 비는
인스턴스 포함


$\kappa // = 10$ 이면 문맥의 0.42
배까지 줄어진다

순서만 . 두 방향으로
결정되어 둔감하다

SWE-Features 가 모든 회계 변종 , 모든 $\kappa_//$ 에서
최하위다 . 절대 임계치는 판정 근거가 아니다

X1 민감도 — 회계를 지탱하는 가장 무거운 상수가 가장 근거가 얇다

회계 ·
비례만



$\kappa=1 \rightarrow 0.42$ 배

• $\kappa=1 \rightarrow 0.42$ 배

• $\kappa=2 \rightarrow 0.83$ 배

• $\kappa=5 \rightarrow 2.08$ 배

• $\kappa=10 \rightarrow 4.17$ 배

• $\kappa=20 \rightarrow 8.33$ 배

κ_{cost} 가 1에 가까워지면 임계가 10분의 1

X2 설계 — 아무도 바이트로 보고하지 않은 값을 복원한다

회계 (측정
아님)



X2 결과 ① — 세 경로의 상태가 약 5.5 자릿수 벌어진다

회계 ·
자릿수만

E 텍스트

56.0 KB · 콜드 · 세션 ~ 사용자 (가정)

Θ delta

16.78 MB · 워م · 사용자 영속 (구성에서 정확)

Θ 직접 편집

delta 0 · 개인화하면 16.0 GB

W fast weights

17.18 GB · 핫 · 세션 (dense 행은
반사실)

지수

$E \propto n \cdot \Theta \propto r \cdot d \cdot L \cdot$
 $W \propto d^2 \cdot L$

56.0 KB · 콜드 · 세션 ~ 사용자 (가정)

X2 결과 ② — 정보 밀도를 정하는 것은 dtype 이다

회계 ·
배수만

bf16

16.78 MB ·
1.82 bits per
byte

int8

8.39
MB · 3.64

int4

4.19
MB · 7.28

유보

세 값 전부
외삽된 양의
하한이다

2×
4
stages
2 refs

bf16

bf16 1.82


int8

int8 3.64 · int4 7.28 bits/...

LIMI
T

저장 폭을 절반으로 내리면 밀도가
정확히 두 배가
된다 . 이 진술은 분자의 지위와
무관하게 성립한다

X2 결과 ③ — 사용자 수를 곱하면 어느 계층이 문제가 되는가



r=16 bf16 16.8 TB

- r=16 bf16 16.8 TB
- r=16 int4 4.2 TB
- r=64 bf16 67 TB
- 직접 편집 16,000 TB
- E 텍스트 0.056 TB

직접 편집 개인화는 세 자릿수가 된다

X3 설계 — B_s 가 어떻게 보고되는지를 규칙으로 전수 감사한다

감사 (측정
아님)



X3 결과 — B_s 는 이 corpus 에서 축이 아니라 각주다

감사 ·
편수만

05

감사 ·
편수만 FINDINGS

절대 1 편
step 5 편
벽시계
2 편 knob 2 편

절대 1 편

→ ReasoningBank 과제당 3748.4
토큰 . 상각 주장 안 함

STEP 5 편

→ 학습 논문의 서식을 물려받은 경로들

벽시계 2 편

→ MFU 보고가 1 편이라 FLOPs 로 옮길
다리가 없다

KNOB 2 편

→ 눈금 없는 비례 손잡이만 . Letta STC
가 여기

없음 19 편

→ 그중 9 편은 애초에 B_s 가 정의되지
않는다

그 19 편 중 9 편은 ' 보고 안 함 ' 이 아니라 오프라인 패스 자체가 없어 B_s 가
정의되지 않는 경우다


X4 설계 — 반복 (U- θ) 를 최소 모형에서 K 라운드 돌린다

최소모형 ·
LLM 아님



X4 결과 — 이송해야 할 양은 ρ 가 아니라 crossover 다

최소모형
부호만



모양

이송량

앵커

이중 해리

1 차 모멘트

과제 지표는 절벽, 연속
신호는 매끄럽게

라운드당 비율이 아니라
마지막 라운드 K^*

gold replay 가 모든
혼합비에서 오래 버틴다

gold 는 유지를, self 는
역량을 산다

평평한 손실 곡선은 안정의
증거가 아니다

replay 는 보존된 원본에 앵커되어야 한다. 이
부호는 세 곳에서 독립적으로 나온다

판정 ① — 이 범주는 A 군 아홉 편이다

본서 판정

통과 9 편

확정

확정 · 네 조건을
모두 만족한 절차만

경계 1 편

서술

서술 · 출발점으로
쓰되 통과군에 안 센다

인접 9 편

이동

이동 · 배제가
아니라 증거로 자리를
옮긴다

조건 없음

확정

확정 · 이
판정은 조건부가
아니다

논문의 자기 규정과 어긋나는 자리가 여럿 있고, 어긋나는 자리에서는 이 발표의 판정을 따른다

판정 ② — 간격은 구조적이다, 세 공동체가 각자의 서식을 쓴다

본서 판정

E의 대화 상대

에이전트 기억 — 경쟁 제품, 지연, 정확도

W의 대화 상대

test-time learning — 고정 상태, recall

Θ 의 대화 상대

지속학습 — 망각, replay, step, 성능행렬

서식의 상속

E의 서식에는 쓰기 비용 칸이 아예 없다

통로 부재

공유 벤치 교집합이 공집합, 바이트 0 편

에이전트 기억 — 경쟁 제품, 지연, 정확도

간격을 방치하면 세 가지 판단이 틀린다

본서 판정

셋 다 문헌의 결함이 아니라 문헌을 읽는 쪽의 결함이다

잘못된 비교

회계의 자리가 다른
수치를 나란히 놓는다

세 실패

잘못된 기대

라운드를
늘릴수록 좋아진다는
기대

잘못된 기대

잘못된 투자

세 인프라 결정을
한 문장으로 뭉갬다

잘못된 투자

잘못된
비교

판정 ③ — 세 경로는 지금 같은 자로 썰 수 없다, 두 층위로

본서 판정

인쇄
된 칸

B_s 1 편, $L_w \cdot C_{cap} \cdot p$ 각각 0 편 (21 편 기준)

층위 ①

보고 관행 — 저자가 인쇄하면 즉시 해소된다

층위 ②

회계 틀 — 값을 인쇄해도 해소되지 않는다

그래서 'sleep-time compute 이 싼가' 는 현재 문헌 상태에서 검증도
반증도 되지 않는다

판정 ④ — 상각 논증에는 구조적 결함이 있다

조건 없이
단정



$Cs/Nq + w \cdot \hat{c} \longrightarrow$ 한 번

나뉘는 항

실험적 반례가 아니라 식의 성질이며, 미보고 값의 선택과 무관하다

식의 성질이지 실험적 반례가 아니다

판정 ⑤ — 그러나 5× 는 반박되지 않는다

조건부 판정 —

조건 ①

조건 ②

그러면

반박 대상



5× 는
생성
토큰
축에서 관측된 사실이...

원 문맥이 짧다


판정 ⑥ — '상태 용량' 은 하나의 수가 아니다

본서 판정



판정 ⑦ — 경로 선택은 곧 메모리 계층 선택이다

본서 판정



W = 핫

Θ = 월

E = 콜드

조건

반례

- 세션당 GB. 토큰마다 RMW 라 HBM 밖에 못 둔다
- 사용자당 MB. 요청당 한번 스테이징
- 사용자당 KB. 질의당 한번 읽힌다
- W 가 고정 크기를 유지한다는 전제 위에 선다
- recall 을 얻으려면 상태가 문맥에 선형으로 크다

배치를 정하는 것은 알고리즘이 아니라 세 성장 지수가 서로 다른 변수라는 구조적 사실이다

판정 ⑧ — E- 경로는 유망하다 , 단 비용 방법으로서

본서 판정

05 본서 판정 FINDINGS

품질 측
비용
방향
비용 크기 총비용

품질 측

→ 네 시스템에서 같은 방향 — 기억 없음이 이긴다

비용 방향

→ 구조적으로 참 . 프롬프트가 짧아지면 prefill 이 준다

비용 크기

→ 미확정 . 상대방에 prefix cache 를 켜지 않았다

총비용

→ 분자 B_s 가 이 경로에서 가장 비어 있는 칸이다

안 쓴 논거

→ batching 보존을 주장한 논문이 다섯 중 0 편

품질 방법로서는 지지되지 않으며 , 그 반증은 이 발표가 아니라 논문들 자신의 표에서 나온다

판정 ⑨ — W- 경로는 판정 불가이고, 그 판정 불가가 결과다

판정 불가

표본

A 군 논문이 1 편이다

비용

그 1 편의 네 칸이 전부 비어 있다

대조군

계산량을 맞춘 baseline 이 없다

설정 의존

판별식 통과가 두 설정 중 하나에서만 성립

그럼에도

원 문맥을 버리는 설계가
결함의 탈출구다

A 군 논문이 1 편이다

판정 ⑩ — Θ - 경로는 조건부로 유망하다 , 조건 셋과 함께

조건부 판정 —



판정 ⑪ — '최선인가'와 '우월한가'는 어디서도 판정되지 않는다


판정 불가

- | | | | |
|----|--|----|--|
| 01 | E vs full-context 품질 · 실행되었고 방법이 졌다 | 08 | 그래서 판정은 · 세 경로 어디에서도 '판정 불가'로 남긴다 |
| 02 | E vs full+prefix cache · 실행되지 않았다 — 비용 축 판정 불가 | 09 | 왜 회피가 아닌가 · 없는 표를 지어내는 것이 회피다 |
| 03 | E vs 순수 검색 · 부분 실행이되 스왑이 baseline에만 걸림 | 10 | 무엇이 필요한가 · 새 수치가 아니라 새 표다 |
| 04 | W vs 계산량 정합 · 실행되지 않았다 — 판정 불가 | 11 | 반증 FQ1 · 빈칸 하나가 채워지면 그 행이 해소된다 |
| 05 | Θ vs in-context · 실행되었으나 레짐이 어긋난다 | 12 | 반증 FQ2 · 부재 판정이 틀렸다면 baseline 열을 세면 된다 |
| 06 | Θ vs 검색 · 두 문장의 기각으로 대신했다 — 판정 불가 | 13 | 비용 · 빠진 대조는 전부 실행 비용이 낮다 |
| 07 | 빠진 대조군의 공통점 · 가장 싸고 가장 자명한 baseline 이다 | 14 | 재채점 · corpus가 커질 때마다 같은 절차로 다시 센다 |

실행되었고 방법이 졌다

판정 ⑫ — 현재 문헌으로 B_s- 품질 곡선은 그릴 수 없다

감사 · 조건
없음



절대 단위 1 편

- 절대 단위 1 편
- 3 점 이상 4 편
- 그중 절대 2 편
- 공유 벤치 0 건
- A 군 중 0 편

x 축과 y 축이 동시에 깨져 있다

그래서 무엇을 인쇄해야 하는가 — 최소 보고 요구 R1-R9

제안

- | | | | |
|----|---|----|--|
| 01 | R1 · B_s 를 절대 FLOPs 로 . 못 하면 환산 입력을 함께 | 08 | R8 · 라운드마다 내는지 한 번인지 , 그리고 라운드 수 |
| 02 | R2 · step · 벽시계면 batch · 길이 · 파라미터 · MFU 를 함께 | 09 | R9 · 그림 축이 아니라 표에 숫자로 |
| 03 | R3 · 한 점이 아니라 최소 3 점 sweep 과 각 점의 품질 | 10 | 최소 실행 집합 · R1(또는 R2) · R3 · R4 — 첫 곡선이 그려진다 |
| 04 | R4 · 공개 벤치에서 같은 지표 · 같은 baseline arm 으로 | 11 | 총비용으로 옮기려면 · R5 · R6 이 더해져야 한다 |
| 05 | R5 · B_s 가 무엇당 예산인지와 N_q 의 분포 | 12 | 포화 귀속 · R7 이 빠지면 예산인지 그릇인지 못 가린다 |
| 06 | R6 · wake 쪽 델타 — $ \hat{c} $ 와 $ c $ | 13 | 총예산 정의 · R8 이 빠지면 라운드 합이 정의되지 않는다 |
| 07 | R7 · 저장소 크기와 질의당 주입량을 분리해서 | 14 | 실행 비용 · 새 실험은 R3 하나 . 나머지 여덟은 인쇄다 |

B_s 를 절대 FLOPs 로 . 못 하면 환산 입력을 함께

판정 ⑬ — device 기회는 읽 계층이지 HBM 대역폭이 아니다

본서 판정

읽기 입도

사용자당 수 MB 객체 하나의 무작위 접근

마감

$t_{\text{load}} + t_{\text{merge}} \leq L_w$. 좌변도 우변도 미보고

쓰기 주기

라운드마다 전량 교체 . N_u 에 선형

대역폭 아님

base 가중치 읽기의 약 0.105% 다

조건

Θ - 경로가 사용자 수준
개인화로 갈 때만 성립

사용자당 수 MB 객체 하나의 무작위 접근

라운드 주기 하나가 소자의 수명 사양을 정한다

본서 산술



$$\frac{DWPD=1\text{day/}}{T_k} \longrightarrow N \cdot C/T$$

쓰기율

용량도 사용자 수도 dtype 도 이 비에서 약분되어 사라지고 남는 것은 라운드 주기 하나다

용량 · 사용자 수 · dtype 이 약분되고 T_k 만 남는다

이 자리는 앞 모노그래프가 짙은 자리와 다르다

조건 없이
단정

병목 자원

HBM 대역폭 대 월 계층의 마감과 내구성

시간 입도

토큰당 대 요청당 · 라운드당

상태 수명

세션 transient 대 사용자 영속

새 primitive

decode 경로 위 RMW 대 delta 스테이징

공존

HBM 은 여전히 포화하고
그 위에 스테이징이 얹힌다

HBM 대역폭 대 월 계층의 마감과 내구성

shared-weight batching 은 이분법이 아니라 네 단계다

구조 분류

E- 경로

유지 · 프롬프트 길이만 늘어난다

W- 경로

세션 단위 부분 파손 · 동시 세션 수가 제한된다

⊖ 사용자 수준

delta 단위 파손 · 라우팅으로 완화 가능

⊖ 인구 수준

유지 · 가중치 1 벌 · 이 기회를 만들지 않는다

직접 편집 개인화

완전 파손 · 완화 수단이
구조적으로 없다

유지 · 프롬프트 길이만 늘어난다

이 기회를 사기 전에 필요한 것은 소자가 아니라 인쇄값 셋

부재 확인

셋 다 corpus 에 0 편이고 셋 다 새 하드웨어를 요구하지 않는다

delta 스테이징

세 방식
어디에도 L_w
측정이 없다

셋 다 0 편

양자화 회수율

가장 큰
지렛대를 당긴 논문이
0 편

양자화 회수율

K* 측정

100 라운드를
넘긴 실험이 0 편

K* 측정

delta
스테이징

이 발표가 틀릴 수 있는 지점 다섯

반증 조건



분류

→ 네 조건을 다 만족하는데 B 군에 넣은 절차가 있으면

간격

→ E 논문이 $W \cdot \Theta$ 를 같은 표에서 baseline 으로 돌리면

측

→ 절대 단위 B_s 3 점을 인쇄한 논문 셋이 나오면

부호

→ self replay 가 gold replay 보다 오래 버티면

계층

→ delta working set 이 노드 로컬에 상주하면

반증 불가능한 판정은 이 발표에서 쓰지 않는다

이 발표의 실험 하나가 초판에서 틀렸다 — 하한을 상한으로

자기 정정

무엇
이

3.64 bits/param 을 상한으로 놓고 경로 간 밀도 비 계산

왜
틀렸나

원 논문이 명시적으로 하한이라고 밝힌 값이다

처리

비교는 철회, dtype 배수는 살아남음, 반증 실험 신설

정정 이력이 없으면 살아남은 주장이 검사를 통과해서 남은 것인지 알 수 없다

판별식을 다르게 그으면 무엇이 달라지는가

감사



GPU 실측이 없다는 것이 막는 것과 막지 않는 것

본서 판정

막는다 ①

절대 지연과 처리량 . 몇 ms 인지 말할 수 없다

막는다 ②

실제 스택에서의 병목 순위

막는다 ③

품질과 비용의 실제 교환 곡선

안 막는다

부재 · 구조 분류 · 식의 성질 · 자릿수 ·
순서 · 부호

대가

웹 계층 기회는 자릿수
논증으로만 서 있다

절대 지연과 처리량 . 몇 ms 인지 말할 수 없다

이 발표가 가장 빨리 낡는 방식은 반박이 아니라 인쇄다

본서 판정 —

N_q 분포

사용자당 바이트

prefix cache

체크포인트 diff



새
방법을
발명할
필요가 없다. 이미...

한 줄

Q&A 지도 — 네 종류의 질문에 답하는 방식이 다르다

부록

사실 질문

출처

출처 · 원문
위치와 절 번호로
답한다

등급 질문

계약

계약 · 무엇을
단정 못 하는지로
답한다

반대 질문

반증

반증 · 어떤 관측이면
제가 틀리는지로
답한다

실무 질문

실험

실험 · 무엇을 재면
결정되는지로 답한다

'근거가 뭐냐'는 질문에는 실험 등급으로, '그래서 어쩌라고'는 실험 목록으로 답한다

예상 질문 ① — 판별식과 분류에 대하여

예상 질문

- | | | | |
|----|---|----|--|
| 01 | 판별식이 자의적 아닌가 · 편의와 반대로 간 판정 셋을 보여 드립니다 | 08 | 왜 성능을 안 보나 · 분류와 평가를 같은 관측으로 못 무너뜨립니다 |
| 02 | 조건 하나 빼면 ? · 매번 다른 종류의 논문이 잘못 들어옵니다 | 09 | 제목은 왜 무시하나 · 제목으로는 좌변도 시계도 답할 수 없습니다 |
| 03 | MemGPT 는 왜 빠나 · 쓰기가 턴 안에 있어 (1) 불충족입니다 | 10 | B 군은 버리는 건가 · 아닙니다 . 증거가 되는 자리로 옮깁니다 |
| 04 | RAG 는 왜 경계 아닌가 · 조상 지목이 없습니다 . 개수 문제가 아닙니다 | 11 | 경계 사례가 더 있나 · 규칙상 조건 셋 + 조상 지목이 함께 필요합니다 |
| 05 | SCM 은 왜 E 인가 · 다섯 연산자의 좌변이 전부 그래프입니다 | 12 | 판별식을 누가 정했나 · 이 발표입니다 . 그래서 변형 넷을 계산해 뒀습니다 |
| 06 | corpus 가 좁지 않나 · 29 편 · 2026-08. 일반화하지 않습니다 | 13 | 재현 가능한가 · 다섯 단계 절차가 그대로 적혀 있습니다 |
| 07 | 다른 corpus 면 답이 다른가 · 편수 판정은 바뀌고 척추 논제 판정 | 14 | 새 논문이 나오면 · 같은 절차를 다시 돌리면 됩니다 |

편의와 반대로 간 판정 셋을 보여 드립니다

예상 질문 ② — 회계와 숫자에 대하여

예상 질문

01 5× 를 부정하나 · 아닙니다 . 부정하는 건 축의 등식입니다

02 L* 가 몇 토큰인가 · 절대치는 단정하지 않습니다 . 순서만 씁니다

03 prefix cache 켜면 ? · 임계가 실무에서 사라질 수 있습니다 — 양방향

04 κ_{cost} 가 정말 10 인가 · 벤더 문서 인용 한 줄입니다 . 측정이 없습니다

05 바이트 값이 왜 다른가 · 앵커 구성이 제 선택입니다 . 자릿수만 보십시오

06 3.64 를 왜 하한이라 하나 · 원 논문 § 3.2 가 그렇게 씁니다

07 int4 로 내려도 되나 · 그 실험이 corpus 에 0 편입니다 .
모름

08 N_q 는 얼마로 보나 · 논문의 {1,2,5,10} 을 그대로 씁니다 . 분포는 없습니다

09 왜 GPU 로 안 켜나 · 이 host 에 GPU 가 없습니다 . 그래서 값 주장을 안 합니다

10 회계가 곧 측정 아닌가 · 아닙니다 . 벽시계도 청구액도 아닙니다

11 결정론이면 맞는 건가 · 재현성은 정확성이 아닙니다

12 가정이 유리하지 않나 · 판정 대상에게 유리한 쪽으로 고정했습니다

13 X3 은 원문을 봤나 · 1 차 대상은 노트입니다 . 원문 probe 를 병기했습니다

14 X4 를 LLM 으로 하면 · 부호가 뒤집히면 제가 틀린 것입니다

아닙니다 . 부정하는 건 축의 등식입니다

예상 질문 ③ — 판정과 전망에 대하여

예상 질문

01 그래서 유망한가 · E 는 비용으로 , W 는 판정 불가 , Θ 는 조건부입니다

02 왜 하나로 답 안 하나 · 셋이 푸는 문제 집합이 겹치지 않습니다

03 E 가 이미 배포됐잖나 · 맞습니다 . 문헌이 약한 채로 주류가 될 수 있습니다

04 Θ 는 언제 쓸 만해지나 · 세 실험이 나오면 판정이 바뀝니다

05 W 는 왜 표본이 1 인가 · 그 사실 자체가 판정이고 조건 (1) 에 의존합니다

06 합성하면 되지 않나 · 구조가 가장 강하게 가리키는데 실험이 0 건입니다

07 몇 년 뒤에 답이 나오나 · 예측하지 않습니다 . 조건과 관측만 적습니다

08 그럼 아무 말도 안 하나 · 판정 불가도 판정입니다 . 관측 형태를 함께 답니다

09 왜 순위표가 없나 · 서로를 baseline 으로 돌린 표가 없습니다

10 E 를 쓰면 되나 · 지속성은 얻고 모델은 안 바꿉니다

11 Θ 를 쓰면 되나 · 즉시성을 잃고 웹 계층을 얻습니다

12 W 를 쓰면 되나 · 문맥 비용은 접고 요청을 넘지 못합니다

13 결국 무엇을 재야 하나 · $B_s \cdot L_w \cdot C_{cap} \cdot p$ 네 칸입니다

14 지금 답이 없는 건 왜 · 그 네 칸이 문헌에서 비어 있기 때문입니다

E 는 비용으로 , W 는 판정 불가 , Θ 는 조건부입니다


그래서 우리가 무엇을 하면 되는가 — 실험 여섯

제안



반대로 지금 사지 말아야 할 것

제안



이 다섯은 전부 '측정되지 않은 값을 전제로 하는 결정'이다

이 다섯은 전부 '측정되지 않은 값을 전제로 하는 결정'이다

근거 지도 — 오늘 나온 주장은 어디를 보면 되는가

근거 지도

- | | | | |
|----|---|----|--|
| 01 | 판별식 · 전수 분류 · ch11 § 11.2–11.7, 표 11-1·11-2·11-3 | 08 | 반복 열화 · ch29 § 29.3.5, 실험 X4 result.json |
| 02 | 대상 확정 판정 · ch24 § 24.4, 반증 조건 § 24.5 F1–F6 | 09 | 한계와 반증 총람 · ch30 표 30-1·30-2·30-3 (판정 32 개) |
| 03 | 통일 비용 회계 · ch25 § 25.2–25.4, 실험 X1 result.json | 10 | 논문별 8 절 해부 · ch12–ch23 (논문 한 편당 한 장) |
| 04 | 상태 용량 회계 · ch26 § 26.3–26.4, 실험 X2 result.json | 11 | training 배경 · ch02–ch10 (레짐 · PEFT · distill · RL · 망각 · 용량) |
| 05 | 경로별 판정 · ch27 § 27.3–27.4, 표 27-2·27-3·27-4·27-5 | 12 | 전수 분류표 · back/92-appendix-census.md |
| 06 | 예산 축 감사 · ch28 § 28.2–28.4, 실험 X3 result.json | 13 | 용어 색인 · back/91-glossary.md (정의 소유 장으로 연결) |
| 07 | systems·device · ch29 § 29.3–29.4, 식 (29-1)(29-2)(29-3) | 14 | 참고문헌 · back/90-bibliography.md (vendored 원문 기준) |

ch11 § 11.2–11.7, 표 11-1·11-2·11-3

한 장 요약 — 오늘 가져가실 여섯 문장

요약



이 발표를 쓰는 가장 좋은 방법은 인용이 아니라 반증이다

답는 말

만든 것

도구

계약

요청



서른
장을
지나 원
질문은 다섯 개로...

답이 아니라 답할 수 있는 형태