

언어 모델에는 잠이 필요하다: 자기 수정과 기억 통합의 학습

Language Models Need Sleep: Learning to Self-Modify and Consolidate Memories

Ali Behrouz, Farnoosh Hashemi, Adel Javanmard, Vahab Mirrokni

문서 성격 원문 순서 · 수치 · 한정어를 보존한 한국어 구조 보존형 의역본이다. 본문 뒤의 원문 보존 부록은 원 논문의 equation, table, figure, caption 을 검증 가능하게 남긴다. 인용과 재현에는 반드시 고정 원문을 사용한다.

고정 버전 arXiv:2606.03979v2

배포 상태 internal-only — arXiv license; translated derivative and complete source plate are not cleared for public redistribution

Contents

Sleep (offline consolidation for LLMs) — 한국어 전문 번역본 (무축약)	2
언어 모델에는 잠이 필요하다: 자기 수정과 기억 통합의 학습	2
초록 (Abstract)	2
1. 서론 (Introduction)	2
2. 예비 지식 및 문제 정식화 (Preliminaries and Problem Formulation)	6
3 Sleep 패러다임 (The Sleep Paradigm)	8
4 실험 결과 (Empirical Results)	12
5 결론 (Conclusion)	16
참고문헌 (References)	16
A. 관련 연구 (Related Work)	27
B	31
추가 실험 결과 및 세부사항	31
번역 · 검증 고지	34
원문 구조 · 그림 보존 부록	35

Sleep (offline consolidation for LLMs) — 한국어 전문 번역본 (무축약)

arXiv:2606.03979 「Sleep (offline consolidation for LLMs)」 ((Google Research))
의 전문 무축약한국어 번역입니다. 스타디용이며 공식 번역이 아닙니다. 원문의 모든문
장·수식·표·각주를 빠짐없이 옮기는 것을 목표로 했고, 수식은 PDF 추출 텍스트 기반
이라 일부 기호가 손상될 수 있습니다. 그림은 원저자의 것입니다.

언어 모델에는 잠이 필요하다: 자기 수정과 기억 통합의 학습

Ali Behrouz ^{†, ‡}, Farnoosh Hashemi [‡], Vahab Mirrokni [†]

[†]

[‡]

arXiv:2606.03979v1 [cs.LG] 2026 년 6 월 2 일

초록 (Abstract)

지난 수십 년 동안 기계 학습 알고리즘 설계에서 상당한 진보가 있었다—과제특화형 (task-specific) 얇은 모델에 관한 초기 연구부터 보다 일반적인 심층대규모 언어 모델 (Large Language Models, LLMs) 에 이르기까지. 즉각적인 예측이나 문맥 내 학습 (in-context learning) 을 요구하는 과제에서 유망한 결과를 보였음에도, 기존 모델들은 지속적으로 학습하고 시간적 (temporal) 문맥 내 지식을 자신의 장기 파라미터로 효과적으로 전이 (transfer) 하는 능력이 결여되어 있다. 인간의 학습 과정에서 영감을 받아, 우리는 모델이 지속적으로 학습하고, 취약한 단기 기억을 리플레이 (replay) 를 통해 안정적인 장기 지식으로 증류 (distill) 하며, “꿈꾸기 (Dreaming)” 과정을 통해 재귀적으로 스스로를 개선하도록 하는 “잠 (Sleep)” 패러다임을 소개한다. 더 자세히 말하면, 잠은 두 단계로 구성된다: (1) 기억 통합 (Memory Consolidation): 지식 씨앗화 (Knowledge Seeding) 라 부르는 상향식 증류 (upward distillation) 과정으로, 여기서 더 작은 자기 자신 (smaller-self) 의 기억이 더 큰 네트워크로 증류되어, 지식을 보존하면서도 더 많은 용량 (capacity) 을 제공한다. 개념 증명 (proof of concept) 으로, 우리는 지식 씨앗화를 위한 새로운 일반화된 증류 (Generalized Distillation) 과정 (즉, 온-폴리시 증류 (on-policy distillation) 와 강화학습 (Reinforcement Learning, RL) 기반 모방 학습 (imitation learning) 의 결합) 을 제시한다; (2) 꿈꾸기 (Dreaming): 자기 개선 (self-improvement) 단계로, 모델이 RL 을 사용해 새로운 지식을 예행연습 (rehearse) 하고 기존 능력을 인간의 감독 없이 정제하기 위한 합성 데이터의 커리큘럼 (curriculum) 을 생성한다. 장기 지평 (long-horizon), 지속학습 (continual learning), 지식 통합 (knowledge incorporation), 소수샷 일반화 (few-shot generalization) 과제에 대한 우리의 실험은 잠 단계의 중요성을 뒷받침한다.

1. 서론 (Introduction)

대규모 언어 모델 (LLMs) 의 발전은 기계 학습 연구에서 중요한 이정표들이론다: 즉, 과제 특화형 모델에서 다양한 창발적 (emergent) 능력을 갖춘 보다 범용적인 시스템으로의 패러다임 전환이다 (Brown et al. 2020; Schaeffer et al. 2023). 다양한 과제 집합에서 LLM 들이 보여준 놀라운 능력에도 불구하고 (Nijkamp et al. 2023; Wang et al. 2023; Comanici et al. 2025), 그것들은 초기 배치 (deployment) 이후 대체로 정적 (static) 이다. 즉, 사전 학습 (pre-training) 또는 사후 학습 (post-training) 동안 학습된 과제는 성공적으로 수행하지만, 자신의 즉각적인 문맥 (immediate context) 을 넘어 새로운 능력을 지속적으로 획득할 수는 없다. 이러한 본질적으로 정적인 성질은 결정적인 취약점을 만들어낸다: 모델의 지식과 기술은 점차 낡아지며 (stale), 고정된 “지식 컷오프

(knowledge cutoff)” 날짜를 기준으로 작동하여 그 이후의 새로운 사실, 사건, 진화하는 정보를 알지 못한다 (Cheng et al. 2024).

이러한 한계를 극복하려는 노력은 주로 다음에 집중되어 왔다: (1) 확장된 데이터셋에 대한 재사전학습 (re-pretraining), 이는 효과적이긴 하지만 계산비용이 크고 빈번한 업데이트에는 비실용적이다 (Ibrahim et al. 2024); (2) 값비싼 지속적 파라미터 업데이트나 미세조정 (fine-tuning) 또는 저랭크 적응 (low-rank adaption) 과 같은 다른 경량 대안들을 사용하는 것 (Hu et al. 2022; Akyurek et al. 2024a), 이는 반복적인 업데이트를 거치면서 흔히 파국적 망각 (Catastrophic Forgetting, CF) 을 초래한다 (Kemker et al. 2018; Shi et al. 2024)—파국적 망각은 모델이 새로운 과제를 학습함에 따라 원래과제에 대한 숙련도가 파국적으로 저하되는 잘 알려진 현상이다. 한편으로는 지식 노후화 (knowledge obsolescence), 다른 한편으로는 파국적 망각과 더불어 업데이트의 막대한 비용 혹은 파국적 성질 사이의 이 딜레마는, 결정적이면서도 미해결된 과제를 부각시킨다: 바로 LLM 들이 그생애주기 (lifecyle) 전반에 걸쳐 점진적이고 효율적으로 학습할 수 있게하는 것이다.

최근 몇 년간, 문맥 내 학습 (In-Context Learning, ICL) (Brown et al. 2020) 은 매우 효율적이고 성공적인 형태의 지속 학습으로 주목받아왔다 (Akyurek et al. 2022, 2024b; Dong et al. 2024; Li et al. 2025). 처음에 ICL 은 대규모 데이터로 학습된 LLM 들의 창발적 능력으로 알려졌으며, 이는 그것들이 문맥에 빠르게 적응하여 제로샷 (zero-shot) 또는 소수샷 (few-shot) 과제를 수행할 수 있게 한다 (Brown et al. 2020). 이후, 더 많은 연구들이 ICL 의 역할을 메타 학습 (meta-learning) 과정으로서 밝히고 형식화했다. 이 과정에서 모델은 시퀀스를 따라 내부 계산을 수행하여 문맥 지식을 자신의 출력에 통합하되, 그것을 단기 기억 (short-term memory) 에 유지하거나 압축한다 (Behrouz et al. 2025; Dherin et al. 2025). 지속학습의 한 형태로서 ICL 의 효과성/효율성에도 불구하고,

§ 교신 저자 (Correspondence to): {alibehrouz, mirrokni}@google.com

및 sh2574@cornell.edu.

* 본 연구의 한 버전은 2025 년 9 월부터 OpenReview 에서 공개적으로 이용가능하였다.

그림 1: (전통적 기계 학습 vs. 지속 학습) 전통적 기계 학습에서는 흔히 모델의 수명 (lifespan) 이 테스트 시간 (test time) 과 학습 시간 (training time) 으로 나뉘는 반면, 지속 학습 설정에는 이러한 단계들이 없다. 우리는 지속 학습자 (continual learner) 가 학습에 있어 서로 다른 활성 상태의 단계들을 가질 필요가 있다고 제안하며, 이를 다음과 같이 부른다: (i) 활성 (Active) 또는 깨어 있는 시간 (Wake Time), 그리고 (ii) 잠 시간 (Sleep Time). 잠 시간은 수동적 상태가 아니라, 오히려 내부적으로 데이터를 처리하여 빠르고 불안정한 모듈에서 보다 안정적인 저주파 (느린) 구성요소로 기억을 통합한다.

지속 학습의 한 형태로서 ICL 은 시퀀스 모델의 문맥 창 (context-window) 에 제한된다. 즉, 새로 획득된 어떤 지식이든 세션/문맥의 끝에서 모델로부터 제거된다는 것을 의미한다. 이 관점은 결정적인 질문을 제기한다: 모델은 어떻게 취약한 단기 기억을 보다 안정적인 장기 지식으로 효과적으로 전이할 수 있는가?

하나의 비유로서, 우리는 Behrouz et al. (2025) 에서 제시된 LLM 에 대한 순행성 기억상실증 (anterograde amnesia) 의 예를 사용한다: 인간에게서 정보를 단기 기억으로부터 보다 장기적인 기억으로 전이하는 과정에 손상이 있는 경우를 생각해 보라. 그 예가 순행성 기억상실증—장애 발병 이후에는 새로운 기억을 형성할 수 없지만 기존 기억은 온전히 남아 있는 신경학적 상태이다 (Scoville et al. 1957). 이러한 상태는 사람의 지식을 단기 기억에 담기는 즉각적인 현재와, 장애 발병 이전의 먼 과거로 제한할 수 있으며, 그 결과 즉각적인 현재를 마치 언제나 새로운 것처럼 지속적으로 경험하게 된다. 현재의 트랜스포머 (Transformer) 기반 LLM 들의 기억 처리에서도 유사한 패턴을 발견할 수 있다. LLM 들의 지식은 다음 중 하나로 제한된다: (1) 그것들의 문맥 창에 담기는 즉각적인 문맥 (다시

말해 문맥 내 학습), 또는 (2) 먼 과거, 즉 “사전 학습의 종료” 발병 이전의 것을 저장하는 MLP 및 투영 (projection) 레이어들. 이러한 패턴상의 유사성은 우리에게 다음을 묻도록 동기를 부여한다. 인간 학습 과정에서 기억을 통합하는 결정적 구성요소는 무엇인가?

인간의 뇌는 기억을 통합하는 데 있어 매우 효율적이고, 손실적 (lossy) 이지만 효과적이며, 이는 흔히 신경가소성 (neuroplasticity)—새로운 경험, 기억, 학습에 반응하여 스스로를 변화시키는 뇌의 능력—에 기인한다 (Pascual-Leone et al. 2005; Johnston 2009). 최근 연구들은 장기 기억 형성이 적어도 두개의 구별되면서도 상호 보완적인 통합 과정을 포함한다는 것을 뒷받침한다 (Frey et al. 1997; Goto et al. 2021; Yang et al. 2024): (1) 빠른 “온라인 (online)” 통합 단계는 학습 직후 또는 곧, 심지어 깨어 있는 동안에도 일어난다. 이때 새로운 취약한 기억흔적 (memory traces) 이 안정화되고 단기 기억으로부터 보다 장기적인 저장소로 전이되기 시작한다; (2) “오프라인 (offline)” 통합 (시스템 통합 (systems consolidation) 이라고도 알려짐) 과정은 잠자는 동안 최근 부호화된 (encoded) 패턴들의 리플레이를 반복하고, 기억을 재조직하며, 피질 (cortical) 부위로의 전이를 지원한다 (Foster et al. 2006; Ji et al. 2007; Peyrache et al. 2009).

인간의 온라인 통합 (활성 단계에서) 인간의 온라인 통합은 새로 학습된 기억을 회상 (recall) 동안 재 활성화 (reactivating) 함으로써 그것을 능동적으로, 깨어 있는 상태에서 강화하고 변형하는 것으로, 시간이 지남에 따라 그 기억을 보다 안정적이고 보다 의미론적 (semantic-like) 으로 만든다.

인간의 오프라인 통합 (잠 및 조용한 휴식 단계에서) 인간의 오프라인 통합은 학습 이후 휴식이나 잠자는 동안 일어나며, 이때 새로 부호화된 기억이 안정화되고 복잡한 손실적 증류 (lossy distillation) 과정을 통해 점진적으로 보다 분산된 신피질 (neocortical) 표상으로 변형된다.

순행성 기억상실증의 비유로 돌아가면, 그 증거는 이 상태가 두 단계 모두에 영향을 미칠 수 있음을 시사한다. Behrouz et al. (2025) 은 최근 중첩 학습 (Nested Learning, NL) 패러다임을 제시하고 첫 번째 형태의 기억 통합 (즉, 온라인 통합) 을 겨냥하였다. 특히, NL 기반 Hope 아키텍처 (그림 1 참고) 는 각 구성요소가 서로 다른 주파수 (frequency) 로 업데이트되되 종단간 (end-to-end) 방식으로 이루어지는 연속체 기억 시스템 (continuum memory system) 내에서 기억을 재활성화함으로써, 지식을 빠르고 불안정한 구성요소로부터 보다 안정적인 저주파 모듈로 온라인 방식으로 전이한다. 이중 단간 과정은 지식을 보다 안정적인 구성요소로 직접 전이하여 망각을 지연시킬 수 있지만, 여전히 같은 양의 모델 용량을 사용한다. 이는 주로 모델이 어떠한 추가적인 손실적 압축 없이 같은 추상화 수준 (level of abstraction) 에서 지식을 유지한다는 사실 때문에 발생한다. 더 나아가, 이 형태의 통합은 견고한 지속 학습에는 충분하지 않다: (i) 선택적이고 인출 의존적 (retrieval-dependent) 이다: 그것은 능동적 인출에 의존하므로 반복적으로 회상되는 기억의 부분들만 강화한다; (ii) 문맥에 의존한다: 온라인 통합에 의해 야기되는 업데이트는 오직 모델의 문맥에만 기반하므로, 새로운 지식과 기존 지식에 대한 더 높은 수준의 이해를 놓친다.

본 논문에서 우리는 두 번째 유형의 통합, 즉 잠을 통한 오프라인 통합에 초점을 맞추며, 이는 인간의 잠 단계에서 영감을 받았다:

인간 학습 과정에서 잠의 역할 잠은 수동적 상태가 아니라 인지 기능에 필수적인 역동적이고 고도로 구조화된 뇌 활동 기간이다 (Rasch et al. 2013; Goldstein et al. 2014). 잠자는 동안, 뇌는 학습, 신경 가소성, 자기 개선, 그리고 기억 통합에 근본적인 복잡한 과정들을 조율한다 (Wamsley et al. 2011; Rasch et al. 2013; Goldstein et al. 2014). 인간에게서 이러한 과정들은 주로 두 개의 결정적이고 교대하는 잠 단계에 의해 지배된다: 급속 안구 운동 (Rapid Eye Movement, REM) 수면과 비-REM (Non-REM, NREM) 수면.

비급속 안구 운동 수면 (서파 수면, Slow-Wave Sleep): 이 단계, 특히 서파 수면 (slow-wave sleep) 으로 알려진 그 가장 깊은 국면은 동기화되고 고진폭이며 저주파인 신경 활동을 특징으로 한다. 서파 수면은 학습에 결정적인 두 가지 주요 기능과 관련된다: 첫째는 시냅스 항상성 (synaptic homeostasis) 으로, 이는 깨어 있는 경험으로부터 비롯된 연결성의 순 증가를 상쇄하기 위해 시냅스 강도를 전역적으로 하향 조정하는 과정이며, 그럼으로써 대사적 균형을 유지하고 신경 포화 (neural saturation) 를 방지한다 (Tononi et al. 2006).

두 번째 핵심 기능은 기억 통합 (memory consolidation) 으로, 이는 취약하고 최근의 경험을 안정적이고 장기적인 지식으로 변형하는 것이다 (Squire et al. 1995). 이 과정은 해마 (hippocampus)

와 신피질 (neocortex) 사이의 정교한대화를 통해 조율된다 (Squire et al. 2015). 해마는 특정한 일상적 경험을빠르게 부호화할 수 있는 고충실도 (high-fidelity) 의 임시 저장 시스템역할을 한다. 이와 대조적으로, 신피질은 이러한 경험들로부터 일반화된규칙과 의미론적 지식을 점진적으로 학습하는 데 더 적합한, 방대한 장기저장소이다 (Squire et al. 1995, 2015). 서파 수면 동안, 뇌는 이 구조들사이에서 정보의 복잡한 전이를 촉진하는 야간의 대화를 개시한다. 특히, 이전이는 단순히 원시 데이터 (raw data) 를 리플레이하는 것이 아니다; 오히려깨어 있는 시간 동안 획득한 지식을 재구조화 (re-architects) 하여, 추상들을추출하고 그것들을 응집된 의미론적 네트워크로 통합한다.

급속 안구 운동 수면: 깨어 있는 상태를 닮은 고주파, 저진폭뇌파를 특징으로 하는 REM 수면은 가장 흔히 꿈꾸기와 관련된다. 기능적으로, 이 단계는 새로 형성된 시냅스의 선택적 강화 및 새로운 정보와 기존의정서적·의미론적 네트워크의 통합과 연결된다. 더 나아가, 그것은 적응적 행동을 개선하기 위해 미래의 시나리오를 시뮬레이션하는역할을 한다고 가설된다.

요약하면, 밤새 NREM 과 REM 단계 사이의 주기적 교대는 결정적이다. NREM 수면은 그날의 경험을 통합하고 가지치기 (prune) 하여 보다 효율적인 지식기반을 구축하는 것으로 보인다. 그 뒤에, REM 수면은 이 정제된 기반 위에서작동하여, 새로운 연결을 탐색하고 두드러진 (salient) 신경 경로를 강화하는것으로 보인다.

지속 학습에는 학습 시간이나 테스트 시간이 없다 지속학습자에게는, 학습 시간과 테스트 시간 사이에 명확한 경계나 구분이 없다. 모델은 오직 두 가지 서로 다른 상태만을 경험한다: 입력으로 정보를 받을때, 혹은 고립된 학습 시스템일 때.

지속 학습에서의 활성화 (깨어 있는) 및 잠 단계 활성화 또는 깨어 있는시간에, 지속 학습자는 새로운 입력 데이터를 받고 필요에 따라 그것을처리한다. 그러나 잠 시간에는, 모델이 최소한의 (또는 아무런) 입력 데이터를받으며 기존 지식을 처리하여 기억을 통합하고 스스로를 개선하는 데집중한다.

기여 (Contributions)

인간의 기억 처리에서 영감을 받아, 우리는 지속 학습자에게는 학습 시간이나테스트 시간이 없다고 주장한다. 대신, 모델은 주기적으로 “활성” 혹은 “잠” 이라는 두 단계를 가질 필요가 있다; 활성화 상태에서 모델은 새로운데이터를 받아 처리하고, 잠 단계에서는 초점이 내부 지식과 최근 기억의통합에 맞춰진다. 이를 위해, 우리는 두 개의 통합된 단계로 구성된 LLM 용 “잠” 패러다임의 한 사례를 소개한다:

- i. **기억 통합 (Memory Consolidation):** 파국적 망각 (CF) 을 완화하고더 높은 수준의 추상을 포착하기 위해, 기억 통합 단계에서 모델은 주기적과정을 사용한다. 이 과정에서 모델은 새로운 파라미터를활성화/잠금 해제 (unlock) 하고, 더 높은 주파수 (즉, 더빠르게 업데이트되는) 레이어/모듈로부터 보다 안정적인 (더낮은 주파수) 레이어/모듈 내의 새로 잠금 해제된 파라미터로 지식을 증류한다. 이 과정은 새로운 파라미터에 대해서는 충분한가소성 (plasticity) 을 허용하면서도 오래된 파라미터의 안정성을 보장하여, 오래된 지식을 보존한다.
- ii. **꿈꾸기를 통한 자기 개선 (Self-Improvement via Dreaming):** 앞선잠의 첫 번째 단계가 지식 추상을 장기 기억으로 전이하는 것을 보장하는반면, 이 단계는 재귀적 자기 개선 (recursive self-improvement) 과정을담당한다. 특히, 모델의 현재 상태가 주어지면, 그것은 일련의꿈들 (dreams)(즉, 합성적으로 스스로 생성한 데이터) 을 생성하여, 특히최근에 추가된 지식에 대한 더 많은 숙련도를 획득하는 데 초점을 두고자신의 성능을 개선한다.

기술적 관점에서, 위 각 단계에 대한 우리의 기여는 다음과 같다:

1. **주기적 파라미터 (비) 활성화 (Periodic Parameter (De)Activation):** 각 구성요소가 자신만의 업데이트 주파수를 가질 수있게 하는 중첩 학습 (Nested Learning, NL) 패러다임 (Behrouz et al. 2025) 을 기반으로, 우리는 주기적이고 점진적인 파라미터 (비) 활성화과정을 제안한다. 이 과정에서는, 하나의 블록이 주어지고 각 잠 단계마다, 우리는 더 빠른 블록 (즉, 더 높은 주파

수 블록) 내의 일련의 파라미터를 비활성화하고 그것들을 현재 블록 내에서 새로 활성화된 일련의 파라미터로 대체한다. 이는 이전 파라미터와의 지식 간섭 (interference) 을 피하면서 가소성을 유지할 수 있게 한다.

2. **지식 씨앗화 (상향식 증류) (Knowledge Seeding (Upward Distillation))**: 우리는 지식 씨앗화라 부르는 새로운 형태의 지식 전이를 제시하는데, 여기서 하나 또는 몇 개의 더 작은 모델이 자신의 지식을 더 큰 모델로 증류한다. 이 설계는 더 큰 모델이 자신의 더 큰 용량을 활용하면서도 더 작은 모델들 내의 기존 지식을 보존할 수 있게 한다. 지식 씨앗화 (Knowledge Seeding, KS) 의 형식화에 기반하여, 우리는 자기 지식 씨앗화 (self-Knowledge Seeding, SKS) 를 제시한다. 여기서 모델의 더 작은 버전 (예: 일부 파라미터가 비활성인) 이 모델의 더 큰 버전 (예: 파라미터가 활성화인) 으로 지식을 증류한다. 그런 다음 우리는 SKS 를 기억 통합의 해법으로 사용하는데, 이때 모델은 자신의 지식을 고주파레이어/블록으로부터 저주파 블록으로 증류한다.
3. **모방 학습을 결합한 일반화된 지식 증류 (Generalized Knowledge Distillation, GKD)**: SKS 의 형식화는 일반적이며, 어떤 형태의 목적 함수 (objective) 와 지식 전이 방법 이든 사용될 수 있다. 여기서 우리는 온-폴리시 증류 (on-policy distillation) 와 모방 학습 (imitation learning) 과정을 결합하는 새로운 목적 함수를 제시한다. 특히, 우리의 모방 학습 과정에서, 우리는 교사 (teacher) (즉, (압축된) 특권 정보 (privilege information) 를 가진 모델의 더 작은 버전) 가 합성 데이터를 생성한 다음 시퀀스를 마스킹 (mask) 할 것을 제안한다; 그러면 학생 (student) 은 시퀀스의 연속을 예측하는 것을 목표로 하며, 교사가 생성한 데이터와 자신의 예측 사이의 거리 (distance) 에 기반하여 보상 (reward) 을 받는다.
4. **실험적 평가 (Experimental Evaluation)**: 우리는 일련의 도전적인 다운스트림 (downstream) 과제들에 대해 잠 패러다임의 효과성을 평가한다: (1) 사실적 지식 통합 (Factual Knowledge Incorporation); (2) 소수샷 학습 (Few-shot Learning); (3) 장문맥 이해 (Long-context Understanding); 그리고 (4) 지속 학습 (Continual Learning). 그 결과들은 잠 패러다임의 효과성뿐만 아니라, 지속 학습을 위한 반복적 지식 증류를 통한 파라미터 성장 (growing parameters) 의 중요성을 뒷받침한다.

2. 예비 지식 및 문제 정식화 (Preliminaries and Problem Formulation)

2.1 표기법 (Notation)

우리는 벡터 (각각 행렬) 에 대해 굵은 소문자 (각각 대문자) 를 사용하며, 시간 t 에 해당하는 개체의 상태를 가리키기 위해 아래첨자 t 를 사용한다. 모듈의 파라미터 (각각 하이퍼파라미터) 에 대한 위첨자는 모듈의 업데이트 주파수를 결정하는 데 (각각 서로 다른 인스턴스를 구별하는 데) 사용된다. 논문 전반에 걸쳐, 우리는 $x \in \mathbb{R}^{L \times d_{in}}$ 을 입력으로, K 를 키 (keys), V 를 값 (values), Q 를 시퀀스 모델에서의 쿼리 (query) 행렬로 두며, L 은 시퀀스 길이를 나타낸다. 필요할 때, 우리는 언어 모델 LM_{θ} 를 다음과 같이 파라미터화한다:

$$\theta = \{W_1^{(f_1)}, \dots, W_{k_1}^{(f_1)}\} \cup \{W_1^{(f_2)}, \dots, W_{k_2}^{(f_2)}\} \cup \dots \cup \{W_1^{(f_c)}, \dots, W_{k_c}^{(f_c)}\},$$

여기서 파라미터 집합들은 그것들의 가중치 업데이트 주파수 $f_1 \geq \dots \geq f_c$ 에 기반하여 정렬된다 (정의 1 (Definition 1) 참고).

2.2 연속체 기억 시스템 (Continuum Memory System)

트랜스포머 아키텍처는 두 가지 결정적 구성요소로 이루어진다: (1) 연상 기억 (associative memory) 역할을 하며 출력을 문맥 내의 과거 토큰들에 조건화하는 어텐션 (Attention) 모듈, 이는 또한 문맥 내 학습 능력을 낳는다; 그리고 (2) 학습 단계 이후 고정되며 사전 학습에 걸쳐 획득한 지식을 부호화하는 MLP 또는 순방향 (feedforward) 레이어들. Behrouz et al. (2025) 에서 논의된 바와 같이, 이러한

아키텍처는 두 수준의 기억시스템 (two-level memory systems) 으로 해석될 수 있다. 여기서 어텐션의 업데이트 스패 (update span) 은 문맥 길이이며—즉, 문맥의 끝에서 그에해당하는 파라미터가 업데이트되고 획득한 지식이 망각된다—MLP의 업데이트스패는 존재하지 않는다—즉, 사전 학습 이후 업데이트가 없음을 나타낸다. 이관점에서, 이 두 구성요소는 주파수 스펙트럼의 양극단으로서, 어텐션 (각각 MLP) 은 무한 (각각 0) 의 업데이트 주파수를 가진다.

이 직관에 기반하여, Behrouz et al. (2025) 은 연속체 기억 시스템 (Continuum Memory System, CMS) 을 제시하였다. 여기서 아키텍처는 어텐션과 같은 시퀀스모델에, 각각 자신만의 주파수로 업데이트되는 MLP 레이어들의 체인 (chain) 이 뒤따르는 형태이다. 더 구체적으로, 가장 느린 모듈에서의 한 단계업데이트에 걸리는 시간을 시간의 단위로 간주하며, 따라서 다른구성요소들의 업데이트 속도 (update rate) 는 다음과 같이 정의된다:

정의 1 (갱신 빈도, Update Frequency). W 의 임의의 가중치성분에 대해, 우리는 그 빈도를 f_W 로 표기하며, 단위 시간당 갱신했수로 정의한다.

이 개념을 더 잘 이해하기 위해, 입력이 길이 L 의 시퀀스인 Fast-weight Programs(빠른-가중치 프로그램)(Schmidhuber 1992) 의 간단한 예를 사용한다. 이 경우, 느린-가중치 (slow-weight) 의 각 스텝 (단위 시간) 마다빠른-가중치 (fast-weight) 는 L 번 갱신되며, 결과적으로 갱신 빈도는 L 이 된다.

빈도에 대한 이 정의를 따르면 — 이는 고수준에서 한 모듈의 파라미터가시간에 걸쳐 얼마나 자주 갱신되는지를 나타낸다 — CMS 는 MLP 블록들의사슬 (chain) $MLP^{(f_1)}(\cdot), \dots, MLP^{(f_k)}(\cdot)$ 로형식화되며, 각각은 하나의 청크 (chunk) 와 연관된다. 그 청크 크기는

$$C^{(\ell)} := \frac{\max_{\ell'} C^{(\ell')}}{f_{\ell}}$$

로 주어진다. 이때 입력 $x = \{x_1, \dots, x_T\}$ 가 주어지면 사슬의출력은 다음과 같이 계산된다 (명료함을 위해 정규화는 무시한다):

$$y_t = MLP^{(f_k)}(MLP^{(f_{k-1})}(\dots MLP^{(f_1)}(x_t))),$$

여기서 ℓ 번째 MLP 블록의 파라미터, 즉 $\theta^{(f_{\ell})}$ 는 매 $C^{(\ell)}$ 스텝마다갱신된다: 즉 $\theta_{i+1}^{(f_{\ell})} = \theta_i^{(f_{\ell})} - e_{i,\ell}$ 이며 여기서

$$e_{i,\ell} = \begin{cases} \sum_{t=i-C^{(\ell)}}^i \eta_t^{(\ell)} f(\theta_t^{(f_{\ell})}; x_t) & \text{if } i \equiv 0 \pmod{C^{(\ell)}}, \\ 0 & \text{otherwise.} \end{cases}$$

여기서 $\eta_t^{(\ell)}$ 은 $\theta^{(f_{\ell})}$ 에대응하는 학습률 (learning rate) 이며, $f(\cdot)$ 는 신경망의종단간 (end-to-end) 최적화에서 임의의 옵티마이저 (optimizer) 의 오차성분 (error component) 이다 (예: 경사하강법 (gradient descent) 의 경우 $\nabla \mathcal{L}(\theta_t^{(f_{\ell})}; x_t)$). CMS 의형식화는 매우 광범위하며, 과업에 따라 목적함수 $\mathcal{L}(\cdot)$ 는변경될 수 있다 (Transformer 의 MLP 블록과 동일하게). 이러한 형식화의일반성과, Transformer 설계의 상위집합 (superset) 이라는 점 (즉, 1 개의 MLP 블록은 Transformer 와 동등해진다) 때문에, 본 논문 전체에 걸쳐 우리는 CMS 를 아키텍처의 기본 (default) 구성 요소로 사용한다. 또한, 명료함을 위해그리고 일반성을 잃지 않고, 우리는 $C^{(\ell)}$ 이 $C^{(\ell-1)}$ 로나누어떨어진다고 가정한다. 주목할 점으로, 식 2 는 중요한 해석을 제공한다: 파라미터 $\theta_t^{(f_{\ell})}$ 는 자신의 문맥 (context) 을자신의 파라미터로 압축하는 역할을 하며, 따라서 이들은 자신의 문맥의추상적 지식 (abstract knowledge) 을 대표한다 (더 자세한 내용은 Nested Learning 논문 (Behrouz et al. 2025) 을 참조하라).

요약하면, 이 관점에서 시퀀스 모델 (예: 어텐션 (attention)(Vaswani et al. 2017) 또는 기타 메모리 모듈이나 RNN(Katharopoulos et al. 2020; Behrouz et al. 2024)) 은 모델의 단기 기억 (short-term memory) 역할을하는데, 이는 그들의 고빈도 (high-frequency) 갱신이 오래된 지식을 밀어내어잊혀지게 하고 새로운 기억을 위한 공간을 만들 수 있기 때문이다. 반면에, CMS 블록들은 메모리 모듈들의 스펙트럼 (spectrum) 역할을 하는데, 여기서이른 (earlier) 블록들 (더 높은 빈도)

은 더 단기적인 기억이고, 나중 (later) 블록들 (그리고 궁극적으로 빈도가 0에 가까운 마지막 블록)은 더 장기적인 기억이다. 이 메모리 시스템을 능동적으로 갱신하는 것은 파국적망각 (Catastrophic Forgetting, CF)에 대한 저항성을 강화할 수 있지만, 모든모델의 갱신 주기가 어느 시점에서 일치할 때 CF가 발생할 수 있다 (Behrouz et al. 2025). 따라서, 각 메모리 블록의 갱신 전에, 그 블록의 추상화된지식을 더 안정적인 파라미터로 통합 (consolidate) 하는 메커니즘이 있는 것이매우 중요하다.

2.3 문헌에서의 Sleep(수면) 용어

인간의 수면 과정은 문헌의 많은 연구 설계에 영감을 주어 왔다 (McClelland et al. 1995; Kumaran et al. 2016; Hassabis et al. 2017; Ha et al. 2018b). 특히, “꿈꾸기 (dreaming)”는 문헌의 여러 과거 연구들이 최근경험/입력 데이터를 재현 (replay) 하는 방법을 설계하도록동기를 부여했다 (Lin 1992; Mnih et al. 2015; Ha et al. 2018a,b). 여러연구들은 모델을 장기 시야 (long-horizon) 작업에 대해 더 견고하게 만들 수있는 오프라인 과정을 설계했다 (Gonzalez et al. 2020; Hafner et al. 2020; Tadros et al. 2022). Lin et al. (2025)은 “수면-시간 연산 (sleep-time compute)”의 한 형태로서, 다음 사용자 세션을 위해 과거 문맥을 요약하는오프라인 자기-학습 (self-study) 과정을 제안한다.

우리가 아는 한, 기존 문헌 (수면-영감 (sleep-inspired) 연구들을 포함하여)은훈련 (training)과 테스트 (testing) 단계라는 관습적 구분에 확고히 정박해있다. 심지어 지속 (continual) 또는 온라인 (online) 학습 설정에서도, 모델들은 파라미터 갱신 (훈련)과 성능 평가 (테스트) 사이를 번갈아 오간다. 우리는 평생 적응 (lifelong adaptation)을 위해서는, 정적인훈련/테스트 패러다임이 연속적이고 주기적인 “각성 (wake)”과 “수면 (sleep)” 생애주기 (lifecycle)로 대체되어야 한다고 주장한다. “각성” 단계에서 모델은 변화하는 입력 데이터와 능동적으로 상호작용하며 일시적정보를 빠르게 획득하는 반면, “수면” 단계에서 모델은 자신의 기억을통합하고 기존 지식을 내부적으로 처리한다.

3 Sleep 패러다임 (The Sleep Paradigm)

3.1 지속 학습에서의 학습 단계 (Learning Phases in Continual Learning)

앞서 논의했듯이, 지속 학습자 (continual learner)는 항상데이터/경험으로부터 학습하고 있다. 따라서, 머신러닝 모델의생애주기에 대한 관습적 분할 (즉, 테스트 시간과 훈련 시간)은 지속 학습설정에 직접 적용될 수 없다. 우리는 지속 학습자의 생애주기의 두 가지 핵심단계로서 “능동 또는 각성 (active or wake)” 시간과 “수면 (sleep)” 시간의사용을 제안한다. 특히, 능동 또는 각성 시간에는 지속 학습자가 새로운 입력데이터를 받아 필요에 따라 처리한다. 그러나 수면 시간에는 모델이최소한의 (또는 전혀 없는) 입력 데이터를 받으며 기억을 통합하고자기-개선 (self-improve) 하기 위해 기존 지식을 처리하는 데 집중한다.

그러나, 기억 통합 (memory consolidation) 과정은 수면 단계에만 국한되지않는다. 사실, Nested Learning(NL)(Behrouz et al. 2025)의 논의를 따르면, 기억 통합에는 두 가지 형태가 있다: (1) 온라인 통합 (Online consolidation); 그리고 (2) 오프라인 통합 (Offline consolidation):

능동 (각성) 단계에서 신경망의 온라인 통합 (Online Consolidation in Neural Networks in Active (Wake) Stage) 온라인 통합은 각성 또는 능동단계에서 신경 학습 모듈 (예: 그림 1의 Hope 아키텍처)의 종단간 (end-to-end) 학습 과정을 통해 발생하는데, 여기서 이른 층들 (더 높은 빈도의 더 빠른블록들)이 그들의 지식을 나중 층들 (즉, 더 낮은 빈도의 더 느린 블록들)로전달한다.

수면 단계에서 신경망의 오프라인 통합 (Offline Consolidation in Neural Networks in Sleep Stage) 오프라인 통합 단계에서는, 모델이 수면단계로 진입하여 새로운 데이터의 처리를 멈추지만, 자기-생성 (self-generated) 데이터를 사용하여 최근 기억들을 통합한다.

다음 절에서, 우리는 Sleep 패러다임을 제시하는데, 여기서는 모델의 각성시간 (또는 능동 시간)과는 반대로, 모델이 어떠한 외부 입력 데이터도 받지않고 자기-개선, 과거 기억의 통합, 그리고 지식의 추상화에 자신의 내부연산을 집중시킨다. 특히, 우리는 수면 과정을 두 가지 핵심 단계로 나눈

다: (1) 기억 통합 (Memory consolidation); 그리고 (2) 자기-개선을 위한꿈꾸기 (Dreaming for self-improvement).

그림 2: 기억 통합 (Memory Consolidation) 의 개요. 모델은 용량을강화하기 위해 자신의 파라미터 수를 늘리고 (3.2 절), 그런 다음 지식시딩 (knowledge seeding) 을 사용하여 지식 추상화를 더 높은 빈도의메모리에서 더 낮은 빈도의 메모리로 전달한다 (3.3 절).

3.2 기억 통합: 파라미터 확장 (Memory Consolidation: Parameter Expansion)

앞서 논의했듯이, 기억 통합에서 우리는 단기적이고 취약한 기억을 더방대하고 안정적인 파라미터로 전달하는 것을 목표로 한다. CMS 형식화의중요한 메시지 중 하나는: 기억의 취약성 (fragility) 및/또는안정성 (stability) 은 상대적이라는 것이다. 즉, 각 메모리 블록에 대해, 다른더 높은 빈도의 메모리들은 더 단기적이고 더 취약하다. 따라서, 기억 통합은단순한 2 단계 과정이 아니라, 더 높은 빈도의 메모리에 저장된 지식을 더안정적인 더 낮은 빈도의 파라미터로 반복적으로 전달하는 반복적 (iterative) 연산이다.

더 빠르게 갱신되는 블록 (그 예로 인-컨텍스트 학습 (in-context learning) (Brown et al. 2020) 이 있다) 의 지식을 잃지 않기 위해, 우리는 그파라미터를 갱신하기 전에 기억 통합 단계를 수행할 필요가 있다. 따라서, 체크 길이의 리스트 $\{C^{(1)}, \dots, C^{(k)}\}$ 가 주어지면, 수면과정 및 이에 따른 기억 통합은 모든 $b \in \mathbb{N}$ 에 대해 $\{C^{(1)} \times b, \dots, C^{(k)} \times b\}$ 스텝에서만 발생한다. MLP 블록들의 갱신 빈도에 따라, 우리는 한 메모리 모듈의 기억을 그 다음메모리 블록으로 여러 번 통합해야 할 수도 있다. 예를 들어, 갱신 빈도가 1K 인 메모리 뒤에 갱신 빈도가 10K 인 메모리가 이어지는 경우를 생각해 보자: 이 경우, 더 빠른 메모리는 더 느린 메모리의 갱신 전에 10 번 갱신되며, 이는더 느린 메모리 자신의 갱신 전에 더 빠른 메모리에서 더 느린 메모리로의 10 번의 기억 통합 스텝을 의미한다. 이 더 느린 메모리로의 여러 통합스텝은, 과국적 망각 (CF) 때문에 LLM 의 지속 학습 능력을 잠금 해제하는 데있어 중대한 병목이 될 수 있다. 이 현상은 모델의 제한된 용량 (예: 파라미터수) 의 본질적 원인으로, 새로운 지식을 통합하기 위해 파라미터가덮어써져야 (overridden) 하는 것이다. 이 도전에 대한 인간 두뇌의 해결책의근간은 신경가소성 (neuroplasticity), 즉 경험에 반응하여 자신의 기능을수정하고 새로운 연결을 형성하는 두뇌의 본질적 능력이다. 이에 영감을받아, 우리는 모델이 새로운 연결을 형성하고 이로써 자신의 용량을 늘릴 수있게 하는, 메모리 블록에서의 효율적인 점진적 파라미터 확장 (gradual parameter expansion) 을 제시한다.

일반성을 잃지 않고, 우리는 MLP 블록들 $\{\text{MLP}^{(f_\ell)}(\cdot)\}_{\ell=1}^k$ 이 라우터 (router) $\mathcal{R}^{(f_\ell)}$ 를 갖는 희소 전문가 혼합 (sparse mixture of experts, MoEs) 이라고 가정한다: 즉, 각 $\text{MLP}^{(f_\ell)}(\cdot)$ 는전문가 집합 $\{W^{(f_\ell),1}, \dots, W^{(f_\ell),s_\ell}\}$ 를포함하며, 여기서 $s_\ell \geq 1$ 은 사슬의 ℓ 번째 블록에서 현재전문가의 수이다. $(\ell^* - 1)$ 을 우리가 그 지식을 인덱스 ℓ^* 를갖는 바로 다음의 더 안정적인 메모리 모듈로 통합하고자 하는 메모리 (또는 MLP) 의 인덱스라고 하자. $\text{MLP}^{(f_{\ell^*})}(\cdot)$ 에서 전달된지식과 이전에 저장된 지식의 간섭을 피하기 위해, 우리는 그것의 파라미터집합에 새로운 저랭크 (low-rank) 전문가를 추가한다. 즉, 우리는 $\{A^{(f_{\ell^*}),s_{\ell^*}+1}, B^{(f_{\ell^*}),s_{\ell^*}+1}\}$ 로파라미터화된 저랭크 MLP 를 전문가 집합에 추가하는데, 여기서 $A^{(f_{\ell^*})} \in \mathbb{R}^{d \times d_{\text{low}}}$ 이고 $B^{(f_{\ell^*})} \in \mathbb{R}^{d_{\text{low}} \times d}$ 이다 ($d_{\text{low}} \ll d$). 이 새로운 파라미터들은 $\text{MLP}^{(f_{\ell^*-1})}(\cdot)$ 로부터 새로전달된 지식을 저장하기 위해 할당될 것이다. 이 과정에 의해, 각 수면 시간이후, 층들의 부분집합의 파라미터가 증가한다.

3.3 지식 시딩을 통한 기억 통합 (Memory Consolidation with Knowledge Seeding)

이 단계에서, 우리는 파라미터 $\theta^{(f_{\ell^*-1})}$ 를갖는 $\text{MLP}^{(f_{\ell^*-1})}(\cdot)$ 의 지식을 $\text{MLP}^{(f_{\ell^*})}(\cdot)$ 의 확장된 파라미터 집합으로 전달하는것을 목표로 한다. 우리는 LM_θ 를 파라미터확장 전 언어 모델의 상태로, $\text{LM}_{\theta_{\text{exp}}}$ 를 (i) 파라미터 확장, 그리고 (ii) 식 2 에 기반한 $\theta^{(f_{\ell^*-1})}$ 의갱신 이후 언어 모델의 상태로 둔다. 주목할 점은, 수면 및 이에 따른 기억통합이 $\text{MLP}^{(f_{\ell^*-1})}(\cdot)$ 에 대해 발생하고 있으므로, 과거 스텝 수는 C^{ℓ^*-1} 로 나누어떨어지고 따라서 이 메모리 블록은갱신된다는 것이다. 우리는 기억 통합 과정을, 더 작은 모델 상태 LM_θ 에 저장된 지식을 $\text{LM}_{\theta_{\text{exp}}}$ 의 더 큰 변형으로전달하는 것을 목표로 하는 증류

(distillation) 문제로 모델링한다.

지식 시딩 (Knowledge Seeding). 우리는 지식 시딩 (knowledge seeding) 이라 불리는 새로운 형태의 지식 전달을 제시하는데, 여기서 하나또는 몇몇의 더 작은 모델들이 그들의 지식을 더 큰 모델로 증류한다. 이설계는 더 큰 모델이 더 작은 모델들의 기존 지식을 보존하면서도, 자신의 더 큰 용량의 이점을 취할 수 있게 한다.

상향 증류 (Upward Distillation) (지식 시딩) 교사 (teacher) 로서작은 모델들의 집합 $S_1(\cdot), \dots, S_k(\cdot)$ 가 주어지면, 지식시딩 (KS) 은 이 모델들의 지식을 더 큰 모델 $\mathcal{M}(\cdot)$ 으로전달하는 것을 목표로 한다.

지식 시딩 (KS) 의 형식화에 기반하여, 우리는 자기-지식 시딩 (self-Knowledge Seeding, SKS) 을 제시하는데, 여기서 한 모델의 더 작은 버전 (위에서 논의한대로) 이 그 모델의 더 큰 버전으로 지식을 증류한다. 이 증류 과정에는 두가지 중대한 도전이 있다: (1) 관습적 경우와는 반대로, 학생 (student) 이 더많은 용량과 따라서 교사보다 더 큰 표현력 (expressive power) 을 갖는다. 따라서, 교사가 생성한 데이터셋으로 학생을 훈련시키는 것 (예: Kim et al. (2016)) 은 학생 모델에서 파라미터의 준최적 (sub-optimal) 사용을 초래할수 있다; (2) 모델이 수면 단계에 있으므로 외부정보/데이터셋에 대한 접근이 제한된다. 따라서, Hinton et al. (2015) 과 같은 대부분의 인기 있는 방법들은 적용할 수 없다. 이러한도전들을 극복하기 위해, 우리는 정책 위 (on-policy) 학생-생성 데이터와교사-생성 데이터의 혼합을 허용하는 일반화 지식 증류 (Generalized Knowledge Distillation, GKD)(Agarwal et al. 2024) 를 기반으로 삼아, 모방학습 (imitation learning) 에 기반한 새로운 증류 과정을 제시한다.

앞서 논의했듯이, 기억 통합 단계는 원시 (raw) 데이터를 단순히 재현해서는안 된다; 대신, 능동 (각성) 스텝 동안 획득된 지식의 추상화를 탐색하고추출해야 한다. 이를 위해, 지식 시딩은 두 가지 주요 단계를 갖는다: (1) 증류 과정으로, 여기서 학생은 자기-생성 시퀀스에 대해 교사의로짓 (logits) 으로부터 토큰별 (token-specific) 피드백을 받는다; 그리고 (2) RL 기반 모방 학습 방법으로, 이는 학생이 교사의 샘플링된 출력을기억하도록 강제하여, 증류된 지식을 보존하면서 그들의 샘플링 과정을정렬 (align) 한다.

우리는 교사 모델, 즉 LM_θ 로부터샘플링하여 데이터셋 $\mathcal{D}$ 를 구성하는 것으로 시작한다. 다음으로, GKD(Agarwal et al. 2024) 와 유사하게, 우리는 정책 위 (on-policy) 증류 목적함수를 다음과 같이 정의한다:

$$\mathcal{L}(\theta, \theta_{\text{exp}}) = (1 - \lambda) \mathbb{E}_{(x,y) \sim \mathcal{D}} [\mathcal{F}(LM_\theta \| LM_{\theta_{\text{exp}}})(y|x)] + \lambda \mathbb{E}_{x \sim \mathcal{D}} \mathbb{E}_{y \sim LM_{\theta_{\text{exp}}}(\cdot|x)} [\mathcal{F}(LM_\theta \| LM_{\theta_{\text{exp}}})(y|x)].$$

여기서 $\mathcal{F}(LM_\theta, LM_{\theta_{\text{exp}}})(y|x)$ 는교사 (즉, LM_θ) 와 학생 (즉, $LM_{\theta_{\text{exp}}}$) 의 출력 분포 사이의발산 (divergence) 이며, $\lambda \in [0, 1]$ 은 정책 위 학생-생성 출력의비율을 제어한다. 이 최적화 과정에서, 우리는 학생의 샘플링 분포를 통해역전파 (backpropagate) 하지 않는데, 이는 훈련 안정성 및 속도에도 도움이 될수 있다. 또한, 우리는 학생 모델의 모든 파라미터를 동결 (freeze) 하고확장된 파라미터만 갱신한다. 이는 전달된 지식이 오래된 지식과 간섭하여파국적 망각을 일으키지 않도록 보장한다.

모방하는 법 학습하기 (Learning to Imitate). 위의 증류 과정은학생의 새로운 파라미터가 더 낮은 빈도의 메모리에 인코딩된 지식을저장하도록 보장한다. 그러나, 우리는 지식에 대한 접근을 가짐에도불구하고, 학생 모델이 그것을 사용하는 법을 학습하지 못하여 교사의샘플링과 성능을 약하게 모방한다는 것을 관찰한다. 이를 위해, 우리는 RL 을통합하여 모델이 교사의 샘플링을 모방하는 법을 가르침으로써 위의 증류과정을 더욱 개선한다. 교사가 생성한 데이터 (꿈, dreams) 의 집합 $\mathcal{D}_T = \{d^{(1)}, \dots, d^{(n)}\}$ 가 주어지면, 모방하는 법학습하기 (Learning to Imitate, LTI) 과정은 먼저 각 $d^{(i)}$ 에서접두부 (prefix) 를 무작위로 샘플링한 다음 학생 모델에게 그연속 (continuation) 을 완성하도록 요청한다. 학생 응답 $\hat{d}^{(i)}$ 가주어지면 할당된 보상 (reward) 은 다음과 같이 정의된다:

$$r(\hat{d}^{(i)}; d^{(i)}; LM_{\theta_{\text{exp}}}) = \gamma \times r^{\text{sem}}(\hat{d}^{(i)}; d^{(i)}; LM_{\theta_{\text{exp}}}) + (1 - \gamma) \times r^{\text{abs}}(\hat{d}^{(i)}; d^{(i)}; LM_{\theta_{\text{exp}}}),$$

여기서 $r^{\text{sem}}(\cdot; \cdot; \cdot)$ (각각 $r^{\text{abs}}(\cdot; \cdot; \cdot)$) 는 의미적 유사도 (semantic similarity) (각각 절대 토큰 수준 유사도 (absolute token-level similarity)) 에 기반하여 보상을 할당한다. 의미적 유사도의 경우, 우리

는동결된 보상 모델을 사용하며, $\hat{d}^{(i)}$ 와 $d^{(i)}$ 의 의미가같으면 (각각 그렇지 않으면) 학생에게 1(각각 0) 의 보상을 준다. 반면에, 절대 보상은 두 시퀀스의 레벤슈타인 거리 (Levenshtein distance)($z(\cdot, \cdot)$ 로 표기) 에 기반하여 정의된다: 즉, $r^{\text{abs}}(\hat{d}^{(i)}; d^{(i)}; \text{LM}_{\theta_{\text{exp}}})$ 는다음과 같이 정의된다:

$$r^{\text{abs}}(\cdot) = \begin{cases} 1 - \frac{z(\hat{d}^{(i)}, d^{(i)})}{\max\{|\hat{d}^{(i)}|, |d^{(i)}|\}} & \text{if } z(\hat{d}^{(i)}, d^{(i)}) \leq z_0, \\ 0 & \text{otherwise,} \end{cases}$$

여기서 z_0 은 유사도 임계값 (similarity threshold) 이다. 위의 LTI 과정을 정책 위 (on-policy) 증류에 통합함으로써, 지식 시딩 (KS) 목적함수는다음과 같이 정의된다:

$$\mathcal{L}_{\text{KS}}(\theta, \theta_{\text{exp}}) = \mathbb{E}_{x \sim \mathcal{D}} \left[(1 - \alpha) \mathbb{E}_{y \sim \text{LM}_{\theta_{\text{exp}}}(\cdot|x)} [r(y)] - \alpha \mathbb{E}_{y \sim \text{LM}_{\theta_{\text{exp}}}(\cdot|x)} \mathcal{D}(\text{LM}_{\theta} \parallel \text{LM}_{\theta_{\text{exp}}})(y|x) \right].$$

여기서 $\alpha \in [0, 1]$ 은 LTI 목적함수 대비 증류의 강도를 제어한다. 이 목적함수에 기반하여, 우리는 모델의 새로운 확장된 파라미터를 갱신하고고빈도 메모리의 기억/지식을 저빈도 메모리 블록으로통합한다. 이제 $\text{MLP}^{(f_{\ell^*-1})}(\cdot)$ 의 기억들이 $\text{MLP}^{(f_{\ell^*})}(\cdot)$ 로 통합되었으므로, 우리는이전에 (과거 수면 기간에) $\text{MLP}^{(f_{\ell^*-1})}(\cdot)$ 에추가되었던 모든 저랭크 파라미터를 재설정 (reset) 하여, 그것의 용량을 사용 가능하게 만든다

미래를 위해 유지한다. 이 단계는 인간 뇌에서 일어나는 시냅스가지치기 (synaptic pruning) 와 유사한 절차로 해석할 수 있는데, 여기서 뇌는불필요하고/또는 중복된 연결을 가지치기하여 (Li et al. 2017) 그 효율성과 성능을 향상시킨다.

구현에 관한 주석 (Note on the Implementation). 성장하는 희소모듈 (growing sparse modules) 을 구현하는 것은, 만약 구현에서 텐서의차원 (dimensionality) 을 직접 변경해야 한다면 극도로 어려울 수 있다. 대안적으로, 우리는 처음부터 그 파라미터들을 모델 안에 갖고 있되, 수면단계에서의 최초 활성화 이전까지는 순전파 (forward) 와 역전파 (backward) 과정에서 그것들을 마스킹 (masking) 할 수 있다. 흥미롭게도, 이는 또한 인간뇌에 대한 우리의 이해와도 부합하는데, 뇌는 (크지만) 고정된 용량을 가지고있으며 시간이 지남에 따라 새로운 구성 요소가 추가되지 않는다. 대신, 뇌영역들 사이의 새로운 연결이 우리의 삶을 통해 형성될 수 있으며, 이는새로운 뉴런의 활성화를 잠금 해제 (unlocking) 하고 새로운 과제를 학습하기위한 더 많은 가소성 (plasticity) 을 낳는다 (Kandell et al. 2021).

3.4 꿈꾸기 (Dreaming): 자기 수정 (Self-Modifying) 과정

더 높은 빈도 (higher-frequency) 의 파라미터들을 동결 (freezing) 하고 그지식을 더 낮은 빈도 (lower-frequency) 의 기억으로 증류 (distilling) 하는것을 포함했던 이전 단계는, 기억 공고화 (memory consolidation) 를 담당하는인간의 서파 수면 (slow-wave stage of sleep, NREM) 단계와 유사하게작동한다. 그러나 REM 단계에서는 뇌가 (심지어 깨어 있는 시간에 필적할정도로) 매우 활성화되어 있으며, 꿈꾸기 (dreaming) 를 통해 새롭게 형성된시냅스를 자기 수정하고 강화하는 것을 목표로 한다. 이로부터 영감을 받아, 우리는 시간이 지남에 따라 스스로를 개선하는 데 도움이 될 수 있는 꿈 (합성데이터, synthetic data) 을 생성하는 방법을 학습하는 꿈꾸기 과정을설계하는 것을 목표로 한다.

실제로는, 자기 개선 (self-improvement) 을 위한 어떠한 합성 데이터 생성과정 (예: Pang et al. (2024a), Huang et al. (2025), Zweiger et al. (2025)) 도 이 단계에 통합될 수 있다. 그러나 한 가지 중대한 고려사항은 지속 학습 (continual learning) 설정에서 자기 개선을 반복적으로적용하는 데 따르는 위험으로, 이는 파국적 망각 (catastrophic forgetting) 을야기할 수 있다 (Zweiger et al. 2025). 우리의 평가에서, 우리는 수면을 기억공고화로, 그다음에 꿈꾸기를 자기 수정 과정으로 설계한 우리의 2 단계설계가 어떻게 파국적 망각에 대해 더 강건한지를 보인다. 개념 증명 (proof of concept) 으로서, 우리는 Zweiger et al. (2025) 의 연구인 SEAL 을 기반으로삼는다. 그러나 이를 우리의 수면 패러다임에 통합하는 데에는 세 가지 도전과제가 있다: (1) SEAL 의 내부 루프 (inner-loop) 에서 지도미세조정 (supervised fine-tuning, SFT) 의 비용 때문에, 그것은 적은 수의자기 편

집 (self-edits, 우리 용어로는 꿈) 으로 제한된다. (2) 수면 기간동안의 반복적 자기 개선의 원인으로서의 잠재적 파국적 망각. (3) 샘플링과정은 오직 모델의 기존 지식 공간 (existing knowledge space) 에서만 샘플링하는 반면, 꿈꾸기의 핵심 역할 중 하나는 기억들의 새로운 종합 (novel synthesis) 을 탐색하는 것이다 (Stickgold 2005).

샘플링된 과제 (C, τ) 가 주어졌을 때, 여기서 C 는 과제와 관련된 정보를 담고있는 맥락 (context) 이고 $\tau(\cdot)$ 는 하위 평가 (downstream evaluation) 에서의 성능을 측정하는 척도이며, 우리의 “꿈꾸기” 과정은 C 를 맥락에 두고 $m \geq 1$ 개의 꿈을 생성하는 것으로 시작한다. 샘플링 과정에서, MoE 블록의 각 라우터 (router) 는 추가로 무작위 전문가 (random expert) 를 선택하고, 그리하여 무작위의 무관한 지식 (random irrelevant knowledge) 을 꿈꾸기에 통합함으로써, 모델의 시야에서 숨겨져 있던 근본 패턴을 학습한다. 이 단계에서, 우리는 $\{DREAM^{(i)}\}_{i=1}^m \sim LM_{\theta}(\cdot|C)$ 로 둔다. 다음으로, 우리는 생성된 꿈들 중 일부를 기각 (reject) 하고 모델의 성능 개선에 가장 잠재력이 있는 샘플들만 유지한다. 이를 위해, 우리는 경사 기반 데이터 선택 (gradient-based data selection) 에 관한 문헌 (Pan et al. 2024; Wang et al. 2024a) 에서 영감을 얻는다: 각 꿈 $DREAM^{(i)}$ 에 대해, 우리는 중요도 점수 (importance score) $\omega^{(i)}$ 를 할당하고, 다양성을 유지하기 위한 b 개의 무작위 샘플과 함께 가장 높은 중요도 점수를 가진 Top- k 개의 꿈을 선택한다. 언어 모델링 목적 함수 $L_{SFT}(\cdot)$ 가 주어졌을 때, 우리는 $DREAM^{(i)}$ 의 중요도 점수를 $g_{DR}^{(i)}$ 로 표기하고 이를 목적 함수의 경사 (gradient) 로 정의한다: $g_{DR}^{(i)} = \nabla_{\theta} L_{SFT}(DREAM^{(i)}, \theta)$. 우리는 위 과정에 의해 선택된 모든 꿈의 집합을 D 로 둔다. 각 $DREAM^{(i)} \in D$ 에 대해, 우리는 모델의 격리된 인스턴스 (isolated instance) 를 고려하고 지도 미세조정 (LoRA (Hu et al. 2022) 사용) 을 통해 그 파라미터를 갱신한다: 즉, $\theta'^{(i)} \leftarrow SFT(\theta^{(i)}, DREAM^{(i)})$. 새롭게 미세조정된 모델이 주어졌을 때, SEAL (Zweiger et al. 2025) 을 따라, 우리는 $LM_{\theta^{(i)}}$ 대비 $LM_{\theta'^{(i)}}$ 의 성능 개선에 기반하여 $DREAM^{(i)}$ 의 생성에 보상을 준다:

$$r(DREAM^{(i)}, \tau(\cdot), LM_{\theta^{(i)}}) = 1 \text{ (개선되면)}, 0 \text{ (그렇지 않으면)}. \quad (5)$$

우리는 SEAL 을 따르며 위 과정을 최적화하기 위해 ReST^{EM} 알고리즘 (Singh et al. 2024a) 을 사용한다.

그림 3(Figure 3): 텍스트 분류를 위한 클래스 증분학습 (class-incremental learning) 이 (왼쪽) CLINC 데이터셋 (Larson et al. 2019), (가운데) Banking 데이터셋 (Casanueva et al. 2020), (오른쪽) DBpedia 데이터셋 (Auer et al. 2007) 에서 평가되었다. Hope 아키텍처는 다른 지속 학습 접근법들을 일관되게 능가하며, 가장 높은 정확도를 달성한다.

그림 4(Figure 4): (왼쪽) RULER 의 MK-NIAH (Hsieh et al. 2024), (가운데) LongHealth (Adams et al. 2025), (오른쪽) QASPER (Dasigi et al. 2021) 에 대한 인-컨텍스트 학습 (in-context learning) 성능에 미치는 기억 수준 (memory levels) 의 효과. QASPER 의 경우 값이 낮을수록 더 나은 성능을 나타낸다.

4 실험 결과 (Empirical Results)

우리의 실험적 평가에서, 우리는 수면의 각 단계의 효과와 함께 모든 단계를 결합한 효과도 연구한다. 첫 번째 절에서, 우리는 지속 학습 능력과 장문맥 (long-context) 이해를 향상시키는 것을 목표로 설계된 기억 공고화 (memory consolidation) 에 초점을 맞춘다. 추가적인 실험 결과는 부록 B (Appendix B) 를 참조하라.

4.1 기억 공고화의 효과 (The Effect of Memory Consolidation)

기억 공고화 과정의 주요 목표 중 하나는 장문맥 이해를 강화하면서 지속학습을 향상시키는 것이다. 이 절에서, 우리는 지속 학습 및 장문맥 벤치마크에서 (자기 개선 없이) 기억 공고화 단계만을 평가한다.

클래스 증분 학습 (Class Incremental Learning). 우리는 먼저 CLINC (Larson et al. 2019), Banking (Casanueva et al. 2020), DBpedia (Auer et al. 2007) 의 세 가지 데이터셋에서의 클

래스 증분 학습에 초점을 맞춘다 (세부 사항은 B.1 절 참조). 우리는 백본 (backbone) 으로 Llama-3B 와 Llama3-8B(Dubey et al. 2024) 를 사용한다. Hope 는 온-폴리시 자기증류 (on-policy self-distillation) 를 통해 추상화 (abstraction) 를 개선하는 우리의 기억 공고화 메커니즘으로 증강 (augmented) 된다. Momeni et al. (2025) 를 따라, 우리는 ICL(수면이 없는 동일한 지속 사전 학습 과정), 탄성 가중치 공고화 (Elastic Weight Consolidation, EWC)(Kirkpatrick et al. 2017), 그리고 외부 학습기를 이용한 인-컨텍스트 지속 학습 (In-context Continual Learning with an External Learner, InCA)(Momeni et al. 2025) 과 비교한다. 우리는 또한 명시적 증류 과정 없이 다중 수준 인-컨텍스트 갱신 (multi-level in-context updating) 베이스라인으로서 Hope(Behrouz et al. 2025) 를 포함한다. 그림 3 의 결과는 Hope 가 외부 학습기 (InCA) 및 정규화 (EWC) 접근법을 포함하여 데이터셋 전반에서 가장 우수한 성능을 보임을 나타낸다. ICL 대비, 이득은 프롬프트 수준의 적응 (prompt-level adaptation) 을 공고화를 통해 지속적인 파라미터 기억 (durable parametric memory) 으로 변환하는 데서 온다. Hope 대비, 명시적 자기 증류는 반복적인 인-컨텍스트 갱신만으로 얻는 것보다 더 나은 추상화를 산출한다.

수면의 수 (#수면 단계) 가 인-컨텍스트 학습에 미치는 효과 (The Effect of Levels (#Sleep Phases) on In-context Learning). Hope 의 공고화 스케줄이 인-컨텍스트 학습과 장문맥 이해에 미치는 영향을 더 잘 분리하기 위해, 우리는 장문맥 하에서의 질의응답 (question answering) 과 다중 키 검색 (multi-key retrieval) 을 평가한다. 우리는 LongHealth(Adams et al. 2025), QASPER(Dasigi et al. 2021), MK-NIAH(Hsieh et al. 2024) 데이터셋을 사용한다 (B.1 절 참조). 베이스라인으로는 ICL, DuoAttention(Xiao et al. 2025), Cartridges(Eyuboglu et al. 2025) 를 사용한다. Hope 변형들에 대해서는, (i) 얼마나 많은 공고화 단계가 사용되는지와 (ii) 가장 안정적인 기억의 지속성 (persistence)—가장 낮은 공고화 빈도 (lowest consolidation frequency) 로 조작화됨—을 변경함으로써 수면 스케줄을 다양화한다. 직관적으로, 더 낮은 빈도는 더 지속적이지만 덜 적응적인 장기 기억 (long-term memory) 을 낳는다. 결과는 그림 4 에 보고되어 있다. 모든 과제에 걸쳐, Hope 는 ICL 과 효율적인 DuoAttention 베이스라인을 일관되게 능가하며, 이는 수면 시 (sleep-time) 공고화가 프롬프트 전용 적응 (prompt-only adaptation) 을 넘어 장문맥 행동을 개선함을 보여준다. 우리는 또한 Hope 가 Cartridges(Eyuboglu et al. 2025) 를 능가함을 관찰한다: Cartridges 는 KV 표현을 압축하기 위해 보조 모델 (auxiliary model) 을 사용하여 효율성을 개선하는 반면, Hope 는 대신 수면 동안 온-폴리시 자기증류를 수행하여 새롭게 획득한 정보를 전이 가능한 파라미터 지식 (transferable parametric knowledge) 으로 공고화하고 더 강건한 장문맥 이해를 산출한다. Hope 변형들을 서로 비교하면, 우리는 두 가지 일관된 경향을 발견한다: (1) 공고화 단계의 수를 늘리면 인-컨텍스트 학습과 장문맥 이해가 개선되며, 이는 수면이 더 나은 지식 추상화 및 압축을 가능하게 하여 모델이 더 적은 유효 파라미터 (effective parameters) 로 더 많은 정보를 유지할 수 있게 한다는 관점을 뒷받침한다; 그리고 (2) 가장 낮은 빈도를 높이면 성능이 감소하는데, 이는 가장 지속적인 기억을 더 적응적으로 만드는 것이 유지 (retention) 를 약화시킨다는 것을 시사한다.

표 1(Table 1): 수학적 추론 (mathematical reasoning) 벤치마크에 대한 서로 다른 방법들의 성능. 우리는 Qwen 모델의 다양한 변형을 사용하고 average@16 을 보고한다.

Method	AIME-24	AIME-25	HMMT-25
Qwen3-8B			
Sleep	79.2	69.0	46.1
- Imitation Learning	76.8	67.9	45.0
- Semantic Reward	78.9	69.2	44.5
- w/o Expansion	78.2	67.9	44.9
OPSD	76.6	67.4	45.1
+ Expansion	77.9	68.2	45.9

그림 5(Figure 5): 새로운 언어의 지속 번역 (Continual Translation of a Novel Language, CTNL) 과제. 빨간 점은 단일 언어로 훈련할 때의 성능을 나타내며, 파란 점은 지속 학습 하에서의 성능을 나타낸다.

그림 6(Figure 6): BABILong 벤치마크에 대한 결과. 빨간 점은 미세조정된 모델에 해당하고, 파란

점은 대규모 모델의 제로샷 (zero-shot) 평가에 해당한다.

인-컨텍스트로 새로운 언어 학습하기 (Learning a New Language In-Context). LLM 은 종종 지속 설정 (continual settings) 에서 실패하는데, 여기서 모델은 이전에 획득한 지식을 덮어쓰지 않으면서 새로운 기술을 순차적으로 습득할 것으로 기대된다. 이 도전 과제를 연구하기 위해, 우리는 Behrouz et al. (2025) 에 의해 도입된 과제를 따르는데, 이는 사전학습 동안 보지 못한 언어들에 대한 두 개의 번역 데이터셋인 MTOB(Tanzer et al. 2024) 와 Manchu(Pei et al. 2025) 데이터셋을 결합한다. 즉, 모델은 이전에 보지 못한 두 언어에 인-컨텍스트로 노출되고 구문을 영어로 번역해야한다. 우리는 두 가지 설정을 고려한다: 각 언어를 독립적으로 학습하고 평가하는 것, 그리고 각 언어에 대한 번역 성능을 평가하기 전에 두 언어를 순차적으로 학습하는 것이다. 우리는 표준 ICL 을, 수면 시 공고화 단계의 수가 다른 Hope 변형들 (Hope-1, Hope-2, Hope-3 로 표기) 과 비교한다. 결과는 그림 5 에 나타나 있으며, 각 점은 Manchu → English(x 축) 와 Kalamang → English(y 축) 에 대한 ChRF 점수를 보고한다. 단일 언어 설정에서, 모든 Hope 변형은 ICL 과 같거나 그것을 초과하며, 이는 공고화가 인-컨텍스트적응을 방해하지 않음을 나타낸다. 지속 학습 설정 하에서, ICL 은 급격한 성능 하락을 보이며 대체로 사전학습된 행동으로 되돌아가는 반면, Hope 는 그이들의 상당 부분을 유지한다. 성능은 추가적인 공고화 단계에 따라 단조적으로 (monotonically) 개선되며, Hope-3 은 순차적 노출에도 불구하고 단일 언어 성능을 거의 회복한다. 이러한 결과는 지속 학습에서 수면 시 공고화의 역할을 강조한다. ICL 의 프롬프트 수준 갱신과 달리, Sleep 은 유용한 추상화를 더 오래 지속되는 파라미터 기억으로 증류하는 명시적 자기개선 단계를 도입하여, 파국적 망각 없이 효과적인 순차 학습을 가능하게한다. 또 다른 베이스라인으로, 우리는 또한 Cartridges(Eyuboglu et al. 2025) 와 언어들에 대한 지도 미세조정 (Supervised Fine-Tuning, SFT) 을 평가했다. 놀랍게도, 두 방법 모두 적어도 하나의 언어에서 파국적 망각을 겪었으며, 적어도 하나의 과제에서 ICL 보다도 약한 성능을 보였다 (그림 5 에서 플롯 바깥에 위치함).

BABILong. 우리는 BABILong 벤치마크 (Kuratov et al. 2024) 에서 Hope(Sleep) 를 평가하며, 다음과 비교한다: (1) 대규모 모델 (GPT-4 및 GPT-4o-mini(Achiam et al. 2023)); (2) RAG 를 갖춘 중간 규모 Llama-8B 모델 (Dubey et al. 2024); 그리고 (3) RMT(Bulatov et al. 2022), ARMT(Rodkin et al. 2024), Titans(Behrouz et al. 2024) 를 포함한 최첨단 소규모 장문맥 모델. 결과에 대한 상세한 논의는 B.2 절에서 찾을 수 있다. 요약하면, Hope 는 1000 만 (10M) 토큰으로의 확장에서 거의 완벽한 점수를 달성한다.

추론을 위한 기억 공고화 (Memory Consolidation for Reasoning). 기억 공고화 단계의 또 다른 중요한 함의는 모델의 추론 능력을 개선하는 것이다. 이 절에서, 우리는 수학적 추론에 대한 그 효과를 평가하고 이를 기본 모델 (base model), SFT, GRPO(Shao et al. 2024) 의 일반적인 베이스라인과 비교한다. 결과는 표 2(Table 2) 에 보고되어 있다. 기억공고화를 위한 우리의 알고리즘은 기본 모델의 추론 능력을 개선하는 데 있어 SFT 와 GRPO 보다 더 나은 성능을 보인다.

표 3(Table 3): 구절 설정 (Passage Settings) 전반에 걸친 지식통합 (Knowledge Incorporation) 성능.

표 2(Table 2): 수학적 추론 벤치마크에 대한 서로 다른 방법들의 성능. 우리는 Qwen 모델의 다양한 변형을 사용하고 average@16 을 보고한다.

Method	AIME-24	AIME-25	HMMT-25
Qwen3-1.7B			
Base (Instruct)	49.8	34.5	
SFT	47.3	36.1	
GRPO	51.0	38.6	
OPSD	51.6	40.0	
Sleep	53.2		

40.2

25.7 22.9 26.1 28.1 29.3

68.1 66.4 68.1 67.4 69.0

42.4 43.7 44.9 45.1 46.1

단일 지문 (Single Passage) (n = 1)

계속된 사전학습 (Continued Pretraining) (n = 200)

기반 모델 (Base model) Dreaming 없이 미세조정된 모델 (Fine-tuned Model with No Dreaming)
SEAL Sleep (Transformer) Sleep (Transformer + 4 단계)

31.9 33.4 46.7 48.1 48.9

31.9 32.0 43.2 44.3 46.2

기울기 기반 선택 제거 (removing gradient-based selection) 무작위 전문가제거 (removing random expert) Dreaming 제거 (removing Dreaming)

47.1 48.0 35.7

45.2 44.7 36.2

방법 (Method)

표 4: 소수샷 추상 추론 (Few-shot Abstract Reasoning)

Qwen3-8B Base (Instruct) SFT GRPO OPSD Sleep

73.8 75.5 76.4 76.6 79.2

방법 (Method)

성공률 (Success Rate, %)

ICL TTT SEAL Sleep

0 10 72.5 80

지식 통합 (Knowledge Incorporation). 다음으로, 우리는 자기개선 (self-improvement) 까지 가능하게 하는 Sleep 의 전체 설계에 초점을 맞춘다. 이 과제에서 우리는 모델이 통합된 사실들에 대한 질문에 답할 수 있기를 기대한다. 공정한 비교를 위해, 우리는 모델과 파라미터의 선택을 포함하여 Zweiger et al.(2025) 의 실험 설정을 따른다. 우리는 SQuAD 데이터셋 (Rajpurkar et al. 2016) 의 새로운 사실 정보를 통합하는 것에 대해 우리 모델을 평가한다. 기준선 (baseline) 으로는 (i) 어떠한 개선도 없거나 지문에 접근할 수 없는 변형인 기반 모델 (base model); (ii) dreaming 이 없는 미세 조정 모델 (fine-tuned model with no dreaming); (iii) RL 과 자기적응 (self-adaption) 을 갖춘 SEAL 모델; (iv) 2 단계 메모리 시스템을 갖춘 우리의 Transformer 기반 아키텍처; 그리고 (v) 4 단계 메모리 시스템을 갖춘 것을 사용한다.

표 3 은 단일 지문 (single-passage, n = 1) 과 계속된 사전학습 (continued pretraining, CPT, n = 200) 설정 모두에 대한 평균 무맥락 (no-context) SQuAD 정확도를 요약한다. 우리의 sleep 과정은 다른 설정들 및 SEAL 과 같은 최첨단 (state-of-the-art) 방법들 가운데 최고의 결과를 달성한다. 우리는 이 결과를 다음에 기인한다고 본다: (1) 모델이 자신의 지식을 더 효과적으로 저장하도록 하는 메모리 통합 (memory consolidation) 단계들; (2) 3.4 절에서 논의한, SEAL 위에 얹은 우리의 개선들. CPT 체제 (regime) 에서, 모델은 단일 계속된 사전학습 실행 동안 n = 200 개의 지문에 노출되며, 연관된 전체 974 개 질문 집합에 대해 평가된다. 각 지문에 대해, 우리는 5 개의 꿈 (dream) 을 샘플링하여 이를 하나의 집계된 합성 데이터셋으로 결합해 학습에 사용한다. Sleep 과정이 최고의 성능을 달성한다.

소수샷 학습 (Few-Shot Learning). 우리는 선행 연구 (Akyurek et al. 2024a; Zweiger et al. 2025) 의 소수샷 ARC 실험 프로토콜을 따르며, 이를 우리의 Sleep 패러다임에 맞게 조정한다. 백본 (backbone) 으로는 Llama-3.2-1B 를 사용한다. 일반적인 관행을 따라, 우리는 표준 구성에서 여전히 풀 수 없는 과제들을 피하기 위해 데이터의 부분 집합을 필터링하여, 학습용 11 개 과제와 평가용 8 개의 홀드아웃 (held-out) 과제를 산출한다. 자세한 내용은 B.3 절을 참조하라. 이 설정에서 (표 4 참조),

Sleep 은 80%의 성공률을 달성하여 다른 방법들보다 높다.

4.2 설계 선택에 대한 절제 실험 (Ablations on the Design Choices)

우리는 수학적 추론 (mathematical reasoning) 에서 메모리 통합 과정에 대한 설계 선택들을 절제 (ablate) 한다. 결과는 그림 1 에 보고되어 있다. 모든 구성요소가 우리 방법의 성능에 긍정적으로 기여한다. 또한, 우리는 표 3 에서 자기개선 (self-improvement) 에 대한 설계 선택들을 추가로 절제 한다.

5 결론 (Conclusion)

본 연구에서, 우리는 대규모 언어 모델 (Large Language Models) 을 위한 Sleep 패러다임을 소개하였으며, 이는 다음으로 구성된다: (i) 지식 시딩 (knowledge seeding), 이는 단기적인 문맥 내 (in-context) 지식을 더 낮은 빈도의 (lower-frequency) 장기 (long-term) 파라미터로 이전하는 상향증류 (upward distillation) 이며, (ii) dreaming, 이는 간섭 (interference) 을 제어하면서 능력을 향상시키는 자기생성 (self-generated) 학습이다. 우리의 실험 결과에서, 장문맥 이해 (long-context understanding), 지식통합 (knowledge incorporation), 소수샷 추론 (few-shot reasoning), 그리고 지속 학습 (continual learning) 에 걸쳐 Sleep 은 일관된 향상을 낳는다.

참고문헌 (References)

- [1] William Beecher Scoville and Brenda Milner. “Loss of recent memory after bilateral hippocampal lesions” . In: Journal of neurology, neurosurgery, and psychiatry 20.1 (1957), p. 11.
- [2] Jurgen Schmidhuber. Evolutionary Principles in Self-Referential Learning. 1987. url: <https://people.idsia.ch/~juergen/diploma1987ocr.pdf>.
- [3] Long-Ji Lin. “Self-improving reactive agents based on reinforcement learning, planning and teaching” . In: Machine Learning 8.3 – 4 (1992), pp. 293 – 321.
- [4] Juergen Schmidhuber. “Learning to control fast-weight memories: An alternative to recurrent nets. Accepted for publication in” . In: Neural Computation (1992).
- [5] James L. McClelland, Bruce L. McNaughton, and Randall C. O’ Reilly. “Why there are complementary learning systems in the hippocampus and neocortex: insights from the successes and failures of connectionist models of learning and memory” . In: Psychological Review 102.3 (1995), pp. 419 – 457.
- [6] Larry R Squire and Pablo Alvarez. “Retrograde amnesia and memory consolidation: a neurobiological perspective” . In: Current opinion in neurobiology 5.2 (1995), pp. 169 – 177.
- [7] Uwe Frey and Richard GM Morris. “Synaptic tagging and long-term potentiation” . In: Nature 385.6616 (1997), pp. 533 – 536.
- [8] Alvaro Pascual-Leone, Amir Amedi, Felipe Fregni, and Lotfi B Merabet. “The plastic human brain cortex” . In: Annu. Rev. Neurosci. 28.1 (2005), pp. 377 – 401.
- [9] Robert Stickgold. “Sleep-dependent memory consolidation” . In: Nature 437.7063 (2005), pp. 1272 – 1278.
- [10] David J Foster and Matthew A Wilson. “Reverse replay of behavioural sequences in hippocampal place cells during the awake state” . In: Nature 440.7084 (2006), pp. 680 –

683.

[11] Giulio Tononi and Chiara Cirelli. “Sleep function and synaptic homeostasis” . In: Sleep medicine reviews 10.1 (2006), pp. 49 – 62.

[12] Soren Auer, Christian Bizer, Georgi Kobilarov, Jens Lehmann, Richard Cyganiak, and Zachary Ives. “Dbpedia: A nucleus for a web of open data” . In: international semantic web conference. Springer. 2007, pp. 722 – 735.

[13] Daoyun Ji and Matthew A Wilson. “Coordinated memory replay in the visual cortex and hippocampus during sleep” . In: Nature neuroscience 10.1 (2007), pp. 100 – 107.

[14] Michael V Johnston. “Plasticity in the developing brain: implications for rehabilitation” . In: Developmental disabilities research reviews 15.2 (2009), pp. 94 – 101.

[15] Adrien Peyrache, Mehdi Khamassi, Karim Benchenane, Sidney I Wiener, and Francesco P Battaglia. “Replay of rule-learning related neural patterns in the prefrontal cortex during sleep” . In: Nature neuroscience 12.7 (2009), pp. 919 – 926.

[16] Erin J Wamsley and Robert Stickgold. “Memory, sleep and dreaming: experiencing consolidation” . In: Sleep medicine clinics 6.1 (2011), p. 97.

[17] Bjorn Rasch and Jan Born. “About sleep’ s role in memory” . In: Physiological reviews (2013).

[18] Andrea N Goldstein and Matthew P Walker. “The role of sleep in emotional brain function” . In: Annual review of clinical psychology 10.1 (2014), pp. 679 – 708.

[19] Geoffrey Hinton, Oriol Vinyals, and Jeff Dean. “Distilling the knowledge in a neural network” . In: arXiv preprint arXiv:1503.02531 (2015).

[20] Volodymyr Mnih, Koray Kavukcuoglu, David Silver, Andrei A. Rusu, Joel Veness, Marc G. Bellemare, Alex Graves, Martin Riedmiller, Andreas K. Fidjeland, Georg Ostrovski, et al. “Human-level control through deep reinforcement learning” . In: Nature 518.7540 (2015), pp. 529 – 533.

[21] Larry R Squire, Lisa Genzel, John T Wixted, and Richard G Morris. “Memory consolidation” . In: Cold Spring Harbor perspectives in biology 7.8 (2015), a021766.

[22] Yoon Kim and Alexander M Rush. “Sequence-level knowledge distillation” . In: Proceedings of the 2016 conference on empirical methods in natural language processing. 2016, pp. 1317 – 1327.

[23] Dharshan Kumaran, Demis Hassabis, and James L. McClelland. “What learning systems do intelligent agents need? Complementary learning systems theory updated” . In: Trends in Cognitive Sciences 20.7 (2016), pp. 512 – 534.

[24] Pranav Rajpurkar, Jian Zhang, Konstantin Lopyrev, and Percy Liang. “SQuAD: 100,000+ Questions for Machine Comprehension of Text” . In: Proceedings of the 2016 Conference on Empirical Methods in Natural Language Processing. Ed. by Jian Su, Kevin Duh, and Xavier Carreras. Association for Computational Linguistics, 2016. url: <https://aclanthology.org/D16-1264/>.

[25] Chelsea Finn, Pieter Abbeel, and Sergey Levine. “Model-Agnostic Meta-Learning for Fast Adaptation of Deep Networks” . In: Proceedings of the 34th International Conference on Machine Learning. Ed. by Doina Precup and Yee Whye Teh. Proceedings of Machine Learning Research. PMLR, 2017. url: <https://proceedings.mlr.press/v70/finn17a.html>.

[26] Demis Hassabis, Dharshan Kumaran, Christopher Summerfield, and Matthew Botvinick. “Neuroscience-inspired artificial intelligence” . In: Neuron 95.2 (2017), pp. 245 – 258.

[27] James Kirkpatrick, Razvan Pascanu, Neil Rabinowitz, Joel Veness, Guillaume Desjardins, Andrei A Rusu, Kieran Milan, John Quan, Tiago Ramalho, Agnieszka Grabska-Barwinska, et al. “Overcoming catastrophic forgetting in neural networks” . In: Proceedings of the national academy of sciences 114.13 (2017), pp. 3521 – 3526.

[28] Wei Li, Lei Ma, Guang Yang, and Wen-Biao Gan. “REM sleep selectively prunes and maintains new synapses in development and learning” . In: Nature neuroscience 20.3 (2017), pp. 427 – 437.

[29] Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N Gomez, Lukasz Kaiser,

(참고문헌 목록 계속 — 서지 항목은 저자명 · 논문제목 · 게재지 정보이므로 원문 표기를 그대로 보존한다.)

…그리고 Illia Polosukhin. “Attention is All you Need” . In: Advances in Neural Information Processing Systems. Ed. by I. Guyon, U. Von Luxburg, S. Bengio, H. Wallach, R. Fergus, S. Vishwanathan, and R. Garnett. Vol. 30. Curran Associates, Inc., 2017. url: https://proceedings.neurips.cc/paper_files/paper/2017/file/3f5ee243547dee91fbd053c1c4a845aa-Paper.pdf.

[30] David Ha and Jurgen Schmidhuber. “Recurrent world models facilitate policy evolution” . In: Advances in Neural Information Processing Systems (NeurIPS). Vol. 31. 2018, pp. 2451 – 2463.

[31] David Ha and Jurgen Schmidhuber. “World models” . In: arXiv preprint arXiv:1803.10122 2.3 (2018), p. 440.

[32] Ronald Kemker, Marc McClure, Angelina Abitino, Tyler Hayes, and Christopher Kanan. “Measuring catastrophic forgetting in neural networks” . In: Proceedings of the AAAI conference on artificial intelligence. Vol. 32. 1. 2018.

[33] Stefan Larson, Anish Mahendran, Joseph J Peper, Christopher Clarke, Andrew Lee, Parker Hill, Jonathan K Kummerfeld, Kevin Leach, Michael A Laurenzano, Lingjia Tang, et al. “An Evaluation Dataset for Intent Classification and Out-of-Scope Prediction” . In: Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing (EMNLP-IJCNLP). 2019, pp. 1311 – 1316.

[34] Noam Shazeer. “Fast transformer decoding: One write-head is all you need” . In: arXiv preprint arXiv:1911.02150 (2019).

[35] Tom Brown, Benjamin Mann, Nick Ryder, Melanie Subbiah, Jared D Kaplan, Prafulla Dhariwal, Arvind Neelakantan, Pranav Shyam, Girish Sastry, Amanda Askell, et al. “Language models are few-shot learners” . In: Advances in neural information processing systems 33 (2020), pp. 1877 – 1901.

[36] Inigo Casanueva, Tadas Temcinas, Daniela Gerz, Matthew Henderson, and Ivan Vulic. “Efficient Intent Detection with Dual Sentence Encoders” . In: ACL 2020 (2020), p. 38.

[37] Oscar C. Gonzalez, Yury Sokolov, Giri P. Krishnan, Jean Erik Delanois, and Maxim Bazhenov. “Can sleep protect memories from catastrophic forgetting?” In: eLife 9 (2020), e51005.

[38] Danijar Hafner, Timothy Lillicrap, Jimmy Ba, and Mohammad Norouzi. “Dream to control: Learning behaviors by latent imagination” . In: International Conference on Learning Representations (ICLR). 2020.

[39] Angelos Katharopoulos, Apoorv Vyas, Nikolaos Pappas, and Francois Fleuret. “Transformers are rnns: Fast autoregressive transformers with linear attention” . In: Interna-

tional conference on machine learning. PMLR. 2020, pp. 5156 – 5165.

[40] Pradeep Dasigi, Kyle Lo, Iz Beltagy, Arman Cohan, Noah A Smith, and Matt Gardner. “A dataset of information-seeking questions and answers anchored in research papers” . In: arXiv preprint arXiv:2105.03011 (2021).

[41] Akihiro Goto, Ayaka Bota, Ken Miya, Jingbo Wang, Suzune Tsukamoto, Xinzhi Jiang, Daichi Hirai, Masanori Murayama, Tomoki Matsuda, Thomas J. McHugh, Takeharu Nagai, and Yasunori Hayashi. “Stepwise synaptic plasticity events drive the early phase of memory consolidation” . In: Science 374.6569 (2021), pp. 857 – 863. doi: 10.1126/science.abj9195. eprint: <https://www.science.org/doi/pdf/10.1126/science.abj9195>. url: <https://www.science.org/doi/abs/10.1126/science.abj9195>.

[42] Eric R Kandell, John D Koester, Sarah H Mack, and Steven Siegelbaum. Principles of neural science. McGraw-Hill, 2021.

[43] Brian Lester, Rami Al-Rfou, and Noah Constant. “The power of scale for parameter-efficient prompt tuning” . In: arXiv preprint arXiv:2104.08691 (2021).

[44] Xiang Lisa Li and Percy Liang. “Prefix-Tuning: Optimizing Continuous Prompts for Generation” . In: Proceedings of the 59th Annual Meeting of the Association for Computational Linguistics and the 11th International Joint Conference on Natural Language Processing (Volume 1: Long Papers). Ed. by Chengqing Zong, Fei Xia, Wenjie Li, and Roberto Navigli. Online: Association for Computational Linguistics, Aug. 2021, pp. 4582 – 4597. doi: 10.18653/v1/2021.acl-long.353. url: <https://aclanthology.org/2021.acl-long.353/>.

[45] Ekin Akyurek, Dale Schuurmans, Jacob Andreas, Tengyu Ma, and Denny Zhou. “What learning algorithm is in-context learning? investigations with linear models” . In: arXiv preprint arXiv:2211.15661 (2022).

[46] Aydar Bulatov, Yury Kuratov, and Mikhail Burtsev. “Recurrent memory transformer” . In: Advances in Neural Information Processing Systems 35 (2022), pp. 11079 – 11091.

[47] Edward J Hu, yelong shen, Phillip Wallis, Zeyuan Allen-Zhu, Yuanzhi Li, Shean Wang, Lu Wang, and Weizhu Chen. “LoRA: Low-Rank Adaptation of Large Language Models” . In: International Conference on Learning Representations. 2022. url: <https://openreview.net/forum?id=nZeVKeeFYf9>.

[48] Kazuki Irie, Imanol Schlag, Robert Csordas, and Jurgen Schmidhuber. “A modern self-referential weight matrix that learns to modify itself” . In: International Conference on Machine Learning. PMLR. 2022. url: <https://proceedings.mlr.press/v162/irie22b.html>.

[49] Timothy Tadros, Giri P. Krishnan, Ramyaa Ramyaa, and Maxim Bazhenov. “Sleep-like unsupervised replay reduces catastrophic forgetting in artificial neural networks” . In: Nature Communications 13.1 (2022), p. 7742.

[50] Eric Zelikman, Yuhuai Wu, Jesse Mu, and Noah Goodman. “STaR: Bootstrapping Reasoning With Reasoning” . In: Advances in Neural Information Processing Systems. Ed. by S. Koyejo, S. Mohamed, A. Agarwal, D. Belgrave, K. Cho, and A. Oh. Curran Associates, Inc., 2022. url: https://proceedings.neurips.cc/paper_files/paper/2022/file/639a9a172c044fbb64175b5fad42e9a5-Paper-Conference.pdf.

[51] Josh Achiam, Steven Adler, Sandhini Agarwal, Lama Ahmad, Ilge Akkaya, Florencia Leoni Aleman, Diogo Almeida, Janko Altschmidt, Sam Altman, Shyamal Anadkat, et al. “Gpt-4 technical report” . In: arXiv preprint arXiv:2303.08774 (2023).

[52] Joshua Ainslie, James Lee-Thorp, Michiel De Jong, Yury Zemlyanskiy, Federico Lebron, and Sumit Sanghai. “Gqa: Training generalized multi-query transformer models

from multi-head checkpoints” . In: arXiv preprint arXiv:2305.13245 (2023).

[53] Alexis Chevalier, Alexander Wettig, Anirudh Ajith, and Danqi Chen. “Adapting language models to compress contexts” . In: arXiv preprint arXiv:2305.14788 (2023).

[54] Tao Ge, Jing Hu, Lei Wang, Xun Wang, Si-Qing Chen, and Furu Wei. “In-context autoencoder for context compression in a large language model” . In: arXiv preprint arXiv:2307.06945 (2023).

[55] Yunhao Gou, Zhili Liu, Kai Chen, Lanqing Hong, Hang Xu, Aoxue Li, Dit-Yan Yeung, James T Kwok, and Yu Zhang. “Mixture of cluster-conditional lora experts for vision-language instruction tuning” . In: arXiv preprint arXiv:2312.12379 (2023).

[56] Albert Gu and Tri Dao. “Mamba: Linear-time sequence modeling with selective state spaces” . In: arXiv preprint arXiv:2312.00752 (2023).

[57] Chengsong Huang, Qian Liu, Bill Yuchen Lin, Tianyu Pang, Chao Du, and Min Lin. “Lorahub: Efficient cross-task generalization via dynamic lora composition” . In: arXiv preprint arXiv:2307.13269 (2023).

[58] Huiqiang Jiang, Qianhui Wu, Chin-Yew Lin, Yuqing Yang, and Lili Qiu. “Llmlingua: Compressing prompts for accelerated inference of large language models” . In: arXiv preprint arXiv:2310.05736 (2023).

[59] Yucheng Li. “Unlocking context constraints of llms: Enhancing context efficiency of llms with self-information-based content filtering” . In: arXiv preprint arXiv:2304.12102 (2023).

[60] Erik Nijkamp, Bo Pang, Hiroaki Hayashi, Lifu Tu, Huan Wang, Yingbo Zhou, Silvio Savarese, and Caiming Xiong. “CodeGen: An Open Large Language Model for Code with Multi-Turn Program Synthesis” . In: The Eleventh International Conference on Learning Representations. 2023. url: https://openreview.net/forum?id=iaYcJKpY2B_.

[61] Charles Packer, Sarah Wooders, Kevin Lin, Vivian Fang, Shishir G Patil, Ion Stoica, and Joseph E Gonzalez. “Memgpt: Towards llms as operating systems” . In: arXiv preprint arXiv:2310.08560 (2023).

[62] Rylan Schaeffer, Brando Miranda, and Sanmi Koyejo. “Are emergent abilities of large language models a mirage?” In: Advances in neural information processing systems 36 (2023), pp. 55565 – 55581.

[63] Wenhai Wang, Zhe Chen, Xiaokang Chen, Jiannan Wu, Xizhou Zhu, Gang Zeng, Ping Luo, Tong Lu, Jie Zhou, Yu Qiao, et al. “Visionllm: Large language model is also an open-ended decoder for vision-centric tasks” . In: Advances in Neural Information Processing Systems 36 (2023), pp. 61501 – 61513.

[64] Zhenyu Zhang, Ying Sheng, Tianyi Zhou, Tianlong Chen, Lianmin Zheng, Ruisi Cai, Zhao Song, Yuandong Tian, Christopher Re, Clark Barrett, et al. “H2o: Heavy-hitter oracle for efficient generative inference of large language models” . In: Advances in Neural Information Processing Systems 36 (2023), pp. 34661 – 34710.

[65] Marah Abdin, Jyoti Aneja, Harkirat Behl, Sebastien Bubeck, Ronen Eldan, Suriya Gunasekar, Michael Harrison, Russell J Hewett, Mojan Javaheripi, Piero Kauffmann, et al. “Phi-4 technical report” . In: arXiv preprint arXiv:2412.08905 (2024).

[66] Rishabh Agarwal, Nino Vieillard, Yongchao Zhou, Piotr Stanczyk, Sabela Ramos Garea, Matthieu Geist, and Olivier Bachem. “On-Policy Distillation of Language Models: Learning from Self-Generated Mistakes” . In: The Twelfth International Conference on Learning Representations. 2024. url: <https://openreview.net/forum?id=3zKtaqxLhW>.

- [67] Ekin Akyurek, Mehul Damani, Adam Zweiger, Linlu Qiu, Han Guo, Jyothish Pari, Yoon Kim, and Jacob Andreas. “The Surprising Effectiveness of Test-Time Training for Few-Shot Learning” . In: Forty-second International Conference on Machine Learning. 2024.
- [68] Ekin Akyurek, Bailin Wang, Yoon Kim, and Jacob Andreas. “In-context language learning: Architectures and algorithms” . In: arXiv preprint arXiv:2401.12973 (2024).
- [69] Simran Arora, Sabri Eyuboglu, Michael Zhang, Aman Timalsina, Silas Alberti, James Zou, Atri Rudra, and Christopher Re. “Simple linear attention language models balance the recall-throughput tradeoff” . In: Forty-first International Conference on Machine Learning. 2024. url: <https://openreview.net/forum?id=e93ffDcpH3>.
- [70] Maximilian Beck, Korbinian Poppel, Markus Spanring, Andreas Auer, Oleksandra Prudnikova, Michael Kopp, Gunter Klambauer, Johannes Brandstetter, and Sepp Hochreiter. “xLSTM: Extended Long Short-Term Memory” . In: arXiv preprint arXiv:2405.04517 (2024).
- [71] Ali Behrouz, Peilin Zhong, and Vahab Mirrokni. “Titans: Learning to memorize at test time” . In: arXiv preprint arXiv:2501.00663 (2024).
- [72] Jeffrey Cheng, Marc Marone, Orion Weller, Dawn Lawrie, Daniel Khashabi, and Benjamin Van Durme. “Dated Data: Tracing Knowledge Cutoffs in Large Language Models” . In: First Conference on Language Modeling. 2024. url: <https://openreview.net/forum?id=wS7PxDjy6m>.
- [73] Qingxiu Dong, Lei Li, Damai Dai, Ce Zheng, Jingyuan Ma, Rui Li, Heming Xia, Jingjing Xu, Zhiyong Wu, Baobao Chang, Xu Sun, Lei Li, and Zhifang Sui. “A Survey on In-context Learning” . In: Proceedings of the 2024 Conference on Empirical Methods in Natural Language Processing. Ed. by Yaser Al-Onaizan, Mohit Bansal, and Yun-Nung Chen. Miami, Florida, USA: Association for Computational Linguistics, Nov. 2024, pp. 1107 – 1128. doi: 10.18653/v1/2024.emnlp-main.64. url: <https://aclanthology.org/2024.emnlp-main.64/>.
- [74] Abhimanyu Dubey, Abhinav Jauhri, Abhinav Pandey, Abhishek Kadian, Ahmad Al-Dahle, Aiesha Letman, Akhil Mathur, Alan Schelten, Amy Yang, Angela Fan, et al. “The llama 3 herd of models” . In: arXiv e-prints (2024), arXiv – 2407.
- [75] Cheng-Ping Hsieh, Simeng Sun, Samuel Kriman, Shantanu Acharya, Dima Rekesh, Fei Jia, and Boris Ginsburg. “RULER: What’s the Real Context Size of Your Long-Context Language Models?” In: First Conference on Language Modeling. 2024. url: <https://openreview.net/forum?id=kIoBbc76Sy>.
- [76] Adam Ibrahim, Benjamin Therien, Kshitij Gupta, Mats Leon Richter, Quentin Gregory Anthony, Eugene Belilovsky, Timothee Lesort, and Irina Rish. “Simple and Scalable Strategies to Continually Pre-train Large Language Models” . In: Transactions on Machine Learning Research (2024). issn: 2835-8856. url: <https://openreview.net/forum?id=DimPeeCxKO>.
- [77] Kalle Kujanpää, Harri Valpola, and Alexander Ilin. “Knowledge injection via prompt distillation” . In: arXiv preprint arXiv:2412.14964 (2024).
- [78] Yury Kuratov, Aydar Bulatov, Petr Anokhin, Ivan Rodkin, Dmitry Sorokin, Artyom Sorokin, and Mikhail Burtsev. “Babilong: Testing the limits of llms with long context reasoning-in-a-haystack” . In: Advances in Neural Information Processing Systems 37 (2024), pp. 106519 – 106554.
- [79] Dengchun Li, Yingzi Ma, Naizheng Wang, Zhengmao Ye, Zhiyuan Cheng, Yinghao

Tang, Yan Zhang, Lei Duan, Jie Zuo, Cal Yang, et al. “Mixlor: Enhancing large language models fine-tuning with lora-based mixture of experts” . In: arXiv preprint arXiv:2404.15159 (2024).

[80] Yuhong Li, Yingbing Huang, Bowen Yang, Bharat Venkitesh, Acyr Locatelli, Hanchen Ye, Tianle Cai, Patrick Lewis, and Deming Chen. “Snapkv: Llm knows what you are looking for before generation” . In: Advances in Neural Information Processing Systems 37 (2024), pp. 22947 – 22970.

[81] Akide Liu, Jing Liu, Zizheng Pan, Yefei He, Gholamreza Haffari, and Bohan Zhuang. “MiniCache: KV Cache Compression in Depth Dimension for Large Language Models” . In: Advances in Neural Information Processing Systems 37 (2024).

[82] Fanxu Meng, Zhaohui Wang, and Muhan Zhang. “Pissa: Principal singular values and singular vectors adaptation of large language models” . In: Advances in Neural Information Processing Systems 37 (2024), pp. 121038 – 121072.

[83] Nihal V Nayak, Yiyang Nan, Avi Trost, and Stephen H Bach. “Learning to generate instruction tuning datasets for zero-shot task adaptation” . In: arXiv preprint arXiv:2402.18334 (2024).

[84] Xingyuan Pan, Luyang Huang, Liyan Kang, Zhicheng Liu, Yu Lu, and Shanbo Cheng. “G-DIG: Towards Gradient-based DIverse and hiGH-quality Instruction Data Selection for Machine Translation” . In: Proceedings of the 62nd Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers). Ed. by Lun-Wei Ku, Andre Martins, and Vivek Srikumar. Bangkok, Thailand: Association for Computational Linguistics, Aug. 2024, pp. 15395 – 15406. doi: 10.18653/v1/2024.acl-long.821. url: <https://aclanthology.org/2024.acl-long.821/>.

[85] Jing-Cheng Pang, Pengyuan Wang, Kaiyuan Li, Xiong-Hui Chen, Jiacheng Xu, Zongzhang Zhang, and Yang Yu. “Language Model Self-improvement by Reinforcement Learning Contemplation” . In: The Twelfth International Conference on Learning Representations. 2024. url: <https://openreview.net/forum?id=38E4yUbrgr>.

[86] Jing-Cheng Pang, Pengyuan Wang, Kaiyuan Li, Xiong-Hui Chen, Jiacheng Xu, Zongzhang Zhang, and Yang Yu. “Language Model Self-improvement by Reinforcement Learning Contemplation” . In: The Twelfth International Conference on Learning Representations. 2024. url: <https://openreview.net/forum?id=38E4yUbrgr>.

[87] Ivan Rodkin, Yuri Kuratov, Aydar Bulatov, and Mikhail Burtsev. “Associative recurrent memory transformer” . In: arXiv preprint arXiv:2407.04841 (2024).

[88] Zhihong Shao, Peiyi Wang, Qihao Zhu, Runxin Xu, Junxiao Song, Xiao Bi, Haowei Zhang, Mingchuan Zhang, YK Li, Yang Wu, et al. “Deepseekmath: Pushing the limits of mathematical reasoning in open language models” . In: arXiv preprint arXiv:2402.03300 (2024).

[89] Haizhou Shi, Zihao Xu, Hengyi Wang, Weiyi Qin, Wenyuan Wang, Yibin Wang, Zifeng Wang, Sayna Ebrahimi, and Hao Wang. “Continual learning of large language models: A comprehensive survey” . In: ACM Computing Surveys (2024).

[90] Avi Singh, John D Co-Reyes, Rishabh Agarwal, Ankesh Anand, Piyush Patil, Xavier Garcia, Peter J Liu, James Harrison, Jaehoon Lee, Kelvin Xu, Aaron T Parisi, Abhishek Kumar, Alexander A Alemi, Alex Rizkowsky, Azade Nova, Ben Adlam, Bernd Bohnet, Gamaleldin Fathy Elsayed, Hanie Sedghi, Igor Mordatch, Isabelle Simpson, Izzeddin Gur, Jasper Snoek, Jeffrey Pennington, Jiri Hron, Kathleen Kenealy, Kevin Swersky, Kshiteej Mahajan, Laura A Culp, Lechao Xiao, Maxwell Bileschi, Noah Constant, Roman Novak, Rosanne Liu, Tris Warkentin, Yamini Bansal, Ethan Dyer, Behnam Neyshabur,

Jascha Sohl-Dickstein, and Noah Fiedel. “Beyond Human Data: Scaling Self-Training for Problem-Solving with Language Models” . In: Transactions on Machine Learning Research (2024). Expert Certification. issn: 2835-8856. url: <https://openreview.net/forum?id=INAYUngGFK>.

[91] Avi Singh, John D Co-Reyes, Rishabh Agarwal, Ankesh Anand, Piyush Patil, Xavier Garcia, Peter J Liu, James Harrison, Jaehoon Lee, Kelvin Xu, Aaron T Parisi, Abhishek Kumar, Alexander A Alemi, Alex Rizkowsky, Azade Nova, Ben Adlam, Bernd Bohnet, Gamaleldin Fathy Elsayed, Hanie Sedghi, Igor Mordatch, Isabelle Simpson, Izzeddin Gur, Jasper Snoek, Jeffrey Pennington, Jiri Hron, Kathleen Kenealy, Kevin Swersky, Kshiteej Mahajan, Laura A Culp, Lechao Xiao, Maxwell Bileschi, Noah Constant, Roman Novak, Rosanne Liu, Tris Warkentin, Yamini Bansal, Ethan Dyer, Behnam Neyshabur, Jascha Sohl-Dickstein, and Noah Fiedel. “Beyond Human Data: Scaling Self-Training for Problem-Solving with Language Models” . In: Transactions on Machine Learning Research (2024). url: <https://openreview.net/forum?id=INAYUngGFK>.

[92] Yu Sun, Xinhao Li, Karan Dalal, Jiarui Xu, Arjun Vikram, Genghan Zhang, Yann Dubois, Xinlei Chen, Xiaolong Wang, Sanmi Koyejo, et al. “Learning to (learn at test time): Rnns with expressive hidden states” . In: arXiv preprint arXiv:2407.04620 (2024).

[93] Sijun Tan, Xiuyu Li, Shishir Patil, Ziyang Wu, Tianjun Zhang, Kurt Keutzer, Joseph E Gonzalez, and Raluca Ada Popa. “Lloco: Learning long contexts offline” . In: arXiv preprint arXiv:2404.07979 (2024).

[94] Jiaming Tang, Yilong Zhao, Kan Zhu, Guangxuan Xiao, Baris Kasikci, and Song Han. “Quest: Query-aware sparsity for efficient long-context llm inference” . In: arXiv preprint arXiv:2406.10774 (2024).

[95] Garrett Tanzer, Mirac Suzgun, Eline Visser, Dan Jurafsky, and Luke Melas-Kyriazi. “A Benchmark for Learning to Translate a New Language from One Grammar Book” . In: The Twelfth International Conference on Learning (계속됨)

Representations. 2024. url: <https://openreview.net/forum?id=tbVWug9f2h>.

[96] Zhongwei Wan, Xinjian Wu, Yu Zhang, Yi Xin, Chaofan Tao, Zhihong Zhu, Xin Wang, Siqi Luo, Jing Xiong, and Mi Zhang. “D2o: Dynamic discriminative operations for efficient generative inference of large language models” . In: arXiv preprint arXiv:2406.13035 (2024).

[97] Jiachen Tianhao Wang, Tong Wu, Dawn Song, Prateek Mittal, and Ruoxi Jia. “Greats: Online selection of high-quality data for llm training in every iteration” . In: Advances in Neural Information Processing Systems 37 (2024), pp. 131197 – 131223.

[98] Zheng Wang, Boxiao Jin, Zhongzhi Yu, and Minjia Zhang. “Model tells you where to merge: Adaptive kv cache merging for llms on long-context tasks” . In: arXiv preprint arXiv:2407.08454 (2024).

[99] Xun Wu, Shaohan Huang, and Furu Wei. “Mixture of lora experts” . In: arXiv preprint arXiv:2404.13628 (2024).

[100] Chaojun Xiao, Zhengyan Zhang, Chenyang Song, Dazhi Jiang, Feng Yao, Xu Han, Xiaozhi Wang, Shuo Wang, Yufei Huang, Guanyu Lin, et al. “Configurable foundation models: Building llms from a modular perspective” . In: arXiv preprint arXiv:2409.02877 (2024).

[101] Prateek Yadav, Colin Raffel, Mohammed Muqeeth, Lucas Caccia, Haokun Liu, Tianlong Chen, Mohit Bansal, Leshem Choshen, and Alessandro Sordoni. “A survey on model moerging: Recycling and routing among specialized experts for collaborative

- learning” . In: arXiv preprint arXiv:2408.07057 (2024).
- [102] Wannan Yang, Chen Sun, Roman Huszar, Thomas Hainmueller, Kirill Kiselev, and Gyorgy Buzsaki. “Selection of experience for memory by hippocampal sharp wave ripples” . In: Science 383.6690 (2024), pp. 1478 – 1483.
- [103] Rongzhi Zhang, Kuang Wang, Liyuan Liu, Shuohang Wang, Hao Cheng, Chao Zhang, and Yelong Shen. “LoRC: Low-Rank Compression for LLMs KV Cache with a Progressive Compression Strategy” . In: arXiv preprint arXiv:2410.03111 (2024).
- [104] Yuxin Zhang, Yuxuan Du, Gen Luo, Yunshan Zhong, Zhenyu Zhang, Shiwei Liu, and Rongrong Ji. “Cam: Cache merging for memory-efficient llms inference” . In: Forty-first International Conference on Machine Learning. 2024.
- [105] Ziyu Zhao, Leilei Gan, Guoyin Wang, Wangchunshu Zhou, Hongxia Yang, Kun Kuang, and Fei Wu. “Loraretriever: Input-aware lora retrieval and composition for mixed tasks in the wild” . In: arXiv preprint arXiv:2402.09997 (2024).
- [106] Ziyu Zhao, Tao Shen, Didi Zhu, Zexi Li, Jing Su, Xuwu Wang, Kun Kuang, and Fei Wu. “Merging loras like playing lego: Pushing the modularity of lora to extremes through rank-wise clustering” . In: arXiv preprint arXiv:2409.16167 (2024).
- [107] Lisa Adams, Felix Busch, Tianyu Han, Jean-Baptiste Excoffier, Matthieu Ortala, Alexander Loser, Hugo JWL Aerts, Jakob Nikolas Kather, Daniel Truhn, and Keno Bressem. “Longhealth: A question answering benchmark with long clinical documents” . In: Journal of Healthcare Informatics Research (2025), pp. 1 – 17.
- [108] Ali Behrouz, Meisam Razaviyayn, Peilin Zhong, and Vahab Mirrokni. “Nested Learning: The Illusion of Deep Learning Architectures” . In: The Thirty-ninth Annual Conference on Neural Information Processing Systems. 2025. url: <https://openreview.net/forum?id=nbMeRvNb7A>.
- [109] Lucas Caccia, Alan Ansell, Edoardo Ponti, Ivan Vulic, and Alessandro Sordoni. “Training Plug-n-Play Knowledge Modules with Deep Context Distillation” . In: arXiv preprint arXiv:2503.08727 (2025).
- [110] Vivek Chari, Guanghui Qin, and Benjamin Van Durme. “KV-Distill: Nearly Lossless Learnable Context Compression for LLMs” . In: arXiv preprint arXiv:2503.10337 (2025).
- [111] Gheorghe Comanici, Eric Bieber, Mike Schaekermann, Ice Pasupat, Noveen Sachdeva, Inderjit Dhillon, Marcel Blistein, Ori Ram, Dan Zhang, Evan Rosen, et al. “Gemini 2.5: Pushing the frontier with advanced reasoning, multimodality, long context, and next generation agentic capabilities” . In: arXiv preprint arXiv:2507.06261 (2025).
- [112] DeepSeek-AI. DeepSeek-R1: Incentivizing Reasoning Capability in LLMs via Reinforcement Learning. 2025. arXiv: 2501.12948 [cs.CL]. url: <https://arxiv.org/abs/2501.12948>.
- [113] Benoit Dherin, Michael Munn, Hanna Mazzawi, Michael Wunder, and Javier Gonzalez. “Learning without training: The implicit dynamics of in-context learning” . In: arXiv preprint arXiv:2507.16003 (2025).
- [114] Sabri Eyuboglu, Ryan Ehrlich, Simran Arora, Neel Guha, Dylan Zinsley, Emily Liu, Will Tennien, Atri Rudra, James Zou, Azalia Mirhoseini, et al. “Cartridges: Lightweight and general-purpose long context representations via self-study” . In: arXiv preprint arXiv:2506.06266 (2025).
- [115] Audrey Huang, Adam Block, Dylan J Foster, Dhruv Rohatgi, Cyril Zhang, Max Simchowitz, Jordan T. Ash, and Akshay Krishnamurthy. “Self-Improvement in Language Models: The Sharpening Mechanism” . In: The Thirteenth International Conference on

Learning Representations. 2025. url: <https://openreview.net/forum?id=WJaUkwci9o>.

[116] Tianle Li, Ge Zhang, Quy Duc Do, Xiang Yue, and Wenhui Chen. “Long-context LLMs Struggle with Long In-context Learning” . In: Transactions on Machine Learning Research (2025). issn: 2835-8856. url: <https://openreview.net/forum?id=Cw2xlg0e46>.

[117] Kevin Lin, Charlie Snell, Yu Wang, Charles Packer, Sarah Wooders, Ion Stoica, and Joseph E Gonzalez. “Sleep-time compute: Beyond inference scaling at test-time” . In: arXiv preprint arXiv:2504.13171 (2025).

[118] Yansheng Mao, Yufei Xu, Jiaqi Li, Fanxu Meng, Haotong Yang, Zilong Zheng, Xiyuan Wang, and Muhan Zhang. “LIFT: Improving Long Context Understanding of Large Language Models through Long Input Fine-Tuning” . In: arXiv preprint arXiv:2502.14644 (2025).

[119] Saleh Momeni, Sahisnu Mazumder, Zixuan Ke, and Bing Liu. “In-context continual learning assisted by an external continual learner” . In: Proceedings of the 31st International Conference on Computational Linguistics. 2025, pp. 7292 – 7306.

[120] Renhao Pei, Yihong Liu, Peiqin Lin, Francois Yvon, and Hinrich Schutze. “Understanding In-Context Machine Translation for Low-Resource Languages: A Case Study on Manchu” . In: arXiv preprint arXiv:2502.11862 (2025).

[121] Haris Riaz, Sourav Bhabesh, Vinayak Arannil, Miguel Ballesteros, and Graham Horwood. “MetaSynth: Meta-Prompting-Driven Agentic Scaffolds for Diverse Synthetic Data Generation” . In: arXiv preprint arXiv:2504.12563 (2025).

[122] Weihang Su, Yichen Tang, Qingyao Ai, Junxi Yan, Changyue Wang, Hongning Wang, Ziyi Ye, Yujia Zhou, and Yiqun Liu. “Parametric retrieval augmented generation” . In: arXiv preprint arXiv:2501.15915 (2025).

[123] Zhaoyang Wang, Weilei He, Zhiyuan Liang, Xuchao Zhang, Chetan Bansal, Ying Wei, Weitong Zhang, and Huaxiu Yao. “CREAM: Consistency Regularized Self-Rewarding Language Models” . In: The Thirteenth International Conference on Learning Representations. 2025. url: <https://openreview.net/forum?id=Vf6RDObyEF>.

[124] Guangxuan Xiao, Jiaming Tang, Jingwei Zuo, junxian guo, Shang Yang, Haotian Tang, Yao Fu, and Song Han. “DuoAttention: Efficient Long-Context LLM Inference with Retrieval and Streaming Heads” . In: The Thirteenth International Conference on Learning Representations. 2025. url: <https://openreview.net/forum?id=cFu7ze7xUm>.

[125] Adam Zweiger, Jyothish Pari, Han Guo, Ekin Akyurek, Yoon Kim, and Pulkit Agrawal. “Self-Adapting Language Models” . In: arXiv preprint arXiv:2506.10943 (2025).

[126] Yinghui He, Simran Kaur, Adithya Bhaskar, Yongjin Yang, Jiarui Liu, Narutatsu Ri, Liam Fowl, Abhishek Panigrahi, Danqi Chen, and Sanjeev Arora. Self-Distillation Zero: Self-Revision Turns Binary Rewards into Dense Supervision. 2026. arXiv: 2604.12002 [cs.CL]. url: <https://arxiv.org/abs/2604.12002>.

[127] Jonas Hubotter, Frederike Lubeck, Lejs Behric, Anton Baumann, Marco Bagatella, Daniel Marta, Ido Hakimi, Idan Shenfeld, Thomas Kleine Buening, Carlos Guestrin, et al. “Reinforcement Learning via Self-Distillation” . In: arXiv preprint arXiv:2601.20802 (2026).

[128] Jeonghye Kim, Xufang Luo, Minbeom Kim, Sangmook Lee, Dohyung Kim, Jiwon Jeon, Dongsheng Li, and Yuqing Yang. Why Does Self-Distillation (Sometimes) Degrade the Reasoning Capability of LLMs? 2026. arXiv: 2603.24472 [cs.CL]. url: <https://arxiv.org/abs/2603.24472>.

[129] John Kirchenbauer, Abhimanyu Hans, Brian Bartoldson, Micah Goldblum, Ashwi-

- nee Panda, and Tom Goldstein. Multi-Token Prediction via Self-Distillation. 2026. arXiv: 2602.06019 [cs.CL]. url: <https://arxiv.org/abs/2602.06019>.
- [130] Yihong Liu, Raoyuan Zhao, Michael A. Hedderich, and Hinrich Schutze. Crosslingual On-Policy Self-Distillation for Multilingual Reasoning. 2026. arXiv: 2605.09548 [cs.CL]. url: <https://arxiv.org/abs/2605.09548>.
- [131] Ruiyang Qin, Qingzhuo Wang, Dongrui Liu, Qiang Li, Zhihua Wei, and Wen Shen. Multilingual Safety Alignment via Self-Distillation. 2026. arXiv: 2605.02971 [cs.LG]. url: <https://arxiv.org/abs/2605.02971>.
- [132] Hejian Sang, Yuanda Xu, Zhengze Zhou, Ran He, Zhipeng Wang, and Jiachen Sun. CRISP: Compressed Reasoning via Iterative Self-Policy Distillation. 2026. arXiv: 2603.05433 [cs.LG]. url: <https://arxiv.org/abs/2603.05433>.
- [133] Idan Shenfeld, Mehul Damani, Jonas Hubotter, and Pulkit Agrawal. “Self-Distillation Enables Continual Learning” . In: arXiv preprint arXiv:2601.19897 (2026).
- [134] Idan Shenfeld, Mehul Damani, Jonas Hubotter, and Pulkit Agrawal. Self-Distillation Enables Continual Learning. 2026. arXiv: 2601.19897 [cs.LG]. url: <https://arxiv.org/abs/2601.19897>.
- [135] Alex Stein, Furong Huang, and Tom Goldstein. GATES: Self-Distillation under Privileged Context with Consensus Gating. 2026. arXiv: 2602.20574 [cs.LG]. url: <https://arxiv.org/abs/2602.20574>.
- [136] Hao Wang, Guozhi Wang, Han Xiao, Yufeng Zhou, Yue Pan, Jichao Wang, Ke Xu, Yafei Wen, Xiaohu Ruan, Xiaoxin Chen, and Honggang Qi. Skill-SD: Skill-Conditioned Self-Distillation for Multi-turn LLM Agents. 2026. arXiv: 2604.10674 [cs.LG]. url: <https://arxiv.org/abs/2604.10674>.
- [137] Tianzhu Ye, Li Dong, Qingxiu Dong, Xun Wu, Shaohan Huang, and Furu Wei. Online Experiential Learning for Language Models. 2026. arXiv: 2603.16856 [cs.CL]. url: <https://arxiv.org/abs/2603.16856>.
- [138] Tianzhu Ye, Li Dong, Xun Wu, Shaohan Huang, and Furu Wei. On-Policy Context Distillation for Language Models. 2026. arXiv: 2602.12275 [cs.CL]. url: <https://arxiv.org/abs/2602.12275>.
- [139] Ruixiang Zhang, Richard He Bai, Huangjie Zheng, Navdeep Jaitly, Ronan Collobert, and Yizhe Zhang. Embarrassingly Simple Self-Distillation Improves Code Generation. 2026. arXiv: 2604.01193 [cs.CL]. url: <https://arxiv.org/abs/2604.01193>.
- [140] Xinsen Zhang, Zhenkai Ding, Tianjun Pan, Run Yang, Chun Kang, Xue Xiong, and Jingnan Gu. “OPSDL: On-Policy Self-Distillation for Long-Context Language Models” . In: arXiv preprint arXiv:2604.17535 (2026).
- [141] Xinsen Zhang, Zhenkai Ding, Tianjun Pan, Run Yang, Chun Kang, Xue Xiong, and Jingnan Gu. OPSDL: On-Policy Self-Distillation for Long-Context Language Models. 2026. arXiv: 2604.17535 [cs.CL]. url: <https://arxiv.org/abs/2604.17535>.
- [142] Yaocheng Zhang, Yuanheng Zhu, Wenyue Chong, Songjun Tu, Qichao Zhang, Jiajun Chai, Xiaohan Wang, Wei Lin, Guojun Yin, and Dongbin Zhao. π -Play: Multi-Agent Self-Play via Privileged Self-Distillation without External Data. 2026. arXiv: 2604.14054 [cs.LG]. url: <https://arxiv.org/abs/2604.14054>.
- [143] Siyan Zhao, Zhihui Xie, Mengchen Liu, Jing Huang, Guan Pang, Feiyu Chen, and Aditya Grover. “Self-Distilled Reasoner: On-Policy Self-Distillation for Large Language Models” . In: arXiv preprint arXiv:2601.18734 (2026).

[144] Siyan Zhao, Zhihui Xie, Mengchen Liu, Jing Huang, Guan Pang, Feiyu Chen, and Aditya Grover. Self-Distilled Reasoner: On-Policy Self-Distillation for Large Language Models. 2026. arXiv: 2601.18734 [cs.LG]. url: <https://arxiv.org/abs/2601.18734>.

그림 7(Figure 7): 다중 주파수 메모리 계층 (Multi-frequency memory hierarchy). 업데이트는 반복적인 파라미터 확장 (Parameter Expansion) 을 통해 고주파 (High-Frequency) FFN 으로 진입한다. 윈도우 f_W 가 만료되면, 지식은 중간 (Mid-) 주파수 FFN 으로, 그다음 저주파 (Low-Frequency) FFN 으로 통합 (Consolidated) 된다 ($1k \rightarrow 5k \rightarrow 10k$).

그림 8(Figure 8): 라우팅된 전문가 업데이트 (routed expert updates) 에 의한 메모리 통합. Sleep 사이클을 거치면서 (왼쪽→오른쪽), 라우터 (router) 는 소수의 전문가 (expert) 집합을 선택하여 업데이트하고 (실선), 나머지는 비활성 상태로 둔다 (빗금). 이를 통해 간섭을 제한하면서 용량을 확장한다.

A. 관련 연구 (Related Work)

A.1 파라미터 효율적 적응 및 합성 (Parameter-Efficient Adaptation and Composition)

파라미터 효율적 미세조정 (parameter-efficient fine-tuning, PEFT) 은 백본 (backbone) 을 동결한 채 최소한의 보조 파라미터 집합만 최적화하여 대규모 언어 모델 (large language models, LLMs) 을 특정 태스크에 적응시킨다. **저랭크 및 프리픽스 적응 (Low-Rank and Prefix Adaptation).** 대표적인 방법으로는 선형 투영 (linear projection) 에 학습가능한 저랭크 행렬을 주입하는 LoRA (Hu et al. 2022) 와, 학습 가능한 가상토큰 (virtual tokens) 을 통해 연산을 유도하는 프리픽스/프롬프트 튜닝 (prefix/prompt-tuning) (Lester et al. 2021; Li et al. 2021) 이 있다. 최근의 변형들은 수렴을 가속하기 위해 초기화를 최적화하거나 (예: PiSSA (Meng et al. 2024)), 이러한 메커니즘을 문맥-대-파라미터 증류 (context-to-parameter distillation) 로 확장한다 (Eyuboglu et al. 2025).

합성 및 라우팅 (Composition and Routing). 단일 태스크 적응을 넘어, 연구는 점차 다수의 어댑터 (adapter) 를 합성하는 데 초점을 맞추고 있다. 이러한 접근에는 in-context learning 을 통한 가중 합성 (Huang et al. 2023) 과, 입력마다 관련 LoRA 모듈을 동적으로 선택하는 검색 기반 라우팅 (retrieval-based routing) (Zhao et al. 2024a) 이 포함된다. 진보된 구성들은 전문가 혼합 (mixture-of-experts, MoE) 아키텍처를 활용하여 태스크에 따라 특정 저랭크 경로를 활성화하거나 어댑터 파라미터를 병합한다 (Gou et al. 2023; Li et al. 2024a; Wu et al. 2024; Xiao et al. 2024; Yadav et al. 2024; Zhao et al. 2024b).

A.2 지식 주입, 증류, 자기 개선 (Knowledge Injection, Distillation, and Self-Improvement)

파라미터적 지식 주입 (Parametric Knowledge Injection). 추론시점 (inference time) 의 검색 의존도를 줄이기 위해, 최근 연구는 외부지식을 모델 파라미터에 직접 주입한다. 그 기법은 문서별 LoRA 어댑터를 할당하는 Parametric RAG (Su et al. 2025) 에서부터, 학생 (student) 모델이 교사 (teacher) 가 생성한 QA 쌍이나 합성 대화 (synthetic conversations) 로부터 학습하는 프롬프트 증류 (prompt distillation) (Kujanpaa et al. 2024; Caccia et al. 2025; Mao et al. 2025) 에 이른다. Cartridges (Eyuboglu et al. 2025) 는 자기학습 (self-study) 목표를 통해 재사용 가능한 “KV 캐시 어댑터 (KV cache adapter)” 를 사전 학습함으로써 PEFT 와 증류를 잇고, 서빙 비용을 줄이면서도 in-context learning (ICL) 품질을 달성한다.

자기 개선 및 메타 학습 (Self-Improvement and Meta-Learning). 증류를 보완하는 것으로 자기 개선을 위한 모델 생성 신호 (model-generated signals) 의 활용이 있다. 여기에는 추론 능력을 향상시키기 위한 검증 가능한 보상 (verifiable rewards) 에 대한 강화학습 (Reinforcement Learning, RL) (Zelikman et al. 2022; Singh et al. 2024b; DeepSeek-AI 2025) 과 자기보상 (self-rewarding) 메커니즘 (Pang et al. 2024b; Wang et al. 2025) 이 포함된다. SEAL (Zweiger et al. 2025) 과 같은 메타 학습 프레임워크는 적응 전략 자체를 최적화—즉 자기 편집 (self-edits) 을

어떻게 생성할지를 학습—함으로써 이를 확장하며, 이는 자기 참조 학습 (self-referential learning)의 보다 넓은 원리 (Schmidhuber 1987; Finn et al. 2017; Irie et al. 2022)에 기반한다. 이러한 방법들은 감독 (supervision)을 확장하기 위해 고품질 합성 데이터 생성에 크게 의존한다 (Abdin et al. 2024; Nayak et al. 2024; Riaz et al. 2025).

최근 동시대의 일군의 연구들은 자기 증류 (self-distillation) 과정을 위해 (Hubotter et al. 2026; Zhang et al. 2026b; Zhao et al. 2026a) 또는 지속 학습 (continual learning)을 위해 (Shenfeld et al. 2026a) 온-폴리시 증류 (on-policy distillation)를 사용할 것을 제안해 왔다. 본 연구가 그러한 방법들보다 더 오래되었다는 사실에 더하여, Sleep은 근본적으로 다른 메시지들을 전달한다. 즉: (1) Sleep은 파라미터를 잠금 해제 (unlock)하는, 자기 자신에 대한 상향식 증류 (upward distillation of self)를 사용한다. (2) Sleep은 온-폴리시 방법과 RL 방법을 결합하는 일반화된 증류 (Generalized Distillation) 방법에 기반한다. (3) Sleep은 지식이 서로 다른 업데이트 주파수를 갖는 모듈들에 저장되는 주기적 과정 (periodic process)을 제안한다.

A.3 효율적 문맥 처리 (Efficient Context Processing)

긴 문맥 (long-context) 처리의 메모리 병목을 해결하는 것은 KV 캐시를 압축하거나 어텐션 아키텍처를 수정하는 것을 포함한다.

프롬프트 및 캐시 압축 (Prompt and Cache Compression). 메모리 사용량을 줄이는 접근은 두 범주로 나뉜다: 프롬프트 압축 (Prompt compression)은 토큰 필터링 (하드 토큰, hard-token)을 통해 입력을 단축하거나 (Jiang et al. 2023; Li 2023), 또는 학습된 압축적 소프트토큰 (soft-token) 임베딩을 통해

오토크인코더 (Chevalier et al. 2023; Ge et al. 2023; Tan et al. 2024). KV 캐시 압축은 런타임에 작동하며, 비필수 키를 버리는 축출 (eviction) 정책 (Zhang et al. 2023; Li et al. 2024b; Tang et al. 2024)이나 유사성과 어텐션 밀도에 기반해 토큰을 병합하는 방식 (Liu et al. 2024; Wan et al. 2024; Wang et al. 2024b; Zhang et al. 2024b)을 활용한다. KV 캐시의 저랭크 (low-rank) 투영 또한 높은 압축률에서 성능을 유지하는 데 유망함을 보였다 (Zhang et al. 2024a; Chari et al. 2025).

아키텍처 혁신 (Architectural Innovations). 다중 헤드 어텐션 (Multi-Head Attention, MHA)에 대한 구조적 변경으로는, KV 헤드를 공유하여 메모리 대역폭을 줄이는 다중 질의 및 그룹 질의 어텐션 (Multi-Query and Grouped-Query Attention, MQA/GQA) (Shazeer 2019; Ainslie et al. 2023)과, 소프트맥스를 제거하여 시퀀스 길이와 무관한 고정 크기 상태 (KTV)를 달성하는 선형화 (linearization) 기법 (Gu et al. 2023; Arora et al. 2024; Beck et al. 2024)이 있다. Titans와 TTT 같은 최근의 “압축을 학습하는 (learning to compress)” 아키텍처는 무한한 컨텍스트를 처리하기 위해 고정 크기 메모리 객체에 대한 경사 기반 (gradient-based) 갱신을 활용한다 (Behrouz et al. 2024; Sun et al. 2024). 마지막으로, MemGPT와 같은 오케스트레이션 시스템은 아키텍처를 변경하는 대신 가상 메모리 페이징 (virtual memory paging)을 통해 컨텍스트를 관리한다 (Packer et al. 2023). 토큰 공간에서의 압축과 유사한 방향으로, Lin et al. (2025)은 수면 시간 연산 (sleep-time compute)을 제시한다. 이름은 유사하지만, 그들의 방법은 우리의 연구와 근본적으로 다르다. 이 방법은 모델이 유휴 상태일 때 텍스트 공간에서 모델과 사용자의 상호작용에 대한 좋은 요약물을 찾는 것을 목표로 하는 반면, 우리의 제안은 증류 (distillation)를 사용하여 텍스트 데이터 지식을 파라메트릭 가중치 갱신 (parametric weight update)의 형태로 전이하는 데 있다.

A.4

온-폴리시 증류 (On-Policy Distillation)에 관한 최근의 동시적 및/또는 후속 연구

온-폴리시 자기 증류 (On-Policy Self-Distillation)에 관한 동시적 및 후속 연구. 본 연구의 초기 버전과 동시에 그리고 후속으로, 온-폴리시 자기 증류 (on-policy self-distillation, OPSD)를 탐구하는 문헌이 급속히 성장해 왔다. OPSD에서는 동일한 모델이 서로 다른 조건화 컨텍스트 (conditioning context) 하에서 교사 (teacher)와 학생 (student)의 역할을 모두 수행하며, 학생은 교사에게 대한 토큰

별 발산 (per-token divergence) 을 통해 자신의 롤아웃 (rollout) 에 대해 감독 (supervise) 된다. 정준적 (canonical) 구현은 OPSD(Zhao et al. 2026b) 로, 이는 검증된 추론궤적 (verified reasoning trace) 에 교사를 조건화하고 학생 자신의 롤아웃에 대해 토큰별 역-KL(reverse-KL) 을 최소화하여, GRPO 와 오프-폴리시 (off-policy) 증류 양쪽 대비 수학적 추론에서 이득을 얻는다. 일련의 후속 연구들은 특권 컨텍스트 (privileged context) 의 형태를 다양하게 변주한다. 온-폴리시 컨텍스트 증류 (On-Policy Context Distillation)(Ye et al. 2026b) 는 학생이 그 정보를 자신의 파라미터로 내재화하도록 일시적인 인-컨텍스트 (in-context) 정보 (과거 해법 궤적이나 최적화된 시스템프롬프트) 에 교사를 조건화한다. GATES(Stein et al. 2026) 는 문서기반 (document-grounded) 특권 컨텍스트를, 여러 튜터 궤적을 샘플링하고 그 합의 (agreement) 에 따라 학습을 게이팅함으로써 신뢰할 수 없는 감독을 처리하는 합의-게이팅 (consensus-gating) 메커니즘과 함께 사용한다. SD-Zero(He et al. 2026) 는 “수정자 (reviser)” 를 학생의 응답과 이진보상 (binary reward) 에 조건화한 뒤, 그 수정자를

23

생성기 (generator) 로 다시 증류하여, 희소한 결과 보상 (sparse outcome reward) 을 조밀한 토큰 수준 감독 (dense token-level supervision) 으로 변환한다. 그리고 COPSD(Liu et al. 2026) 는 교사에게 영어 번역과 참조해법을 특권적 교차언어 (crosslingual) 컨텍스트로 제공함으로써 추론 행동을 저자원 (low-resource) 언어로 전이한다. Apple 의 “당혹스러운 정도로 단순한 (embarrassingly simple)” 자기 증류 (Zhang et al. 2026a) 는 이스펙트럼의 극한에 위치한다. 이는 명시적 교사를 아예 제거하고 서로 다른 디코딩 구성 (decoding configuration) 하에서 모델 자신의 샘플에 대해 지도 미세조정 (supervised-finetune) 하는데, 이 최소한의 레시피만으로도 코드생성이 유의미하게 개선됨을 보인다.

지속적, 경험적, 온라인 적응 (Continual, Experiential, and Online Adaptation). 두 번째 부류의 연구들은 자기 증류를 지속적 (continual), 경험적 (experiential), 또는 온라인 개선에 적용한다. SDFT(Shenfeld et al. 2026b) 는 시연 조건화된 (demonstration-conditioned) 모델을 온-폴리시교사로 사용하여 시연으로부터의 지속 학습을 명시적으로 겨냥하며, 표준 SFT 대비 파국적 망각 (catastrophic forgetting) 을 줄인다. OEL(Ye et al. 2026a) 은 컨텍스트 증류를 배포 (deployment) 와 결합한다. 즉, 상호작용궤적 (interaction trajectory) 에서 전이 가능한 경험적 지식을 추출하고 온-폴리시 컨텍스트 증류를 통해 이를 파라미터로 통합하며, 두 단계를 반복하여 닫힌 온라인 학습 루프 (closed online-learning loop) 를 형성한다. π -Play(Zhang et al. 2026d) 는 이 아이디어를 다중 에이전트 자기대전 (multi-agent self-play) 체제로 더 밀어붙여, 과제 제안자 (task proposer) 가 생성한 질문 구성 경로 (question-construction path) 를 교사를 위한 특권 컨텍스트로 사용하고, 심층 탐색 에이전트 (deep search agent) 훈련에서 외부 데이터나 인간 피드백의 필요성을 제거한다. 이러한 연구들은 LLM 이 배포 후 정적으로 머물러서는 안 된다는 우리의 동기와 밀접하게 부합한다. 그러나 이들은 지속적 또는 경험적 개선을 고정 용량체크포인트 (fixed-capacity checkpoint) 에 대한 후속 훈련 (post-training) 목표로 정식화한다. 이와 대조적으로, 우리의 Sleep 패러다임은 지속 학습을 메모리 시스템 문제로 취급한다. 즉, 새로 획득된 정보는 먼저 빠르고 취약한 (fast, fragile) 메모리 모듈에 표현된 뒤, 지식 시딩 (Knowledge Seeding) 을 통해 주기적으로 더 느리고 안정적인 파라미터로 통합되며, 이는 점진적 용량 확장 (gradual capacity expansion) 과 통합 후고빈도 (higher-frequency) 메모리의 재설정 (resetting) 을 동반한다.

응용 특화 OPSD 레시피 (Application-Specific OPSD Recipes). 세 번째 부류의 논문들은 OPSD 템플릿을 특정 배포 체제에 맞게 조정한다. CRISP/OPSDC(Sang et al. 2026) 는 교사를 “간결하게 (be concise)” 지시 접두사 (instruction prefix) 에 조건화하고 학생 롤아웃에 대한 토큰별 역-KL 을 사용하여, 엔트로피 붕괴 (entropy collapse) 없이 긴사고 연쇄 (chain-of-thought) 궤적을 압축한다. MTP(Kirchenbauer et al. 2026) 는 단일 온라인 자기 증류 목표로 사전 훈련된 다음-토큰-예측 (next-token-prediction) 모델을 다중 토큰예측기 (multi-token predictor) 로 변환하여, GSM8K 에서 5% 미만의 정확도감소로 3 배 이상의 추론 가속을 달성한다. OPSDL(Zhang et al. 2026c) 은 추출된 관련 구간 (extracted relevant span) 에 대한 모델 자신의 단문맥 (short-context) 행동을 그 장문맥 (long-context) 학생을 위한 자기교사 (self-teacher) 로 사용함으로써 장문맥 생성을 공략한다. Skill-SD(Wang et al. 2026) 는 다중 턴 (multi-turn) 에이전트를 겨냥한다. 완료된 궤적은 간결한 자연어 “스킬 (skill)” 로 요약되어 교사만을 조건화하고, 학생은 평범한 과제 프롬프트 하에서

훈련된다. MSD(Qin et al. 2026)는 다중언어질의만을 사용하여 고자원 (high-resource) 언어에서 저자원 언어로 안전 (safety) 행동을 전이함으로써 OPSD를 다중언어 (multilingual) 설정으로 옮긴다. 종합적으로, 이러한 연구들은 특권적 조건화 (privileged conditioning) 하의 자기 증류가 추론, 효율성, 에이전트, 다중언어 축에 걸쳐 일반적이고 유연한 후속 훈련 레시피임을 보여준다 — 그러나 각 경우 그것은 고정된 모델과 고정된 응용에 대한 단일 목표 절차 (single-objective procedure)로 배포된다.

OPSD의 한계와 Sleep 패러다임에 대한 동기 (Limitations of OPSD and Motivation for the Sleep Paradigm). 이러한 영역들에 걸친 OPSD의 실증적 성공에도 불구하고, 최근의 분석들은 그 실패 양상 (failure mode)을 드러내기 시작했다. Kim et al. (2026)은 수학적 추론에서, 교사를 풍부한 특권 정보에 조건화하는 것이 모델의 인식론적 언어화 (epistemic verbalisation, 추론 중 불확실성의 표현)를 억제하여, 심각한 분포 외 (out-of-distribution) 성능 저하를 대가로 빠른 도메인 내 (in-domain) 최적화를 가능하게 함을 보인다. 이때 Qwen3-8B, DeepSeek-Distill-Qwen-7B, Olmo3-7B-Instruct에 걸쳐 최대 40%의 하락이 나타난다. 여러 최근 OPSD 연구들 또한 장기 (long-horizon) 훈련 파이프라인에서 자기 증류를 순진하게 반복하면 특권 교사로부터의 정보 누출 (information leakage)과 훈련 붕괴 (training collapse)로 이어질 수 있음을 보고한다 (He et al. 2026; Wang et al. 2026). 이러한 결과들은 자기 증류만으로는 강건한 지속적 개선에 충분하지 않음을 시사한다. 즉, 고정된 모델에 직접 적용된 반복적 자기 개선 루프는 이전 능력을 침식하거나 추론을 불안정하게 만들 수 있다. 우리의 2 단계 Sleep 프레임워크는 메모리 통합 (memory consolidation)을 자기 개선 (self-improvement)과 분리함으로써 우려를 직접적으로 다룬다. 통합은 Dreaming이 모델을 추가로 수정하기 전에 새로 획득한 지식을 새롭게 확장된 저빈도 (lower-frequency) 파라미터에 먼저 안정화시켜, 반복적 자기 훈련이 유용한 이전 능력을 덮어쓸 위험을 줄인다.

우리 연구의 위치 설정 (Positioning of Our Work). 우리의 연구는 함께 Sleep 패러다임의 동기가 되는 네 가지 축을 따라 OPSD 문헌과 차별화된다. **(i) 메모리 통합으로서의 상향 증류 (Upward distillation as memory consolidation).** 위에 나열된 모든 자기 증류 연구들은 교사와 학생 사이에 동일한 백본 (backbone)을 공유하며 오직 조건화 컨텍스트에서만 차이가 난다 — 특권 궤적 (privileged trace)(Kim et al. 2026; Zhao et al. 2026b), 시연 (demonstration)(Shenfeld et al. 2026b), 문서 (document)(Stein et al. 2026), 컨텍스트 또는 시스템 프롬프트 (Ye et al. 2026a,b), “간결 (concise)” 접두사 (Sang et al. 2026), 디코딩 구성 (Zhang et al. 2026a), 스킬 요약 (skill summary)(Wang et al. 2026), 수정자 컨텍스트 (reviser context)(He et al. 2026), 질문 구성 경로 (question-construction path)(Zhang et al. 2026d), 단문맥 부분 문자열 (short-context substring)(Zhang et al. 2026c), 또는 영어 참조 (English reference)(Liu et al. 2026; Qin et al. 2026). 이와 대조적으로, 우리의 지식 시딩 (Knowledge Seeding) 단계는 상향 증류 (upward distillation)이다. 즉, 더 작고 고빈도인 메모리 모듈이 저빈도 메모리 모듈 내의 새롭게 확장된 엄격히 더 큰 저랭크 전문가 (low-rank experts) 집합으로 증류된다. 이는

24

파국적 망각을 샘플링 분포 (sampling distribution)의 문제가 아니라 불충분한 용량 (insufficient capacity)의 문제로 재구성하고, 고정된 교사를 재조건화하는 대신 통합 단계 사이의 점진적 파라미터 성장 (gradual parameter growth)으로 이를 다룬다. **(ii) 메모리 빈도의 연속체 (Continuum of memory frequencies).** 위 연구들이 증류를 평평한 (flat) 학생/교사 쌍으로 취급하는 반면, 우리의 방법은 엄격히 순서 지어진 갱신 빈도 (update frequency)를 갖는 메모리 블록의 사슬 (chain) 위에서 작동하며 연속된 각 블록 쌍 사이에서 통합을 수행한다. 우리가 아는 한, SDFT(Shenfeld et al. 2026b)만이 우리에게 동기를 부여하는 지속 학습 요건 (continual-learning desideratum)을 명시적으로 겨냥하지만, 그것은 아키텍처 성장 (architectural growth)이나 계층적 메모리 (hierarchical memory) 없이 그렇게 한다. **(iii) 통합을 넘어서는 2 단계 과정으로서의 Sleep (Sleep as a two-phase process beyond consolidation).** OPSD 문헌은 거의 전적으로 통합 단계에 집중한다. 우리의 프레임워크는 추가로 REM 수면에 비유되는 Dreaming 단계를 포함하는데, 여기서 모델은 합성 데이터 (synthetic data)의 커리큘럼을 생성하고, 경사 기반 중요도 점수 (gradient-based importance score)로 샘플에 가중치를 부여하며, MoE 라우터를 활용하여 통제된 새로움 (controlled novelty)을 주입한다 — 이는 (He et al. 2026; Kim et al. 2026)이 지적한 반복적 자기 개선 실패 양상에 대해 강건하도록 명시적으로 설계되었다. **(iv) 지식 시딩은 온-폴리시 증류를 모방 학습으로 증강한다**

(**Knowledge seeding augments on-policy distillation with imitation learning**). (Liu et al. 2026; Qin et al. 2026; Sang et al. 2026; Stein et al. 2026; Ye et al. 2026a,b; Zhang et al. 2026c; Zhao et al. 2026b) 와 같은 연구들의 온-폴리시 증류 목표가 학생 롤아웃에 대한 토큰별 역-KL 로 환원되는 반면, 우리의 지식 시딩 목표는 GKD 스타일의 온-폴리시 증류를, 교사의 샘플링 분포와의 의미론적 (semantic) 및 레벤슈타인 수준 (Levenshtein-level) 정렬을 공동으로 보상하는 RL 기반 모방 학습 (Learning-to-Imitate) 향으로 증강한다. 이로써 더 큰 학생이 교사의 지식을 물려받을 뿐만 아니라 교사가 그것을 사용하는 방식까지도 모방할 수 있게 한다.

B

추가 실험 결과 및 세부사항

우리의 모든 실험에서, 우리는 원래 벤치마크의 설정 (각 섹션에 인용됨) 을 따른다. 따라서 지면을 아끼고 정보를 중복하지 않기 위해, 모델의 세부사항에 대해서는 해당 연구들을 참조한다. 우리의 설계에서는 추가파라미터로 차원 64 의 MLP 블록 5 개를 사용하며 활성 파라미터 수 (active parameter count) 는 변경하지 않고 유지한다 (즉, 기저 모델과 동일하며, 이는 8B 또는 3B 이다).

B.1

데이터셋 (Datasets)

클래스 증분 학습 (Class Incremental Learning). 우리는 세 개의 데이터셋에 대한 클래스 증분 학습에 집중한다:

- **CLINC (Larson et al. 2019)**: CLINC150 은 과제 지향대화 (task-oriented dialog) 를 위한 다중 도메인 의도 분류 (intent classification) 벤치마크로, 범위 내 (in-scope) 의도 예측과 범위 외 (out-of-scope, OOS) 탐지를 모두 평가하는 데 흔히 사용된다. 이는 10 개도메인에 걸친 150 개의 범위 내 의도를 포함하며, 총 23.7K 개의 질의 (범위내 22.5K, OOS 1.2K) 를 갖는다.
- **Banking (Casanueva et al. 2020)**: Banking77 은 짧은 은행 고객 서비스 질의로 구성된 단일 도메인 의도 데이터셋으로, 77 개의 세분화된 의도 (예: 카드 문제 또는 PIN 재설정) 로 레이블이 달려있다. 13,083 개의 예제를 포함하며, 의도 분포는 눈에 띄게 불균형하다.
- **DBpedia (Auer et al. 2007)**: DBpedia 기반 분류는 위키피디아에서 파생된 설명 (일반적으로 초록) 을 온톨로지 범주 (예: 책, 영화, 동물, 장소) 로 매핑한다. 우리는 70-클래스, 레벨-2 설정을 사용하며 실험을 위해 10K 개의 훈련 인스턴스와 1K 개의 테스트 인스턴스를 서브샘플링한다.

인-컨텍스트 학습에 대한 레벨의 효과 (The Effect of Levels on In-context Learning). Hope 의 통합 스케줄 (consolidation schedule) 이 인-컨텍스트 학습과 장문맥 이해에 어떻게 영향을 미치는지 더 잘 분리해내기 위해, 우리는 장문맥 하에서 질의응답 (question answering) 과 다중 키 검색 (multi-key retrieval) 을 평가한다. 이 평가에는 다음 데이터셋을 사용한다:

- **LongHealth (Adams et al. 2025)**: LongHealth 는 긴가상의 환자 사례 기록으로부터 구축된 장문맥 임상 다지선다형 QA 벤치마크이다. 20 개의 사례 문서 (각각 약 5.1K – 6.8K 단어) 를 포함하며, 우리는 이 기록들에서 샘플링된 200 개의 질문에 대해 평가한다.
- **QASPER (Dasigi et al. 2021)**: QASPER 는 전문 (full-text) NLP 논문에 기반한 정보 탐색형 (information-seeking) QA 벤치마크로, 약 1.6K 개 논문에 걸쳐 대략 5K 개의 질문을 갖는다. 우리는 각 논문의 전문을 컨텍스트로 사용한다.
- **MK-NIAH (Hsieh et al. 2024)**: MK-NIAH 는 RULER (Hsieh et al. 2024) 의 다중 키 건초 더미 속 바늘 (multi-key needle-in-a-haystack) 과제로, 여러 키-값 사실이 긴 컨텍스트에 삽입되고 모델은 질의된 키에 대한 값을 검색해야 한다.

25

B.2

추가 결과: BABILong

우리는 BABILong 벤치마크 (Kuratov et al. 2024) 에서 Hope(Sleep) 를 평가하며, 다음과 비교한다: (1) 대형 모델 (GPT-4 및 GPT-4o-mini (Achiam et al. 2023)); (2) RAG 를 갖춘 중간 규모의 Llama-8B 모델 (Dubey et al. 2024); 그리고 (3) RMT(Bulatov et al. 2022), ARMT(Rodkin et al. 2024), Titans(Behrouz et al. 2024) 를 포함한 최첨단 (state-of-the-art) 소형장문맥 모델. 모든 소형 모델은 공식 BABILong 훈련 프로토콜 (Kuratov et al. 2024) 을 사용하여 미세조정된다. 그림 6 에 나타난 바와 같이, 대형모델은 컨텍스트 길이가 증가함에 따라 급격한 성능 저하를 보이며 128K - 256K 토큰을 넘어서면 실패한다. RAG 는 더 긴 컨텍스트에서 강건성을 개선하지만 여전히 시퀀스 길이가 늘어남에 따라 저하된다. 미세조정된 소형 모델들중에서 Titans, ARMT, Hope 는 대략 1M 토큰까지 비슷하게 작동한다. 이 지점을 넘어서면 Titans 와 ARMT 는 급격히 저하되는 반면, Hope 는 최대 10M 토큰의 극단적 길이에서도 안정적으로 유지된다. 이 강건성은 단기활성화 (short-lived activation) 를 간결한 파라메트릭 표현으로 변환하는 Sleep 의 명시적 통합 및 자기 개선 메커니즘에 의해 주도된다. 통합 과정에서 더 높은 수준의 추상화를 학습함으로써, Hope 는 과제 관련 정보를 더 효율적으로 보존하여 증가하는 컨텍스트 길이에 대한 민감도를 줄인다. 마지막으로, 우리는 Hope 를 포함한 모든 소형 모델이 미세조정 없이도 상당한 성능 하락을 겪는다는 것을 관찰한다. 초장문맥 (ultra-long context) 을 압축하려면 중요한 정보를 식별하고 보존하기 위한 저빈도 메모리 레벨에서의 충분한 용량이 필요하다. 미세조정은 이러한 구성요소들이 빠르게 적응하고 추론 중 고빈도 메모리와 효과적으로 협응하도록 해준다.

B.3

추가 실험: ARC

우리는 선행 연구 (Akyurek et al. 2024a; Zweiger et al. 2025) 의 소수샷 (few-shot) ARC 실험 프로토콜을 따르고 이를 우리의 Sleep 패러다임에 맞게 조정한다. 백본으로는 Llama-3.2-1B 를 사용한다. 일반적인 관행을 따라, 표준 구성 하에서 풀 수 없는 과제를 피하기 위해 데이터의 부분집합을 필터링하여, 훈련용 11 개 과제와 평가용 8 개의 보류 (held-out) 과제를 산출한다. 각 Sleep 주기 (cycle) 동안, 모델은 먼저 이전 기억들을 통합한 뒤, 소수 샷 데모로부터 합성 경험 (synthetic experience) 을 생성함으로써 꿈을 꾸다 (dreams). 각 과제에 대해 우리는 60 개의 꿈을 샘플링하고 그중 45 개를 기각한다. 테스트 시점에는, 각 미지의 과제에 대해 모델이 5 개의 꿈을 생성하고 보류된 출력을 예측하기 전에 이들을 독립적으로 적용한다. 우리는 정답을 산출하는 꿈의 비율을 보고한다. 기준선 (baseline) 으로는 Zweiger et al. (2025) 을 따라 다음을 사용한다: (i) ICL(In-Context Learning); (ii) TTT + 합성 갱신 (synthetic updates)(꿈 없음); 그리고 (iii) SEAL(Zweiger et al. 2025). 이 설정에서 Sleep 은 80%의 성공률을 달성하여 다른 방법들보다 높다.

B.4

추가 세부사항

표 5: GRPO, SFT, Sleep 에 대한 훈련 구성 (Training Configuration)

파라미터 (Parameter)	GRPO	SFT	Sleep
학습률 (Learning Rate)	5×10^{-6}	5×10^{-6}	5×10^{-6}

파라미터 (Parameter)	GRPO	SFT	Sleep
유효 배치 크기 (Effective Batch Size)	32	32	32
훈련 스텝 (Training Steps)	500	100	100
LoRA 랭크 (LoRA Rank, r)	64	64	64
LoRA 알파 (LoRA Alpha, α)	128	128	128

B.5

효율성 (Efficiency)

동일한 스텝 수에서, SFT는 우리의 방법보다 4배 더 효율적이다. 그러나 그들의 성능은 비교 가능하지 않다. 이에 따라, 우리는 특정 성능을 목표로 할 때의 효율성 또한 비교한다. 우리는 AIME-24, AIME-25, HMMT-25에서 동일한 성능을 달성하도록 모델들을 훈련하였다. 이 경우, SFT는 우리 설계의 성능에 맞추기 위해 각각 4.3배, 3.6배, 4.8배의 실제 소요 시간 (wall-clock time)을 필요로 한다. 따라서 이러한 관점에서, 특정 성능을 목표로 할 때 Sleep은 매우 효율적이다.

번역·검증 고지

이 문서는 분석이나 평가를 추가하지 않는 것을 원칙으로 하며, 원문의 주장 강도와 수치를 유지하도록 작성되었다. 한국어 초안 작성과 구조 검수에는 Codex GPT-5.6 을 사용했고, 고정 source hash·원문 보존 부록·역대조 표를 통해 검증했다. 불일치가 있을 때에는 원문이 우선한다.

원문 구조·그림 보존 부록

아래 부록은 고정 원문의 equation, table, figure, caption 과 section 배치를 대조하기 위한 검증판이다. arXiv license; translated derivative and complete source plate are not cleared for public redistribution

Language Models Need Sleep: Learning to Self-Modify and Consolidate Memories

Ali Behrouz[†], Farnoosh Hashemi[‡], Adel Javanmard[†], and Vahab Mirrokni[†]

[†]Google Research

[‡]Cornell University

Abstract

The past few decades have witnessed significant advances in the design of machine learning algorithms—from early studies on task-specific shallow models to more general deep Large Language Models (LLMs). Despite showing promising results in tasks that require instant prediction or in-context learning, existing models lack the ability to continually learn and effectively transfer their temporal in-context knowledge to their long-term parameters. Inspired by human learning process, we introduce a “*Sleep*” paradigm that allows the models to continually learn, distill their short-term fragile memories into stable long-term knowledge with replay, and recursively improve themselves with “*Dreaming*” process. In more detail, sleep consists of two stages: (1) **Memory Consolidation**: an *upward* distillation process, called *Knowledge Seeding*, where the memories of a *smaller*-self are distilled into a *larger* network to provide more capacity while preserving the knowledge. As a proof of concept, we present a new *Generalized Distillation* process for Knowledge Seeding (i.e., the combination of on-policy distillation with Reinforcement Learning (RL)-based imitation learning); (2) **Dreaming**: a self-improvement phase, where the model uses RL to generate a curriculum of synthetic data to rehearse new knowledge and refine existing capabilities without human supervision. Our experiments on long-horizon, continual learning, knowledge incorporation, and few-shot generalization tasks support the importance of the sleep stage.

1 Introduction

The development of Large Language Models (LLMs) marks a pivotal milestone in machine learning research: a paradigm shift from task-specific models to more general-purpose systems with various emergent capabilities (Brown et al. 2020; Schaeffer et al. 2023). Despite LLMs’ remarkable capabilities in diverse sets of tasks (Nijkamp et al. 2023; Wang et al. 2023; Comanici et al. 2025), they are largely static after their initial deployment, meaning that they successfully perform tasks learned during pre- or post-training, but are unable to *continually acquire* new capabilities beyond their immediate context. This inherent static nature creates a crucial vulnerability: The model’s knowledge and skills become progressively stale, operating with a fixed “knowledge cutoff” date beyond which it is unaware of new facts, events, and evolving information (Cheng et al. 2024).

Efforts to overcome this limitation have primarily focused on: (1) re-pretraining on an expanded dataset, which despite its effectiveness, is computationally expensive and impractical for frequent updates (Ibrahim et al. 2024); (2) using expensive continual parameter updates or other lightweight alternatives, such as fine-tuning or low-rank adaption (Hu et al. 2022; Akyürek et al. 2024a), which with iterative updates often results in Catastrophic Forgetting (CF) (Kemker et al. 2018; Shi et al. 2024)—a well-known phenomenon where the model’s proficiency on original tasks degrades catastrophically as it learns new ones. This dilemma—between knowledge obsolescence on one hand and catastrophic forgetting as well as the prohibitive cost or destructive nature of updates on the other—underscores a critical, unresolved challenge: enabling LLMs to learn incrementally and efficiently throughout their lifecycle.

In recent years, In-Context Learning (ICL) (Brown et al. 2020) has gained attention as a highly efficient and successful form of continual learning (Akyürek et al. 2022, 2024b; Dong et al. 2024; Li et al. 2025). Initially, ICL was known as an emergent ability of LLMs that is trained on large scale data, enabling them to adapt fast to the context and so perform zero- or few-shot tasks (Brown et al. 2020). Later, more studies revealed and formalized the role of ICL as a meta-learning process in which the model performs internal computations along the sequence to incorporate context knowledge to its output by keeping or compress it into a short-term memory (Behrouz et al. 2025; Dherin et al. 2025). Despite the effectiveness/efficiency of ICL

[§]Correspondence to: {alibehrouz, adeljavanmard, mirrokni}@google.com and sh2574@cornell.edu.

^{*}A version of this work has been publicly available from September 2025 on OpenReview.




Figure 1: **(Conventional Machine Learning vs. Continual Learning)** While in conventional machine learning often the lifespan of the model is divided to *test and training time*, continual learning setup does not have these phases. We suggest that a continual learner need to have different stages of activeness in learning, which we refer to as: (i) *Active or Wake Time*, and (ii) *Sleep Time*. Sleep time is not a passive state, rather it internally process the data to consolidate the memories from fast unstable modules to more stable low frequency (slow) components.

as a form of continual learning, it is limited to the context-window of sequence models, meaning that any new acquired knowledge will be removed from the model at the end of the session/context. This perspective raises a critical question: *How the model can effectively transfer the fragile short-term memories into more stable long-term knowledge?*

As an analogy, we use the example of anterograde amnesia for LLMs from Behrouz et al. (2025): Consider an impairment in the process of transferring the information from short-term to longer-term memories in humans, example of which is anterograde amnesia—a neurological condition where a person cannot form new memories after the onset of the disorder, while existing memories remain intact (Scoville et al. 1957). Such conditions can limit the person’s knowledge to immediate present that fits in the short-term memory and long past, before the onset of the disorder, resulting in continuously experiencing the immediate present as if it were always new. One might notice a similar pattern in the memory processing of current Transformer-based LLMs. The knowledge of LLMs are limited in either: (1) the immediate context that fits into their context window (a.k.a. in-context learning), or (2) MLP and projection layers, storing long-past, before the onset of “end of pre-training.” This similarity in pattern motivates us to ask, *What is the critical component in human learning process that consolidates memories?*

The human brain is highly efficient, lossy but effective when it comes to consolidating memory, which is often attributed to neuroplasticity—the brain’s ability to change itself in response to new experiences, memories, and learning (Pascual-Leone et al. 2005; Johnston 2009). Recent studies support that long-term memory formation involves at least two distinct but complementary consolidation processes (Frey et al. 1997; Goto et al. 2021; Yang et al. 2024): (1) A rapid “online” consolidation phase occurs immediately or soon after learning, even during wakefulness. This is when new fragile memory traces are stabilized and begin transferring from short-term to more longer-term storage; (2) An “offline” consolidation (also known as systems consolidation) process repeats the replay of the recently encoded patterns during sleep and reorganizes the memory and supports transfer to cortical sites (Foster et al. 2006; Ji et al. 2007; Peyrache et al. 2009).

Online Consolidation in Humans (in Active Stage)

Online consolidation in humans is the active, wake-state strengthening and transformation of a newly learned memory by reactivating the memory during recall, making it more stable and more semantic-like over time.

Offline Consolidation in Humans (in Sleep and Quiet Rest Stages)

Offline consolidation in humans occurs after learning during rest or sleep, when a newly encoded memory is stabilized and gradually transformed into a more distributed neocortical representation by a complex lossy distillation process.

Returning to the analogy of anterograde amnesia, the evidence indicates that the condition can affect both stages. Behrouz et al. (2025), recently, presented the Nested Learning (NL) paradigm and aimed at the first form of memory consolidation (i.e., online consolidation). In particular, NL-based Hope architecture (see Figure 1) with the reactivation of the memory in a continuum memory system, where each component is updated with a different frequency but in an end-to-end manner, transfers the knowledge from fast unstable components to more stable low frequency modules in an online manner. Although this end-to-end process can directly transfer the knowledge to more stable components and so *postpone* forgetting, it still uses the same amount of model’s capacity. This mainly happens due the fact that the model does keep the knowledge at the same level of abstraction without any additional lossy compression. Furthermore, this form of consolidation is not enough for robust continual learning: **(i)** Is selective and retrieval-dependent: it depends on active retrieval and so strengthens the parts of a memory that are repeatedly recalled; **(ii)** Depends on the context: the update caused by the online consolidation is based only on the context of the model, and so misses the higher-level understanding of new knowledge with existing one. In this paper, we focus on the second type of consolidation: i.e., offline consolidation via sleep, which is inspired by the sleep stage in humans:

The Role of Sleep in Human Learning Process

Sleep is not a passive state but a dynamic and highly structured period of brain activity essential for cognitive function (Rasch et al. 2013; Goldstein et al. 2014). During sleep, the brain orchestrates complex processes fundamental to learning, neural plasticity, self-improvement, and memory consolidation (Wamsley et al. 2011; Rasch et al. 2013; Goldstein et al. 2014). In humans, these processes are primarily governed by two critical and alternating stages of sleep: Rapid Eye Movement (REM) and Non-REM (NREM) sleep.

Non-Rapid Eye Movement Sleep (Slow-Wave Sleep): This stage, particularly its deepest phase known as slow-wave sleep, is characterized by synchronized, high-amplitude, low-frequency neural activity. Slow-wave sleep is associated with two primary functions crucial for learning: The first is synaptic homeostasis, a process that globally downscales synaptic strengths to counteract the net increase in connectivity from waking experiences, thereby maintaining metabolic balance and preventing neural saturation (Tononi et al. 2006).

The second core function is memory consolidation, the transformation of fragile, recent experiences into stable, long-term knowledge (Squire et al. 1995). This process is orchestrated through a sophisticated dialogue between the hippocampus and the neocortex (Squire et al. 2015). The hippocampus serves as a high-fidelity temporary storage system, capable of rapidly encoding specific daily experiences. In contrast, the neocortex is a vast, long-term repository better suited for the gradual learning of generalized rules and semantic knowledge from these experiences (Squire et al. 1995, 2015). During slow-wave sleep, the brain initiates a nightly dialogue between these structures that facilitates an intricate transfer of information. Notably, this transfer does not simply replay raw data; instead, it re-architects the knowledge acquired during waking hours, extracting abstractions and integrating them into a cohesive semantic network.

Rapid Eye Movement Sleep: Characterized by high-frequency, low-amplitude brain waves that resemble an awake state, REM sleep is most commonly associated with dreaming. Functionally, this stage is linked to the selective strengthening of newly formed synapses and the integration of new information with pre-existing emotional and semantic networks. Furthermore, it is hypothesized to play a role in simulating future scenarios to improve adaptive behavior.

In summary, the cyclical alternation between NREM and REM stages throughout the night is crucial. NREM sleep appears to consolidate and prune the day’s experiences to build a more efficient knowledge base. Subsequently, REM sleep seems to operate on this refined base, exploring novel connections and strengthening salient neural pathways.

No Training or Test Time in Continual Learning

For a continual learner, there is no boarder and clear distinction between training and test time. The model only experiences two different states: when it receives information as input, or when it is an isolated learning system.

Active (Wake) and Sleep Phases in Continual Learning

In the active or wake time, continual learner receives new input data and process it as needed. In the sleep time, however, the model receives minimal (or none) input data and focus on processing existing knowledge to consolidate memories and self-improve.

Contributions

Inspired by the memory processing in humans, we argue that for a continual learner, there is no train or test time. Instead, the model needs to periodically have two phases of being "active" or "Sleep"; In the active state, the model receives new data and processes it, while in the sleep phase the focus is on the internal knowledge and the consolidation of recent memories. To this end, we introduce an instance of "sleep" paradigm for LLMs that consists of two integrated phases:

- i **Memory Consolidation:** To mitigate catastrophic forgetting (CF) and to capture higher-levels of abstraction, in the memory consolidation phase, the model uses a periodic process in which it activates/unlocks new parameters and distills the knowledge from higher-frequency (i.e., faster updating) layers/modules to the newly unlocked parameters in more stable (lower-frequency) layers/modules. This process allows enough plasticity for new parameters while ensuring the stability of old parameters, preserving the old knowledge.
- ii **Self-Improvement via Dreaming:** While the previous first stage of sleep ensures transferring the knowledge abstraction to longer-term memories, this stage is responsible for the process of recursive self-improvement. In particular, given the current state of the model, it generates a set of dreams (i.e., synthetically self-generated data) to improve its own performance with particular focus on the acquiring more proficiency on the recently added knowledge.

From the technical point of view, our contributions to each of the above phases are:

1. **Periodic Parameter (De)Activation:** Building on the Nested Learning (NL) paradigm (Behrouz et al. 2025) that allows each component to have its own frequency of update, we suggest a periodic and gradual parameter (de)activation process, where given a block and for each sleep step, we deactivate a set of parameters in a faster block (i.e., higher frequency block) and replace them with a set of newly activated parameters in the current block. This allows maintaining plasticity while avoiding knowledge interference with previous parameters.
2. **Knowledge Seeding (Upward Distillation):** We present a new form of knowledge transfer, called knowledge seeding, where one or some *smaller* models distill their knowledge to a *larger* model. This design allows the larger model to preserve existing knowledge in smaller models, while taking advantage of its larger capacity. Based on the formulation of Knowledge Seeding (KS), we present self-Knowledge Seeding (SKS), where a smaller version of a model (e.g., some parameters are not active), distill the knowledge to a larger version of the model (e.g., where parameters are active). We then use SKS as a solution for memory consolidation, in which the model distills its knowledge from high-frequency layer/blocks to low-frequency blocks.
3. **Generalized Knowledge Distillation (GKD) with Imitation Learning:** The formulation of SKS is general, and any form of objective and knowledge transfer method can be used. Here, we present a new objective that combines on-policy distillation with an imitation learning process. In particular, in our imitation learning process, we suggest that the teacher (i.e., a smaller version of model with (compressed) privilege information), generates synthetic data and then masks the sequence; Then, the student aims to predict the continuation of the sequence and gets its reward based on the distance of teacher generated data and its own prediction.
4. **Random Expert Selection for Dreaming:** The dreaming phase is responsible for understanding the relationship between different types of knowledge, and so we present a random low-rank expert selection in Mixture of Experts (MoE) (Wu et al. 2024) that aims to mix the knowledge by combining the knowledge of irrelevant experts for output computation.
5. **Experimental Evaluation:** We evaluate the effectiveness of sleep paradigm on a set of challenging downstream tasks: (1) Factual Knowledge Incorporation; (2) Few-shot Learning; (3) Long-context Understanding; and (4) Continual Learning. The results support the effectiveness of Sleep paradigm as well as the importance of growing parameters with iterative knowledge distillation for continual learning.

2 Preliminaries and Problem Formulation

2.1 Notation

We use bold lowercase (resp. uppercase) letters for vectors (resp. matrices) and use subscript t to refer to the state of the entities correspond to time t . Superscripts for parameters of a module (resp. hyperparameters) are used to determine the update frequency of the module (resp. distinguish different instances). Through the paper, we let $x \in \mathbb{R}^{L \times d_{\text{in}}}$ be the input, $\mathbf{K}$ be the keys, $\mathbf{V}$ be the values, $\mathbf{Q}$ be the query matrices in the sequence model, and L denote the sequence length. When it is needed, we parameterize the language model LM_θ with $\theta = \{W_1^{(f_1)}, \dots, W_{k_1}^{(f_1)}\} \cup \{W_1^{(f_2)}, \dots, W_{k_2}^{(f_2)}\} \cup \dots \{W_1^{(f_c)}, \dots, W_{k_c}^{(f_c)}\}$, where parameter sets are sorted based on their weight update frequencies $f_1 \geq \dots \geq f_c$ (see Definition 1).

2.2 Continuum Memory System

Transformer architectures consist of two critical components: (1) Attention module that acts as an associative memory and conditions the output on the past tokens in the context, which also results in in-context learning ability; and (2) MLP or feedforward layers, which are fixed after the training phase and encodes the knowledge acquired over the pre-training. As discussed by Behrouz et al. (2025), one can interpret such architectures as two-level memory systems, in which the attention’s update span is the context length—meaning that at the end of the context, its corresponding parameters are updated and the acquired knowledge is forgotten—and MLP’s update span is non-existence—indicating no update after pre-training. From this perspective, these two components are two extreme sides of the frequency spectrum, where the attention (resp. MLP) has infinite (resp. zero) update frequency.

Building on this intuition, Behrouz et al. (2025) presented Continuum Memory System (CMS), where the architecture is a sequence model such as attention, followed by a chain of MLP layers, each of which updated with its own frequency. More specifically, the time for one step of update in the slowest module is considered as the unit of time, and so the update rate of other components are defined as:

Definition 1 (Update Frequency). *For any weight component of W , we define its frequency, denoted as f_W , as its number of updates per unit of time.*

To better understand this concept, we use a simple example of Fast-weight Programs (Schmidhuber 1992), where the input is a sequence of length L . In this case, for each step of slow-weight (the unit of time), the fast-weight is updated L times, resulting in an update frequency of L .

Following this definition of frequency, which at high-level indicates how often the parameters of a module are updated over time, CMS is formalized as a chain of MLP blocks $\text{MLP}^{(f_1)}(\cdot), \dots, \text{MLP}^{(f_k)}(\cdot)$, each of which is associated with a chunk size of $C^{(\ell)} := \frac{\max_{\ell'} C^{(\ell')}}{f_\ell}$ such that given input $x = \{x_1, \dots, x_T\}$, with each x_t as one of the input data, the output of the chain is calculated as (we disregard normalizations for the sake of clarity):

$$y_t = \text{MLP}^{(f_k)}(\text{MLP}^{(f_{k-1})}(\dots \text{MLP}^{(f_1)}(x_t))), \quad (1)$$

where the parameters of ℓ -th MLP block, i.e., $\theta^{(f_\ell)}$, are updated every $C^{(\ell)}$ steps: i.e., $\theta_{i+1}^{(f_\ell)} = \theta_i^{(f_\ell)} - \mathbf{e}_{i,\ell}$ where:

$$\mathbf{e}_{i,\ell} = \begin{cases} \sum_{t=i-C^{(\ell)}}^i \eta_t^{(\ell)} f(\theta_t^{(f_\ell)}; x_t) & \text{if } i \equiv 0 \pmod{C^{(\ell)}}, \\ 0 & \text{otherwise.} \end{cases} \quad (2)$$

Here $\eta_t^{(\ell)}$ are learning rates corresponds to $\theta^{(f_\ell)}$, and $f(\cdot)$ is the error component of an arbitrary optimizer (e.g., $\nabla \mathcal{L}(\theta_t^{(f_\ell)}; x_t)$ in gradient descent) in an end-to-end optimization of the neural network. The formulation of CMS is very broad and, depending on the task, the objective $\mathcal{L}(\cdot)$ can be changed (the same as the MLP blocks in Transformers). Due to this generality of formulation and being the superset of Transformers design (i.e., 1 MLP blocks will be equivalent to Transformers), throughout the paper, we use CMS as the default building blocks of the architectures. Also, for the sake of clarity and without loss of generality, we assume that $C^{(\ell)}$ is divisible by $C^{(\ell-1)}$. It is notable that Equation 2 provides an important interpretation: parameters $\theta_t^{(f_\ell)}$ are responsible for compressing their own context into the their parameters and so they are a representative of abstract knowledge of their context (We refer to the Nested Learning paper (Behrouz et al. 2025) for more details).

In summary, in this perspective, the sequence model (e.g., attention (Vaswani et al. 2017) or other memory modules or RNNs (Katharopoulos et al. 2020; Behrouz et al. 2024)) acts as the short-term memory of the model since their high-frequency update can push the old knowledge to be forgotten, making space for new memories. On the other hand, CMS blocks act as a spectrum of memory modules, in which earlier blocks (higher-frequency) are shorter-term memories, while later blocks (and ultimately the last one with close to zero frequency) are longer-term memories. While actively updating this memory system can enhance the resistance to CF, the CF can happen when the update period of all models matched at some point (Behrouz et al. 2025). Therefore, it is crucial that before each update of a memory block, a mechanism consolidates the abstracted knowledge of that block to more stable parameters.

2.3 Sleep Terminology in the Literature

The human sleep process has been an inspiration for the design of many studies in the literature (McClelland et al. 1995; Kumaran et al. 2016; Hassabis et al. 2017; Ha et al. 2018b). In particular, “dreaming” has motivated several past studies in the literature to design methods that replay recent experiences/input data (Lin 1992; Mnih et al. 2015; Ha et al. 2018a,b). Several studies designed an offline process that can make the model more robust for long-horizon tasks (González et al. 2020; Hafner et al. 2020; Tadros et al. 2022). Lin et al. (2025) suggest an offline self-study process as a form of “sleep-time compute” that summarizes the past context for the next user session, mainly is designed as a proposal for spending compute on the context rather than training the model itself.

To the best of our knowledge, the existing literature (including sleep-inspired studies) remains firmly anchored in the conventional distinction of training and testing phases. Even in the continual or online learning setups, models alternate between updating parameters (training) and evaluating performance (testing). We argue that for lifelong adaptation, the static train/test paradigm needs to be replaced with a continuous periodic “wake” and “sleep” lifecycle. During the “wake” phase, the model is actively interacting with varying input data and rapidly acquiring temporary information while during the “sleep” phase, the model consolidates its memory and internally processes existing knowledge.

3 The Sleep Paradigm

3.1 Learning Phases in Continual Learning

As discussed earlier, a continual learner is always learning from the data/experience. Therefore, the conventional split of the machine learning models’ lifecycle (i.e., test and train time) is not directly applicable in the continual learning setup. We suggest the use of “active or wake” time and “sleep” time as the two critical phases of a lifecycle of a continual learner. In particular, in the active or wake time, continual learner receives new input data and process it as needed. In the sleep time, however, the model receives minimal (or none) input data and focus on processing existing knowledge to consolidate memories and self-improve.

However, the process of memory consolidation is not limited to the sleep phase. In fact, following the discussion in Nested Learning (NL) (Behrouz et al. 2025), there are two forms of memory consolidations: (1) Online consolidation; and (2) Offline consolidation:

Online Consolidation in Neural Networks in Active (Wake) Stage

Online consolidation happens through the end-to-end learning process of neural learning modules (e.g., Hope architecture in Figure 1) in the wake or active phase, where earlier layers (faster blocks with higher frequency) transfer their knowledge to later layers (i.e., slower blocks with lower frequency).

Offline Consolidation in Neural Networks in Sleep Stage

In offline consolidation phase, the model enters the sleep phase, where it stops processing new data, but uses self-generated data to consolidate the recent memories.

In the next section, we present Sleep paradigm, in which contrary to the model’s waking time (or active time), the model does not receive any external input data and concentrates its internal computations on self-improvement, consolidating




Figure 2: An overview of Memory Consolidation. The model increases its own number of parameters to enhance its capacity (Section 3.2), and then using the knowledge seeding, it transfers the knowledge abstractions from the higher to a lower-frequency memory (Section 3.3).

the past memories, and abstracting knowledge. In particular, we divide the sleep process into two key stages: (1) Memory consolidation; and (2) Dreaming for self-improvement.

3.2 Memory Consolidation: Parameter Expansion

As discussed earlier, in memory consolidation, we aim to transfer the short-term fragile memories into more vast and stable parameters. One of the important messages in CMS formulation is: the fragility and/or stability of memories are relative. That is, for each memory block, other higher frequency memories are shorter-term and more fragile. Therefore, memory consolidation is not a simple two-step process, but an iterative operation that repeatedly transfers the knowledge stored in higher frequency memories into more stable lower-frequency parameters.

To avoid losing the knowledge of a faster updating block; an example of which is in-context learning (Brown et al. 2020), we need to perform memory consolidation step before updating its parameters. Therefore, given the list of chunk lengths $\{C^{(1)}, \dots, C^{(k)}\}$, the sleep process and so memory consolidation happens only at $\{C^{(1)} \times b, \dots, C^{(k)} \times b\}$ steps for all $b \in \mathbb{N}$. Based on the update frequency of MLP blocks, we might need to consolidate the memory of a memory module into its next memory block multiple times. For example, consider a memory with update frequency of 1K followed by a memory with update frequency of 10K: in this case, the faster memory is updated 10 times before the update of slower memory block, which means 10 memory consolidation steps of faster memory to slower memory before slower memory’s own update. This multiple consolidation steps into the slower memory can be a critical bottleneck to unlock continual learning capabilities of LLMs, due to the Catastrophic Forgetting (CF). This phenomenon is an inherent cause of model’s limited capacity (e.g., number of parameters), where parameters need to be overridden to incorporate the new knowledge. The foundation of human’s brain solution to this challenge is neuroplasticity, the brain’s inherent ability to modify its own function and shape new connections in response to experiences. Inspired by this, we present an efficient gradual parameter expansion in memory blocks that allows the model to shape new connections and so increases its own capacity.

Without loss of generality, we assume that the MLP blocks $\{\text{MLP}^{(f_\ell)}(\cdot)\}_{\ell=1}^k$ are sparse mixture of experts (MoEs) with a router $\mathcal{R}^{(f_\ell)}$: i.e., each $\text{MLP}^{(f_\ell)}(\cdot)$ includes a set of experts $\{W^{(f_\ell),1}, \dots, W^{(f_\ell),s_\ell}\}$, where $s_\ell \geq 1$ is the current number of experts in the ℓ -th block of the chain. Let $(\ell^* - 1)$ be the index of the memory (or MLP) that we aim to consolidate its knowledge to its immediate next more stable memory module with index ℓ^* . To avoid the interference of transferred and previously stored knowledge in $\text{MLP}^{(f_{\ell^*})}(\cdot)$, we add a new low-rank expert to its set of parameters. That is, we add a low-rank MLP parametrized by $\{\mathbf{A}^{(f_{\ell^*}),s_{\ell^*}+1}, \mathbf{B}^{(f_{\ell^*}),s_{\ell^*}+1}\}$, where $\mathbf{A}^{(f_{\ell^*})} \in \mathbb{R}^{d \times d_{\text{low}}}$ and $\mathbf{B}^{(f_{\ell^*})} \in \mathbb{R}^{d_{\text{low}} \times d}$ ($d_{\text{low}} \ll d$), to the set of experts. These new parameters will be allocated for storing the new transferred knowledge from $\text{MLP}^{(f_{\ell^*-1})}(\cdot)$. Given this process, after each sleep time, the parameters of a subset of layers are growing.

3.3 Memory Consolidation with Knowledge Seeding

In this step, we aim to transfer the knowledge of $\text{MLP}^{(f_{\ell^*-1})}(\cdot)$ with parameters $\theta^{(f_{\ell^*-1})}$ into the expanded set of parameters in $\text{MLP}^{(f_{\ell^*})}(\cdot)$. Since sleep is triggered when the number of past steps is divisible by C^{ℓ^*-1} , the sender block $\text{MLP}^{(f_{\ell^*-1})}(\cdot)$ is scheduled for a base-weight update at this time. The consolidation procedure follows a compute-consolidate-update protocol:

(a) *Compute*. The base-weight update for the sender is computed from the accumulated gradients (Equation (2)), yielding prospective new parameters $\theta^{(f_{t^*-1})}$. Crucially, this update is computed but not yet applied to the running model.

(b) *Consolidate*. We define:

- **Teacher (LM_θ)**: the state of the model before the base-weight update or parameter expansion — i.e., $\text{MLP}^{(f_{t^*})}(\cdot)$ still uses its original parameters $\theta^{(f_{t^*-1})}$ plus its accumulated experts;
- **Student ($\text{LM}_{\theta_{\text{exp}}}$)**: the state of the model using the prospective updated parameters $\theta_{\text{new}}^{(f_{t^*-1})}$ (with experts in $\text{MLP}^{(f_{t^*-1})}(\cdot)$ reset), and with a newly added low-rank expert A, B in $\text{MLP}^{(f_{t^*})}(\cdot)$.

The low-rank parameters $\{A, B\}$ are then optimized via the Knowledge Seeding objective (defined below) to minimize the distillation loss between teacher and student.

(c) *Update*. After the optimal A, B are found: (a) the base-weight update $\theta^{(f_{t^*-1})} \rightarrow \theta_{\text{new}}^{(f_{t^*-1})}$ is applied, (b) the low-rank experts previously added to $\text{MLP}^{(f_{t^*-1})}(\cdot)$ are reset (synaptic pruning), and (c) the new expert $\{A, B\}$ is activated in $\text{MLP}^{(f_{t^*})}(\cdot)$.

This ordering ensures that the prospective weights $\theta_{\text{new}}^{(f_{t^*-1})}$ are available for defining the student model at step 2, while the teacher still faithfully reflects the pre-update state. We model this as a distillation problem: transferring the knowledge stored in the smaller-state teacher LM_θ to the larger-capacity student $\text{LM}_{\theta_{\text{exp}}}$.

Knowledge Seeding. We present a new form of knowledge transfer, called knowledge seeding, where one or some *smaller* models distill their knowledge to a *larger* model. This design allows the larger model to preserve existing knowledge in smaller models, while taking advantage of its larger capacity.

Upward Distillation (Knowledge Seeding)

Given a set of small models $\mathcal{S}_1(\cdot), \dots, \mathcal{S}_k(\cdot)$ as the teacher, Knowledge Seeding (KS) aims to transfer the knowledge in these models to a larger model $\mathcal{M}(\cdot)$.

Based on the formulation of Knowledge Seeding (KS), we present self-Knowledge Seeding (SKS), where a smaller version of a model (as discussed above) distills the knowledge to a larger version of the model. This distillation process has two critical challenges: (1) Contrary to conventional cases, student has more capacity and so more expressive power than the teacher. Therefore, training the student on the teacher generated dataset (e.g., Kim et al. (2016)) can result in sub-optimal use of parameters in student model; (2) The model is in sleep stage and so the access to the external information/dataset is limited. Therefore, most popular methods like Hinton et al. (2015) are not applicable. To overcome these challenges, we build upon Generalized Knowledge Distillation (GKD) (Agarwal et al. 2024), which allows a mixture of on-policy student generated data with a teacher-generated data, and present a novel distillation process based on imitation learning.

As discussed earlier, the memory consolidation step should not simply replay raw data; instead, it needs to explore and extract abstractions of knowledge acquired during active (waking) steps. To this end, knowledge seeding has two main steps: (1) A distillation process, in which student receives token-specific feedback from the teacher’s logits on the self-generated sequences; and (2) An RL-based imitation learning method that forces the student to memorize the sampled outputs of teacher, aligning their sampling process while preserving the distilled knowledge.

We start with constructing a dataset $\mathcal{D}$ by sampling from the teacher model, i.e., LM_θ . Next, similar to GKD (Agarwal et al. 2024), we define on policy distillation objective as:

$$\mathcal{L}(\theta, \theta_{\text{exp}}) = (1 - \lambda) \mathbb{E}_{(x, y) \sim \mathcal{D}} \left[\mathcal{F}(\text{LM}_\theta \| \text{LM}_{\theta_{\text{exp}}})(y|x) \right] + \lambda \mathbb{E}_{x \sim \mathcal{D}} \left[\mathbb{E}_{y \sim \text{LM}_{\theta_{\text{exp}}}(\cdot|x)} \left[\mathcal{F}(\text{LM}_\theta \| \text{LM}_{\theta_{\text{exp}}})(y|x) \right] \right].$$

where $\mathcal{F}(\text{LM}_\theta, \text{LM}_{\theta_{\text{exp}}})(y|x)$ is a divergence between teacher (i.e., LM_θ) and student (i.e., $\text{LM}_{\theta_{\text{exp}}}$) output distributions, and $\lambda \in [0, 1]$ controls the fraction of on-policy student-generated outputs. In this optimization process, we do not backpropagate through the sampling distribution of the student, which can help with training stability and also speed. Also, we freeze all the parameters in the student model and only updates the expanded parameters. This ensures that the transferred knowledge does not interfere with the old knowledge, causing catastrophic forgetting.

Learning to Imitate. The above distillation process ensures that the student new parameters store the knowledge encoded in the lower-frequency memory. However, we observe that despite having access to the knowledge, the student model

has not learned to use it and so weakly mimics the sampling and performance of the teacher. To this end, we further improve the above distillation process by incorporating RL to teach model how to imitate the teacher sampling. Given a set of teacher generated data (dreams), $\mathcal{D}_T = \{d^{(1)}, \dots, d^{(n)}\}$, Learning to Imitate (LTI) process first randomly samples a prefix from each $d^{(i)}$ and then asks the student model to complete the continuation. Given the student responses $\hat{d}^{(i)}$ the assigned reward is defined as:

$$r(\hat{d}^{(i)}; d^{(i)}; \text{LM}_{\theta_{\text{exp}}}) = \gamma \times r_{\text{sem}}(\hat{d}^{(i)}; d^{(i)}; \text{LM}_{\theta_{\text{exp}}}) + (1 - \gamma) \times r_{\text{abs}}(\hat{d}^{(i)}; d^{(i)}; \text{LM}_{\theta_{\text{exp}}}), \quad (3)$$

where $r_{\text{sem}}(\cdot; \cdot; \cdot)$ (resp. $r_{\text{abs}}(\cdot; \cdot; \cdot)$) assigns a reward based on the semantic similarity (resp. absolute token-level similarity). For semantic similarity, we use a reward model that is frozen and rewards the student with 1 (resp. 0), if the semantic of $\hat{d}^{(i)}$ and $d^{(i)}$ are the same (resp. otherwise). On the other hand, absolute reward is defined based on the Levenshtein distance of the two sequences (denoted by $z(\cdot, \cdot)$): i.e., $r_{\text{abs}}(\hat{d}^{(i)}; d^{(i)}; \text{LM}_{\theta_{\text{exp}}})$ is defined as:

$$r_{\text{abs}}(\cdot) = \begin{cases} 1 - \frac{z(\hat{d}^{(i)}, d^{(i)})}{\max\{|\hat{d}^{(i)}|, |d^{(i)}|\}} & \text{if } z(\hat{d}^{(i)}, d^{(i)}) \leq z_0, \\ 0 & \text{otherwise,} \end{cases} \quad (4)$$

where z_0 is a similarity threshold. By incorporating the above LTI process to on-policy distillation, our on-policy knowledge seeding (KS) objective is defined as:

$$\mathcal{L}_{\text{KS}}(\theta, \theta_{\text{exp}}) = \mathbb{E}_{x \sim \mathcal{D}} \left[(1 - \alpha) \mathbb{E}_{y \sim \text{LM}_{\theta_{\text{exp}}}(\cdot|x)} [r(y)] - \alpha \mathbb{E}_{y \sim \text{LM}_{\theta_{\text{exp}}}(\cdot|x)} [\mathcal{D}(\text{LM}_{\theta} \parallel \text{LM}_{\theta_{\text{exp}}})(y|x)] \right].$$

where $\alpha \in [0, 1]$ controls the strength of the distillation compared to the LTI objective. Based on this objective, we update the new expanded parameters of the model and consolidate the memory/knowledge of high frequency memory into lower-frequency memory blocks. Now that the memories in $\text{MLP}^{(f_{e^*-1})}(\cdot)$ are consolidated in $\text{MLP}^{(f_{e^*})}(\cdot)$, we reset all the low-rank parameters that previously (in past sleep periods) have been added to $\text{MLP}^{(f_{e^*-1})}(\cdot)$, making its capacity available for future. This step, can be interpreted as a similar procedure of synaptic pruning in human brain, in which brain prunes connections that are unnecessarily and/or redundant (Li et al. 2017) to enhance its efficiency and performance.

Note on the Implementation. Implementing the growing sparse modules can be extremely challenging if it requires a direct change in the dimensionality of tensors in the implementation. Alternatively, we can initially have those parameters in the model, but masked them in the forward and backward pass, before their initial activation in a sleep stage. Interestingly, it also aligns with our understanding of human brain, where brain has (large but) fixed capacity and new components are not added over time. Instead, new connections between brain regions can shape through our life, unlocking the activation of new neurons and resulting in more plasticity to learn new tasks (Kandell et al. 2021).

3.4 Dreaming: A Self-Modifying Process

The previous stage, which involved freezing higher-frequency parameters and distilling their knowledge to lower-frequency memories acts similar to slow-wave stage of sleep (NREM) in humans, which is responsible for memory consolidation. In REM stage, however, the brain is highly active (even on par with waking time) and aims to self-modify and strengthen newly formed synapses by dreaming. Inspired by this, we aim to design a dreaming process that learns how to generate dreams (synthetic data) that can help itself to improve over time.

In practice, any synthetic data generation process for self-improvement (e.g., Pang et al. (2024a), Huang et al. (2025), and Zweiger et al. (2025)) can be incorporated in this stage. A critical consideration, however, is the risk of iteratively applying self-improvement in continual learning setup, which might cause catastrophic forgetting (Zweiger et al. 2025). In our evaluation, we show that how our two-step design of sleep as memory consolidation and then dreaming as self-modifying process is more robust to catastrophic forgetting. As a proof of concept, we build upon the work of Zweiger et al. (2025), SEAL; however, there are three challenges to incorporate it in our sleep paradigm: (1) Due to the cost of supervised fine-tuning (SFT) in SEAL’s inner-loop, it is limited to small number of self-edits (dreams in our terminology). (2) Potential catastrophic forgetting as the cause of iterative self-improvement in sleep periods. (3) The sampling process only samples from the existing knowledge space of the model, while one of the key roles of dreaming is to explore novel synthesis of memories (Stickgold 2005).

Given a sampled task (C, τ) , where C is the context containing information relevant to the task and $\tau(\cdot)$ is a measure to assess the performance in the downstream evaluation, our “dreaming” process starts with generating $m \geq 1$ dreams




Figure 3: Class-incremental learning for text classification is evaluated on the (Left) CLINC dataset (Larson et al. 2019), (Middle) Banking dataset (Casanueva et al. 2020), and (Right) DBpedia dataset (Auer et al. 2007). The HOPE architecture consistently outperforms other continual learning approaches, achieving the highest accuracy.




Figure 4: Effect of memory levels on in-context learning performance for (Left) MK-NIAH from RULER (Hsieh et al. 2024), (Middle) LongHealth (Adams et al. 2025), and (Right) QASPER (Dasigi et al. 2021). Lower values indicate better performance for QASPER.

with having C in context. In the sampling process, each router in MoE blocks additionally chooses a random expert and so incorporates random irrelevant knowledge to the dreaming, learning the underlying patterns that are hidden from model’s sight. For this step, we let $\{\text{DREAM}^{(i)}\}_{i=1}^m \sim \text{LM}_{\theta}(\cdot|C)$. Next, we reject some of the generated dreams and only keeps the samples with the most potential in improving the model’s performance. To this end, we take inspiration from the literature on gradient-based data selection (Pan et al. 2024; Wang et al. 2024a): for each dream, $\text{DREAM}^{(i)}$, we assign an importance score $\omega^{(i)}$ and select Top- k dreams with highest importance score along with b random samples to maintain diversity. Given language modeling objective $\mathcal{L}_{\text{SFT}}(\cdot)$, we define importance score of $\text{DREAM}^{(i)}$, denoted as $g_{\text{DR}}^{(i)}$, as the gradient of the objective: $g_{\text{DR}}^{(i)} = \nabla_{\theta} \mathcal{L}_{\text{SFT}}(\text{DREAM}^{(i)}, \theta)$. We let D be the set of all selected dreams by the above process. For each $\text{DREAM}^{(i)} \in D$ we consider an isolated instance of the model and updates its parameters via supervised finetuning (with LoRA (Hu et al. 2022)): i.e., $\theta'^{(i)} \leftarrow \text{SFT}(\theta^{(i)}, \text{DREAM}^{(i)})$. Given the new fine-tuned model, following SEAL (Zweiger et al. 2025), we reward the generation of $\text{DREAM}^{(i)}$ based on $\text{LM}_{\theta'^{(i)}}$ ’s performance improvement over $\text{LM}_{\theta^{(i)}}$:

$$r\left(\text{DREAM}^{(i)}, \tau(\cdot), \text{LM}_{\theta^{(i)}}\right) = \begin{cases} 1 & \text{If improves,} \\ 0 & \text{Otherwise.} \end{cases} \quad (5)$$

We follow SEAL and use ReST^{EM} algorithm (Singh et al. 2024a) to optimize the above process.

4 Empirical Results

In our empirical evaluation, we study the effect of each stage of the sleep and also all the stages together. In the first section, we focus on the memory consolidation, which is designed with the goal of enhancing the continual learning abilities and long-context understanding. See Appendix B for additional experimental results.

4.1 The Effect of Memory Consolidation

One of the main goals of memory consolidation process is to improve continual learning while strengthening long-context understanding. In this section, we evaluate *only* memory consolidation phase (without self-improvement) on continual-learning and long-context benchmarks.

Class Incremental Learning. We first focus on class-incremental learning on three datasets of CLINC (Larson et al. 2019), Banking (Casanueva et al. 2020), and DBpedia (Auer et al. 2007) (see Section B.1 for the details). We use Llama-3B and Llama3-8B (Dubey et al. 2024) as the backbones. HOPE is augmented with our memory consolidation mechanism, which improves abstraction via on-policy self-distillation. Following Momeni et al. (2025) we compare against ICL (same continual pre-training process but without sleep), Elastic Weight Consolidation (EWC) (Kirkpatrick et al. 2017), and In-context Continual Learning with an External Learner (InCA) (Momeni et al. 2025). We also include Hope (Behrouz et al. 2025) as a multi-level in-context updating baseline without explicit distillation process. Results in Figure 3 show that HOPE performs best across datasets, including over external-learner (InCA) and regularization (EWC) approaches. Relative to ICL, gains come from converting prompt-level adaptation into durable parametric memory through consolidation. Relative to Hope, explicit self-distillation yields better abstractions than repeated in-context updates alone.

The Effect of Levels (#Sleep Phases) on In-context Learning. To better isolate how HOPE’s consolidation schedule impacts in-context learning and long-context understanding, we evaluate question answering and multi-key retrieval under long contexts. We use LongHealth (Adams et al. 2025), QASPER (Dasigi et al. 2021), and MK-NIAH (Hsieh et al. 2024) datasets (see Section B.1). As baselines, we use ICL, DuoAttention (Xiao et al. 2025), and Cartridges (Eyuboglu et al. 2025). For HOPE variants, we vary the sleep schedule by changing (i) how many consolidation stages are used and (ii) the persistence of the most stable memory, operationalized by the lowest consolidation frequency. Intuitively, a lower frequency yields more persistent but less adaptive long-term memory. Results are reported in Figure 4. Across all tasks, HOPE consistently outperforms ICL and the efficient DuoAttention baseline, showing that sleep-time consolidation improves long-context behavior beyond prompt-only adaptation. We also observe that HOPE outperforms Cartridges (Eyuboglu et al. 2025): while Cartridges improves efficiency by using an auxiliary model to compress KV representations, HOPE instead performs on-policy self-distillation during sleep, consolidating newly acquired information into transferable parametric knowledge and yielding more robust long-context understanding. Comparing HOPE variants with each other, we find two consistent trends: (1) increasing the number of consolidation stages improves in-context learning and long-context understanding, supporting the view that sleep enables better knowledge abstraction and compression, allowing the model to retain more information with fewer effective parameters; and (2) increasing the lowest frequency reduces performance, suggesting that making the most persistent memory more adaptive weakens retention.




Figure 5: Continual Translation of a Novel Language (CTNL) task. Red points show performance when training on a single language, whereas blue points show performance under continual learning.




Figure 6: Results on the BABILong benchmark. Red points correspond to fine-tuned models, whereas blue points correspond to zero-shot evaluations of large-scale models.

Table 1: Performance of different methods on mathematical reasoning benchmarks. We use different variants of Qwen models and report average@16.

Method	AIME-24	AIME-25	HMMT-25
<i>Qwen3-8B</i>			
Sleep	79.2	69.0	46.1
- Imitation Learning	76.8	67.9	45.0
- Semantic Reward	78.9	69.2	44.5
- w/o Expansion	78.2	67.9	44.9
OPSD	76.6	67.4	45.1
+ Expansion	77.9	68.2	45.9

Learning a New Language In-Context. LLMs often fail in continual settings, where models are expected to acquire new skills sequentially without overwriting previously acquired knowledge. To study this challenge, we follow the task introduced by Behrouz et al. (2025), which combines MTOB (Tanzer et al. 2024) and Manchu (Pei et al. 2025) datasets, two translation datasets for unseen languages during pre-training. That is, models are exposed in-context to two previously

unseen languages and must translate phrases into English. We consider two setups: learning and evaluating each language independently, and sequentially learning both languages before evaluating translation performance on each. We compare standard ICL with variants of HOPE that differ in the number of sleep-time consolidation stages, denoted as HOPE-1, HOPE-2, and HOPE-3. Results are shown in Figure 5, where each point reports ChRF scores for Manchu→English (x-axis) and Kalamang→English (y-axis). In the single-language setting, all HOPE variants match or exceed ICL, indicating that consolidation does not hinder in-context adaptation. Under continual learning setup, ICL exhibits a sharp performance drop, largely reverting to pre-trained behavior, whereas HOPE retains substantially more of its gains. Performance improves monotonically with additional consolidation stages, and HOPE-3 nearly recovers its single-language performance despite sequential exposure. These results underscore the role of sleep-time consolidation in continual learning. Unlike ICL’s prompt-level updates, Sleep introduces an explicit self-improvement phase that distills useful abstractions into longer-lasting parametric memory, enabling effective sequential learning without catastrophic forgetting. As another baseline, we also evaluated Cartridges (Eyuboglu et al. 2025) and Supervised Fine-Tuning (SFT) over the languages. Surprisingly, both methods faced catastrophic forgetting in at least one of the languages, performing even weaker than ICL in at least one of the tasks (placing them outside of the plot in Figure 5).

BABILong. We evaluate HOPE (Sleep) on the BABILong benchmark (Kuratov et al. 2024), comparing against: (1) large models (GPT-4 and GPT-4o-mini (Achiam et al. 2023)); (2) a mid-scale Llama-8B model (Dubey et al. 2024) with RAG; and (3) state-of-the-art small long-context models, including RMT (Bulatov et al. 2022), ARMT (Rodkin et al. 2024), and Titans (Behrouz et al. 2024). Detailed discussion on the results can be found in Section B.2. In summary, HOPE achieve almost perfect score in scaling to 10M of tokens.

Memory Consolidation for Reasoning. Another important implication of memory consolidation phase is improving the reasoning capability of the model. In this section, we evaluate its effect of mathematical reasoning and compare it with common baselines of base model, SFT, and GRPO (Shao et al. 2024). The results are reported in Table 2. Our algorithm for memory consolidation performs better than SFT and GRPO for improving the reasoning capabilities of the base model.

Table 2: Performance of different methods on mathematical reasoning benchmarks. We use different variants of Qwen models and report average@16.

Method	AIME-24	AIME-25	HMMT-25
<i>Qwen3-1.7B</i>			
Base (Instruct)	49.8	34.5	25.7
SFT	47.3	36.1	22.9
GRPO	51.0	38.6	26.1
OPSD	51.6	40.0	28.1
Sleep	53.2	40.2	29.3
<i>Qwen3-8B</i>			
Base (Instruct)	73.8	68.1	42.4
SFT	75.5	66.4	43.7
GRPO	76.4	68.1	44.9
OPSD	76.6	67.4	45.1
Sleep	79.2	69.0	46.1

Table 3: Knowledge Incorporation Performance across Passage Settings

Method	Single Passage (n = 1)	Continued Pretraining (n = 200)
Base model	31.9	31.9
Fine-tuned Model with No Dreaming	33.4	32.0
SEAL	46.7	43.2
Sleep (Transformer)	48.1	44.3
Sleep (Transformer + four-level)	48.9	46.2
removing gradient-based selection	47.1	45.2
removing random expert	48.0	44.7
removing Dreaming	35.7	36.2

Table 4: Few-shot Abstract Reasoning

Method	Success Rate (%)
ICL	0
TTT	10
SEAL	72.5
Sleep	80

Knowledge Incorporation. Next, we focus on the full design of Sleep, allowing for self-improvement as well. In this task, we expect the model to be able to answer questions about the incorporated facts. We follow the experimental setup of Zweiger et al. (2025), including the choice of models and parameters, for the sake of fair comparison. We evaluate our model on integrating new factual information from SQuAD dataset (Rajpurkar et al. 2016). As baselines, we use (i) a base model, which is the variant without any improvement or having access to the passage; (ii) a fine-tuned model with no dreaming, (iii) SEAL model with RL and self-adaption; (iv) our Transformer-based architecture with two level memory system; and (v) with four-level memory system.

Table 3 summarizes mean no-context SQuAD accuracy for both the single-passage ($n = 1$) and continued pretraining (CPT, $n = 200$) settings. Our sleep process achieves the best results among other settings and state-of-the-art methods like SEAL. We attribute this results to: (1) memory consolidation steps that let the model store its knowledge more effectively; (2) our improvements on top of the SEAL that we discussed in Section 3.4. In the CPT regime, the model is exposed to $n = 200$ passages during a single continued pretraining run and is evaluated on the full set of 974 associated questions. For each passage, we sample five dreams and combine them into an aggregated synthetic dataset for training. Sleep process achieves the best performance.

Few-Shot Learning. We follow the few-shot ARC experimental protocol from prior work (Akyürek et al. 2024a; Zweiger et al. 2025) and adapting it to our SLEEP paradigm. As the backbone we use Llama-3.2-1B. Following common practice, we filter subset of data to avoid tasks that remain unsolvable under standard configurations, yielding 11 tasks for training and 8 held-out tasks for evaluation. See Section B.3 for the details. In this setting (see Table 4), SLEEP achieves a 80% success rate, higher then the other methods.

4.2 Ablations on the Design Choices

We ablate the design choices for the memory consolidation process on the mathematical reasoning. The results are reported in Figure 1. All the components contribute positively to the performance of our method. We also, further ablate the design choices on self-improvement in Table 3.

5 Conclusion

In this work, we introduced the SLEEP paradigm for Large Language Models, consists of: (i) *knowledge seeding*, an upward distillation that transfers short-term, in-context knowledge into lower-frequency, long-term parameters, and (ii) *dreaming*, self-generated training that improves capabilities while controlling interference. In our experimental results, across long-context understanding, knowledge incorporation, few-shot reasoning, and continual learning, SLEEP yields consistent gains.

References

- [1] William Beecher Scoville and Brenda Milner. “Loss of recent memory after bilateral hippocampal lesions”. In: *Journal of neurology, neurosurgery, and psychiatry* 20.1 (1957), p. 11.
- [2] Jürgen Schmidhuber. *Evolutionary Principles in Self-Referential Learning*. 1987. URL: <https://people.idsia.ch/~juergen/diploma1987ocr.pdf>.
- [3] Long-Ji Lin. “Self-improving reactive agents based on reinforcement learning, planning and teaching”. In: *Machine Learning* 8.3–4 (1992), pp. 293–321.
- [4] Juergen Schmidhuber. “Learning to control fast-weight memories: An alternative to recurrent nets. Accepted for publication in”. In: *Neural Computation* (1992).
- [5] James L. McClelland, Bruce L. McNaughton, and Randall C. O’Reilly. “Why there are complementary learning systems in the hippocampus and neocortex: insights from the successes and failures of connectionist models of learning and memory”. In: *Psychological Review* 102.3 (1995), pp. 419–457.
- [6] Larry R Squire and Pablo Alvarez. “Retrograde amnesia and memory consolidation: a neurobiological perspective”. In: *Current opinion in neurobiology* 5.2 (1995), pp. 169–177.
- [7] Uwe Frey and Richard GM Morris. “Synaptic tagging and long-term potentiation”. In: *Nature* 385.6616 (1997), pp. 533–536.
- [8] Alvaro Pascual-Leone, Amir Amedi, Felipe Fregni, and Lotfi B Merabet. “The plastic human brain cortex”. In: *Annu. Rev. Neurosci.* 28.1 (2005), pp. 377–401.
- [9] Robert Stickgold. “Sleep-dependent memory consolidation”. In: *Nature* 437.7063 (2005), pp. 1272–1278.
- [10] David J Foster and Matthew A Wilson. “Reverse replay of behavioural sequences in hippocampal place cells during the awake state”. In: *Nature* 440.7084 (2006), pp. 680–683.
- [11] Giulio Tononi and Chiara Cirelli. “Sleep function and synaptic homeostasis”. In: *Sleep medicine reviews* 10.1 (2006), pp. 49–62.
- [12] Sören Auer, Christian Bizer, Georgi Kobilarov, Jens Lehmann, Richard Cyganiak, and Zachary Ives. “Dbpedia: A nucleus for a web of open data”. In: *international semantic web conference*. Springer. 2007, pp. 722–735.
- [13] Daoyun Ji and Matthew A Wilson. “Coordinated memory replay in the visual cortex and hippocampus during sleep”. In: *Nature neuroscience* 10.1 (2007), pp. 100–107.
- [14] Michael V Johnston. “Plasticity in the developing brain: implications for rehabilitation”. In: *Developmental disabilities research reviews* 15.2 (2009), pp. 94–101.
- [15] Adrien Peyrache, Mehdi Khamassi, Karim Benchenane, Sidney I Wiener, and Francesco P Battaglia. “Replay of rule-learning related neural patterns in the prefrontal cortex during sleep”. In: *Nature neuroscience* 12.7 (2009), pp. 919–926.
- [16] Erin J Wamsley and Robert Stickgold. “Memory, sleep and dreaming: experiencing consolidation”. In: *Sleep medicine clinics* 6.1 (2011), p. 97.
- [17] Björn Rasch and Jan Born. “About sleep’s role in memory”. In: *Physiological reviews* (2013).
- [18] Andrea N Goldstein and Matthew P Walker. “The role of sleep in emotional brain function”. In: *Annual review of clinical psychology* 10.1 (2014), pp. 679–708.
- [19] Geoffrey Hinton, Oriol Vinyals, and Jeff Dean. “Distilling the knowledge in a neural network”. In: *arXiv preprint arXiv:1503.02531* (2015).
- [20] Volodymyr Mnih, Koray Kavukcuoglu, David Silver, Andrei A. Rusu, Joel Veness, Marc G. Bellemare, Alex Graves, Martin Riedmiller, Andreas K. Fidjeland, Georg Ostrovski, et al. “Human-level control through deep reinforcement learning”. In: *Nature* 518.7540 (2015), pp. 529–533.
- [21] Larry R Squire, Lisa Genzel, John T Wixted, and Richard G Morris. “Memory consolidation”. In: *Cold Spring Harbor perspectives in biology* 7.8 (2015), a021766.
- [22] Yoon Kim and Alexander M Rush. “Sequence-level knowledge distillation”. In: *Proceedings of the 2016 conference on empirical methods in natural language processing*. 2016, pp. 1317–1327.
- [23] Dharshan Kumaran, Demis Hassabis, and James L. McClelland. “What learning systems do intelligent agents need? Complementary learning systems theory updated”. In: *Trends in Cognitive Sciences* 20.7 (2016), pp. 512–534.
- [24] Pranav Rajpurkar, Jian Zhang, Konstantin Lopyrev, and Percy Liang. “SQuAD: 100,000+ Questions for Machine Comprehension of Text”. In: *Proceedings of the 2016 Conference on Empirical Methods in Natural Language Processing*. Ed. by Jian Su, Kevin Duh, and Xavier Carreras. Association for Computational Linguistics, 2016. URL: <https://aclanthology.org/D16-1264/>.

- [25] Chelsea Finn, Pieter Abbeel, and Sergey Levine. “Model-Agnostic Meta-Learning for Fast Adaptation of Deep Networks”. In: *Proceedings of the 34th International Conference on Machine Learning*. Ed. by Doina Precup and Yee Whye Teh. Proceedings of Machine Learning Research. PMLR, 2017. URL: <https://proceedings.mlr.press/v70/finn17a.html>.
- [26] Demis Hassabis, Dhharshan Kumaran, Christopher Summerfield, and Matthew Botvinick. “Neuroscience-inspired artificial intelligence”. In: *Neuron* 95.2 (2017), pp. 245–258.
- [27] James Kirkpatrick, Razvan Pascanu, Neil Rabinowitz, Joel Veness, Guillaume Desjardins, Andrei A Rusu, Kieran Milan, John Quan, Tiago Ramalho, Agnieszka Grabska-Barwinska, et al. “Overcoming catastrophic forgetting in neural networks”. In: *Proceedings of the national academy of sciences* 114.13 (2017), pp. 3521–3526.
- [28] Wei Li, Lei Ma, Guang Yang, and Wen-Biao Gan. “REM sleep selectively prunes and maintains new synapses in development and learning”. In: *Nature neuroscience* 20.3 (2017), pp. 427–437.
- [29] Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N Gomez, Łukasz Kaiser, and Illia Polosukhin. “Attention is All you Need”. In: *Advances in Neural Information Processing Systems*. Ed. by I. Guyon, U. Von Luxburg, S. Bengio, H. Wallach, R. Fergus, S. Vishwanathan, and R. Garnett. Vol. 30. Curran Associates, Inc., 2017. URL: https://proceedings.neurips.cc/paper_files/paper/2017/file/3f5ee243547dee91fbd053c1c4a845aa-Paper.pdf.
- [30] David Ha and Jürgen Schmidhuber. “Recurrent world models facilitate policy evolution”. In: *Advances in Neural Information Processing Systems (NeurIPS)*. Vol. 31. 2018, pp. 2451–2463.
- [31] David Ha and Jürgen Schmidhuber. “World models”. In: *arXiv preprint arXiv:1803.10122* 2.3 (2018), p. 440.
- [32] Ronald Kemker, Marc McClure, Angelina Abitino, Tyler Hayes, and Christopher Kanan. “Measuring catastrophic forgetting in neural networks”. In: *Proceedings of the AAAI conference on artificial intelligence*. Vol. 32. 1. 2018.
- [33] Stefan Larson, Anish Mahendran, Joseph J Peper, Christopher Clarke, Andrew Lee, Parker Hill, Jonathan K Kummerfeld, Kevin Leach, Michael A Laurenzano, Lingjia Tang, et al. “An Evaluation Dataset for Intent Classification and Out-of-Scope Prediction”. In: *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing (EMNLP-IJCNLP)*. 2019, pp. 1311–1316.
- [34] Noam Shazeer. “Fast transformer decoding: One write-head is all you need”. In: *arXiv preprint arXiv:1911.02150* (2019).
- [35] Tom Brown, Benjamin Mann, Nick Ryder, Melanie Subbiah, Jared D Kaplan, Prafulla Dhariwal, Arvind Neelakantan, Pranav Shyam, Girish Sastry, Amanda Askell, et al. “Language models are few-shot learners”. In: *Advances in neural information processing systems* 33 (2020), pp. 1877–1901.
- [36] Inigo Casanueva, Tadas Temcinas, Daniela Gerz, Matthew Henderson, and Ivan Vulic. “Efficient Intent Detection with Dual Sentence Encoders”. In: *ACL 2020* (2020), p. 38.
- [37] Oscar C. González, Yury Sokolov, Giri P. Krishnan, Jean Erik Delanois, and Maxim Bazhenov. “Can sleep protect memories from catastrophic forgetting?” In: *eLife* 9 (2020), e51005.
- [38] Danijar Hafner, Timothy Lillicrap, Jimmy Ba, and Mohammad Norouzi. “Dream to control: Learning behaviors by latent imagination”. In: *International Conference on Learning Representations (ICLR)*. 2020.
- [39] Angelos Katharopoulos, Apoorv Vyas, Nikolaos Pappas, and François Fleuret. “Transformers are rnns: Fast autoregressive transformers with linear attention”. In: *International conference on machine learning*. PMLR. 2020, pp. 5156–5165.
- [40] Pradeep Dasigi, Kyle Lo, Iz Beltagy, Arman Cohan, Noah A Smith, and Matt Gardner. “A dataset of information-seeking questions and answers anchored in research papers”. In: *arXiv preprint arXiv:2105.03011* (2021).
- [41] Akihiro Goto, Ayaka Bota, Ken Miya, Jingbo Wang, Suzune Tsukamoto, Xinzhi Jiang, Daichi Hirai, Masanori Murayama, Tomoki Matsuda, Thomas J. McHugh, Takeharu Nagai, and Yasunori Hayashi. “Stepwise synaptic plasticity events drive the early phase of memory consolidation”. In: *Science* 374.6569 (2021), pp. 857–863. DOI: 10.1126/science.abj9195. eprint: <https://www.science.org/doi/pdf/10.1126/science.abj9195>. URL: <https://www.science.org/doi/abs/10.1126/science.abj9195>.
- [42] Eric R Kandell, John D Koester, Sarah H Mack, and Steven Siegelbaum. *Principles of neural science*. McGraw-Hill, 2021.
- [43] Brian Lester, Rami Al-Rfou, and Noah Constant. “The power of scale for parameter-efficient prompt tuning”. In: *arXiv preprint arXiv:2104.08691* (2021).
- [44] Xiang Lisa Li and Percy Liang. “Prefix-Tuning: Optimizing Continuous Prompts for Generation”. In: *Proceedings of the 59th Annual Meeting of the Association for Computational Linguistics and the 11th International Joint Conference on Natural Language Processing (Volume 1: Long Papers)*. Ed. by Chengqing Zong, Fei Xia, Wenjie Li, and Roberto

- Navigli. Online: Association for Computational Linguistics, Aug. 2021, pp. 4582–4597. doi: 10.18653/v1/2021.acl-long.353. URL: <https://aclanthology.org/2021.acl-long.353/>.
- [45] Ekin Akyürek, Dale Schuurmans, Jacob Andreas, Tengyu Ma, and Denny Zhou. “What learning algorithm is in-context learning? investigations with linear models”. In: *arXiv preprint arXiv:2211.15661* (2022).
 - [46] Aydar Bulatov, Yury Kuratov, and Mikhail Burtsev. “Recurrent memory transformer”. In: *Advances in Neural Information Processing Systems* 35 (2022), pp. 11079–11091.
 - [47] Edward J Hu, yelong shen, Phillip Wallis, Zeyuan Allen-Zhu, Yanzhi Li, Shean Wang, Lu Wang, and Weizhu Chen. “LoRA: Low-Rank Adaptation of Large Language Models”. In: *International Conference on Learning Representations*. 2022. URL: <https://openreview.net/forum?id=nZeVKeeFYf9>.
 - [48] Kazuki Irie, Imanol Schlag, Róbert Csordás, and Jürgen Schmidhuber. “A modern self-referential weight matrix that learns to modify itself”. In: *International Conference on Machine Learning*. PMLR. 2022. URL: <https://proceedings.mlr.press/v162/irie22b.html>.
 - [49] Timothy Tadros, Giri P. Krishnan, Ramyaa Ramyaa, and Maxim Bazhenov. “Sleep-like unsupervised replay reduces catastrophic forgetting in artificial neural networks”. In: *Nature Communications* 13.1 (2022), p. 7742.
 - [50] Eric Zelikman, Yuhuai Wu, Jesse Mu, and Noah Goodman. “STaR: Bootstrapping Reasoning With Reasoning”. In: *Advances in Neural Information Processing Systems*. Ed. by S. Koyejo, S. Mohamed, A. Agarwal, D. Belgrave, K. Cho, and A. Oh. Curran Associates, Inc., 2022. URL: https://proceedings.neurips.cc/paper_files/paper/2022/file/639a9a172c044fbb64175b5fad42e9a5-Paper-Conference.pdf.
 - [51] Josh Achiam, Steven Adler, Sandhini Agarwal, Lama Ahmad, Ilge Akkaya, Florencia Leoni Aleman, Diogo Almeida, Janko Altmenschmidt, Sam Altman, Shyamal Anadkat, et al. “Gpt-4 technical report”. In: *arXiv preprint arXiv:2303.08774* (2023).
 - [52] Joshua Ainslie, James Lee-Thorp, Michiel De Jong, Yury Zemlyanskiy, Federico Lebrón, and Sumit Sanghai. “Gqa: Training generalized multi-query transformer models from multi-head checkpoints”. In: *arXiv preprint arXiv:2305.13245* (2023).
 - [53] Alexis Chevalier, Alexander Wettig, Anirudh Ajith, and Danqi Chen. “Adapting language models to compress contexts”. In: *arXiv preprint arXiv:2305.14788* (2023).
 - [54] Tao Ge, Jing Hu, Lei Wang, Xun Wang, Si-Qing Chen, and Furu Wei. “In-context autoencoder for context compression in a large language model”. In: *arXiv preprint arXiv:2307.06945* (2023).
 - [55] Yunhao Gou, Zhili Liu, Kai Chen, Lanqing Hong, Hang Xu, Aoxue Li, Dit-Yan Yeung, James T Kwok, and Yu Zhang. “Mixture of cluster-conditional lora experts for vision-language instruction tuning”. In: *arXiv preprint arXiv:2312.12379* (2023).
 - [56] Albert Gu and Tri Dao. “Mamba: Linear-time sequence modeling with selective state spaces”. In: *arXiv preprint arXiv:2312.00752* (2023).
 - [57] Chengsong Huang, Qian Liu, Bill Yuchen Lin, Tianyu Pang, Chao Du, and Min Lin. “Lorahub: Efficient cross-task generalization via dynamic lora composition”. In: *arXiv preprint arXiv:2307.13269* (2023).
 - [58] Huiqiang Jiang, Qianhui Wu, Chin-Yew Lin, Yuqing Yang, and Lili Qiu. “Lmlingua: Compressing prompts for accelerated inference of large language models”. In: *arXiv preprint arXiv:2310.05736* (2023).
 - [59] Yucheng Li. “Unlocking context constraints of llms: Enhancing context efficiency of llms with self-information-based content filtering”. In: *arXiv preprint arXiv:2304.12102* (2023).
 - [60] Erik Nijkamp, Bo Pang, Hiroaki Hayashi, Lifu Tu, Huan Wang, Yingbo Zhou, Silvio Savarese, and Caiming Xiong. “CodeGen: An Open Large Language Model for Code with Multi-Turn Program Synthesis”. In: *The Eleventh International Conference on Learning Representations*. 2023. URL: https://openreview.net/forum?id=iaYcJKpY2B_.
 - [61] Charles Packer, Sarah Wooders, Kevin Lin, Vivian Fang, Shishir G Patil, Ion Stoica, and Joseph E Gonzalez. “Memgpt: Towards llms as operating systems”. In: *arXiv preprint arXiv:2310.08560* (2023).
 - [62] Rylan Schaeffer, Brando Miranda, and Sanmi Koyejo. “Are emergent abilities of large language models a mirage?” In: *Advances in neural information processing systems* 36 (2023), pp. 55565–55581.
 - [63] Wenhai Wang, Zhe Chen, Xiaokang Chen, Jiannan Wu, Xizhou Zhu, Gang Zeng, Ping Luo, Tong Lu, Jie Zhou, Yu Qiao, et al. “Visionllm: Large language model is also an open-ended decoder for vision-centric tasks”. In: *Advances in Neural Information Processing Systems* 36 (2023), pp. 61501–61513.
 - [64] Zhenyu Zhang, Ying Sheng, Tianyi Zhou, Tianlong Chen, Lianmin Zheng, Ruisi Cai, Zhao Song, Yuandong Tian, Christopher Ré, Clark Barrett, et al. “H2o: Heavy-hitter oracle for efficient generative inference of large language models”. In: *Advances in Neural Information Processing Systems* 36 (2023), pp. 34661–34710.

- [65] Marah Abdin, Jyoti Aneja, Harkirat Behl, Sébastien Bubeck, Ronen Eldan, Suriya Gunasekar, Michael Harrison, Russell J Hewett, Mojan Javaheripi, Piero Kauffmann, et al. “Phi-4 technical report”. In: *arXiv preprint arXiv:2412.08905* (2024).
- [66] Rishabh Agarwal, Nino Vieillard, Yongchao Zhou, Piotr Stanczyk, Sabela Ramos Garea, Matthieu Geist, and Olivier Bachem. “On-Policy Distillation of Language Models: Learning from Self-Generated Mistakes”. In: *The Twelfth International Conference on Learning Representations*. 2024. URL: <https://openreview.net/forum?id=3zKtaqxLhW>.
- [67] Ekin Akyürek, Mehul Damani, Adam Zweiger, Linlu Qiu, Han Guo, Jyothish Pari, Yoon Kim, and Jacob Andreas. “The Surprising Effectiveness of Test-Time Training for Few-Shot Learning”. In: *Forty-second International Conference on Machine Learning*. 2024.
- [68] Ekin Akyürek, Bailin Wang, Yoon Kim, and Jacob Andreas. “In-context language learning: Architectures and algorithms”. In: *arXiv preprint arXiv:2401.12973* (2024).
- [69] Simran Arora, Sabri Eyuboglu, Michael Zhang, Aman Timalsina, Silas Alberti, James Zou, Atri Rudra, and Christopher Re. “Simple linear attention language models balance the recall-throughput tradeoff”. In: *Forty-first International Conference on Machine Learning*. 2024. URL: <https://openreview.net/forum?id=e93ffDcpH3>.
- [70] Maximilian Beck, Korbinian Pöppel, Markus Spanring, Andreas Auer, Oleksandra Prudnikova, Michael Kopp, Günter Klambauer, Johannes Brandstetter, and Sepp Hochreiter. “xLSTM: Extended Long Short-Term Memory”. In: *arXiv preprint arXiv:2405.04517* (2024).
- [71] Ali Behrouz, Peilin Zhong, and Vahab Mirrokni. “Titans: Learning to memorize at test time”. In: *arXiv preprint arXiv:2501.00663* (2024).
- [72] Jeffrey Cheng, Marc Marone, Orion Weller, Dawn Lawrie, Daniel Khashabi, and Benjamin Van Durme. “Dated Data: Tracing Knowledge Cutoffs in Large Language Models”. In: *First Conference on Language Modeling*. 2024. URL: <https://openreview.net/forum?id=wS7PxDjy6m>.
- [73] Qingxiu Dong, Lei Li, Damai Dai, Ce Zheng, Jingyuan Ma, Rui Li, Heming Xia, Jingjing Xu, Zhiyong Wu, Baobao Chang, Xu Sun, Lei Li, and Zhifang Sui. “A Survey on In-context Learning”. In: *Proceedings of the 2024 Conference on Empirical Methods in Natural Language Processing*. Ed. by Yaser Al-Onaizan, Mohit Bansal, and Yun-Nung Chen. Miami, Florida, USA: Association for Computational Linguistics, Nov. 2024, pp. 1107–1128. doi: 10.18653/v1/2024.emnlp-main.64. URL: <https://aclanthology.org/2024.emnlp-main.64/>.
- [74] Abhimanyu Dubey, Abhinav Jauhri, Abhinav Pandey, Abhishek Kadian, Ahmad Al-Dahle, Aiesha Letman, Akhil Mathur, Alan Schelten, Amy Yang, Angela Fan, et al. “The llama 3 herd of models”. In: *arXiv e-prints* (2024), arXiv–2407.
- [75] Cheng-Ping Hsieh, Simeng Sun, Samuel Kriman, Shantanu Acharya, Dima Rekeshe, Fei Jia, and Boris Ginsburg. “RULER: What’s the Real Context Size of Your Long-Context Language Models?” In: *First Conference on Language Modeling*. 2024. URL: <https://openreview.net/forum?id=kIoBbc76Sy>.
- [76] Adam Ibrahim, Benjamin Thérien, Kshitij Gupta, Mats Leon Richter, Quentin Gregory Anthony, Eugene Belilovsky, Timothée Lesort, and Irina Rish. “Simple and Scalable Strategies to Continually Pre-train Large Language Models”. In: *Transactions on Machine Learning Research* (2024). ISSN: 2835-8856. URL: <https://openreview.net/forum?id=DimPeeCxKO>.
- [77] Kalle Kujanpää, Harri Valpola, and Alexander Ilin. “Knowledge injection via prompt distillation”. In: *arXiv preprint arXiv:2412.14964* (2024).
- [78] Yury Kuratov, Aydar Bulatov, Petr Anokhin, Ivan Rodkin, Dmitry Sorokin, Artyom Sorokin, and Mikhail Burtsev. “Babilong: Testing the limits of llms with long context reasoning-in-a-haystack”. In: *Advances in Neural Information Processing Systems 37* (2024), pp. 106519–106554.
- [79] Dengchun Li, Yingzi Ma, Naizheng Wang, Zhengmao Ye, Zhiyuan Cheng, Yinghao Tang, Yan Zhang, Lei Duan, Jie Zuo, Cal Yang, et al. “Mixlor: Enhancing large language models fine-tuning with lora-based mixture of experts”. In: *arXiv preprint arXiv:2404.15159* (2024).
- [80] Yuhong Li, Yingbing Huang, Bowen Yang, Bharat Venkitesh, Acyr Locatelli, Hanchen Ye, Tianle Cai, Patrick Lewis, and Deming Chen. “Snapkv: Llm knows what you are looking for before generation”. In: *Advances in Neural Information Processing Systems 37* (2024), pp. 22947–22970.
- [81] Akide Liu, Jing Liu, Zizheng Pan, Yefei He, Gholamreza Haffari, and Bohan Zhuang. “MiniCache: KV Cache Compression in Depth Dimension for Large Language Models”. In: *Advances in Neural Information Processing Systems 37* (2024).
- [82] Fanxu Meng, Zhaohui Wang, and Muhan Zhang. “Pissa: Principal singular values and singular vectors adaptation of large language models”. In: *Advances in Neural Information Processing Systems 37* (2024), pp. 121038–121072.

- [83] Nihal V Nayak, Yiyang Nan, Avi Trost, and Stephen H Bach. “Learning to generate instruction tuning datasets for zero-shot task adaptation”. In: *arXiv preprint arXiv:2402.18334* (2024).
- [84] Xingyuan Pan, Luyang Huang, Liyan Kang, Zhicheng Liu, Yu Lu, and Shanbo Cheng. “G-DIG: Towards Gradient-based DIverse and hiGh-quality Instruction Data Selection for Machine Translation”. In: *Proceedings of the 62nd Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*. Ed. by Lun-Wei Ku, Andre Martins, and Vivek Srikumar. Bangkok, Thailand: Association for Computational Linguistics, Aug. 2024, pp. 15395–15406. DOI: 10.18653/v1/2024.acl-long.821. URL: <https://aclanthology.org/2024.acl-long.821/>.
- [85] Jing-Cheng Pang, Pengyuan Wang, Kaiyuan Li, Xiong-Hui Chen, Jiacheng Xu, Zongzhang Zhang, and Yang Yu. “Language Model Self-improvement by Reinforcement Learning Contemplation”. In: *The Twelfth International Conference on Learning Representations*. 2024. URL: <https://openreview.net/forum?id=38E4yUbrgr>.
- [86] Jing-Cheng Pang, Pengyuan Wang, Kaiyuan Li, Xiong-Hui Chen, Jiacheng Xu, Zongzhang Zhang, and Yang Yu. “Language Model Self-improvement by Reinforcement Learning Contemplation”. In: *The Twelfth International Conference on Learning Representations*. 2024. URL: <https://openreview.net/forum?id=38E4yUbrgr>.
- [87] Ivan Rodkin, Yuri Kuratov, Aydar Bulatov, and Mikhail Burtsev. “Associative recurrent memory transformer”. In: *arXiv preprint arXiv:2407.04841* (2024).
- [88] Zhihong Shao, Peiyi Wang, Qihao Zhu, Runxin Xu, Junxiao Song, Xiao Bi, Haowei Zhang, Mingchuan Zhang, YK Li, Yang Wu, et al. “Deepseekmath: Pushing the limits of mathematical reasoning in open language models”. In: *arXiv preprint arXiv:2402.03300* (2024).
- [89] Haizhou Shi, Zihao Xu, Hengyi Wang, Weiyei Qin, Wenyuan Wang, Yibin Wang, Zifeng Wang, Sayna Ebrahimi, and Hao Wang. “Continual learning of large language models: A comprehensive survey”. In: *ACM Computing Surveys* (2024).
- [90] Avi Singh, John D Co-Reyes, Rishabh Agarwal, Ankesh Anand, Piyush Patil, Xavier Garcia, Peter J Liu, James Harrison, Jaehoon Lee, Kelvin Xu, Aaron T Parisi, Abhishek Kumar, Alexander A Alemi, Alex Rizkowsky, Azade Nova, Ben Adlam, Bernd Bohnet, Gamaleldin Fathy Elsayed, Hanie Sedghi, Igor Mordatch, Isabelle Simpson, Izzeddin Gur, Jasper Snoek, Jeffrey Pennington, Jiri Hron, Kathleen Kenealy, Kevin Swersky, Kshiteej Mahajan, Laura A Culp, Lechao Xiao, Maxwell Bileschi, Noah Constant, Roman Novak, Rosanne Liu, Tris Warkentin, Yamini Bansal, Ethan Dyer, Behnam Neyshabur, Jascha Sohl-Dickstein, and Noah Fiedel. “Beyond Human Data: Scaling Self-Training for Problem-Solving with Language Models”. In: *Transactions on Machine Learning Research* (2024). Expert Certification. ISSN: 2835-8856. URL: <https://openreview.net/forum?id=1NAyUngGFK>.
- [91] Avi Singh, John D Co-Reyes, Rishabh Agarwal, Ankesh Anand, Piyush Patil, Xavier Garcia, Peter J Liu, James Harrison, Jaehoon Lee, Kelvin Xu, Aaron T Parisi, Abhishek Kumar, Alexander A Alemi, Alex Rizkowsky, Azade Nova, Ben Adlam, Bernd Bohnet, Gamaleldin Fathy Elsayed, Hanie Sedghi, Igor Mordatch, Isabelle Simpson, Izzeddin Gur, Jasper Snoek, Jeffrey Pennington, Jiri Hron, Kathleen Kenealy, Kevin Swersky, Kshiteej Mahajan, Laura A Culp, Lechao Xiao, Maxwell Bileschi, Noah Constant, Roman Novak, Rosanne Liu, Tris Warkentin, Yamini Bansal, Ethan Dyer, Behnam Neyshabur, Jascha Sohl-Dickstein, and Noah Fiedel. “Beyond Human Data: Scaling Self-Training for Problem-Solving with Language Models”. In: *Transactions on Machine Learning Research* (2024). URL: <https://openreview.net/forum?id=1NAyUngGFK>.
- [92] Yu Sun, Xinhao Li, Karan Dalal, Jiarui Xu, Arjun Vikram, Genghan Zhang, Yann Dubois, Xinlei Chen, Xiaolong Wang, Sanmi Koyejo, et al. “Learning to (learn at test time): Rnns with expressive hidden states”. In: *arXiv preprint arXiv:2407.04620* (2024).
- [93] Sijun Tan, Xiuyu Li, Shishir Patil, Ziyang Wu, Tianjun Zhang, Kurt Keutzer, Joseph E Gonzalez, and Raluca Ada Popa. “Lloco: Learning long contexts offline”. In: *arXiv preprint arXiv:2404.07979* (2024).
- [94] Jiaming Tang, Yilong Zhao, Kan Zhu, Guangxuan Xiao, Baris Kasikci, and Song Han. “Quest: Query-aware sparsity for efficient long-context llm inference”. In: *arXiv preprint arXiv:2406.10774* (2024).
- [95] Garrett Tanzer, Mirac Suzgun, Eline Visser, Dan Jurafsky, and Luke Melas-Kyriazi. “A Benchmark for Learning to Translate a New Language from One Grammar Book”. In: *The Twelfth International Conference on Learning Representations*. 2024. URL: <https://openreview.net/forum?id=tbVWug9f2h>.
- [96] Zhongwei Wan, Xinjian Wu, Yu Zhang, Yi Xin, Chaofan Tao, Zhihong Zhu, Xin Wang, Siqi Luo, Jing Xiong, and Mi Zhang. “D2o: Dynamic discriminative operations for efficient generative inference of large language models”. In: *arXiv preprint arXiv:2406.13035* (2024).
- [97] Jiachen Tianhao Wang, Tong Wu, Dawn Song, Prateek Mittal, and Ruoxi Jia. “Greats: Online selection of high-quality data for llm training in every iteration”. In: *Advances in Neural Information Processing Systems 37* (2024), pp. 131197–131223.

- [98] Zheng Wang, Boxiao Jin, Zhongzhi Yu, and Minjia Zhang. “Model tells you where to merge: Adaptive kv cache merging for llms on long-context tasks”. In: *arXiv preprint arXiv:2407.08454* (2024).
- [99] Xun Wu, Shaohan Huang, and Furu Wei. “Mixture of lora experts”. In: *arXiv preprint arXiv:2404.13628* (2024).
- [100] Chaojun Xiao, Zhengyan Zhang, Chenyang Song, Dazhi Jiang, Feng Yao, Xu Han, Xiaozhi Wang, Shuo Wang, Yufei Huang, Guanyu Lin, et al. “Configurable foundation models: Building llms from a modular perspective”. In: *arXiv preprint arXiv:2409.02877* (2024).
- [101] Prateek Yadav, Colin Raffel, Mohammed Muqeeth, Lucas Caccia, Haokun Liu, Tianlong Chen, Mohit Bansal, Leshem Choshen, and Alessandro Sordoni. “A survey on model moerging: Recycling and routing among specialized experts for collaborative learning”. In: *arXiv preprint arXiv:2408.07057* (2024).
- [102] Wannan Yang, Chen Sun, Roman Huszár, Thomas Hainmueller, Kirill Kiselev, and György Buzsáki. “Selection of experience for memory by hippocampal sharp wave ripples”. In: *Science* 383.6690 (2024), pp. 1478–1483.
- [103] Rongzhi Zhang, Kuang Wang, Liyuan Liu, Shuohang Wang, Hao Cheng, Chao Zhang, and Yelong Shen. “LoRC: Low-Rank Compression for LLMs KV Cache with a Progressive Compression Strategy”. In: *arXiv preprint arXiv:2410.03111* (2024).
- [104] Yuxin Zhang, Yuxuan Du, Gen Luo, Yunshan Zhong, Zhenyu Zhang, Shiwei Liu, and Rongrong Ji. “Cam: Cache merging for memory-efficient llms inference”. In: *Forty-first International Conference on Machine Learning*. 2024.
- [105] Ziyu Zhao, Leilei Gan, Guoyin Wang, Wangchunshu Zhou, Hongxia Yang, Kun Kuang, and Fei Wu. “Loraretriever: Input-aware lora retrieval and composition for mixed tasks in the wild”. In: *arXiv preprint arXiv:2402.09997* (2024).
- [106] Ziyu Zhao, Tao Shen, Didi Zhu, Zexi Li, Jing Su, Xuwu Wang, Kun Kuang, and Fei Wu. “Merging loras like playing lego: Pushing the modularity of lora to extremes through rank-wise clustering”. In: *arXiv preprint arXiv:2409.16167* (2024).
- [107] Lisa Adams, Felix Busch, Tianyu Han, Jean-Baptiste Excoffier, Matthieu Ortala, Alexander Löser, Hugo JWL Aerts, Jakob Nikolas Kather, Daniel Truhn, and Keno Bressem. “Longhealth: A question answering benchmark with long clinical documents”. In: *Journal of Healthcare Informatics Research* (2025), pp. 1–17.
- [108] Ali Behrouz, Meisam Razaviyayn, Peilin Zhong, and Vahab Mirrokni. “Nested Learning: The Illusion of Deep Learning Architectures”. In: *The Thirty-ninth Annual Conference on Neural Information Processing Systems*. 2025. URL: <https://openreview.net/forum?id=nbMeRvNb7A>.
- [109] Lucas Caccia, Alan Ansell, Edoardo Ponti, Ivan Vulic, and Alessandro Sordoni. “Training Plug-n-Play Knowledge Modules with Deep Context Distillation”. In: *arXiv preprint arXiv:2503.08727* (2025).
- [110] Vivek Chari, Guanghui Qin, and Benjamin Van Durme. “KV-Distill: Nearly Lossless Learnable Context Compression for LLMs”. In: *arXiv preprint arXiv:2503.10337* (2025).
- [111] Gheorghe Comanici, Eric Bieber, Mike Schaeckermann, Ice Pasupat, Naveen Sachdeva, Inderjit Dhillon, Marcel Blistein, Ori Ram, Dan Zhang, Evan Rosen, et al. “Gemini 2.5: Pushing the frontier with advanced reasoning, multimodality, long context, and next generation agentic capabilities”. In: *arXiv preprint arXiv:2507.06261* (2025).
- [112] DeepSeek-AI. *DeepSeek-R1: Incentivizing Reasoning Capability in LLMs via Reinforcement Learning*. 2025. arXiv: 2501.12948 [cs.CL]. URL: <https://arxiv.org/abs/2501.12948>.
- [113] Benoit Dherin, Michael Munn, Hanna Mazzawi, Michael Wunder, and Javier Gonzalvo. “Learning without training: The implicit dynamics of in-context learning”. In: *arXiv preprint arXiv:2507.16003* (2025).
- [114] Sabri Eyuboglu, Ryan Ehrlich, Simran Arora, Neel Guha, Dylan Zinsley, Emily Liu, Will Tennien, Atri Rudra, James Zou, Azalia Mirhoseini, et al. “Cartridges: Lightweight and general-purpose long context representations via self-study”. In: *arXiv preprint arXiv:2506.06266* (2025).
- [115] Audrey Huang, Adam Block, Dylan J Foster, Dhruv Rohatgi, Cyril Zhang, Max Simchowitz, Jordan T. Ash, and Akshay Krishnamurthy. “Self-Improvement in Language Models: The Sharpening Mechanism”. In: *The Thirteenth International Conference on Learning Representations*. 2025. URL: <https://openreview.net/forum?id=WJaUkwci9o>.
- [116] Tianle Li, Ge Zhang, Quy Duc Do, Xiang Yue, and Wenhui Chen. “Long-context LLMs Struggle with Long In-context Learning”. In: *Transactions on Machine Learning Research* (2025). ISSN: 2835-8856. URL: <https://openreview.net/forum?id=Cw2xlg0e46>.
- [117] Kevin Lin, Charlie Snell, Yu Wang, Charles Packer, Sarah Wooders, Ion Stoica, and Joseph E Gonzalez. “Sleep-time compute: Beyond inference scaling at test-time”. In: *arXiv preprint arXiv:2504.13171* (2025).
- [118] Yansheng Mao, Yufei Xu, Jiaqi Li, Fanxu Meng, Haotong Yang, Zilong Zheng, Xiyuan Wang, and Muhan Zhang. “LIFT: Improving Long Context Understanding of Large Language Models through Long Input Fine-Tuning”. In: *arXiv preprint arXiv:2502.14644* (2025).

- [119] Saleh Momeni, Sahisnu Mazumder, Zixuan Ke, and Bing Liu. “In-context continual learning assisted by an external continual learner”. In: *Proceedings of the 31st International Conference on Computational Linguistics*. 2025, pp. 7292–7306.
- [120] Renhao Pei, Yihong Liu, Peiqin Lin, François Yvon, and Hinrich Schütze. “Understanding In-Context Machine Translation for Low-Resource Languages: A Case Study on Manchu”. In: *arXiv preprint arXiv:2502.11862* (2025).
- [121] Haris Riaz, Sourav Bhabesh, Vinayak Arannil, Miguel Ballesteros, and Graham Horwood. “MetaSynth: Meta-Prompting-Driven Agentic Scaffolds for Diverse Synthetic Data Generation”. In: *arXiv preprint arXiv:2504.12563* (2025).
- [122] Weihang Su, Yichen Tang, Qingyao Ai, Junxi Yan, Changyue Wang, Hongning Wang, Ziyi Ye, Yujia Zhou, and Yiqun Liu. “Parametric retrieval augmented generation”. In: *arXiv preprint arXiv:2501.15915* (2025).
- [123] Zhaoyang Wang, Weilei He, Zhiyuan Liang, Xuchao Zhang, Chetan Bansal, Ying Wei, Weitong Zhang, and Huaxiu Yao. “CREAM: Consistency Regularized Self-Rewarding Language Models”. In: *The Thirteenth International Conference on Learning Representations*. 2025. URL: <https://openreview.net/forum?id=Vf6RD0byEF>.
- [124] Guangxuan Xiao, Jiaming Tang, Jingwei Zuo, junxian guo, Shang Yang, Haotian Tang, Yao Fu, and Song Han. “DuoAttention: Efficient Long-Context LLM Inference with Retrieval and Streaming Heads”. In: *The Thirteenth International Conference on Learning Representations*. 2025. URL: <https://openreview.net/forum?id=cFu7ze7xUm>.
- [125] Adam Zweiger, Jyothish Pari, Han Guo, Ekin Akyürek, Yoon Kim, and Pulkit Agrawal. “Self-Adapting Language Models”. In: *arXiv preprint arXiv:2506.10943* (2025).
- [126] Yinghui He, Simran Kaur, Adithya Bhaskar, Yongjin Yang, Jiarui Liu, Narutatsu Ri, Liam Fowl, Abhishek Panigrahi, Danqi Chen, and Sanjeev Arora. *Self-Distillation Zero: Self-Revision Turns Binary Rewards into Dense Supervision*. 2026. arXiv: 2604.12002 [cs.CL]. URL: <https://arxiv.org/abs/2604.12002>.
- [127] Jonas Hübner, Frederike Lübeck, Lejs Behric, Anton Baumann, Marco Bagatella, Daniel Marta, Ido Hakimi, Idan Shenfeld, Thomas Kleine Buening, Carlos Guestrin, et al. “Reinforcement Learning via Self-Distillation”. In: *arXiv preprint arXiv:2601.20802* (2026).
- [128] Jeonghye Kim, Xufang Luo, Minbeom Kim, Sangmook Lee, Dohyung Kim, Jiwon Jeon, Dongsheng Li, and Yuqing Yang. *Why Does Self-Distillation (Sometimes) Degrade the Reasoning Capability of LLMs?* 2026. arXiv: 2603.24472 [cs.CL]. URL: <https://arxiv.org/abs/2603.24472>.
- [129] John Kirchenbauer, Abhimanyu Hans, Brian Bartoldson, Micah Goldblum, Ashwinee Panda, and Tom Goldstein. *Multi-Token Prediction via Self-Distillation*. 2026. arXiv: 2602.06019 [cs.CL]. URL: <https://arxiv.org/abs/2602.06019>.
- [130] Yihong Liu, Raoyuan Zhao, Michael A. Hedderich, and Hinrich Schütze. *Crosslingual On-Policy Self-Distillation for Multilingual Reasoning*. 2026. arXiv: 2605.09548 [cs.CL]. URL: <https://arxiv.org/abs/2605.09548>.
- [131] Ruiyang Qin, Qingzhuo Wang, Dongrui Liu, Qiang Li, Zhihua Wei, and Wen Shen. *Multilingual Safety Alignment via Self-Distillation*. 2026. arXiv: 2605.02971 [cs.LG]. URL: <https://arxiv.org/abs/2605.02971>.
- [132] Hejian Sang, Yuanda Xu, Zhengze Zhou, Ran He, Zhipeng Wang, and Jiachen Sun. *CRISP: Compressed Reasoning via Iterative Self-Policy Distillation*. 2026. arXiv: 2603.05433 [cs.LG]. URL: <https://arxiv.org/abs/2603.05433>.
- [133] Idan Shenfeld, Mehul Damani, Jonas Hübner, and Pulkit Agrawal. “Self-Distillation Enables Continual Learning”. In: *arXiv preprint arXiv:2601.19897* (2026).
- [134] Idan Shenfeld, Mehul Damani, Jonas Hübner, and Pulkit Agrawal. *Self-Distillation Enables Continual Learning*. 2026. arXiv: 2601.19897 [cs.LG]. URL: <https://arxiv.org/abs/2601.19897>.
- [135] Alex Stein, Furong Huang, and Tom Goldstein. *GATES: Self-Distillation under Privileged Context with Consensus Gating*. 2026. arXiv: 2602.20574 [cs.LG]. URL: <https://arxiv.org/abs/2602.20574>.
- [136] Hao Wang, Guozhi Wang, Han Xiao, Yufeng Zhou, Yue Pan, Jichao Wang, Ke Xu, Yafei Wen, Xiaohu Ruan, Xiaoxin Chen, and Honggang Qi. *Skill-SD: Skill-Conditioned Self-Distillation for Multi-turn LLM Agents*. 2026. arXiv: 2604.10674 [cs.LG]. URL: <https://arxiv.org/abs/2604.10674>.
- [137] Tianzhu Ye, Li Dong, Qingxiu Dong, Xun Wu, Shaohan Huang, and Furu Wei. *Online Experiential Learning for Language Models*. 2026. arXiv: 2603.16856 [cs.CL]. URL: <https://arxiv.org/abs/2603.16856>.
- [138] Tianzhu Ye, Li Dong, Xun Wu, Shaohan Huang, and Furu Wei. *On-Policy Context Distillation for Language Models*. 2026. arXiv: 2602.12275 [cs.CL]. URL: <https://arxiv.org/abs/2602.12275>.
- [139] Ruixiang Zhang, Richard He Bai, Huangjie Zheng, Navdeep Jaitly, Ronan Collobert, and Yizhe Zhang. *Embarrassingly Simple Self-Distillation Improves Code Generation*. 2026. arXiv: 2604.01193 [cs.CL]. URL: <https://arxiv.org/abs/2604.01193>.
- [140] Xinsen Zhang, Zhenkai Ding, Tianjun Pan, Run Yang, Chun Kang, Xue Xiong, and Jingnan Gu. “OPSDL: On-Policy Self-Distillation for Long-Context Language Models”. In: *arXiv preprint arXiv:2604.17535* (2026).

- [141] Xinsen Zhang, Zhenkai Ding, Tianjun Pan, Run Yang, Chun Kang, Xue Xiong, and Jingnan Gu. *OPSDL: On-Policy Self-Distillation for Long-Context Language Models*. 2026. arXiv: 2604.17535 [cs.CL]. URL: <https://arxiv.org/abs/2604.17535>.
- [142] Yaocheng Zhang, Yuanheng Zhu, Wenyue Chong, Songjun Tu, Qichao Zhang, Jiajun Chai, Xiaohan Wang, Wei Lin, Guojun Yin, and Dongbin Zhao. *π -Play: Multi-Agent Self-Play via Privileged Self-Distillation without External Data*. 2026. arXiv: 2604.14054 [cs.LG]. URL: <https://arxiv.org/abs/2604.14054>.
- [143] Siyan Zhao, Zhihui Xie, Mengchen Liu, Jing Huang, Guan Pang, Feiyu Chen, and Aditya Grover. “Self-Distilled Reasoner: On-Policy Self-Distillation for Large Language Models”. In: *arXiv preprint arXiv:2601.18734* (2026).
- [144] Siyan Zhao, Zhihui Xie, Mengchen Liu, Jing Huang, Guan Pang, Feiyu Chen, and Aditya Grover. *Self-Distilled Reasoner: On-Policy Self-Distillation for Large Language Models*. 2026. arXiv: 2601.18734 [cs.LG]. URL: <https://arxiv.org/abs/2601.18734>.




Figure 7: Multi-frequency memory hierarchy. Updates enter the High-Frequency FFN via repeated Parameter Expansion; when the window f_W expires, knowledge is Consolidated to the Mid- and then Low-Frequency FFNs (1k→5k→10k).




Figure 8: Memory consolidation by routed expert updates. Across Sleep cycles (left→right), a router selects and updates a small set of experts (solid), leaving others inactive (hatched), expanding capacity while limiting interference.

A Related Work

A.1 Parameter-Efficient Adaptation and Composition

Parameter-efficient fine-tuning (PEFT) adapts large language models (LLMs) to specific tasks by optimizing a minimal set of auxiliary parameters while freezing the backbone. **Low-Rank and Prefix Adaptation.** Prominent methods include LoRA (Hu et al. 2022), which injects trainable low-rank matrices into linear projections, and prefix/prompt-tuning (Lester et al. 2021; Li et al. 2021), which steers computation via learnable virtual tokens. Recent variants optimize initialization to accelerate convergence, such as PiSSA (Meng et al. 2024), or extend these mechanisms for context-to-parameter distillation (Eyuboglu et al. 2025).

Composition and Routing. Beyond single-task adaptation, research increasingly focuses on composing multiple adapters. Approaches include weighted composition via in-context learning (Huang et al. 2023) and retrieval-based routing, where relevant LoRA modules are selected dynamically per input (Zhao et al. 2024a). Advanced configurations utilize mixture-of-experts (MoE) architectures to activate specific low-rank paths or merge adapter parameters dependent on the task (Gou et al. 2023; Li et al. 2024a; Wu et al. 2024; Xiao et al. 2024; Yadav et al. 2024; Zhao et al. 2024b).

A.2 Knowledge Injection, Distillation, and Self-Improvement

Parametric Knowledge Injection. To reduce reliance on retrieval at inference time, recent work injects external knowledge directly into model parameters. Techniques range from *Parametric RAG*, which assigns document-specific LoRA adapters (Su et al. 2025), to prompt distillation, where student models learn from teacher-generated QA pairs or

synthetic conversations (Kujanpää et al. 2024; Caccia et al. 2025; Mao et al. 2025). *Cartridges* (Eyuboglu et al. 2025) bridge PEFT and distillation by pre-training a reusable "KV cache adapter" via a self-study objective, achieving in-context learning (ICL) quality with reduced serving costs.

Self-Improvement and Meta-Learning. Complementary to distillation is the use of model-generated signals for self-improvement. This includes Reinforcement Learning (RL) on verifiable rewards to enhance reasoning (Zelikman et al. 2022; Singh et al. 2024b; DeepSeek-AI 2025) and self-rewarding mechanisms (Pang et al. 2024b; Wang et al. 2025). Meta-learning frameworks, such as SEAL (Zweiger et al. 2025), extend this by optimizing the adaptation strategy itself—learning *how* to generate self-edits—drawing on broader principles of self-referential learning (Schmidhuber 1987; Finn et al. 2017; Irie et al. 2022). These methods rely heavily on high-quality synthetic data generation to scale supervision (Abdin et al. 2024; Nayak et al. 2024; Riaz et al. 2025).

A recent group of concurrent studies has suggested to use on-policy distillation for self-distillation process (Hübotter et al. 2026; Zhang et al. 2026b; Zhao et al. 2026a) or for continual learning (Shenfeld et al. 2026a). In addition to the fact that this study is older than such methods, Sleep fundamentally delivers a different messages that: (1) Sleep uses an *upward distillation of self*, where it unlocks parameters. (2) Sleep is based on Generalized Distillation method that combines on-policy method with an RL method. (3) Sleep suggest a periodic process where knowledge stores in modules in different frequency of update.

A.3 Efficient Context Processing

Addressing the memory bottleneck of long-context processing involves compressing the KV cache or modifying the attention architecture.

Prompt and Cache Compression. Approaches to reduce memory footprints fall into two categories: *Prompt compression* shortens inputs via token filtering (hard-token) (Jiang et al. 2023; Li 2023) or by learning compact soft-token embeddings via auto-encoders (Chevalier et al. 2023; Ge et al. 2023; Tan et al. 2024). *KV cache compression* operates at runtime, employing eviction policies to drop non-essential keys (Zhang et al. 2023; Li et al. 2024b; Tang et al. 2024) or merging tokens based on similarity and attention density (Liu et al. 2024; Wan et al. 2024; Wang et al. 2024b; Zhang et al. 2024b). Low-rank projections of the KV cache have also shown promise in maintaining performance at high compression rates (Zhang et al. 2024a; Chari et al. 2025).

Architectural Innovations. Structural changes to Multi-Head Attention (MHA) include Multi-Query and Grouped-Query Attention (MQA/GQA), which share KV heads to reduce memory bandwidth (Shazeer 2019; Ainslie et al. 2023), and linearization techniques that remove the softmax to achieve fixed-size states ($K^T V$) independent of sequence length (Gu et al. 2023; Arora et al. 2024; Beck et al. 2024). Recent "learning to compress" architectures, such as Titans and TTT, utilize gradient-based updates on constant-sized memory objects to handle infinite contexts (Behrouz et al. 2024; Sun et al. 2024). Finally, orchestration systems like MemGPT manage context via virtual memory paging rather than architectural modification (Packer et al. 2023). In a similar direction to compression in the token space, Lin et al. (2025) present sleep-time compute. Despite similarity in the name, their method is fundamentally different from our work. While this method aim to find a good summary of the interactions of the model with users in the text space, when the model is idle, our proposal is on using distillation to transfer text data knowledge into a form of parametric weight update.

A.4 Recent Concurrent and/or Later Work on On-Policy Distillation

Concurrent and Subsequent Work on On-Policy Self-Distillation. Concurrent and subsequent to the initial version of this work, a rapidly growing line of literature has explored *on-policy self-distillation* (OPSD), in which the same model plays the role of both teacher and student under different conditioning contexts and the student is supervised on its own rollouts via a per-token divergence against the teacher. The canonical instantiation is OPSD (Zhao et al. 2026b), which conditions the teacher on a verified reasoning trace and minimises a per-token reverse-KL on the student’s own rollouts, yielding gains on mathematical reasoning over both GRPO and off-policy distillation. A wave of follow-up works varies the form of the privileged context: On-Policy Context Distillation (Ye et al. 2026b) conditions the teacher on transient in-context information (historical solution traces or optimised system prompts) so that the student internalises that information into its parameters; GATES (Stein et al. 2026) uses document-grounded privileged context together with a consensus-gating mechanism that handles unreliable supervision by sampling multiple tutor traces and gating learning by their agreement; SD-Zero (He et al. 2026) conditions a “reviser” on the student’s response and a binary reward, then distils the reviser

back into the generator, converting sparse outcome rewards into dense token-level supervision; and COPSD (Liu et al. 2026) transfers reasoning behaviour to low-resource languages by giving the teacher an English translation and reference solution as privileged crosslingual context. Apple’s “embarrassingly simple” self-distillation (Zhang et al. 2026a) sits at the limit of this spectrum: it drops the explicit teacher altogether and supervised-finetunes on the model’s own samples under different decoding configurations, showing that even this minimal recipe meaningfully improves code generation.

Continual, Experiential, and Online Adaptation. A second cluster of works applies self-distillation to continual, experiential, or online improvement. SDFT (Shenfeld et al. 2026b) explicitly targets continual learning from demonstrations by using a demonstration-conditioned model as an on-policy teacher, reducing catastrophic forgetting compared with standard SFT. OEL (Ye et al. 2026a) couples context distillation with deployment: it extracts transferable experiential knowledge from interaction trajectories and consolidates it into parameters via on-policy context distillation, iterating both stages to form a closed online-learning loop. π -Play (Zhang et al. 2026d) pushes this idea further into a multi-agent self-play regime, using the question-construction path produced by the task proposer as privileged context for the teacher and removing the need for external data or human feedback in training deep search agents. These works are closely aligned with our motivation that LLMs should not remain static after deployment. However, they formulate continual or experiential improvement as a post-training objective on a *fixed-capacity* checkpoint. In contrast, our Sleep paradigm treats continual learning as a *memory-system* problem: newly acquired information is first represented in fast, fragile memory modules and then periodically consolidated into slower, more stable parameters via Knowledge Seeding, accompanied by gradual capacity expansion and the resetting of higher-frequency memory after consolidation.

Application-Specific OPSD Recipes. A third group of papers adapts the OPSD template to specific deployment regimes. CRISP/OPSDC (Sang et al. 2026) conditions the teacher on a “be concise” instruction prefix and uses per-token reverse-KL on student rollouts to compress long chain-of-thought traces without entropy collapse. MTP (Kirchenbauer et al. 2026) converts a pretrained next-token-prediction model into a multi-token predictor with a single online self-distillation objective, yielding more than 3 $\times$ inference acceleration on GSM8K at < 5% accuracy drop. OPSDL (Zhang et al. 2026c) attacks long-context generation by using the model’s own short-context behaviour on extracted relevant spans as a self-teacher for its long-context student. Skill-SD (Wang et al. 2026) targets multi-turn agents: completed trajectories are summarised into compact natural-language “skills” that condition only the teacher while the student trains under the plain task prompt. MSD (Qin et al. 2026) moves OPSD into the multilingual setting by transferring safety behaviour from high-resource to low-resource languages using only multilingual queries. Collectively, these works show that self-distillation under privileged conditioning is a general and flexible post-training recipe across reasoning, efficiency, agentic, and multilingual axes – but in each case it is deployed as a single-objective procedure on a fixed model and a fixed application.

Limitations of OPSD and Motivation for the Sleep Paradigm. Despite the empirical success of OPSD across these domains, recent analyses have begun to expose its failure modes. Kim et al. (2026) show that, in mathematical reasoning, conditioning the teacher on rich privileged information can suppress the model’s epistemic verbalisation (its expression of uncertainty during reasoning), enabling fast in-domain optimisation at the cost of severe out-of-distribution degradation, with drops of up to 40% across Qwen3-8B, DeepSeek-Distill-Qwen-7B, and Olmo3-7B-Instruct. Several recent OPSD works also report that naïvely iterating self-distillation in a long-horizon training pipeline can lead to information leakage from the privileged teacher and to training collapse (He et al. 2026; Wang et al. 2026). These results suggest that self-distillation alone is not sufficient for robust continual improvement: an iterative self-improvement loop applied directly to a fixed model can erode prior capabilities or destabilise reasoning. Our two-stage Sleep framework directly addresses this concern by separating memory consolidation from self-improvement: consolidation first stabilises newly acquired knowledge in freshly expanded lower-frequency parameters before Dreaming further modifies the model, reducing the risk that iterative self-training overwrites useful prior capabilities.

Positioning of Our Work. Our work differs from the OPSD literature along four axes that together motivate the Sleep paradigm. **(i) Upward distillation as memory consolidation.** All of the self-distillation works listed above share the same backbone between teacher and student and differ only in conditioning context – privileged trace (Kim et al. 2026; Zhao et al. 2026b), demonstration (Shenfeld et al. 2026b), document (Stein et al. 2026), context or system prompt (Ye et al. 2026a,b), “concise” prefix (Sang et al. 2026), decoding configuration (Zhang et al. 2026a), skill summary (Wang et al. 2026), reviser context (He et al. 2026), question-construction path (Zhang et al. 2026d), short-context substring (Zhang et al. 2026c), or English reference (Liu et al. 2026; Qin et al. 2026). In contrast, our Knowledge Seeding step is an *upward* distillation: a

smaller, higher-frequency memory module is distilled into a strictly *larger* set of newly expanded low-rank experts in a lower-frequency memory module. This reframes catastrophic forgetting as a problem of insufficient capacity rather than of sampling distribution, and addresses it by gradual parameter growth between consolidation steps rather than by re-conditioning a fixed teacher. **(ii) Continuum of memory frequencies.** Where the above works treat distillation as a flat student/teacher pair, our method operates over a chain of memory blocks with strictly ordered update frequencies and performs consolidation between each pair of consecutive blocks; to our knowledge, only SDFT (Shenfeld et al. 2026b) explicitly targets the continual-learning desideratum that motivates us, and it does so without architectural growth or hierarchical memory. **(iii) Sleep as a two-phase process beyond consolidation.** The OPSD literature focuses almost entirely on the consolidation step. Our framework additionally includes a Dreaming phase analogous to REM sleep, in which the model generates a curriculum of synthetic data, weights samples by a gradient-based importance score, and exploits the MoE router to inject controlled novelty – explicitly designed to be robust to the iterative self-improvement failure modes flagged by (He et al. 2026; Kim et al. 2026). **(iv) Knowledge seeding augments on-policy distillation with imitation learning.** Where the on-policy distillation objective in works such as (Liu et al. 2026; Qin et al. 2026; Sang et al. 2026; Stein et al. 2026; Ye et al. 2026a,b; Zhang et al. 2026c; Zhao et al. 2026b) reduces to a per-token reverse-KL on student rollouts, our Knowledge Seeding objective augments GKD-style on-policy distillation with an RL-based Learning-to-Imitate term that jointly rewards semantic and Levenshtein-level alignment with the teacher’s sampling distribution, enabling the larger student not only to inherit the teacher’s knowledge but also to imitate the way the teacher uses it.

B Additional Experimental Results and Details

In all of our experiments, we follow the settings of the original benchmark (cited in each section). Therefore, for the sake of space and not duplicating information, we refer to those studies for the details of the models. In our design, we use 5 MLP blocks with dimension 64 as the additional parameters and keep the active parameter count unchanged (I.e., the same as the base model, which is either 8B or 3B).

B.1 Datasets

Class Incremental Learning. We focus on class-incremental learning on three datasets:

- CLINC (Larson et al. 2019): CLINC150 is a multi-domain intent classification benchmark for task-oriented dialog, and it is commonly used to evaluate both in-scope intent prediction and out-of-scope (OOS) detection. It contains 150 in-scope intents spanning 10 domains, with 23.7K total queries (22.5K in-scope and 1.2K OOS).
- Banking (Casanueva et al. 2020): Banking77 is a single-domain intent dataset of short banking customer-service queries, labeled with 77 fine-grained intents (e.g., card issues or PIN resets). It includes 13,083 examples, and the intent distribution is noticeably imbalanced.
- DBpedia (Auer et al. 2007): DBpedia-based classification maps Wikipedia-derived descriptions (typically abstracts) to ontology categories (e.g., book, film, animal, place). We use the 70-class, level-2 setting and subsample 10K training and 1K test instances for our experiments.

The Effect of Levels on In-context Learning. To better isolate how HOPE’s consolidation schedule impacts in-context learning and long-context understanding, we evaluate question answering and multi-key retrieval under long contexts. We use the following datasets for this evaluation:

- LongHealth (Adams et al. 2025): LongHealth is a long-context clinical multiple-choice QA benchmark built from lengthy fictional patient-case records. It includes 20 case documents (about 5.1K–6.8K words each); we evaluate on 200 questions sampled from these records.
- QASPER (Dasigi et al. 2021): QASPER is an information-seeking QA benchmark grounded in full-text NLP papers, with roughly 5K questions over about 1.6K papers. We use each paper’s full text as the context.
- MK-NIAH (Hsieh et al. 2024): MK-NIAH is the multi-key needle-in-a-haystack task from RULER (Hsieh et al. 2024), where multiple key–value facts are embedded in a long context and the model must retrieve the value for a queried key.

B.2 Additional Results: BABILong

We evaluate HOPE (Sleep) on the BABILong benchmark (Kuratov et al. 2024), comparing against: (1) large models (GPT-4 and GPT-4o-mini (Achiam et al. 2023)); (2) a mid-scale Llama-8B model (Dubey et al. 2024) with RAG; and (3) state-of-the-art small long-context models, including RMT (Bulatov et al. 2022), ARMT (Rodkin et al. 2024), and Titans (Behrouz et al. 2024). All small models are fine-tuned using the official BABILong training protocol (Kuratov et al. 2024). As shown in Figure 6, large models exhibit rapid degradation as context length increases, failing beyond 128K–256K tokens. RAG improves robustness at longer contexts but still degrades as sequence length grows. Among fine-tuned small models, Titans, ARMT, and HOPE perform comparably up to approximately 1M tokens; beyond this point, Titans and ARMT degrade sharply, whereas HOPE remains stable even at extreme lengths up to 10M tokens. This robustness is driven by Sleep’s explicit consolidation and self-improvement mechanism, which transforms short-lived activations into compact parametric representations. By learning higher-level abstractions during consolidation, HOPE retains task-relevant information more efficiently, reducing sensitivity to increasing context length. Finally, we observe that all small models, including HOPE, suffer substantial performance drops without fine-tuning. Compressing ultra-long contexts requires sufficient capacity at lower-frequency memory levels to identify and preserve critical information; fine-tuning enables these components to adapt rapidly and coordinate effectively with high-frequency memory during inference.

B.3 Additional Experiments: ARC

We follow the few-shot ARC experimental protocol from prior work (Akyürek et al. 2024a; Zweiger et al. 2025) and adapting it to our SLEEP paradigm. As the backbone we use Llama-3.2-1B. Following common practice, we filter subset of data to avoid tasks that remain unsolvable under standard configurations, yielding 11 tasks for training and 8 held-out tasks for evaluation. During each *Sleep* cycle, the model first consolidate its previous memories, and then *dreams* by generating synthetic experiences from the few-shot demos. For each task, we sample 60 dreams and reject 45 of them. At test time, for each unseen task, the model generates 5 dreams and applies them independently before predicting the held-out output. We report the fraction of dreams that yield a correct answer. As the baselines, we follow Zweiger et al. (2025) and use: (i) ICL (In-Context Learning); (ii) TTT + synthetic updates (no dreaming); and (iii) SEAL (Zweiger et al. 2025). In this setting, SLEEP achieves a 80% success rate, higher than the other methods.

B.4 Additional Details

Table 5: Training Configuration for GRPO, SFT, and Sleep

Parameter	GRPO	SFT	Sleep
Learning Rate	5×10^{-6}	5×10^{-6}	5×10^{-6}
Effective Batch Size	32	32	32
Training Steps	500	100	100
LoRA Rank (r)	64	64	64
LoRA Alpha (α)	128	128	128

B.5 Efficiency

With the same number of steps, SFT is 4x more efficient than our method, however, their performance is not comparable. Accordingly, we also compare the efficiency, when targeting a specific performance. We trained the models so they achieve the same performance in AIME-24, AIME-25, and HMMT-25. In this case, SFT requires 4.3x, 3.6x, and 4.8x wall-clock time to match the performance of our design. Therefore, from this perspective, Sleep is very efficient, when targeting a specific performance.