

Nested Learning — 한국어의역본

이 문서는 arXiv:2512.24695 「Nested Learning: The Illusion of Deep Learning Architecture」 (Behrouz, Razaviyayn, Zhong, Mirrokni (Google)) 의 한국어 의역본입니다. 스타디용이며 공식번역이 아닙니다. 수식·수치·그림은 원문기준이고, 그림은 원저자의 것입니다. 자연스러운 이해를 위해문장은 의역했습니다.

초록 (Abstract)

지난 수십 년간 머신러닝 모델의 성능을 끌어올리려는 연구의 핵심은, 더강력한 신경망 아키텍처를 설계하는 일과 그것을 효과적으로 훈련시키는최적화 알고리즘을 동시에 고안하는 일이었다. 특히 언어 모델 (LM) 분야에서는눈부신 진전이 있었지만, 모델이 어떻게 **지속적으로학습·기억하고, 스스로 개선하며, 효과적인 해를 찾을 수 있는가**에 관한 근본적인 물음들은 여전히 열려 있다.

이 논문은 **Nested Learning(NL, 중첩 학습)** 이라는 새로운 학습패러다임을 제안한다. NL 은 하나의 머신러닝 모델을**중첩되고 (nested), 여러 수준 (multi-level) 이며, 병렬적일 수도 있는최적화 문제들의 집합**으로 일관되게 표현하며, 각 문제는 자신만의 “**context flow(맥락 흐름)**” 를 가진다. NL 의 렌즈로 보면 기존딥러닝 기법들은 저마다의 context flow 를 압축함으로써 데이터로부터학습하고 있으며, 대형 모델에서 **in-context learning** 은 자연스럽게**창발한다**. NL 은 더 많은 “레벨 (level)” 을 쌓아 더 표현력 있는 학습알고리즘을 설계하자는 철학을 제시하며, 이는 **더 높은 차수의 in-context learning** 과 나아가 **효과적인 continual learning** 능력을 열어줄 수 있다.

신경과학적 동기에 더해, 우리는 세 가지 핵심 기여로 NL 을 뒷받침한다. (1) **표현력 있는 최적화기 (Expressive Optimizers)**: Adam, 모멘텀 SGD 등 잘 알려진 경사기반 최적화기가 사실은 **그래디언트 정보를 (경사하강으로) 압축하는 associative memory 모듈**임을 보이고, 이 통찰을 바탕으로 더 깊은 메모리 구조나 더 강력한 학습 규칙을 갖춘 “더 표현력있는” 최적화기들을 제시한다. (2) **자기수정 학습모듈 (Self-Modifying Learning Module)**: 학습 알고리즘에 대한 NL 의 통찰을활용해, 자신의 갱신 알고리즘을 스스로 학습하여 자기 자신을수정하는 시퀀스 모델을 제안한다. (3) **Continuum Memory System(CMS, 연속체 메모리 시스템)**: 전통적인 “장기/단기 기억” 관점을 일반화하는 새로운 메모리 시스템 정식화를 제시한다. 이자기수정 시퀀스 모델과 CMS 를 결합하여 **Hope** 라는 continual learning 모듈을 제안하며, 언어 모델링·지식통합·few-shot 일반화·continual learning·장문맥 추론 과제에서 유망한 결과를 보인다.

“우리는 문제를 만들어낼 때 썼던 사고방식으로는 그 문제를 풀 수 없다!” —알베르트 아인슈타인의 말로 전해짐

1 서론 (Introduction)

수십 년간 AI 연구는 데이터 혹은 경험으로부터 학습하는 머신러닝알고리즘을 설계하는 데 집중해왔으며, 흔히 파라미터 $\theta \in \Theta$ 에 대해 목적함수 $L(\theta)$ 를 경사기반 방법으로최적화하는 방식을 취했다. 전통적인 머신러닝이 특징 추출기를 세심하게설계해야 했던 것과 달리, 딥 표현학습은 과제에 필요한 표현을 완전히자동으로 발견하는 대안을 제시했고, 이후 딥러닝은화학·생물학, 게임, 컴퓨터 비전, 멀티모달·자연어 이해 등에서 눈부신 성과를 거두며 대규모계산 모델의 핵심이 되었다.

딥러닝처럼 여러 층을 쌓는 것은 복잡한 특징을 표현하는 능력과 내부연산량 (예: FLOPS) 을 늘려주며, 이는 사전에 고정된 집합에 대한 분포내 (in-distribution) 예측이 필요한 정적 과제에서는 바람직한 성질이다. 그러나 이 “깊은” 설계가 모든 도전을 푸는 만능 해법은 아니며, 다음과 같은여러 측면에서 표현력을 끌어올리지 못한다. (i) 층을 더 쌓아도모델의 **계산 깊이 (computational depth)** 는 바뀌지 않을 수 있어 (Merrill et al. 2022), 복잡한 알고리즘을 구현하는 능력이 그대로다. (ii) 어떤 부류의 파라미터는 깊이/너비를 늘려도용량이 미미하게만 개선된다. (iii) 최적화기나 그 하이퍼파라미터선택이 부적절하면 훈련이 준최적해로 수렴할 수 있다. (iv) 새과제에 빠르게 적

응하거나 continual learning 을 하거나 분포 밖 (OOD) 데이터로 일반화하는 능력은 층을 더 쌓는다고 나아지지 않으며, 더 세심한설계를 요구한다.

이 도전들을 극복하려는 노력은 대체로 (1) 더 표현력 있는 파라미터 부류 (즉 신경망 아키텍처) 개발, (2) 과제를 더 잘 모델링하는 목적함수 도입, (3) 더 나은 해를 찾거나 망각에 강한 최적화 알고리즘 설계, (4) 올바른 아키텍처 · 목적 · 최적화 선택이 이루어졌을 때의 모델 규모 확장에 집중해 왔다. 이 성과들이 모여 대형 언어 모델 (LLM) 의 토대를 이루었다.

LLM 의 등장은 딥러닝 연구의 결정적 이정표다. 그러나 여러 놀라운 능력에도 불구하고 LLM 은 초기 배포 이후로는 사실상 정적이다. 즉 사전 · 사후 학습 때 익힌 과제는 잘 수행하지만, 자신의 즉각적인 맥락을 넘어 새로운 능력을 지속적으로 습득하지는 못한다. LLM 에서 적응 가능한 유일한 요소는 in-context learning 능력 — 맥락 (예: 몇몇 예시나 자연어 지시) 에 빠르게 적응하여 zero-/few-shot 과제를 수행하는, 창발적이라 알려진 성질 — 뿐이다. 그 너머의 시도들은 계산 비용이 크거나, 외부 구성요소를 요구하거나, 일반화가 부족하거나, catastrophic forgetting (파국적 망각) 을 겪는다.

현재 모델은 오직 ‘즉각적인 현재’ 만을 경험한다. LLM 의 정적성질을 비유하자면 전향성 기억상실 (anterograde amnesia) — 장애발병 이후 새로운 장기 기억을 형성하지 못하지만 기존 기억은 온전한 신경학적 상태 — 과 같다. 이 환자는 지식과 경험이 짧은 현재의 창과 먼 과거 (발병 이전) 에 갇혀, 언제나 즉각적 현재를 새롭게 되 겪는다. 현재 LLM 의 기억 처리도 유사하다. 그들의 지식은 문맥 창에 들어가는 즉각적 맥락, 혹은 “사전학습 종료” 이전의 먼 과거를 저장한 MLP 중 하나에만 담긴다. 이 비유가 신경생리학에서 영감을 얻어 뇌가 단기 기억을 어떻게 공고화 (consolidation) 하는지 살펴보게 한 동기다.

1.1 인간 뇌 관점과 신경생리학적 동기

인간의 뇌는 continual learning 에 매우 효율적 · 효과적인데, 이는 흔히 신경가소성 (neuroplasticity) — 새로운 경험 · 기억 · 학습, 심지어 손상에 반응해 스스로를 바꾸는 뇌의 능력 — 에 기인한다. 최근 연구는 장기 기억의 형성이 적어도 두가지 상보적인 공고화 과정을 포함함을 뒷받침한다. (1) 빠른 “온라인” 공고화 (시냅스 공고화) 는 학습 직후, 심지어 깨어 있는 동안에도 일어나며, 새롭고 취약한 기억 흔적이 안정화되어 단기에서 장기 저장으로 옮겨가기 시작하는 단계다. (2) “오프라인” 공고화 (시스템 공고화) 는 최근 부호화된 패턴의 재생 (replay) — 해마의 sharp-wave ripple 이 피질 수면 방추 · 서파 진동과 협응 — 을 반복하며 기억을 강화 · 재조직하고 피질로의 전이를 돕는다.

전향성 기억상실은 두 단계 모두에 영향을 줄 수 있지만 특히 온라인 공고화 단계에 타격을 준다. 해마가 새로운 서술 기억 부호화의 관문이기 때문이다. 앞서 말했듯 LLM, 특히 Transformer 기반 백본은 사전학습 이후 이와 유사한 상태에 놓인다. 즉 맥락에 주어진 정보는 결코 장기 기억 파라미터 (예: 피드포워드 층) 에 영향을 주지 못하며, 정보가 여전히 단기기억 (예: in-context 나 attention) 에 남아 있지 않는 한 새로운 지식 · 기술을 습득하지 못한다. 두 번째 (오프라인) 단계도 똑같이, 혹은 더 중요하지만, 이 연구에서는 첫 번째 단계 — 온라인 과정으로서의 기억 공고화 — 에 집중한다.

다중 시간척도 처리 시스템. 뇌 진동 (뇌파) 은 단순한 부산물이 아니라 주의 · 기억 · 의사결정 같은 인지 기능에 핵심 역할을 하며, 신경 계산을 조직하고 뇌 영역 간 소통을 조율하며 학습 · 기억의 바탕인 시냅스 가소성을 게이팅하는 핵심 기제로 이해된다. 이 뇌파는 뇌가 여러 시간척도와 갱신 빈도에서 계산을 협응한 결과이며, 각 빈도는 뉴런 집단이 얼마나 자주 활성화되어 갱신 정보를 공유하는지를 결정한다. 구체적으로, (1) 주로 감각 정보와 연관된 빠른 감마파 (30 – 150 Hz), (2) 능동적 사고와 연관된 베타파 (13 – 30 Hz), (3) 기억 공고화 · 학습을 담당하는 느린 델타 · 세타파 (0.5 – 8 Hz) 로 나뉜다.

반면 딥러닝 모델에서는 아키텍처의 가중치가 테스트 시점에 고정되며, 사전학습에서도 모든 블록/층에 동일한 갱신률을 쓰는 것이 일반적이다. 뒤의 6 장에서 보이듯 in-context learning 은 이 설계의 극단적 사례이며, 실제로 Transformer 는 두 극단 빈도 — attention 은 ∞ , MLP 는 0 — 에 기반한다.

뇌의 균일하고 재사용 가능한 구조. 신경가소성은 뇌가 신경 요소를 한 기능에 경직되게 배정하지 않고, 여러 인지적 필요에 유연하게 재배치할 수 있는 균일한 구조를 시사한다. 한 실험이 반구절제술 (hemispherectomy) 이다. 유년기에 시행되면 환자는 성인기까지 대체로 정상적인 삶을 영위하며, 언어 · 시각 등 두반구 뇌에 있는 핵심 신경망을 모두 갖춘 채 높은 인지 기능을 유지한다. 절




그림 1: 뇌의 균일하고 재사용 가능한 구조와 다중 시간척도 갱신은 인간의 continual learning 을 여는 핵심 요소다. NL 은 뇌의 각 구성요소가 다중 시간척도로 갱신되도록 허용하며, Transformer 같은 잘 알려진 아키텍처가 사실은 갱신 빈도만 다른 선형 층들을 보인다. 출처: 원저자, arXiv: 2512.24695 Fig.1

반의 뇌만으로도 자원을 재할당·재조직해 사람이 아주 잘기능할 수 있는 것이다. 나아가 이 해석은 인간 뇌의 기억이 특정 영역에 고립된 시스템이 아니라 **뇌 전반에 분산**되어 있음을 보여준다.

그러나 최근의 현대 딥러닝 아키텍처는 적어도 표면적으로는 self-attention 변형, 현대 RNN, canon 층, 전역 합성곱, MLP 블록의 조합으로 **이질적 (heterogeneous)** 으로 보인다. 이는 새로운 균일 아키텍처가 필요한지, 아니면 현재 모델의 이질성에 대한 우리의 믿음을 재검토해야 하는지를 묻게 한다.

1.2 기여와 로드맵

이 논문은 기존 알고리즘·방법·아키텍처에 새로운 통찰을 줄 뿐 아니라, 딥러닝에서 층을 쌓는 것과는 다른 **새로운 차원**—계산 깊이와 continual learning 능력을 향상시키는 차원—을 드러내는 통합 학습 패러다임을 제시한다.

Nested Learning 패러다임 (§ 3). NL 은 머신러닝 모델의 각 구성요소가 여러 레벨에서 자신의 맥락에 대해 자신만의 내부 그래디언트 흐름을 갖도록 허용하며, 모델과 그 학습 과정 (즉 최적화) 을 **중첩·다수준·병렬 최적화 문제들의 상호연결 시스템**으로 표현한다. 우리는 **최적화 과정과 학습 알고리즘/아키텍처가 근본적으로 같은 개념**이며 다만 시스템 내에서 서로 다른 레벨과 다른 맥락 (그라디언트 대 토큰) 에 있을 뿐이라고 주장한다. 나아가 이 둘은 상호연결되어 있으며, **학습 알고리즘/아키텍처가 최적화기의 맥락 (즉 그래디언트) 을 생성**하므로, 아키텍처별 맞춤 최적화기를 설계할 것을 옹호한다. 레벨 간 지식 전달의 여러 방식을 논하며, 메타러닝·in-context learning·RNN·하이퍼네트워크 등을 통합·일반화한다.

학습 모듈로서의 최적화기와 아키텍처 (§ 4, § 5). 역전파와 경사하강으로 신경망을 훈련하는 것은 각 층의 입력을 그 예측의 국소 오차로 매핑하는 **associative memory** 를 훈련하는 압축·최적화 문제라고 주장한다. 따라서 **사전학습은 in-context learning 의 한 형태**이며, 이때 맥락은 사전 학습 데이터 전체이고 층들은 그 맥락을 파라미터로 압축한다. 같은 논리가 다른 경사기반 최적화기에도 적용되어, 그들은 **그래디언트를 파라미터로 압축하는 associative memory** 다. NL 용어로, 모멘텀 경사하강·Adam·AdaGrad 는 각각 단순 경사하강으로 최적화되는 **2-레벨 중첩 최적화 문제**로 분해된다. 특히 이 관점에서 보면, 그래디언트를 압축하는 데 **Adam 은 원소별 (element-wise) L_2 회귀 목적에 대한 최적 associative memory** 임이 드러난다. 아키텍처와 최적화기를 결합한 **neural learning module** (아키텍처+훈련 과정의 결합 시스템) 은 모든 요소가 선형 또는 깊은 MLP 이며, 저마다 다른 레벨에서 다른 빈도로 자신의 내부 목적을 최적화하는 균일한 모델이다. 또한 우리는 **Delta Gradient Descent (DGD)** 를 제안한다. 이 갱신은 현재 입력뿐 아니라 신경망가중치의 상태에도 의존하여, i.i.d. 가정 없이 데이터 표본 간 의존성을 포착한다.

주요 시사점과 용어 재검토 (§ 6). (1) **Continual learning** 은 들어오는 맥락·에피소드의 시퀀

스에 대한 학습문제로 볼 수 있으며, 서로 다른 레벨이 각자의 in-context 지식을 압축해 상위 레벨로 전달한다. (2) **In-context learning**은 “여러 중첩레벨을 가짐”이라는 성질이다. Transformer의 ICL은 토큰에 대한 특정 회귀목적의 **비모수 (non-parametric)** 해여서 비롯되고, 현대 RNN은 하위레벨에서 **모수적 (parametric)** 학습 과정을 쓴다. (3) 학습/기억, 하이브리드 아키텍처, looped 아키텍처, learned optimizer 같은 용어도 재검토한다.

CMS, Self-Referential Titans, Hope (§ 7, § 8). “장기/단기 기억 (LSM)” 관점을 일반화해 **Continuum Memory System(CMS)**을 제시하고, 메모리를 **갱신 빈도의 스펙트럼**을 갖는 **분산 · 상호연결 시스템**으로 본다. 고빈도 뉴런은 빠른적응을 담당하되 짧게 기억하고, 저빈도 뉴런은 더 지속적인 지식을담당한다. LSM과 비교해 이 다중 빈도 설계는 모델 기억에 **루프과정**을 만들어, 망각된 지식이 부분적으로 복구될 수 있게 한다. 이 직관을활용해 **Multi-scale Momentum Muon(M3)** 최적화기도 설계한다.

평가 (§ 9). (1) 새 언어 학습 · 클래스 증분학습 · 새 코퍼스 QA를 포함한 continual/in-context 학습, (2) needle-in-a-haystack와 BABILong를 포함한 장문맥 이해, (3) 언어 모델링 · 상식 추론, (4) in-context recall·memorization, (5) 언어 인식 (state tracking) 과제, (6) M3를 포함한 최적화기 비교를 수행한다.

2 준비 (Preliminaries)

표기법. 입력을 $x \in \mathbb{R}^{N \times d_{in}}$, 시각 t 에서 메모리/모델 $\mathcal{M}$ 의 상태를 $\mathcal{M}_t$, 키 · 값 · 질의 행렬을 각각 K, V, Q 로 둔다. 입력 t 에 대응하는 벡터는 볼드 소문자 $\mathbf{k}_t, \mathbf{v}_t, \mathbf{q}_t$ 로 쓴다. 메모리 모듈 $\mathcal{M}(\cdot)$ 의 아키텍처로는 잔차연결을 갖는 $L_{\mathcal{M}} \geq 1$ 층의 단순 MLP를 사용하며, 필요 시 $\theta_{\mathcal{M}} \supseteq \{W_1, \dots, W_{L_{\mathcal{M}}}\}$ 로 매개변수화한다. 서로 다른 레벨 (다른 갱신 빈도)의 파라미터는 위첨자 $W^{(\ell)}$ 또는 빈도 $W^{(f_\ell)}$ 로 나타낸다.

경사하강 (Gradient Descent). 목적 $L(\cdot; \cdot)$ 과 학습률 $\eta_t > 0$ 에 대해 SGD는

$$W_{t+1} = W_t - \eta_t \nabla_{W_t} L(W_t; \mathbf{x}_t)$$

로 파라미터를 갱신한다. 이 갱신은 유클리드 계량에서의 **최급강하 (steepest descent)**와 동치이며, 다음의 근접 (proximal) 형태로 쓸 수 있다.

$$W_{t+1} = \arg \min_W \langle \nabla_W L(W_t; \mathbf{x}_t), W \rangle + \frac{1}{2\eta_t} \|W - W_t\|_2^2$$

이 식은 L 을 W_t 에서 1차 테일러 근사한 뒤 2차 근접 항으로 정규화한 것으로, L_2 -거리에서 작은 이동을 선호하는 암묵적 편향을 드러낸다. 상수 학습률로 스텝을 누적하면 **follow-the-regularized-leader(FTRL)** 형태

$$W_{t+1} = \arg \min_W \left\{ \sum_{s=1}^t \langle \nabla L(W_s; \mathbf{x}_s), W \rangle + \frac{1}{2\eta} \|W - W_1\|_2^2 \right\}$$

가 되며, 그 해는 $W_{t+1} = W_1 - \eta \sum_{s=1}^t \nabla L(W_s; \mathbf{x}_s)$ 이다. 이 두 정식화는 논문 전반에서 교환하여 쓴다. 이 근접/FTRL 동치가 논문의 모든 재해석을 떠받치는 대수적 엔진이다.

메타러닝 (Meta Learning). 메타러닝 (“learning to learn”)은 모델설계의 일부 (아키텍처 · 목적 · 최적화기 선택)를 **이중 수준 (two-level) 최적화**로 모델링해 자동화한다. 즉 파라미터 Φ 로 매개변수화된 목적 $\ell(\theta, \mathcal{D}; \Phi)$ 에 대해, 외부 루프는 과제 분포 $p(\mathcal{T})$ 위에서

$$\Phi^* = \arg \min_{\Phi} \mathbb{E}_{\mathcal{T}_i \sim p(\mathcal{T})} [\ell(\theta, \mathcal{T}_i; \Phi)]$$

를 최적화한다. 이 식은 여러 과제에 걸쳐 내부 절차가 성능을 극대화하도록 외부 모델이 파라미터를 설정하는 법을 배우는 것을 뜻한다. 최근에는 강력한 시퀀스 모델 설계 패러다임으로도 인기를 얻고 있다.

Fast Weight Programmers(FWPs). FWP(최근엔 linear Transformer 로도 불림) 는 메모리 (은닉 상태) 가 **행렬값**인 RNN 이다. 시변 fast-weight 행렬 $\mathcal{M}_t \in \mathbb{R}^{d_{out} \times d_{key}}$ 가 단기 기억으로 작동하며, 별도의 “프로그래머” (느린 망) 가 각 입력 $\mathbf{x}_t$ 를 질의 · 키 · 값으로 매핑하고 fast weight 를 온라인으로 갱신한다. 기본 (Hebbian/외적) FWP 의 갱신은

$$\mathcal{M}_t = \alpha_t \mathcal{M}_{t-1} + \mathbf{v}_t \phi(\mathbf{k}_t)^\top$$

이며, 읽기는 $y_t = \mathcal{M}_t \phi(\mathbf{q}_t)$ 로한다 (ϕ 는 원소별 특징 사상). 상태는 rank-1 갱신으로 쓰이고 행렬-벡터 곱으로 읽히며, 시간에 걸쳐 상태 크기가 일정한 콤팩트한 키-값 메모리를 제공한다.

In-context Learning(ICL). ICL 은 원래 Brown et al.(2020) 이 “언어 모델이 사전 학습에서 얻은 지식을 활용해, 오직 맥락 (예: 몇몇 예시나 자연어 지시) 만으로 새 과제를 추론 · 수행하는 능력” 으로 정의했다. 이후 Transformer+다음 토큰 예측에 한정되어 형식화되기도 했으나, 이 논문은 **가장 일반적인 정의**—모델이 주어진 맥락에 자신을 적응시키고 그로부터 학습하는 능력—를 사용한다. NL 정식화는 ICL 을 associative memory 개념과 연결하여, 아키텍처 백본이나 목적에 무관하게 ICL 능력을 통합적으로 설명한다.

3 Nested Learning

이 장은 NL 의 동기, 형식적 정의, 일반적 시사점을 다룬다.

Definition 1 (Associative Memory). 키 집합 $\mathcal{K} \subseteq \mathbb{R}^{d_k}$ 와 값 집합 $\mathcal{V} \subseteq \mathbb{R}^{d_v}$ 가 주어질 때, associative memory 는 연산자 $\mathcal{M}(\cdot)$ 로서

$$\mathcal{M}^* = \arg \min_{\mathcal{M}} \tilde{L}(\mathcal{M}(\mathcal{K}); \mathcal{V})$$

로 찾아진다. 여기서 $\tilde{L}$ 은 매핑의 품질을 재는 손실이다. (신경심리학에서 빌려온 용어로) “**memory**” 는 입력이 야기한 신경 갱신, “**learning**” 은 효과적 memory 를 획득하는 과정이다. 키 · 값은 반드시 토큰일 필요가 없으며 그래디언트 · 부분 시퀀스 등이 될 수 있다.

특별한 경우로, $\tilde{L}(\mathcal{M}_{t-1}; \mathbf{k}_t, \mathbf{v}_t) := -\langle \mathcal{M}_{t-1} \mathbf{k}_t, \mathbf{v}_t \rangle$ 로 두고 이 메모리를 경사하강으로 최적화하면 앞서 본 Hebbian FWP 갱신이 그대로 나온다. 즉 선형 어텐션류의 아키텍처가 한 스텝 경사하강의 associative memory 임을 알 수 있다.

Definition 2 (Update Frequency, 갱신 빈도). 임의의 구성요소 A (가중치 · 모멘텀 같은 파라미터 요소든, attention 블록 같은 비파라미터 요소든) 에 대해, f_A 를 단위 시간당 갱신 횟수로 정의한다 (한 데이터 점에 대한 한 번의 갱신이 시간 단위). $f_A > f_B$ 이거나, $f_A = f_B$ 이지만 시각 t 에서 B 의 상태를 계산하려면 t 에서 A 의 상태가 필요할 때 $A \succ B$ 로 순서를 매긴다. 비교 불가능한 요소들은 같은 레벨을 공유한다 (예: Adam 의 1 차 · 2 차 모멘트—같은 빈도, 독립 계산). 요소들은 순서 있는 레벨로 정렬되며, **레벨이 높을수록 빈도가 낮다**. attention 은 $f = \infty$, 고정 MLP 는 $f = 0$ 이다.

Definition 3 (Nested System, 중첩 시스템). 순서 있는 K 개 레벨을 갖는 시스템으로, 레벨 k 는 최적화 문제들 $\{(L_i^{(k)}, \mathcal{C}_i^{(k)}, \Theta_i^{(k)})\}_{i=1}^{N_k}$ (목적, 맥락=최적화 대상 데이터 흐름, 허용 파라미터 집합) 를 담는다. 각 문제는 근접형 경사하강

$$\theta_{i,t+1}^{(k)} = \arg \min_{\Phi} \langle \Phi \mathbf{x}_{t+1}, -\nabla L_i^{(k)}(\theta_{i,t}^{(k)}; \mathbf{x}_{t+1}) \rangle + \frac{1}{2\eta} \|\Phi - \theta_{i,t}^{(k)}\|_2^2, \quad \mathbf{x}_{t+1} \sim \mathcal{C}_i^{(k)}$$

로 풀리며, 일부 “박스” 에는 비모수 해도 허용된다.




그림 2: 머신러닝 모델과 그 훈련 절차를 중첩 최적화 문제집합으로 표현하는 Nested Learning 패러다임. (왼쪽) 하이브리드 아키텍처의 예. NL을 평면화한 이미지인 딥러닝 관점은 블록 내부의 계산 깊이에 대한 통찰을 주지 못하는 반면, NL은 모든 내부 그래디언트 흐름을 투명하게 표현한다. (오른쪽) Neural Learning Module: 자신의 context flow를 압축하는 법을 배우는 계산 모델. 첫 레벨이 모델의 가장 바깥 루프 훈련, 곧 “사전학습” 단계에 해당한다. 출처: 원저자, arXiv:2512.24695 Fig.2

Definition 4 (NSAM, Nested System of Associative Memories). 위와 같되 모든 문제의 맥락이 키-값 쌍 $C_i = \{(\mathbf{k}_j^{(i)}, \mathbf{v}_j^{(i)})\}$ 인 특수경우다 (부록 A의 Definition 6/7은 선형화된 목적을 완전한 $L_i^{(k)}(\Phi; \mathbf{x}_{t+1})$ 로 대체한 일반화형을 준다). **neural learning module**은 아키텍처+최적화를 하나의 NSAM으로 결합 표현한 것이며, 모델의 거동은 시스템 전체의 성질이다 (SGD로 훈련한 Transformer와 Adam으로 훈련한 Transformer는 **다른 모듈**이다).

대표 예시. (a) 1층 MLP + GD = 데이터를 국소 오차로 매핑하는 1-레벨 메모리. (b) GD+모멘텀 = 2-레벨 (내부는 그래디언트를 모멘텀 메모리로 압축, 외부는 그 모멘텀 상태를 가중치에 적용). (c) GD로 훈련한 선형 어텐션 = 2-레벨 (외부는 투영 W_k, W_v, W_q 를 최적화, 내부의 재귀 $\mathcal{M}_t = \mathcal{M}_{t-1} + \mathbf{v}_t \mathbf{k}_t^\top$ 를 실행하는데 이는 $\tilde{L}(\mathcal{M}; \mathbf{k}_t, \mathbf{v}_t) = -\langle \mathcal{M} \mathbf{k}_t, \mathbf{v}_t \rangle$ 에 대한 한 번의 GD 스텝). (d) 모멘텀-GD로 훈련한 선형 어텐션 = 3-레벨.

3.x 중첩 학습에서 레벨 쌓기 (Stacking Levels)

MLP 대 ‘Linear Attention++’ (AdaTransformer). Transformer 블록은 $\mathbf{y}_{block} = \mathbf{y}_{attn} W_{MLP}$ 를 계산하며, W_{MLP} 는 레벨 1에서 고정 (빈도 0)이다. 이 MLP를, 초기 상태 $\mathcal{M}_0 = W_{LinAttn_{init}}$ 가 **레벨 1에서 메타러닝되는** 선형어텐션 메모리로 바꾸면, 대수적으로 동일한 형태 $\mathbf{y}_{block} = \mathbf{y}_{attn} W_{LinAttn}$ 을 얻되 이제 $W_{LinAttn}$ 은 레벨 2에서 in-context로 갱신된다. 즉 **재귀메모리 모듈은 레벨이 하나 더 있는 MLP 블록**이며, 하이브리드는 MLP가 in-context 적응 능력을 얻은 Transformer다. 초기 상태가 메타러닝되지 않으면 ($\mathcal{M}_0 = 0$, 초기 선형 Transformer), 선형 층에 의한 출력 게이팅이 사라진 지속 메모리의 역할을 대신한다.

3.x 레벨 간 지식 전달 (Knowledge Transfer Between Levels)

최적화 문제와 빈도를 고르는 것과 나란히, **레벨 간 지식을 어떻게 전달하는가**가 NL의 두 번째 설계 축이다. 저빈도 블록 $B^{(0)}$ 과 고빈도블록 $B^{(1)}$ 사이에 다섯 가지 기제가 있다.

1. **직접 모수 조건화 (Direct parametric conditioning):** $\mathcal{M}^{(0)}(\cdot) := \mathcal{M}^{(0)}(\cdot; \Theta^{(1)})$ 또는 순전파 상에서 $\mathcal{M}^{(0)}(\cdot; \mathcal{M}^{(1)}(\cdot))$. 예: FWP의 fast weight가 느린 망의 출력을 먹임. 레벨 간 역전파 없이 서로의 상태를 하이퍼파라미터로 취급한다.




그림 3: Transformer 백본에서 FFN(예: MLP)과 선형 어텐션을 경사하강으로 최적화하며 비교한 예. 붉은 요소는 첫 레벨(빈도 1)의 블록, 파란 요소는 둘째 레벨(빈도 L)의 블록이다. 학습 가능한 초기 메모리상태를 갖는 선형 어텐션(Linear Attention++)은 in-context learning 능력과 입력 시퀀스에 대한 적응력을 더한다는 점만 빼면 MLP 층과 동일하다. 출처: 원저자, arXiv:2512.24695 Fig.3

2. 직접 비모수 조건화 (Direct non-parametric conditioning): $\mathcal{M}^{(0)}(\cdot; \mathcal{C}^{(1)})$. 예: softmax attention이 원시 맥락에 조건화.
3. 레벨 간 역전파 (Backpropagation across levels): 공유그래디언트 흐름이되 갱신 빈도가 다름. $\Theta_{t+1}^{(1)} = \Theta_t^{(1)} - \eta \delta_1 \hat{\mathbf{x}}_{t+1}^\top$, $\Theta_{t+1}^{(0)} = \Theta_t^{(0)} - \eta \delta_0 \mathbf{x}_{t+1}^\top$ ($\delta^{(0)}$ 은 자코비안 사슬로 얻음). CMS 레벨들이 이렇게 연결된다.
4. 초기화 (MAML 방식): $\Theta_0^{(1)} = \arg \min_{\Phi} \mathbb{E}_{\mathcal{C} \sim \mathcal{C}^{(0)}} [\ell(\mathcal{M}^{(1)}(\cdot; \Phi), \mathcal{C})]$. 내부 메모리의 초기 상태를 메타러닝한다 (Titans/TTT가 이렇게 함; 대부분의 선형 RNN은 하지 않음).
5. 생성 (Generation): 한 블록이 다른 블록의 가중치 (하이퍼네트워크)나 맥락을 생성한다. 핵심 예는 아키텍처가 최적화기의 맥락 (그래디언트)을 생성한다는 점이며, 이는 학습된 최적화기뿐 아니라 평범한 최적화기에도 성립하여 아키텍처별 맞춤 최적화기를 동기화한다.

4 학습 모듈로서의 최적화기 (Optimizers as Learning Modules)

훈련은 '놀람 (surprise)'에 대한 associative memory다. 선형 층 $y = Wx$ 에 대해 한 번의 SGD 스텝은

$$W_{t+1} = W_t - \eta_{t+1} \nabla_W L(W_t; \mathbf{x}_{t+1}) = W_t - \eta_{t+1} \nabla_{y_{t+1}} L(W_t; \mathbf{x}_{t+1}) \otimes \mathbf{x}_{t+1}$$

로 분해된다. 여기서 $\nabla_W L$ 이 "놀람"이고, $\mathbf{u}_{t+1} := \nabla_{y_{t+1}} L$ 이 표현 공간의 Local Surprise Signal(LSS, 국소 놀람 신호)–국소 예측 오차–다. 동치로

$$W_{t+1} = \arg \min_W \langle W \mathbf{x}_{t+1}, \mathbf{u}_{t+1} \rangle + \frac{1}{2\eta_{t+1}} \|W - W_t\|_F^2$$

이며, 이는 역전파 훈련이 각 입력을 그 국소 오차로 매핑하는 associative memory임을 뜻한다. 깊은 MLP $\{W_\ell \cdot + b_\ell\}_{\ell=1}^L$ 에서 역전파는 $\partial L / \partial W_\ell = \delta_\ell \hat{\mathbf{x}}_{\ell-1}^\top$ 을, $\delta_\ell = J_{\phi_\ell}(z_\ell)^\top W_{\ell+1}^\top \delta_{\ell+1}$ 로 계산하므로, 층 ℓ 의 갱신

$$W_{\ell,t+1} = \arg \min_W \langle W \hat{\mathbf{x}}_{\ell-1}, \delta_\ell \rangle + \frac{1}{2\eta} \|W - W_{\ell,t}\|_F^2$$

은 층 입력을 국소 오차 신호로 매핑한다.

핵심 미묘함: 역전파는 **그래디언트에 대한 선형 어텐션이 아니다**. 값 δ_ℓ 이 메모리 자신의 현재 상태로부터 생성되기 때문이다 ($\mathbf{v}_t = f_{W_t}(\mathbf{x}_t) = -\nabla_{y_t} L(W_t; \mathbf{x}_t)$). 이것은 **자기 자신의 목표 (target)**를 생성하는 자기참조 (**self-referential**) 메모리 (Schmidhuber 1993)이며, 바로 이 때문에 선형 재귀처럼 병렬화할 수 없다.

4.2 모멘텀 기반 최적화기 = associative memory

모멘텀은

$$W_{\ell,t+1} = W_{\ell,t} + m_{\ell,t+1}, \quad m_{\ell,t+1} = \alpha_{\ell,t+1} m_{\ell,t} - \eta_{\ell,t+1} \delta_\ell \hat{\mathbf{X}}_{\ell-1}^\top$$

이며, $\alpha = 1$ 일 때 $\min_m \langle m \hat{\mathbf{x}}_{\ell-1}, \delta_\ell \rangle$ 를 GD 로 푸는 것에 해당한다 ($\alpha \neq 1$ 이면 m 에 L_2 정규화 추가). 즉 모멘텀은 과거 그래디언트를 압축하는 **값-없는 (Hebbian) associative memory**, 곧 저역통과 필터다.

용량 분석. 감쇠 $\beta = 0.9$ 일 때 최근 6 개의 그래디언트가 누적 기여의 $\geq 50\%$, 최근 43 개가 $\geq 99\%$ 를 차지한다. 즉 최적화기는 오래된 과제의 그래디언트 부분공간을 잊으며, 과제 그래디언트 가직교하는 continual learning 에서 catastrophic forgetting 을 일으킨다. 이는 모델 용량이 아니라 **최적화기 메모리 관리 (memory management)** 의 실패다.

Adam(부록 B). 원소별 목적

$$\tilde{L}_t = \sum_{i=1}^t \|m_{\ell,t} \odot g_{\ell,i+1} - P_{\ell,t}\|_2^2 + \lambda_\ell \|m_{\ell,t}\|_F^2, \quad g = -\nabla_W L$$

을 상정하면 최적해는 $m^* = (H + \lambda I)^{-1} \odot \tilde{M} \odot P$ 이며, $\tilde{M}_{i+1} = \tilde{M}_i + \beta_1 g_{i+1}$ (1 차 모멘트), $H_{i+1} = H_i + \beta_2 g_{i+1}^2$ (2 차 모멘트) 다. 목표를 $P_{\ell,t} = \sqrt{\sum_i g_i^2}$ (그래디언트의 ‘분산’) 로 고르면

$$W_{i+1} \approx W_i - \frac{\eta}{\sqrt{\beta_2}} \frac{\tilde{M}_{i+1}}{H_i^{1/2}} + \varepsilon$$

곧 **Adam** 을 얻는다. 즉 Adam 은 그래디언트를 그 분산으로 매핑하는 원소별 L_2 목적의 **최적 associative memory** 다. 외적 버전은 모멘텀 있는 AdaGrad 를 회복하며, RMSProp·SignSGD·NAdam·AMSGrad·RAdam·Lion·Shampoo·SOAP 도 알려진 관계로 따라온다.

전처리 (Preconditioning). $W_{t+1} = W_t - \eta P_{t+1}^{-1} g_{t+1}$ 에서 P 는 내부적으로 $\min_P \tilde{L}(P(\hat{g}); g)$ 를 학습—그래디언트를 선택된 좌표계로 매핑하는 중첩 메모리다. **Muon:** $W_{t+1} = W_t + \text{NewtonSchulz}_k(m_{t+1})$ 이며, 직교화 목적 $\tilde{L}(P(g); g) = \|P(g)^\top P(g) - I\|_F^2$ 를 한 번의 GD 스텝 $O_{i+1} = O_i - \zeta(O_i - g_t + 2O_i(O_i^\top O_i - I))$ (초기 $O_0 = g_t$) 로 풀면 차수-3 Newton-Schulz 다항식이 나온다. 즉 Muon 의 NS 반복은 **내부 최적화 레벨** (k 번의 내부 스텝 = 뉴턴당 더 많은 계산)이다.

새로운 최적화기 설계. (a) **전처리 모멘텀:** $m_{i+1} = m_i - \eta_i P_i \nabla L(W_i; x_i)$. (b) **Delta Momentum:** 내적 목적을 L_2 회귀 $\|m \nabla L(W_i; x_i)^\top - P_i\|_2^2$ 로 바꿔 델타 규칙 갱신 $m_{i+1} = m_i \alpha_{i+1} - \eta_t (m_i \nabla L(W_i; x_i) - P_i) \nabla L(W_i; x_i)^\top$ 을 얻는다 (그래디언트 의존 감쇠, 과거 그래디언트 메모리 관리가 개선됨). (c) **Deep Momentum GD (DMGD):** 모멘텀을 MLP 로, $W_{i+1} = W_i + m_{i+1}(u_i)$, $m_{i+1} = \alpha_{i+1} m_i - \eta_t \nabla L^{(2)}(m_i; u_i, 1)(u_i = \nabla L(W_i; x_i))$. (d) **고차 특징 사상:** $m_{i+1} = \alpha m_i - \eta P_i \phi(\nabla L)$. (e) **비선형 출력:** $W_{i+1} = W_i + \sigma(m_{i+1}(u_i))$ ($\sigma = \text{NewtonSchulz}$, 선형 m 이면 Muon 회복).




그림 4: 함수 $\psi(r, \theta)$ 를 표준 모멘텀과 우리의 델타모멘텀으로 최적화한 결과. 출처: 원저자, arXiv: 2512.24695 Fig.4

진동하는 곡률을 가진 장난감 목적 $\psi(r, \theta) = r^2 + k(r - \theta + \alpha \sin(\omega r))^2$ 에서, $(r_0, \theta_0) = (-3.5, 2)$ 부터 최적화하면 **델타 모멘텀이 더빨리 해에 도달한다**. 그래디언트 의존 가중치 감쇠가 필요할 때 모멘텀 항을 감쇠 · 정지시키기 때문이다.

단순 GD· 모멘텀을 넘어서. (f) **Delta Gradient Descent(DGD)**: 학습 규칙 자체를 내적에서 L_2 회귀로 승격한다.

$$W_{t+1} = \arg \min_W \frac{1}{2} \|W \mathbf{x}_t - \mathbf{u}_t\|_2^2 + \frac{1}{2\eta_t} \|W - W_t\|_2^2, \quad \mathbf{u}_t = -\nabla_{y_t} L(W_t; \mathbf{x}_t)$$

정규화된 입력 ($\|\mathbf{x}_t\|_2 = \lambda$) 에 대해 Sherman – Morrison 항등식 (부록 C) 을 쓰면 닫힌 형태

$$W_{t+1} = W_t(I - \eta'_t \mathbf{x}_t \mathbf{x}_t^\top) - \eta'_t \nabla_{y_t} L(W_t; \mathbf{x}_t) \otimes \mathbf{x}_t, \quad \eta'_t = \frac{\eta_t}{1 + \eta_t}$$

을 얻는다. 이는 GD 에 **데이터 의존 감쇠** ($I - \eta' \mathbf{x} \mathbf{x}^\top$) 를 더한 것으로, 표본 간 상관을 반영한다 (i.i.d. 가정을 버림). 표본이 강하게 의존하는 토큰 공간에 알맞은 규칙이다.

Definition 5 (Generalized Gradient Descent, GGD). 자기생성 값 $u_t = f_{W_t}(x_t)$ 를 갖는 임의의 자기참조 메모리

$$W_{t+1} = \arg \min_W \tilde{L}(x_t, u_t) + \text{Ret}(W, \{W_i\}_{i=t-c+1}^t)$$

로, Ret 은 해를 최근 상태들 근처에 붙든다. GD·DGD 등을 포함하는 족이며, 유사하게 **Generalized Momentum(GM)** 도 정의된다.

4.3 최적화기의 장문맥: 직교 과제 continual learning 예시

앞서 보였듯 모멘텀은 과거 그래디언트를 압축하는 메모리다. 과제 그래디언트가 직교하는 continual learning 에서, 모멘텀의 저역통과 특성은 오래된 과제의 그래디언트 부분공간을 잊게 만들어 forgetting 을 일으킨다. 이는 모델 용량이 아니라 **최적화기 자신의 장문맥 이해 (메모리관리)** 문제이며, 더 표현력 있는 최적화기 (예: DMGD, Delta Momentum) 로 완화할 여지가 있다. **continual learning 시나리오에서 optimizer 의 역할**: 최적화기 자체가 학습 모듈이므로, “사전학습 종료” 에서 옵티마이저 상태 (손실 지형에 관한 지식) 를 버리면 그 저빈도 레벨의 지식도 사라진다. 지속적으로 학습하는 모듈은 이 하위 레벨도 보존해야 한다.

5 학습 모듈로서의 기존 아키텍처 (Existing Architectures as Neural Learning Modules)

Miras 관점을 되짚어, 아키텍처들도 **사전학습 위 레벨**에서 associative memory 로 나타난다 (키 $\mathbf{k}_t = \mathbf{x}_t W_k$ 등은 레벨-1 투영이 공급).

Softmax attention = 다음 회귀 목적의 **비모수해** (Nadaraya – Watson):

$$\mathcal{M}^* = \arg \min_{\mathcal{M}} \sum_{i=1}^L s(\mathbf{k}_i, \mathbf{q}) \|\mathbf{v}_i - \mathcal{M}\|_2^2 = \sum_i \frac{s(\mathbf{k}_i, \mathbf{q})}{\sum_j s(\mathbf{k}_j, \mathbf{q})} \mathbf{v}_i$$

최근 c 개 토큰으로 제한하면 sliding-window attention 이 된다.

Hebbian RNN(선형 어텐션, RetNet, RWKV, lightning attention) = $\tilde{L} = -2\langle \mathcal{M} \mathbf{k}_t, \mathbf{v}_t \rangle$ 에 대한 GD+weight decay:

$$\mathcal{M}_t = \alpha_t \mathcal{M}_{t-1} + \eta_t \mathbf{v}_t \phi(\mathbf{k}_t)^\top$$

Delta-rule RNN(DeltaNet, Longhorn, RWKV-7) = $\tilde{L}_t = \|\mathcal{M}_t \mathbf{k}_t - \mathbf{v}_t\|_2^2$ 에 retention $\|\mathcal{M}_t - \mathcal{M}_{t-1}\|_F^2$ 를 더한 SGD:

$$\mathcal{M}_t = (I - \eta_t \mathbf{k}_t \mathbf{k}_t^\top) \mathcal{M}_{t-1} + \eta_t \mathbf{v}_t \mathbf{k}_t^\top$$

Oja(OjaNet):

$$\mathcal{M}_t = \alpha_t \mathcal{M}_{t-1} + \eta_t (\mathbf{v}_t \phi(\mathbf{k}_t)^\top - \mathcal{M}_{t-1}^\top \mathbf{v}_t)$$

이는 $\tilde{L} = -2\langle \mathcal{M} \mathbf{k}_t, \mathbf{v}_t \rangle + \|\mathcal{M}^\top \mathbf{v}_t\|_2^2$ 에 대한 GD 다. **Omega rule**(Atlas) 은 캐시된 c 개 입력 창에 대한 비온라인 갱신 $\mathcal{M}_t = \alpha_t \mathcal{M}_{t-1} - \sum_{i=t-c+1}^t \gamma_{t,i} \tilde{L}(\mathcal{M}_t; \phi(\mathbf{k}_i), \mathbf{v}_i)$ 이며, Miras의 L_p -norm attentional bias가 L_2 목적을 일반화한다.

이렇게 보면 현대 아키텍처는 **선형 또는 깊은 피드포워드 뉴런들의 집합**이며, 각 뉴런 집단이 자신의 내부 목적과 갱신 기제를 가진다. 이는 서론에서 던진 질문—현대 스택의 이질성은 실은 환상(illusion)인가—에 대한 답이다. 겉보기의 이질성은 최적화 문제의 해만 보고 문제 자체를 보지 않은 데서 온다.

6 Nested Learning의 인간 뇌 관점 재조명 (Revisiting the Human Brain Perspective)

NL 관점에서 본 기억과 학습. 딥러닝은 attention(빈도 ∞ , 매 토큰 재계산)과 MLP(빈도 0, 테스트 시 고정)라는 두 극단 빈도만 쓴다. NL은 이 사이의 연속 스펙트럼을 허용하며, 이것이 뇌파의 다중 시간척도 갱신에 대응한다. **In-context learning**은 **창발이 아니라 구조적**이다— ≥ 2 개의 중첩 레벨을 가진 데서 오는 필연적 결과다. Transformer는 **비모수 ICL**(원시 맥락에 대한 닫힌 형태 Nadaraya–Watson 해), 현대 RNN/TTT 모델은 **모수 ICL**(맥락을 가중치로 압축)을 한다. “test-time training/memorization”은 곧 모수 ICL이며, **사전학습도 코퍼스를 맥락으로 하는 ICL**이다.

In-context learning으로부터의 지식 전달. 각 레벨은 자기 context flow에 대해 ICL을 수행하고, 압축한 지식을 상위 레벨로 전달한다. 이 관점은 continual learning을 “들어오는 맥락 시퀀스에 대한 학습”으로 재정의하며, 훈련/테스트 단계 구분에 의존하지 않고 지식·메모리를 지속 관리하는 모델을 옹호한다.

아키텍처가 최적화기의 맥락을 생성한다. 모멘텀·경사하강·전처리에 대한 우리 정식화는 학습된 (learned) 최적화기에만 국한되지 않는다. 평범한 최적화기도 아키텍처가 만들어내는 그래디언트를 맥락으로 압축하는 associative memory이므로, 주어진 아키텍처가 생성하는 그래디언트 분포에 맞춘 최적화기를 설계할 근거가 된다.

7 Continuum Memory System (CMS)

빈도 정의 (Definition 2)를 바탕으로, CMS는 **MLP 블록들의 사슬** $\text{MLP}^{(f_1)}, \dots, \text{MLP}^{(f_k)}$ 로 형식화된다. 각 블록의 체크 크기는 $C^{(\ell)} := \max_i f_i \cdot C / f_\ell$ 이며 (레벨 ℓ 은 $C^{(\ell)}$ 토큰마다 갱신), 순전파는

$$y_t = \text{MLP}^{(f_k)} \left(\text{MLP}^{(f_{k-1})} (\dots \text{MLP}^{(f_1)} (x_t)) \right)$$

갱신은

$$\theta_{i+1}^{(f_\ell)} = \theta_i^{(f_\ell)} - \eta^{(\ell)} \sum_{t=i-C^{(\ell)}}^i f(\theta_t^{(f_\ell)}; x_t) \quad \text{if } i \equiv 0 \pmod{C^{(\ell)}}, \text{ else no update}$$

여기서 $f(\cdot)$ 은 임의 최적화기의 오차항 (예: GD 면 ∇L), L 은 과제 목적 (다음 토큰 예측) 이다. 즉 각 블록이 자신의 최근 맥락을 가중치로 압축하며, 표준 Transformer MLP 는 $k = 1$, 빈도 0 의 퇴화 사례다.

세 가지 배선 변형. (i) **Nested CMS**—레벨 s 가 레벨 $s+1$ 의 초기 상태 $\theta_0^{(f_{s+1})} = \arg \min_{\Phi} \mathbb{E}_{T \sim \mathcal{C}(s)} [\ell(\Theta, T; \Phi)]$ 를 메타러닝하고, 각 블록은 자기 맥락 창이 끝나면 메타러닝된 초기값으로 재초기화된다 (고차 ICL). (ii) **Sequential CMS**—블록을 직렬배치하고 모든 초기 상태를 최저빈도 레벨에서 역전파로 메타러닝. (iii) **Independent(head-wise) CMS**—서로 다른 맥락 길이를 가진 병렬 블록들을 $y_t = \text{Agg}(\text{MLP}^{(f_k)}(x_t), \dots, \text{MLP}^{(f_1)}(x_t))$ (예: 학습 가능한 가중합) 로 결합.

왜 continual learning 에 도움이 되는가. 빠른 블록 $\text{MLP}^{(f_s)}$ 에서 잊힌 지식은 대체로 느린 블록 $s' < s$ 에 살아남으며, 초기 상태의 역전파 기반 지식 전달이 그것을 되돌려순환 (loop) 시킬 수 있다—시간 차원의 루프가 hard forgetting 을 어렵게 만든다. 설계 근거: 다중 빈도 = 뇌파 유비 + 비용분할상환, 레벨별 체크 누적 = 체크 내부의 시퀀스 병렬성 회복, 메타러닝 초기값 = 빠른 적응과 안정성.

7.3 Ad-hoc 레벨 쌓기: 사전학습 모델로 CMS 초기화

CMS 블록을 사전학습된 Transformer 의 MLP 로 초기화한다: $\text{MLP}_0^{(f_i)} = \text{MLP}_{\text{pretrained}_i}$. 내부 학습률 $\eta^{(\ell)}$ 은 동결된 사전학습 거동 ($\eta \rightarrow 0$) 과 완전 적응사이를 보간한다. 이것이 continual learning 실험에서 Llama-3 모델을 개조하는 방법이다.

7.x 최적화기 속 CMS: Multi-scale Momentum Muon (M3)

CMS 를 그래디언트 context flow 에 적용한 것이 M3 (Algorithm 1) 다. 매 스텝 갱신되는 빠른 모멘텀 $M_t^{(1)} = M_{t-1}^{(1)} + \beta_1 g_t$, f 스텝마다 한 번 갱신되는 느린 모멘텀 $M_t^{(2)} = M_{t-1}^{(2)} + \beta_3 \sum_{i=(k-1)f}^{kf} g_i$, Adam 식 2 차 모멘트 $V_t = V_{t-1} + \beta_2 g_t^2$ 를 유지한 뒤, 두 모멘텀을 직교화 $O^{(j)} = \text{NewtonSchulz}_T(M^{(j)})$ 하고

$$\Theta_t = \Theta_{t-1} - \eta \frac{O_t^{(1)} + \alpha O_t^{(2)}}{\sqrt{V_t} + \epsilon}$$

로 갱신한다. 즉 “Adam + Muon + CMS” 이며, independent-CMS 의 가중합 결합에 해당한다. 장문맥 모멘텀을 (튜닝된 감쇠가 아니라) 지연갱신으로 구현한 CMS 의 개념 증명이다.

8 Hope: 연속체 메모리를 갖춘 자기참조 학습모델

Hope 블록은 자기수정 Titans (작은 상태, 표현력 있는 DGD 규칙) 가 CMS 사슬 (큰 용량, 단순 규칙) 로 이어지는 구조로, 두 부분의 이도적으로 상보적이다.

8.1 자기수정 (자기참조) Titans

동기. Transformer 의 투영 W_k, W_v, W_q 는 in-context 에서 고정되어, 토큰을 맥락화하는 방식을 제한한다 (1 층 Transformer 의 투영은 토큰+위치만 봄). 해법: 모든 투영을 테스트 시점에 갱신되는 메모리로 승격한다.

1 단계 (완전 적응 메모리):

$$\mathbf{k}_t = \mathcal{M}_{k,t-1}(\mathbf{x}_t), \quad \mathbf{v}_t = \mathcal{M}_{v,t-1}(\mathbf{x}_t), \quad \mathbf{q}_t = \mathcal{M}_{q,t-1}(\mathbf{x}_t), \quad \eta_t = \mathcal{M}_{\eta,t-1}(\mathbf{x}_t), \quad \alpha_t = \mathcal{M}_{\alpha,t-1}(\mathbf{x}_t)$$

각 $\mathcal{M}_{\square}$ 와 주 메모리 $\mathcal{M}_{mem}$ 은 어떤최적화기로 $\min L(\mathcal{M}_{\square}; \mathbf{k}_t, \mathbf{v}_t)$ 를최적화하고, 출력은 $y_t = \mathcal{M}_{mem,t}(\mathbf{q}_t)$. 여기서 η_t (내부 학습률) 와 α_t (retention/forget 게이트) 도 입력 의존 메모리가 만든다. 모든 초기 상태 $\mathcal{M}_{\square,0}$ 은 시퀀스에 걸쳐 메타러닝된다(빠른적응 · 안정성 · 잡음 강건성에 필수).

2 단계 (자기수정): 모두가 공유하는 목표 $\mathbf{v}_t$ 대신, 각메모리가 자기 값을 스스로 생성한다.

$$\hat{\mathbf{v}}_{\square,t} = \mathcal{M}_{\square,t-1}(\mathbf{v}_t)$$

즉 모델이 자신의 훈련 목표를 만들어 **자신의 갱신 알고리즘을학습**한다 (Schmidhuber 의 self-referential weight matrix 계보). $\mathbf{q}_t = \mathbf{x}_t W_q$ 만 유일하게 비적응 투영으로 남긴다.

3 단계 (학습 규칙): 토큰이 상관되어 있으므로 내부최적화기로 **weight decay** 를 갖춘 DGD 를 쓴다. $\square \in \{k, v, q, \eta, \alpha, \text{memory}\}$ 에 대해

$$\mathcal{M}_{\square,t} = \mathcal{M}_{\square,t-1}(\alpha_t I - \eta_t \mathbf{k}_t \mathbf{k}_t^T) - \eta_t \nabla L_{\mathcal{M}_{\square,t-1}}(\mathcal{M}_{\square,t-1}; \mathbf{k}_t, \hat{\mathbf{v}}_{\square,t}), \quad L(\mathcal{M}; \mathbf{k}, \mathbf{v}) = \|\mathcal{M}(\mathbf{k}) - \mathbf{v}\|_2^2$$

메모리 아키텍처는 2 층 잔차 MLP $\mathcal{M}_{\square}(\cdot) = (\cdot) + W_{\square,1}\sigma(W_{\square,2}(\cdot))$ 이다 (원칙적으로임의). 선형 메모리 특수 사례로, 내적 목적이면 $\mathcal{M}_{\square,t} = \mathcal{M}_{\square,t-1}(\alpha_t I - \eta_t \mathbf{k}_t \mathbf{k}_t^T) - \eta_t \hat{\mathbf{v}}_{\square,t} \mathbf{k}_t^T$, L_2 목적이면 $\mathcal{M}_{\square,t} = \mathcal{M}_{\square,t-1}(\alpha_t I - \eta_t \mathbf{k}_t \mathbf{k}_t^T) - \eta_t (\mathcal{M}_{\square,C[t/C]} \mathbf{k}_t - \hat{\mathbf{v}}_{\square,t}) \mathbf{k}_t^T$ 이다.

8.2 Hope 순전파와 청크병렬화

정규화 · 합성곱을 생략한 Hope 순전파는

$$\mathbf{o}_t = \mathcal{M}_{mem,t-1}(\mathbf{q}_t), \quad y_t = \text{MLP}^{(f_k)}(\dots \text{MLP}^{(f_1)}(\mathbf{o}_t))$$

이며, 위의 자기수정 갱신을 모두 수행한다. 실무 세부: $\mathbf{q}, \mathbf{k}$ 는 L_2 정규화, 창 4 의 국소 합성곱을 쓴다.

청크 병렬화. 길이 L 시퀀스를 $\lceil L/C \rceil$ 개 청크로나누고, 각 메모리를 **직전 청크의 끝 상태** $\mathcal{M}_{\square,C[t/C]}$ 로 동결한 채 (a) 다음 청크전체의키/값/자기목표/학습률/게이트를생성하고 (b) 그 동결 스냅샷에 대한 내부 그래디언트를 계산한다. 그러면 한청크의 모든 내부 그래디언트를 청크 처리 전에 병렬로 구할 수 있어, TTT/Titans 의 빠른 dual/병렬 형태를 허용한다. 실무에서는 $\mathcal{M}_{mem}$ 용과 나머지 메모리 공용으로 **서로다른 두 청크 크기**를 쓴다. 이 청킹이 자기참조의 순차성을 깨는지점이며—청크 안에서 값 생성기는 낡은 스냅샷이므로—병렬 훈련을 사는근사다. 참고로 **진짜 역전파는 값이 상태 의존적 (자기참조) 이라이렇게 병렬화할 수 없다.**

Hope-Attention 변형: 자기수정 Titans 를 softmax 전역 어텐션으로대체해 CMS 의 기여만 분리한다.

9 실험 (Experiments)

세 축으로 평가한다. (1) 제안한 최적화 알고리즘을 SOTA 와 비교, (2) in-context/continual learning 과제에서 NL 과 고차 ICL 의 효과확인 (CMS 대 단순 MLP, 사전학습 모델의 continual learner 개조), (3) Hope 의 언어 모델링 · 장문맥 이해를 Transformer · 현대 RNN 과 비교.




그림 5: Hope 아키텍처 백본과 Transformer 의 비교 (명료성을 위해정규화 · 데이터 의존 요소는 제거). 출처: 원저자, arXiv:2512.24695 Fig.5




그림 6: 텍스트 분류 도메인의 클래스 증분 학습. (왼쪽) CLINC, (가운데) Banking, (오른쪽) DBpedia. Hope 개조 아키텍처가 ICL 을 포함한여러 continual learning 방법 중 최고 정확도를 달성한다. 출처: 원저자, arXiv:2512.24695 Fig.6

9.1 Hope: Continual Learning 과 장문맥이해

클래스 증분 학습 (Class Incremental Learning). 세 데이터셋에서평가한다. CLINC(150 개 인텐트, 10 개 도메인, 23.7K 질의), Banking(단일 도메인 77 개 인텐트, 3083 예시), DBpedia(70 개 온톨로지 클래스, 학습 10K/테스트 1K 표본). 백본으로 Llama3-8B·Llama-3B 를 쓰고 § 7.3 기법으로 MLP 블록을 적응 가능하게 만든 뒤 15B 토큰 continual 사전학습을 한다. 베이스라인은 Llama-3 의 단순 ICL, EWC(Elastic Weight Consolidation), InCA(외부 학습기 기반 continual learning). **Hope 가 InCA 를 포함한모든 베이스라인을 앞선다.** ICL 과의 차이는 Hope 의 다중 ICL 레벨 (=MLP 블록의 상이한 갱신 빈도) 에서 오며, InCA·EWC 대비 우위는레벨 간 지식 전달의 중요성을 보인다.

레벨이 ICL 에 미치는 효과. LongHealth(장문맥 임상 QA, 20 개 환자문서, 200 질문), QASPER(NLP 논문 정보탐색 QA, 약 5K QA), MK-NIAH(RULER 의다중키 needle) 로 평가한다. 베이스라인은 ICL(=1-레벨 Hope) 과 DuoAttention. **Hope 는 레벨 수 · 최저빈도에 무관하게 ICL 과 DuoAttention 을 모두 능가한다.** 또 (1) 메모리 레벨이 많을수록 ICL · 장기기억 · 장문맥 이해가 향상되고, (2) 최저빈도가 높을수록 (더 적응적 · 덜 지속적) 성능이 낮아진다. 갱신 빈도가 효율에 직결되므로, “최저빈도 = 2K” 가 “512” 에 근접한성능을 훨씬 효율적인 순전파로 내는 최적점일 수 있다.

In-context 새 언어 학습. MTOB(Kalamang) 와 Manchu 를 결합해 CTNL(Continual Translation of a Novel Language) 과제를설계한다. 두 설정: (1) 각 언어를 개별 학습 · 평가(빨강, forgetting 측정 기준선), (2) 두 언어를 순차로 in-context 학습 후 영어로번역(파랑). 베이스라인 ICL 과, 레벨 1/2/3 을더한 Hope-1/2/3 를 쓴다. 첫 설정에서 모든 Hope 변형이 ICL 과 대등 이상이며, 둘째 (continual) 설정에서 ICL 은급락 (catastrophic forgetting) 하지만 레벨




그림 7: 메모리 레벨이 ICL 성능에 미치는 효과. (왼쪽) RULER 의 MK-NIAH, (가운데) LongHealth, (오른쪽) QASPER. QASPER 는 값이 낮을수록 좋다. 출처: 원저자, arXiv:2512.24695 Fig.7

을 늘린 Hope 는 뚜렷이 개선되어 Hope-3 는 continual 없는 첫 설정 성능을 거의 회복한다.

9.2 Hope: 장문맥이해

이 절은 Hope 를 처음부터 (from scratch) 학습시켜 장문맥 이해를 평가한다. FineWeb-Edu 와 장문맥 문서 혼합의 약 50B 토큰, 어휘 32K, AdamW(모델별 튜닝 학습률) 로 학습한다.

Needle-in-a-Haystack(NIAH). 단일 needle(pass-key, number, uuid) · 다중키 · 다중질의 · 다중값설정을 평가한다. 베이스라인은 RetNet·DeltaNet(Hebbian/Delta 규칙 대표), RWKV-7·Comba(최고 성능 현대 선형 RNN), DLA·Titans(내적/ L_2 회귀 깊은 메모리).

표 1: Needle-In-A-Haystack 실험 (단일/다중키/다중질의/다중값)

Model	S-NIAH-1 4K			S-NIAH-2 4K			S-NIAH-3 4K		
	8K	16K		8K	16K		8K	16K	
Transformer	88.6	76.4	79.8	100	98.8	94.2	78.0	69.2	40.8
Hope-Attention	100	100	100	100	98.4	94.4	76.8	68.8	42.4
RWKV-7	100	100	99.6	93.8	44.8	12.6	63.8	13.2	5.8
Comba	100	100	99.4	92.6	47.2	13.4	62.4	13.8	7.4
DLA	96.4	71.2	44.0	79.6	42.6	28.2	18.2	8.8	4.0
Titans	100	100	100	99.6	84.6	75.4	74.2	42.8	21.2
Hope	100	100	100	99.2	88.4	78.2	73.2	46.2	24.8

Model	MK-NIAH-1 4K			MQ-NIAH 4K			MV-NIAH 4K		
	8K	16K		8K	16K		8K	16K	
Transformer	79.4	83.0	61.4	58.9	48.0	29.8	37.5	34.1	21.5
Hope-Attention	80.2	84.8	60.8	60.4	47.8	30.6	35.2	34.4	24.8
RWKV-7	21.4	18.8	9.6	20.4	14.8	8.6	16.2	13.4	6.8
Comba	21.4	19.4	8.2	21.8	15.2	6.4	16.5	13.5	7.2
DLA	27.4	20.0	11.8	26.4	22.0	6.4	25.6	12.8	9.6
Titans	26.4	23.6	8.2	22.8	19.8	9.4	24.6	15.1	8.2
Hope	29.4	24.8	14.8	31.7	24.8	14.2	31.4	17.2	11.4




그림 8: CTNL 과제. 빨간 점은 한 언어만 쓴 결과, 파란 점은 continual 설정 결과. 출처: 원저자, arXiv:2512.24695 Fig.8

Hope는 모든 **attention-free** 모델 중 전과제·난이도에서 최고다. 선형 메모리 대비 깊은 메모리모듈이 긴 시퀀스에서 우세하며 (더 큰 압축 용량), Titans 대비 Hope의 우위는 자기참조 갱신과 CMS 설계 둘 다의 중요성을 뒷받침한다. Hope-Attention은 Transformer보다 나아 CMS의 이점을 확인시킨다.

BABILong. GPT-4·GPT-4o-mini(대형), Llama-8B+RAG(중형), RMT·ARMT·Titans(SOTA 소형)와 비교한다. **대형 모델은 128K – 256K에서 모두 실패**하고, RAG 증강 모델도 하락하되 256K 이후 상대적으로 유지된다. 미세조정 소형 중 Titans·ARMT·Hope는 1M까지 경쟁적이나 Titans·ARMT는 그 이후 급락하는 반면, **Hope는 CMS 덕분에 10M 토큰까지 좋은 성능을 유지**한다. 단, 미세조정 없이는 모든 소형모델 (Hope 포함)이 크게 떨어진다.

9.3 Hope: 언어 모델링과 상식추론

Wikitext·LMB·PIQA·HellaSwag·WinoGrande·ARC-e·ARC-c·SIQA·BoolQ에서 평가한다. 760M/30B 토큰과 1.3B/100B 토큰으로 학습 (FineWeb-Edu+장문맥, 어휘 32K, AdamW).

표 2: 언어 모델링·상식 추론 성능
760M params / 30B tokens

Model	Wiki ppl ↓	LMB ppl ↓	LMB acc ↑	PIQA	Hella.	Wino.	ARC- e	ARC- c	SIQA	BoolQ	Avg ↑
Trans- former++	24.18	24.27	37.1	67.2	43.8	53.0	65.6	33.4	39.1	61.7	50.11
Samba*	21.07	22.85	39.2	68.9	47.8	53.1	65.8	34.9	38.9	63.1	51.46
Ret- Net	25.77	24.19	34.5	66.8	41.2	51.9	63.6	32.5	38.8	56.2	48.19
DeltaNet	24.52	24.38	36.8	67.3	44.5	51.8	64.2	32.7	39.6	60.1	49.63
RWKV- 7	23.75	23.08	37.1	67.3	47.6	52.2	64.7	34.2	39.4	61.9	50.55
Comba	22.41	22.19	37.5	66.9	48.2	52.4	65.1	34.1	40.1	62.8	50.89
TTT	24.17	23.51	34.7	67.3	43.9	51.0	64.5	33.8	40.2	59.6	47.32
Mi- ras (Mem- ora)	22.28	22.31	38.2	67.8	49.3	53.3	63.6	36.1	40.9	63.0	51.53
DLA	23.12	22.09	36.1	68.0	47.9	52.7	65.8	34.6	39.1	59.6	50.48
Ti- tans	20.08	21.52	38.1	69.1	48.5	52.7	66.2	35.7	40.3	62.8	51.68
Hope	18.68	20.07	38.8	69.2	49.1	53.6	66.8	36.1	41.2	63.4	52.28

1.3B params / 100B tokens

Model	Wiki ppl ↓	LMB ppl ↓	LMB acc ↑	PIQA	Hella.	Wino.	ARC- e	ARC- c	SIQA	BoolQ	Avg ↑
Trans- former++	17.92	17.73	42.6	71.4	52.3	54.1	69.9	36.5	41.8	58.4	53.38
Samba*	16.15	13.21	45.2	71.5	53.8	55.8	69.1	36.7	40.6	63.0	54.46
Ret- Net	18.91	17.04	41.2	71.3	49.1	55.2	67.5	34.1	41.4	61.0	52.60
DeltaNet	18.62	17.10	41.6	70.1	49.4	52.7	67.6	35.2	39.7	54.8	51.39
RWKV- 7	18.44	15.96	46.7	72.4	54.9	57.5	71.6	38.2	40.7	60.4	55.30
Comba	18.16	14.87	46.9	73.1	54.5	57.7	72.0	39.1	40.2	60.6	55.39
TTT	18.42	14.51	46.8	72.9	55.2	59.0	71.8	39.5	39.8	59.6	55.58

Model	Wiki ppl ↓	LMB ppl ↓	LMB acc ↑	PIQA	Hella.	Wino.	ARC- e	ARC- c	SIQA	BoolQ	Avg ↑
Mi- ras (Mem- ora)	15.90	12.04	48.7	73.1	56.0	57.4	71.5	37.9	40.2	61.3	55.76
DLA	16.31	12.29	44.5	70.6	53.9	54.2	69.6	36.0	40.8	60.2	53.72
Ti- tans	15.60	11.41	49.1	73.1	56.3	59.8	72.4	40.8	42.1	61.0	56.82
Hope	14.39	10.08	51.0	73.9	57.5	61.2	73.8	42.7	42.8	61.4	58.04

(* Samba 는 attention+선형 RNN 하이브리드.) **Hope** 가 두 규모모두에서 평균 성능 1 위이며, 특히 파라미터를 키울수록 다른 attention-free 모델 대비 성능 이득이 더 커진다.

9.4 Hope: In-context Recall 과 MAD 합성벤치마크

표 3: 짧은 in-context recall 성능

Model	SWDE	NQ	DROP	FDA	SQuAD	TQA
Transformers	71.4	22.0	23.9	67.3	39.4	59.1
RWKV-7	52.3	17.8	21.7	32.8	28.5	56.2
Comba	53.9	19.1	21.9	35.5	30.2	56.4
Titans	60.8	20.3	22.0	37.6	31.8	57.5
Hope	65.9	21.2	22.8	41.9	33.0	57.7

표 4: MAD 합성 벤치마크 성능

Model	Compress.	ICR	Fuzzy ICR	Selective Copying	Memory
Transformers	49.4	100	47.9	96.2	83.7
RWKV-7	45.1	100	32.8	95.6	82.2
Comba	46.3	100	32.8	96.4	82.9
Titans	49.8	100	50.0	99.4	83.4
Hope	51.2	100	52.1	99.7	85.2

짧은 in-context recall 에서는 **Transformer** 가 여전히 최고지만 Hope 가 모든 attention-free 베이스라인을 앞서며 격차를 좁힌다. MAD 합성벤치마크에서는 **Hope** 가 **Transformer** 를 포함한 모든 베이스라인을 능가한다.

9.5 언어 인식 (Language Recognition) 과제

Transformer 의 한계 중 하나는 재귀가 중요한 비병렬 과제 (state tracking) 다. Irie et al.(2023) 의 형식언어 인식 벤치마크를 따른다.

표 5: 형식언어 인식 과제 정확도 (Bin0=학습 분포 내, Bin1=분포밖 길이)

Model	병렬훈련	Parity Bin0/ Bin1	$(aa)^*$ B0/ B1	$(abab)^*$ B0/B1	$a^n b^n$ B0/ B1	$a^n b^n c^n$ B0/B1	Shuffle-2 B0/B1
LSTM	×	100 / 100	100 / 100	100 / 100	100 / 100	100 / 100	100 / 100
Trans- former	✓	46.4 / 0.0	0.0 / 0.0	0.0 / 0.0	100 / 100	100 / 100	100 / 100
Linear	✓	78.1 / 0.0	0.0 / 0.0	0.0 / 0.0	100 / 100	100 / 100	100 / 100

Model	병렬훈련	Parity Bin0/ Bin1	$(aa)^*$ B0/ B1	$(abab)^*$ B0/B1	$a^n b^n$ B0/ B1	$a^n b^n c^n$ B0/B1	Shuffle-2 B0/B1
DeltaNet	✓	98.2 / 10.1	0.0 / 0.0	0.0 / 0.0	100 / 100	100 / 100	100 / 100
SRWM	×	100 / 100	100 / 100	100 / 100	100 / 100	100 / 100	100 / 100
Hope	✓	100 / 100	100 / 100	100 / 100	100 / 100	100 / 100	100 / 100

Hope는 LSTM·SRWM 같은 비선형 재귀 모델처럼 모든과제에서 완벽 점수를 얻으며, 결정적으로 이들과 달리 병렬 훈련이 가능해 언어 모델링을 위한 대규모 확장에 유리하다.

9.6 Hope: Ablation 과스케일링

한 번에 하나씩 구성요소를 제거·변경해 설계 선택의 중요성을 검증한다 (평균 perplexity/평균 상식추론 정확도).

표 6: Hope Ablation Study

Model	언어모델링 ppl ↓	추론 acc ↑
Hope	12.24	58.1
w/o DGD (→ 단순 GD)	13.41	56.5
w/o Momentum	13.58	56.9
w/o weight decay	13.71	57.2
w/o CMS	13.04	57.3
w/o inner-projection k	13.77	56.9
w/o inner-projection v	13.90	55.1
w/o inner-projection q	12.19	57.4

inner-projection **q**를 제외한 모든 구성요소가 성능에 긍정적으로 기여한다 (제거·변경 시 ppl·정확도가 나빠짐). **q**의 적응은 오히려 미미하게 ppl을 개선하는데, 이는 최종 설계에서 **q**를 정적으로 유지한 선택과 일관된다.

9.7 표현력 있는 최적화기 (Expressive Optimizers)

ImageNet. ViT(24M·86M, patch 16, MLP dim 1536·3072)를 ImageNet-21K(11M 이미지, 10,450 클래스)에 사전학습한다. 다른 요소·하이퍼파라미터를 통제해 공정비교하며, **M3**가 AdamW·Muon 대비 최고의 학습/테스트 손실을 낸다.

대형 모델 효율. 140M·1.3B Transformer를 Muon·AdaMuon·M3로 학습한다. M3는 여러모멘텀 (메모리)을 쓰므로 Muon보다 다소 느리고 AdaMuon과 동등한 효율을 보인다.

10 결론 (Conclusion)

이 논문은 현대 머신러닝 시스템을 상호연결된 다수준 최적화문제들—각기 자신의 context flow와 갱신 빈도를 가진—로 모델링하는 **Nested Learning(NL)** 패러다임을 도입했다. 이 관점에서 아키텍처와 최적화기는 모두 자신의 맥락 (토큰·그래디언트·상위 신호)을 내부파라미터로 압축하는 **NSAM의 사례**이며, 사전학습·in-context learning·continual learning은 같은 기저 기제—서로 다른 레벨·시간척도에서 맥락을 압축·재사용하는 학습—의 발현으로 재정식화된다. 역전파·모멘텀·전처리는 associative memory 기제로 재해석되고, 방대한 기존 방법들이 (이전엔 숨겨져 있던) 더 큰 설계공간의 특정 설계점으로 설명된다.

NL 관점에서 우리는 **Delta Gradient Descent, Delta Momentum, Multi-scale Momentum Muon(M3)** 같은 일반화된 경사기반 갱신을 유도했고, 현대 시퀀스 아키텍처를 NSAM으로





Figure 8: Continual Translation of a Novel Language (CTNL) task. **Red** points are the results with only one language. **Blue** points are the results in the continual learning setup.



Model	Language Modeling ppl ↓	Reasoning acc ↑
HOPE	12.24	58.1
w/o DGD	13.41	56.5
w/o Momentum	13.58	56.9
w/o weight decay	13.71	57.2
w/o CMS	13.04	57.3
w/o inner-projection k	13.77	56.9
w/o inner-projection v	13.90	55.1
w/o inner-projection q	12.19	57.4




그림 11: ImageNet-21K 에서 AdamW·Muon·M3 로 학습한 ViT 의테스트 · 학습 손실. 출처: 원저자, arXiv:2512.24695 Fig.11





Figure 10: The effect of context usage on the perplexity of the model. We expect the perplexity of a model with powerful memory management to decrease with more context



재해석했다. 메모리 처리를 강화하기 위해 “장기/단기 기억 블록” 관점을 일반화하는 **CMS** 를 도입했다. 자기수정 Titans 와 CMS 에 기반한 **Hope** 아키텍처는 continual learning 과 장문맥 추론을 개선하면서 범용 백본으로서도 경쟁력을유지한다.

Catastrophic Forgetting 은 해결되었는가? Hope 와 CMS 는 실험한과제들에서 forgetting 을 줄이는 유망한 결과를 보였지만, 이 현상이일반적으로 “해결” 된 것은 아니다. NL 관점에서 catastrophic forgetting 은 압축의 자연스러운 귀결이다—망의 유한한 용량이 새정보를 위한 여지를 남기려고 모델을 잊게 만든다. 우리는 NL 을 종착점이 아니라 **로드맵**으로 본다. continual learning, 장문맥 추론, 현대최적화기, 자기수정 모델의 진보는 점점 더 깊은 정적 망이 아니라**레벨**이라는 추가 설계 축을 더 잘 활용하는 데서 올 것이다.

부록 A: 중첩 시스템과 NSAM 의 일반화된정식화

Definition 6 ((일반화된) Nested System). Definition 3 과 같되, 근접 스텝 내부의 선형화된 목적을 완전한 목적 $L_i^{(k)}(\Phi; \mathbf{x}_{t+1})$ 로 대체한다. 즉

$$\theta_{i,t+1}^{(k)} = \arg \min_{\Phi} L_i^{(k)}(\Phi; \mathbf{x}_{t+1}) + \frac{1}{2\eta} \|\Phi - \theta_{i,t}^{(k)}\|_2^2$$

이는 1 차 테일러 근사에 의존하지 않는 더 일반적인 근접 갱신을 허용한다.

Definition 7 ((일반화된) NSAM). Definition 6 과 같되 모든 문제의 맥락이 키-값 쌍인 특수 경우다. 이 일반화는 어텐션의 비모수 해부터 Adam 까지가 NL 틀 안에 들어옴을 보장한다.

부록 B: Adam, AdaGrad 및 유사 최적화기 = associative memory

원소별 목적 $\tilde{L}_t = \sum_{i=1}^t \|m_{\ell,t} \odot g_{\ell,i+1} - P_{\ell,t}\|_2^2 + \lambda_\ell \|m_{\ell,t}\|_F^2 (g = -\nabla_W L)$ 의 닫힌 형태 최적해는

$$m^* = (H + \lambda I)^{-1} \odot \tilde{M} \odot P, \quad \tilde{M}_{i+1} = \tilde{M}_i + \beta_1 g_{i+1}, \quad H_{i+1} = H_i + \beta_2 g_{i+1}^2$$

이며, 목표 $P_{\ell,t} = \sqrt{\sum_i g_i^2}$ 를 고르면 Adam 이 나온다. 외적 버전 ($\|mg - P\|^2, H_{i+1} = H_i + \beta_2 g g^\top$) 은모멘텀 있는 AdaGrad 를 회복한다. 1 차 ·2 차 모멘트는 같은레벨의 두 병렬 메모리다. RMSProp·SignSGD·NAdam·AMSGrad·RAdam·Lion·Shampoo·SOAP 는알려진 관계로 이 틀에 편입된다.

부록 C: DGD 닫힌 형태 유도보조정리

정규화된 입력 ($\|\mathbf{x}_t\|_2 = \lambda$) 에 대해 Sherman – Morrison 항등식

$$(\mathbf{X}_t \mathbf{X}_t^\top + \eta_t I)^{-1} = \frac{1}{\eta_t} \left(I - \frac{1}{\lambda^2 + \eta_t} \mathbf{X}_t \mathbf{X}_t^\top \right)$$

을 § 4 의 DGD 근접 문제에 적용하면 본문의 닫힌 형태 갱신을 얻는다.