

Sleep 말고 가능한 최신 대안들

어려운 Study paper 를 그림과 예로 다시 읽는 안내서

읽는 법 이 문서는 원 Study 의 결론을 바꾸지 않고, 질문→세 문장→직관→예/반례→그림→대안→미증명 지점 순서로 풀어 쓴다. 파란색 training 용어는 별도 Background paper 의 해당 개념으로 연결된다. 주장 ID 와 figure ID 는 원 Study 와 동일하다.

Contents

E04 · Sleep 말고 가능한 최신대안들	2
이 권이 답할질문	2
먼저 세 문장	2
직관	2
예와 반례	3
그림 읽기	4
대안과 비교	4
아직 모르는것	5
더 깊이 읽기	5
문서 경계와 사용법	7

E04 · Sleep 말고 가능한 최신대안들

이 권이 답할질문

장기 기억과 continual adaptation 을 해결하려면 정말 sleep-time compute 가 최선인가? 비교 대상은 “아무것도 안 함” 이 아니라 2026 년 현재 강한대안들이다: long context 와 retrieval, temporal graph, recurrent state, model editing, LoRA/adapter, latent compilation, self-adaptation. Sleep 은 이들을 대체하는 새 layer 라기보다, 여러 대안을 **언제실행하고 어떤 state 로 승격할지** 정하는 orchestration 축에 가깝다.

이 권은 alternative frontier 를 바탕으로 **STC-C026 · author_claim · confidence high, STC-C027 · synthesis · confidence high, STC-C028 · synthesis · confidence high, STC-C029 · synthesis · confidence high, STC-C030 · synthesis · confidence high, STC-C031 · synthesis · confidence high** 을 비교한다.

먼저 세 문장

1. 사실의 최신성 · 출처 · 삭제가 중요하면 외부 기억과 retrieval 이 기본값이다. 이 문제를 weight update 로 풀 이유가 약하다.
2. 반복 사용되는 stable skill 이나 style 처럼 retrieval overhead 가 계속 발생하면 LoRA · adapter · latent compilation 으로 선택적 parametric promotion 을 고려할 수 있다.
3. Sleep 의 경쟁력은 한 method 의 peak accuracy 보다, evidence 를 accumulate 해 **admission** → **compaction** → **evaluation** → **versioning** 을 응답 밖에서 운영할 수 있다는 데 있다.

직관

대안 1 — Long context 와 RAG

RAG 는 mutable knowledge 를 model 밖에 두고 필요한 passage 만 context 에 넣는다. 원문을 citation 할 수 있고 update · delete 가 쉽다. 약점은 retrieval miss, context token, index maintenance 다. 하지만 factual memory 에 대한 governance baseline 으로 매우 강하다. Sleep 이 RAG 보다 낫다고 주장하려면 future query 에서 반복 retrieval 하는 비용보다 background synthesis 비용이 작고, 정확도 · 삭제 가능성도 유지되어야 한다.

대안 2 — Temporal graph

Entity 와 relation 에 validity interval 을 붙이면 “A 가 B 였다가 C 가 됨” 을 표현할 수 있다. Vector similarity 만으로 해결하기 어려운 contradiction 과 temporal query 에 강하다. Graph maintenance 자체가 background compute 일수 있지만 foundation weight 를 바꾸지 않는다. 즉 external-memory STC 의 대표 medium 이다.

대안 3 — Recurrent/learned state

RNN, state-space model, Titans-like neural memory 는 긴 prefix 를 fixed-size 또는 learned state 로 압축한다. 매 token 의 context 재읽기를 줄일 수 있지만 state 가 어떤 prefix 에서 만들어졌는지 keying · sharing · cache invalidation 이 필요하다. 이 문제는 model architecture 와 serving infra 를 함께 요구한다.

대안 4 — Model editing

모델편집은 특정 factual association 을 localization 해 바꾼다. ROME 은 targeted edit, MEMIT 은 여러 memory 의 batch edit 가능성을 보였다. 그러나 bounded edit 성공은 lifelong sequence 에서 locality·retention·delete 가보장된다는 뜻이 아니다. “한 번 잘 고친다” 와 “영원히 안전하게 축적한다” 는다른 문제다.

대안 5 — Adapter 와 latent compilation

LoRA 는 weight delta 를 low-rank 로 제한해 trainable parameter 와 optimizer state 를 줄인다. Generative Adapter 처럼 context 를 한 번의 forward 로 parameter-like state 로 compile 하는 접근은 iterative gradient training 을피할 수 있다. 공통 관건은 compile cost 가 later reuse 로 상각되는지, version 과 tenant 별 delta 를 어떻게 관리하는지다.

대안 6 —Self-adaptation

Self-Adapting Language Models 계열은 model 이 adaptation data 와 update rule 을 스스로 생성한다. 이는 wake 와 sleep 사이를 잊지만, synthetic data quality 와 recursive error 가 핵심 risk 다. 좋은 data generation policy 를학습하는 것과 generated data 가 truth 를 보존하는 것은 별개다.

예와 반례

예 — 회사 규정 FAQ

규정은 출처·effective date·삭제가 중요하므로 temporal document store+RAG 가 우선이다. 질문 빈도가 높은 stable procedure 는 작은 domain adapter 로 promotion 할 수 있다. 매일 바뀌는 숫자까지 adapter 에 넣으면 stale weight 가 된다. Sleep job 은 모든 정보를 weight 로 옮기는 것이 아니라 promotion 후보를 평가한다.

예 — 개인 글쓰기 style

Style 은 하나의 원문 passage 보다 많은 episode 의 공통 pattern 이다. Retrieval 로 매번 예시를 넣을 수 있지만 token cost 가 반복된다. 충분한 consent 와 검증이 있다면 user adapter 가 효율적일 수 있다. 그러나 잘못학습된 style 은 모든 response 에 확산되므로 versioned rollback 이 필수다.

반례 — “Weight 면 retrieval 이 필요 없어 항상빠르다”

Adapter routing, loading, batching fragmentation, cache invalidation 까지포함하면 per-user weight 는 공짜가 아니다. 수백만 user 의 sparse delta 는 storage·metadata·activation 문제를 만든다. 또한 source citation 이필요하면 결국 external store 를 유지해야 한다.

반례 — “External memory 면안전하다”

Poisoned record 가 retrieval 되거나, summary 가 잘못 merge 되거나, delete 가 derived graph 까지 전파되지 않으면 external memory 도 위험하다. 외부라는사실은 observability 가능성을 높일 뿐, 올바른 policy 를 자동 제공하지않는다.




Figure 1: STC-F004. Problem-to-solution comparison matrix. 원 Study 의저자 작성 합성 figure 이며, 사실 주장의 인용은 원 Study 와 figure ledger 를따른다.

그림 읽기

문제-대안 matrix 에서 하나의 열이 모든 행을 지배하지 않는다. RAG 는 provenance, adapter 는 repeated access, graph 는 temporal conflict, recurrent state 는 sequence compression 에서 강하다. 비교의 단위는 accuracy 하나가 아니라 update cost, read latency, interference, delete, rollback, reuse 다.

Hybrid architecture 는 external system-of-record 를 아래에 두고, 검증된 high-reuse knowledge 만 reversible adapter 나 cache 로 promotion 한다. 이그림에서 sleep cluster 는 source-of-truth 가 아니다. evidence 를 읽고 derived state 를 생성하는 compiler 다. 따라서 derived artifact 는 언제든지 원 evidence 에서 rebuild 가능해야 한다.

대안과 비교

접근	가장 잘 푸는 문제	reusable state	sleep 이 추가하는 가치	결정적 약점
long context	한 번의 깊은 이해	현재 context	사전 selec-tion·summary	매 요청 재독해
RAG/vector	factual lookup	document/in-dex	dedup·index rebuild	retrieval miss
temporal KG	변화 · 관계	graph	merge·super-sede	graph maintenance
recurrent state	prefix compression	hidden/neural state	snapshot·cache	state reuse/keying
editing	targeted correction	base weight	batch evaluation	lifelong locality
LoRA/adapter	stable repeated behavior	delta weight	promotion·ver-sion	fragmenta-tion/delete

접근	가장 잘 푸는 문제	reusable state	sleep 이 추가하는 가치	결정적 약점
latent compiler	fast parameterization	generated delta	batch compilation	fidelity·amortization

가장 합리적인 선택 순서는 “외부에 남겨도 되는가?” 부터 묻는 것이다. 예라면 external memory 가 governance 기준선이다. 이후 reuse 가 높고 stable 하며 latency 가치가 큰 subset 만 parametric state 로 올린다. 이순서를 뒤집으면 모든 transient fact 가 weight 에 들어가 capacity 와 deletion debt 를 만든다.

아직 모르는것

- Retrieval token 을 adapter 로 compile 할 때 정확히 몇 회의 reuse 에서 break-even 인지 workload 별 측정이 부족하다.
- Generative Adapter 같은 one-pass compilation 이 iterative fine-tuning 의 retention 과 locality 를 어디까지 따라가는지 대규모 evidence 가 없다.
- Recurrent state cache 의 cross-request reuse 율과 invalidation cost 가 KV prefix cache 와 공정하게 비교되지 않았다.
- Editing·LoRA·external memory 를 동일한 continual stream, delete request, poisoning attack 에서 비교한 benchmark 가 부족하다.
- Self-generated adaptation data 의 quality 를 external ground truth 없이 평가하는 방법이 미해결이다.

핵심

Sleep 은 “RAG 다음의 새 memory” 가 아니다. RAG·graph·adapter·state 를 어떤 cadence 와 evidence gate 로 유지할지 결정하는 lifecycle layer 다.

더 깊이 읽기

- 원 분석: 최신대안 frontier 와 선택 조건
- Training Background: 외부기억, LoRA, adapter, 모델편집, test-time training, 합성데이터
- Claim route: **STC-C026** · author_claim · confidence high · **STC-C027** · synthesis · confidence high · **STC-C028** · synthesis · confidence high · **STC-C029** · synthesis · confidence high · **STC-C030** · synthesis · confidence high · **STC-C031** · synthesis · confidence high

Hybrid: external system-of-record → selective reversible promotion




Figure 2: STC-F006. Hybrid system-of-record and selective-promotion architecture. 원 Study 의 저자 작성 합성 figure 이며, 사실 주장의 인용은 원 Study 와 figure ledger 를 따른다.

문서 경계와 사용법

이 문서는 쉬운 설명본이지 새로운 증거원이 아니다. 수치 · 인용 · claim status 는 원 Study paper 와 claim map 이 우선한다. 학습 개념은 Training Background paper 를 함께 읽고, 논문 재현이나 외부 배포 판단에는 고정 source 와 rights audit 를 사용한다.