

Memory device 회사에 생기는 기회

어려운 Study paper 를 그림과 예로 다시 읽는 안내서

읽는 법 이 문서는 원 Study 의 결론을 바꾸지 않고, 질문→세 문장→직관→예/반례→그림→대안→미증명 지점 순서로 풀어 쓴다. 파란색 training 용어는 별도 Background paper 의 해당 개념으로 연결된다. 주장 ID 와 figure ID 는 원 Study 와 동일하다.

Contents

E11 · Memory device 회사에 생기는 기회	2
이 권이 답할질문	2
먼저 세 문장	2
직관	2
예와 반례	3
그림 읽기	4
대안과 비교	5
아직 모르는것	6
더 깊이 읽기	6
문서 경계와 사용법	7

E11 · Memory device 회사에 생기는 기회

이 권이 답할질문

Sleep-time compute 가 확산되면 memory device solution 회사는 단순히 더 큰 HBM-SSD 를 파는 것 외에 무엇을 할 수 있는가? 기회는 새 FLOP 수요보다 **derived memory lifecycle** 의 **byte movement, random rewrite, snapshot, provenance, delete/rebuild** 에서 더 선명하다. Device 는 저장매체와 software primitive 를 함께 제안해야 한다.

이 권은 device opportunity map 을 설명하며 **STC-C048** · hypothesis · confidence medium, **STC-C049** · hypothesis · confidence medium, **STC-C050** · hypothesis · confidence medium, **STC-C051** · hypothesis · confidence low, **STC-C052** · hypothesis · confidence medium, **STC-C053** · hypothesis · confidence medium, **STC-C054** · hypothesis · confidence medium, **STC-C055** · hypothesis · confidence medium, **STC-C056** · hypothesis · confidence low, **STC-C057** · hypothesis · confidence medium 을 제품 가설로 변환한다.

먼저 세 문장

1. Sleep workload 는 sequential checkpoint 뿐 아니라 vector/graph metadata 의 작은 random rewrite 와 versioned adapter read 가 크다. Endurance·index locality·copy-on-write 가 중요하다.
2. 가장 차별화 가능한 solution 은 provenance-first store, snapshot/rollback, near-data preprocessing, adapter fabric, reusable-state cache, secure delete/rebuild 다.
3. 평가 지표는 raw bandwidth 가 아니라 **retained useful evidence, migration byte, write amplification, rollback time, wake-SLA interference** 여야 한다.

직관

Opportunity 1 — Provenance-first append-only store

Episode 와 derived memory 를 content-addressed object 로 저장하고 “어느 evidence 와 transform 에서 만들어졌는가” 를 edge 로 남긴다. Append-only generation 은 in-place corruption 을 줄이고 rollback 을 쉽게 한다. 장치는 small metadata lookup 과 sequential object write 를 함께 최적화할 수 있다.

Opportunity 2 — Snapshot 과 copy-on-write

Sleep job 마다 full model·index·graph 를 복제하면 byte 가 폭증한다. Unchanged block 을 공유하고 changed delta 만 쓰는 copy-on-write snapshot 은 버전관리과 롤백을 싸게 만든다. Atomic root pointer switch 는 publish primitive 가 된다.

Opportunity 3 — High-endurance indexed tier

Vector insert, graph edge update, supersede metadata, decay score 는 작은 random write 를 반복한다. HBM peak bandwidth 보다 endurance, write amplification, tail latency 가 중요하다. Log-structured layout, compaction offload, metadata cache 가 solution 이 될 수 있다.

Opportunity 4 — Near-data preprocessing

Raw episode 를 모두 GPU 로 보내기 전에 dedup, filtering, tokenization, embedding candidate search, graph neighborhood gather 를 storage 근처에서 수행한다. 이 기능은 expensive accelerator token 과 interconnect byte 를 줄인다. **STC-C051** · hypothesis · confidence low 은 near-data 를 training accelerator 대체가 아니라 data reduction stage 로 본다.

Opportunity 5 — Versioned adapter fabric

Adapter 는 full model 보다 작지만 user/domain 수가 많아지면 active set 관리가 어렵다. Adapter store 가 version, tenant, base-model compatibility, hotness 를 index 하고 GPU cache 에 prefetch·merge·evict 하면 serving fragmentation 을 줄일 수 있다.

Opportunity 6 — Reusable-state cache

RNN/neural-memory model 은 prefix 를 compressed state 로 materialize 한다. Cache 가 model version+prefix hash 로 state 를 재사용하면 full prefill 을 피할 수 있다. Device 는 KV 뿐 아니라 dense recurrent state, optimizer-like accumulator, memory block snapshot 을 지원해야 한다.

Opportunity 7 — Secure delete-and-rebuild

Source episode 가 삭제되면 summary, vector, graph, adapter 까지 lineage 를 따라 invalidate 해야 한다. Device/firmware 가 cryptographic erase, generation tombstone, fast rebuild scan 을 제공하면 compliance SLA 가 제품 차별점이 된다.

핵심

Memory device 기회는 capacity 판매가 아니라 “기억 generation 의 lifecycle transaction” 을 빠르고 검증 가능하게 만드는 데 있다.

예와 반례

Device solution package 예

1. **Evidence Log Tier** — immutable append, encryption, content hash
2. **Derived Index Tier** — high-endurance vector/graph update, compaction engine
3. **Adapter Vault** — versioned small tensor object, compatibility metadata
4. **Hot State Cache** — KV/recurrent/neural state unified caching
5. **Snapshot Engine** — COW generation, atomic publish, rollback
6. **Lineage/Deletion Engine** — provenance traversal, tombstone, rebuild queue
7. **Telemetry** — byte moved, WA, cache hit, rollback, staleness counters

이는 단일 chip 보다 controller, firmware, runtime, reference architecture 의 결합이다.

On-device sleep 예

Smartphone 이 charging·Wi-Fi·thermal 여유 상태에서 private episode 를 local summary 로 만들고, small personalization adapter 를 업데이트한다. Raw data 는 device 를 떠나지 않는다.




Figure 1: STC-F011. State-migration roofline for wake and sleep clusters. 원 Study 의 저자 작성 합성 figure 이며, 사실 주장의 인용은 원 Study 와 figure ledger 를 따른다.

NPU/DRAM/flash 사이 이동, flash endurance, encrypted snapshot, 실패 시 rollback 이 중요하다. 모든 task 가 아니라 privacy 가치가 큰 개인 assistant 에서 유망하다.

반례 — HBM 용량만 2 배

Working set 이 adapter·index·graph·episode 로 섞여 있고 access 가 sparse 하면 HBM 에 모두 올리는 것은 비싸다. Capacity 가 늘어도 cold object, random write, version metadata 문제는 남는다. Tiering policy 와 object semantics 가 없으면 usable utility 는 선형 증가하지 않는다.

반례 — GPU 근처에 모든 preprocessing 배치

Dedup 할 raw episode 를 먼저 GPU 까지 옮기면 interconnect 와 HBM bandwidth 를 이미 썼다. Storage-side filter 가 90%를 제거할 수 있다면 near-data 가 더합리적이다. 반대로 deep semantic evaluator 는 GPU 가 필요하므로 function placement 를 workload 별로 나눠야 한다.

그림 읽기

Roofline 의 각 점은 다른 device 병목을 가진다. Teacher/student training 은 compute-dense, graph maintenance 는 bandwidth/random-write, snapshot 은 sequential capacity, adapter serve 는 latency/cache hit 가 지배한다. “Sleep accelerator” 하나보다 heterogeneous tier 를 연결하는 것이 중요하다.

Opportunity map 은 가까운 기회와 먼 가설을 나눈다. Snapshot, provenance store, indexed tier, adapter cache 는 기존 storage primitive 의 확장으로 시작할 수 있다. Learned in-memory consolidation 이나 autonomous on-device dreaming 은 연구 위험이 더 높다. SAIT/메모리 팀 은 가까운 primitive 부터 trace 와 benchmark 를 확보할 수 있다.




Figure 2: STC-F012. Memory-device opportunity map. 원 Study 의 저자 작성합성 figure 이며, 사실 주장의 인용은 원 Study 와 figure ledger 를 따른다.

대안과 비교

solution	고객 문제	device primitive	KPI	first demo
provenance store	audit/rebuild	append+lineage index	lineage query latency	memory delete trace
COW snapshot	safe publish	block sharing+atomic root	snapshot byte/time	adapter generations
indexed endurance tier	graph/vector rewrite	log structure+compaction	WA/endurance	temporal KG stream
near-data preprocessing	state migration	filter/dedup/-gather	bytes avoided/J	episode synthesis
adapter fabric	version explosion	object index+prefetch	hit/batching gain	multi-tenant LoRA
reusable-state cache	RNN prefix reuse	state key+cache	state hit/TTFT	HOPE/NSTM serving
delete/rebuild engine	compliance	tomb-stone+scan	delete SLA/leakage	derived-memory DAG

옵티마이저상태도 sleep checkpoint 에서 weight 보다 2 배 이상 클 수 있어 sharded snapshot 과 cold tier 가 필요하다. 다만 inference-only adapter 는 optimizer state 를 publish 하지 않아도 되므로 train-time object 와 serve-time object 를 분리해야 한다.

아직 모르는것

- 실제 production trace 에서 graph/vector/adaptor/episode byte 비율과 hotness distribution 이 공개되지 않았다.
- Near-data semantic filtering 의 accuracy loss 와 accelerator byte 절감 tradeoff 가 측정 되지 않았다.
- Recurrent state cache 가 어떤 granularity 에서 KV cache 보다 경제적인지 workload 가 부족하다.
- Adapter merge 가 quality 와 batch efficiency 에 미치는 영향이 model 별로 다르다.
- Secure delete 가 parametric artifact 에 대해 “완료” 되었다고 증명하는방법이 없다.

시스템 모델링 관점

Device roadmap 은 speculative STC FLOP forecast 보다, 오늘 구현 가능한 lifecycle trace 를 수집하고 state-migration roofline 을 만드는 것에서 시작해야 한다.

더 깊이 읽기

- 원 분석: 10 개 memory-device opportunity 와 maturity
- Training Background: adapter, 옵티마이저상태, 샤딩, 버전관리, 롤백, 출처추적성
- Claim route: **STC-C048** · hypothesis · confidence medium · **STC-C049** · hypothesis · confidence medium · **STC-C050** · hypothesis · confidence medium · **STC-C051** · hypothesis · confidence low · **STC-C052** · hypothesis · confidence medium · **STC-C053** · hypothesis · confidence medium · **STC-C054** · hypothesis · confidence medium · **STC-C055** · hypothesis · confidence medium · **STC-C056** · hypothesis · confidence low · **STC-C057** · hypothesis · confidence medium

문서 경계와 사용법

이 문서는 쉬운 설명본이지 새로운 증거원이 아니다. 수치 · 인용 · claim status 는 원 Study paper 와 claim map 이 우선한다. 학습 개념은 Training Background paper 를 함께 읽고, 논문 재현이나 외부 배포 판단에는 고정 source 와 rights audit 를 사용한다.