

E10 · 무엇이 무너지나 — 반증축

이 권은 본문 ch22(반증 축)와 이 저장소의 실험 X4를 수식과 증명 없이 다시설명한다. 앞의 권들은 “가중치에 사실을 어떻게 쓰는가”를 다뤘다. 이 권의질문은 방향이 반대다 — 같은 쓰기를 스무 번, 백 번 반복하면무엇이 남는가.

답을 미리 적어 둔다. 무너지는 것은 네 가지이고 서로 다른 처방을요구한다. 그중 둘은 어떤 처방으로도 고쳐지지 않았다. 그리고 이 권의후반은 두 문장에 걸쳐 있다 — 평평한 손실 곡선은 안정의 증거가아니다. “라운드당 몇 %”는 운영 지표가 될 수 없다.

1. 질문을 뒤집는 논문하나

이 라인의 논문은 거의 전부 한 번의 쓰기를 보인다. 통합 라운드하나, 혹은 짧은 수열. 그 관행을 깬 논문이 한 편 있다 — [Continual Facts] (Can a Language Model Learn Facts Continually in Its Weights?, arXiv:2607.11020) 다.

절차는 단순하다. 발명된 사실 한 문장으로 학습 데이터를 만들고, 작은 adapter를 학습시킨 뒤, 그 adapter를 모델 가중치에 **merge**하고, 다음 사실로 넘어간다. 이것을 20 회, 이어서 100 회 반복한다. 나란히대조군을 세운다 — 똑같은 사실을 가중치에 쓰지 않고 그냥 프롬프트에 넣는다.

기호 풀이 Θ (slow weights) = 배포되는 가중치. .safetensors로 굽는 그것이다. W (fast weights) = 요청 처리 중에만 사는 고정 크기 상태. E (external store) = 모델 밖의 저장소. k = **sleep 라운드** 침자. 오프라인 정리 작업의회차이며 토큰 침자 t 와 완전히 다른 시계다. **adapter** = 가중치전체 대신 작은 행렬 두 개만 학습해 그 굽을 원래 행렬에 더하는 장치 (→ E01 § 9). r = 그 행렬의 rank. **merge** = adapter를 원래 가중치에실제로 더해 넣고 adapter 객체는 버리는 연산. merge하는 순간 그 변화는모델 자체가 되고 되돌릴 수 없다.

설정은 Qwen3-4B, $r \in \{4, 16\}$, attention과 MLP의 일곱 투영 행렬전부, 사실 하나당 optimizer step 24·96·192 회다. 사실 247 개는 전부 발명된 것이고대부분 익숙한 기본값을 위반한다.

이 논문에는 드문 성질이 하나 있다. 이 라인의 논문을 한 편도인용하지 않는다 — SEAL도 Nested Learning도 sleep 관련 논문도 참고문헌에없고, “sleep-time compute”이라는 말을 쓰지도 않는다. 즉 가장강한 반증 후보가 반증 대상을 읽지 않고 쓰였다. 이것은 약점이면서강점이다. 약점은 그 판정이 이 라인이 실제로 제안한 절차를 겨냥하지않았다는 것이고, 강점은 그 판정이 이 라인의 주장에 맞춰 설계되지않았다는 것이다. 수렴이 독립적일 때 증거는 더 강해진다.

자세한 것은 ch22 § 22.1.

2. 반증 조건은 셋이고, 하나만 깨져도진다

논문은 지속 쓰기를 세 요구로 쪼갬다.

핵심 Θ -경로의 반증 조건. 다음 셋 중 하나라도 성립하면 같은 쓰기를 반복하는 설계는 목적을 달성하지 못한다. (i) **생성 실패** — 한 번의 쓰기가 회수는 되지만 사용은 되지 않는 물건을 만든다. (ii) **역량 실패** — 라운드가 쌓일수록 모델이 원래 갖고있던 일반 능력이 무너진다. (iii) **도달 실패** — 앞서 쓴 내용이 가중치 안에 남아 있는데도 질문으로 닿지 않는다. 셋은 독립이며, 하나를 고치는 처방이 다른 하나를 고치지 않는다.

논문의 판정은 이렇다. 첫째는 데이터의 폭으로 다룰 수 있다. 둘째는 고정된 교사나 명시적 별점으로 다룰 수 있다. 셋째는 **미해결이다**.

루프 자체는 표준형 ($U-\Theta$) 와 네 곳에서 갈라진다. (1) 한 라운드가 gradient step 한 번이 아니라 수렴까지의 완전한 최적화이고, rank 로 제약되며, 그 뒤 merge 가 붙는다. (2) 라운드의 학습 집합 $\mathcal{R}_k$ 가 부산물이 아니라 조작되는 독립변수다. (3) 별점의 기준점이 원본 Θ_0 가 아니라 현재의 Θ_k 다. (4) 20 라운드마다 가중치를 Θ_0 로 되돌리고 지금까지의 모든 사실을 한꺼번에 다시 쓰는 둘째 시계가 있다.

그리고 이 논문에서 W 는 빈칸이다. fast weight 가 없고, 토큰마다 움직이는 상태가 없다. 그래서 이 논문의 결론인 “가중치는 잘못된 기록 매체다” 는 Θ 에 대한 판정이며 fast weights 로 이월되지 않는다.

시스템 모델링 관점 decode 에서 바뀌는 것이 하나도 없다. 새 GEMM 도, attention 변경도, KV cache 를 넘어 자라는 상태도 없고, 100 회 쓰기 뒤의 서빙은 가중치 하나 위의 평범한 frozen forward pass 다. 여기서 나오는 사실이 결정적이다 — **adapter 가 merge 되어 사라지므로 저장된 사실 하나당 한계 decode 비용이 정확히 0 이다.** 사실 100 개를 넣은 모델의 토큰당 비용은 0 개를 넣은 모델과 같다. 반대편에서 프롬프트 대조군은 질문마다 문장 토큰을 prefill 하고 KV 를 잡는다. 논문은 이 비대칭을 한 번도 적지 않고, 양쪽 비용을 하나도 재지 않는다. 트래픽은 읽기가 아니라 쓰기 쪽에 있다 — 사실 하나가 forward+backward 192 step 과 전 층 일곱 투영 텐서에 걸친 full read-modify-write 한 번이고, 100 회 쓰기는 전체 모델 RMW 100 회다. 반면 **batching 은 온전하다.** 모든 사실이 전역 가중치 하나에 merge 되고 사용자별 가중치 상태가 없기 때문이다. 사용자별 사실로 옮기는 순간 이 성질은 깨지는데, 논문은 그 배포 형태를 고려하지 않는다.

자세한 것은 ch22 § 22.2 – § 22.4, § 22.7.

3. 회수는 되는데 사용이 안된다

첫째 실패 양상을 재려면 계기가 필요하다. 논문은 채점 정책을 둘 만든다.

기호 풀이 **strict** = 요구된 결론만 정답으로 인정한다. **lenient** = 그 결론을 함의하는 사실도 정답으로 인정한다. 예를 들어 “그래서 A 와 B 중 어느 쪽인가” 라는 질문에 원 사실 문장을 그대로 옮기는 답은 strict 에서 오답이고 lenient 에서 정답이다. **entailment gap** = lenient 정확도 - strict 정확도. **pp**(percentage point) = 백분율끼리의 차. 60%와 40%의 차는 20pp 다.

gap 이 크다는 것은 모델이 문장은 갖고 있는데 그것으로 결론을 내지 못한다는 뜻이다.

학습 데이터의 폭을 두 조건으로 가른다. **bare-statement** 는 사실문장 자체를 두 가지 사소한 틀에 넣은 것 (항목 2 개) 이고, **study** 는 사실 하나당 24 개 항목 — 바뀌 쓴 문장, 질문-답 쌍, 함의를 전개한 예, 위반된 기본값과의 대조 — 이다.

결과가 부호까지 갈린다. 96 step-strict 에서 study 가 10.1pp 이기고 (95% CI [+7.0, +13.3]), **lenient** 에서는 **bare-statement** 가 **13.6pp** 이긴다. 유형별로 보면 갈림이 선명하다. bare 는 24 step 만에 recall 97%·paraphrase 95%에 도달한다 — 외우는 데는 좁은 데이터가 더 낫다. 반면 counterfactual 에서 bare 는 192 step 까지도 21–23%에 머물고 study 는 45–50%에 도달한다. gap 은 bare 조건에서 22–42pp, study 학습 후 1–5pp, 사실을 그냥 프롬프트에 넣으면 1–6pp 다.

이것이 rank 제약의 부작용이 아니라는 것을 논문이 직접 확인한다. adapter 를 쓰지 않고 전 파라미터를 푸는 조건에서도 bare 28pp, study 4pp 로 재현되고, 8B 모델에서도 bare 26pp 로 재현된다. 논문의 문장은 “**Narrow supervision, not the number of trainable parameters, creates the gap**” 이다 — gap 을 만드는 것은 좁은 감독이지 학습 가능한 파라미터 수가 아니다.

비유 시험 범위를 한 문장으로만 준 학생이다. 그 문장은 완벽하게 외우지만 응용문제에서 그 문장을 그대로 옮겨 적는다. — **비유가 깨지는 곳**: 학생은 자기가 응용을 못 한다는 것을 알지만 모델은 모른다. 게다가 gap 을 만드는 것은 **범위의 좁음**이지 공부량의 부족이 아니다 — bare 조건에 step 예산을 여덟 배 줘도 application·composition·counterfactual 중 어느것도 올라가지 않는다.

자세한 것은 ch22 § 22.6.1.

4. 논문이 자기 설명을 자기가반증한다

여기까지 읽으면 처방이 뻔해 보인다 — sleep 라운드에서 **추론흔적**을 만들어 학습시키면 지식이 “쓸 수 있게” 들어간다는 것. 이것이 이라인 전체의 상식이고, study set 이 설계된 근거이기도 하다.

논문이 그 상식을 자기 실험으로 부순다. 같은 32 개 사실 위에서 생성 요인을 분해하면 이렇게 된다. bare-statement 는 27.4pp gap 을 남긴다. **파생결론이 데이터 어디에도 없는** 다양한 recall·paraphrase 프롬프트 24 개만 주면 gap 이 5.4pp 로 줄어든다. 그리고 study set 이 그주위에 설계된 바로 그 성분 — 함의와 대조를 담은 use-bearing 예시 — 은 단순한 다양 반복보다 **8.7pp 낮은 점수를 받는다** (95% CI [– 15.7, – 1.9]).

핵심 인과 변수는 **프롬프트의 폭**이지 명시적 추론 단계의 존재가 아니다. 같은 내용에 달는 표면형을 늘리는 것이 작동하고, 결론을 대신 적어 주는 것은 작동하지 않는다.

이 한 줄이 이 라인의 처방을 바꾼다. self-edit 으로 학습 데이터를 만드는 설계 (SEAL) 도, 오프라인에서 예시를 합성하는 설계 (Dreaming) 도 만드는 물건은 use-bearing 예시다. **두 논문 어느 쪽도 폭과 use-bearing 을 분리한 통제군을 갖고 있지 않다.** 그러므로 그 설계들이 폭 덕분에 작동하는지, 자기가 주장하는 이유 덕분에 작동하는지는 판정되지 않은 상태다.

자세한 것은 ch22 § 22.6.1, § 22.8.4.

5. 스무 번 뒤 — 1% 대 46%

여기서 둘째 요구로 넘어간다. 20 회 순차 쓰기 후 처음 쓴 사실들이 얼마나 살아 있는가.

study 46%, bare-statement 1%다 (짜지은 차 45.6pp, 95% CI [38.8, 52.6]). 이 대비를 정확히 읽으려면 두 가지를 배제해야 한다. **쓰기 실패가 아니다** — bare 조건도 후속 쓰기가 오기 전에는 문항의 65%를 맞힌다. **예산 인공물도 아니다** — step 예산을 8 분의 1로 낮춰도 bare 는 6%만 유지한다.

그리고 **한 번의 쓰기가 만든 물건의 종류가 생존을 예측한다**. entailment gap 과 생존율의 순위상관이 $\rho_S = -0.526$ 이다 (조건별평균으로 접으면 -0.675).

기호 풀이 ρ_S = Spearman 순위상관. 두 양을 크기 순서로만 바꿔 놓고 그순서가 얼마나 같은 방향인지 재는 값이며, +1 이면 같은 순서, - 1 이면 정확히반대 순서다. **이 책에서 맨 ρ 는 망각률이므로 상관에는반드시 아래첨자 S 를 붙인다.** 두 기호를 섞으면 이장의 표가 읽히지않는다.

100 회로 늘리면 유지율이 0 으로 가지 않고 **25–28%의 고원**에앉는다. 단 이 결과는 이 논문에서 **가장 약한 증거**다 — 조건이 12 셀에서 8 셀로 줄었고, 대비가 사후에 선택되었으며, 조건마다 학습률이따로 조정되었고, 불확실성 구간이 없다.

20 라운드마다 도는 리셋-후-재작성 (본서는 **frozen-anchor consolidation** 이라 부른다) 의 결과가 이 절의 핵심이다. $k = 100$ 에서유지율 25%로, 통합을 아예 하지 않은 28%와 잡음 안에서 같다. 첫 통합**직후** 시점에서서도 41% 대 38%다. 반면 **일반 역량은 매통합에서 회복하고** 100 라운드에서 무통합보다 12pp 높다.

핵심 역량을 고치는 처방이 도달성을 고치지 못한다. 그러므로 이 붕괴들은 하나의 “catastrophic forgetting” 이 아니다.

자세한 것은 ch22 § 22.6.2, § 22.8.1.

6. 잊힌 사실은 어디에 있나 — 소거가 아니라 주소상실

셋째 요구, 미해결로 남은 그것이다.

$k = 20$ 에서 strict 문항을 **전부** 틀린 사실들을 골라 그 내용이가중치에 남아 있는지 직접 조사한다. 방법은 사실 문장 자체의 log-probability 다.

기호 풀이 **log-probability** = 모델이 그 문장을 만들어 낼 확률에 로그를 씌운값. 문장을 학습시키면 올라가고, 지워지면 학습 전 수준으로 돌아온다. 쓰기가 만든 상승분이 지금 몇 % 남았는지를 재는 비율이 $R_{\log p}$ 이며, 1 이면 완전 보존, 0 이면 완전 소거다.

답이 셋째 실패 양상을 정의한다. 문항을 전부 틀린 사실도 자기 쓰기가 만든상승분의 중앙값 69%(bare) / 79%(study) 를 그대로 갖고있다. 모델이 전반적으로 이동한 몫을 빼도 57% / 67%다. 논문의 문장은 “**No fact in either condition approaches the erased floor**” 다.

틀린 답의 내용도 특징적이다. bare 조건 모델은 실패의 **70%에서**질문받은 개체에 **가장 최근에 쓴 사실**의 내용을 갖다붙인다 (study 는 1%). 그리고 재학습 절약이 역전된다 — 잊

한 study 사실을다시 가르치는 데 step 예산 전부가 들었고 한 번도 쓴 적 없는통제 사실은 8 step 이 들었다. 한 번 쓰고 잊은 것이 처음 배우는것보다 비싸다.

합성은 망각보다 먼저 무너진다. 두 사실을 함께 써야 답할 수 있는 문항에서 둘 다 가중치에 있으면 32%, 둘 다 프롬프트에 있으면 91%다. 개별 사용가능성 심사는 87.5%가 통과하므로 개별 실패로는 설명되지 않는다. 병목은자기 검색이다 — 문항에는 답할 수 있는 사실을 “그냥 진술해보라” 고 하면 34%만 올바른 내용을 낸다. 논문의 문장은 “**There is nothing to search**” 다.

반대로 그 문장을 문맥에 넣어 주면 잊힌 사실이 study 조건에서 77–80%로돌아온다.

핵심 가중치는 넣을 자리가 없어서 지는 것이 아니라 넣은 것을 부를이름이 없어서 진다. 100 회 실험의 고원은 용량 천장에 닿아서 생긴 것이아니다 — 4B 모델에 사실 100 개는 어떤 용량 회계로도 근처에 가지않는다 (→ E04). 남는 원인은 접근뿐이다.

자세한 것은 ch22 § 22.6.3, § 22.8.3.

7. 대가는 KL 로 정렬된다 — 그러나 KL 은 조종간이아니다

둘째 요구, 역량 쪽이다. 여기에는 이 논문에서 가장 깨끗한 정량 법칙이있다.

기호 풀이 drift = 고정된 프롬프트 묶음을 원본 모델과 현재 모델에 각각통과시키고, 두 출력 분포가 토큰마다 얼마나 다른지를 KL 로 재서 평균한 값. KL 은 두 확률분포의 어긋남을 재는 양이며 0 이면 완전히 같다. 요점은 이것이 **정답을 필요로 하지 않는다는** 것이다 — 벤치마크없이 forward pass 만으로 쟀다.

역량 손실이 이 값을 따라간다. 12 개 조건에서 $\rho_S = 0.83$, 400 항목역량 집합에서는 $\rho_S = 0.946$ 이다. **원본에서 멀어진 만큼능력을 잃는다.**

처방도 둘 나온다. 첫째, **교사를 고정하는 것** — 순차 증류에서교사를 원본 모델로 고정 하면 역량 +2pp·유지율 54%인데, 자기누적 merge 결과로 두면 - 31pp·21%다 (짜지은 차 33.0pp). 둘째, **원본에서 멀어지는 것에 별점을 붙이는 것** — 별점 0 에서- 66pp·1%이던 것이 별점을 키우면 - 5pp·36%가된다.

여기서 이 절의 반전이 나온다. **별점을 키워 역량을 60pp 넘게되살리는 동안 원본으로부터의 KL 은 1.8–2.4 사이에 그대로 머문다.** 논문자신의 표현으로 KL 은 “a cost coordinate that holds across methods, not a sufficient causal mechanism” — 여러 방법에 걸쳐 성립하는 비용 좌표이지충분한 인과 기제가 아니다.

시스템 모델링 관점 그래서 drift 는 바로 쓸 수 있는 운영 계기다. 고정 프롬프트 풀에 대해 고정된 참조 모델과 비교하는 forward pass 일 뿐이므로 정답 라벨도벤치마크 실행도 필요 없고, 서빙 fleet 에서 야간에 싸게 돌릴 수 있으며, 이논문에서 역량 손상과 $\rho_S = 0.83-0.946$ 으로 정렬한다. **단 계기판이지 조종간이 아니다.** KL 을 목적함수에 직접 넣어 늘려도역량은 그 좌표를 통하지 않고 회복했다. 카나리아로 배치하고 임계값 하나로 sleep 라운드를 중단시키는 데까지가 이 증거가 허락하는 사용법이다. 손실함수의 손잡이로 쓰는 것은 아니다.

자세한 것은 ch22 § 22.6.4, § 22.7.

8. 여기서 실험이 들어온다 — 최소 모형으로 되짚기

지금까지는 4B 모델 위의 관측이었다. 이제 같은 루프를 **가장 단순한 형태로 축소해서** 다시 돌린다. 이 저장소의 실험 X4이며 두 부분으로 되어있다. **PART A**는 평균과 분산 두 개짜리 모형이다 — 모델이 자기가추정한 분포에서 데이터를 뽑고 그걸로 다시 추정하기를 200라운드 반복한다. **PART B**는 키에서 값으로 가는 선형 사상이다 — 사실 5개를 먼저쓰고, 그 뒤 150라운드 동안 매라운드 새 사실 하나를 쓰고 merge 한다. [Continual Facts]의 순차 (U- Θ)와 같은 형태다.

한계 이것은 LLM 실험이 아니다. transformer도 토큰도 의미론도 없다. 그러므로 여기서 나온 절대 수치를 옮기면 안 된다 — 유지율 %, 라운드 수, 필요한 replay 비율은 전부 이 장난감의 산물이다. 옮길 수 있는것은 넷뿐이다: 부호, 함수형, 조건 간 순서, 그리고 무너지는 지점이 어느 방향으로 움직이는가. 이 권은 그 넷만 쓴다.

축소를 하는 이유는 하나다. 의미론이 전혀 없는 모형에서도 같은현상이 나온다면, 그 현상은 언어의 성질이 아니라 반복 덮어쓰기의성질이다. 반대로 축소 모형이 재현하지 못하는 효과는, 그 효과가 LLM 고유의 무언가를 요구한다는 뜻이다. 이 권의 § 9 – § 11이 앞의 것이고 § 12가 뒤의 것이다.

자세한 것은 ch06 § 06.6과 실험 X4.

9. 평평한 손실 곡선은 안정의 증거가아니다

E02 § 14에서 세 스케줄을 배웠다 — **replace**(이전 학습 집합을버리고 새로 생성한 것으로 바꾼다), **replace-multiple**(실데이터만버리고 합성은 키운다), **accumulate**(버리지 않고 덧붙인다). 오차가각각 k , $\log k$, 유계로 간다는 결과도 봤다.

X4의 PART A가 먼저 확인한 것은 그 결과의 범위다. 원래 정리는선형회귀에서 나왔다. 그런데 설계행렬이 **아예 없는** 평균-분산모형에서도 세 함수형이 그대로 나온다. 배율만 다르고 부호와 모양은 같다. 즉 $1/i$ 가중은 회귀의 성질이 아니라 데이터 스케줄의성질이다. 200라운드에서 replace의 위험은 accumulate의 122배다.

여기까지는 확인이다. 반전은 다음이다.

그 정리는 라운드마다 분산을 상수로 다시 주입한다. 즉 생성분포의 퍼짐이 가정에 의해 고정되어 있고, 그래서 그 좌표에서무슨 일이 일어나는지를 **원리적으로 볼 수 없다**. X4는 그 가정을푼다. 그러자 replace에서 추정 분산이 라운드마다 일정 비율씩 줄어드는기하 붕괴를 한다 — 라운드당 표본이 50개일 때 반감기가 약 34라운드다. accumulate는 200라운드 뒤에도 퍼짐을 거의 그대로 갖고있다 (replace의 55배).

그리고 바로 그 좌표가 원 논문 자신의 이미지 실험이 실패한좌표다. 그 실험에서 손실은 (거의) 유계인데 생성물의 다양성이 사라진다 —안경과 액세서리가 라운드가 갈수록 그림에서 없어진다. 그 그림의 캡션은 “Avoids Model Collapse” 다.

이제 이 권의 제목 문장이 나온다. 표본분산을 계산할 때 표본 수로 나누면참값보다 체계적으로 작은 값이 나오고 (MLE 추정량), 하나 적은수로 나누면 그 편향이 사라진다 (불편 추정량). 이 한 칸의 차이가루프의 운명을 가른다.

핵심 MLE 추정량으로 돌리면 위치 오차가 발산하지 않고 **포화한다**. 발산이 아니라 포화가 나오는 이유는 생성 분포가 죽어서 걸음의 폭 자체가 작아지기 때문이다. 같은 루프를 불편 추정량으로 돌리면 정확히 선형으로 발산한다. **곡선이 평평해지는 것과 루프가 죽는 것이 같은 사건이다**.

비유 자기 목소리를 녹음해 그것을 다시 재생하며 녹음하기를 반복하는 것이다. 소리가 점점 작아지면 왜곡도 같이 줄어들어 파형이 안정된 것처럼 보인다. — **비유가 깨지는 곳**: 녹음은 볼륨을 다시 올리면 원래 내용이어느 정도 돌아오지만, 여기서는 퍼짐이 줄어드는 만큼 **그 방향의 정보가 표본에서 사라진 것**이라 스케일을 되돌려도 내용이 돌아오지 않는다.

시스템 모델링 관점 반복 sleep 루프에 붙일 모니터는 held-out perplexity 가 아니다. 그 지표는 1 차 모멘트의 성질이고, 위에서 본 대로 **루프가 죽는 동안에도 평평하거나 심지어 좋아진다**. 프로덕션 대시보드에 loss 곡선 하나만 걸어두면 이 붕괴에 경보가 울리지 않는다. 걸어야 할 것은 **라운드함수로 잤 생성 분포의 퍼짐**이다 — 라운드마다 같은 프롬프트 묶음으로 수백 개를 표집해 출력 임베딩의 분산이나 distinct- n 을 기록하면 되고, 비용은 야간 배치 하나다. 그런데 **corpus**에서 **이 값을 라운드 함수로 보고한 논문은 0 편이다**. 이 계기를 세우는 것은 새 연구가 아니라 밀린 배관작업이다.

자세한 것은 ch06 § 06.6, ch29, 실험 X4 PART A.

10. “라운드당 몇 %” 는 지표가 될 수 없다

PART B로 넘어간다. 여기서는 같은 루프를 두 개의 계기로 **동시에** 잤다.

기호 풀이 **access**(과제 지표) = 저장한 사실을 지금 맞히는가 틀리는가. 0 또는 1로 판정되는 임계 지표이며, 논문들이 “유지율” 이라고 부르는 것이 이것이다. **lift**(연속 신호) = 그 사실을 쓸 때 만들어진 신호가 지금 몇 % 남아 있는가. 앞 절의 $R_{\log p}$ 에 대응하는 양이며 임계가 없다.

replay 없이 150 라운드를 돌린 결과가 이 권에서 가장 중요한 표다.

표 E10-1. 같은 루프를 두 계기로 잤 결과 (실험 X4 PART B, replay 없음). 절대 라운드 수는 이 최소 모형의 값이며 옮길 수 없다. 옮길 수 있는 것은 **두 열의 모양 차이**다.

관측	access (과제 지표)	lift (연속 신호)
처음으로 0.95 아래로 내려간 라운드	27	4
앞 10 라운드의 라운드당 손실 0.9에서 0.1 까지 떨어지는 데 걸린 라운드 폭	0.00 pp 29	1.41 pp 82
라운드당 손실의 최댓값과 그 위치	8.00 pp @ 라운드 43	2.61 pp @ 라운드 16

읽는 법은 한 줄이다. 저장은 1 라운드부터 꾸준히 깎이는데 과제지표는 스물몇 라운드 동안 전혀 움직이지 않다가 절벽으로 떨어진다. 과제지표의 라운드당 손실은 앞 10 라운드에서 0.00pp 이고 라운드 43 에서 8.00pp 다 — 같은 실행, 같은 지표에서 나온 두 값이다.

핵심 같은 루프의 망각률 ρ 가 무엇을 재느냐에 따라 모양이다르다. 그러므로 “라운드당 몇 %” 라는 단일 비율로 ρ 를보고하는 관행 자체가 오도다. E03 § 7 에서 같은 실행의 “라운드당 망각” 을부르는 방식이 넷이고 값이 4 배 넘게 벌어지는 것을 봤다. 그 벌어짐의원인이 여기 있다 — ρ 는 상수가 아니라 라운드에 몰려 있고, 그몰림의 위치가 계기마다 다르다.

corpus 의 두 논문이 ρ 를 서로 다른 형태로 보고하는 것 — 하나는 닫힌형태로, 하나는 곡선과 종점 수준으로 — 은 게으름이 아니다. 비율로 쓸 수 있는 양이 아니기 때문이다. 그러면 무엇을 보고해야 하는가.

핵심 이송해야 할 양은 ρ 가 아니라 K^* — 성능이 기준선을유지하는 마지막 라운드다. 임계로 무너지는 지표의 정보는 기울기가 아니라위치에 있다.

이 최소 모형에서 replay 없는 조건의 K^* 는 46 이고 시드 간표준편차가 4.5 다. 즉 무너지는 위치 자체는 재현 가능하다 — 비율은상수가 아니지만 crossover 는 안정적이다.

비유 연료 게이지와 시동 꺼짐이다. 게이지는 처음부터 꾸준히 내려가지만 차는마지막 순간까지 똑같이 달린다. — 비유가 깨지는 곳: 연료는남은 양과 남은 거리가 비례하지만, 여기서는 lift 가 절반 남았을 때 access 가 아직 만점이고 lift 가 조금 더 줄면 access 가 통째로 사라진다. 게이지와 성능 사이가 선형이 아니다.

시스템 모델링 관점 SLA 를 K^* 로 쓴다. “라운드당 열화 x% 이하” 는 계약서에 쓸 수 없는문장이다 — 앞 구간에서 그 값이 0 이고 절벽에서 자릿수가 바뀌므로 어느구간을 평균 내느냐가 답을 정한다. 쓸 수 있는 문장은 “이 서비스는 통합라운드 K 회까지 기준선 대비 x% 이내를 유지한다” 이고, 그것을 재려면실제로 K 회를 돌려 봐야 한다. 그리고 경보를 과제 지표에만 걸어 두면울릴 때는 이미 늦다 — 절벽 구간의 폭이 앞 유예 구간보다 짧다. 야간 job 은 둘을 함께 본다: 과제 지표는 무너졌는지를, 연속 신호는 얼마나남았는지를 말하고, 뒤의 것이 훨씬 일찍 움직인다.

자세한 것은 ch07 § 07.6, ch29, 실험 X4 PART B.

11. replay 는 하나의 처방이아니다

K^* 를 정의하고 나면 처방을 비교할 자가 생긴다. PART B 는 replay 비율 ω 를 끌어 본다.

기호 풀이 ω = replay 혼합비. 한 라운드의 학습 집합에서 과거데이터가 차지하는 비율이다. 그리고 그 과거 데이터를 어디서가져오는가로 두 조건이 갈린다. gold = 보존해 둔 원본을 그대로다시 넣는다. self = 현재 모델에게 그 내용을 다시 만들게 해서그것을 넣는다.

결과가 모든 ω 에서 한 방향이다. **gold** 의 K^* 가 **self** 의 1.5–2.5 배다. **self** 는 어느 ω 에서도 150 라운드를 버티지 못하고, **gold** 는 $\omega \geq 0.25$ 에서 150 라운드 안에 기준선 아래로 내려가지 않는다.

이것은 새 발견이 아니라 **재현**이다. PART A 의 accumulate 대 replace 가 사실 주입 설정에서 다시 나온 것이고, [Continual Facts] 의 고정 교사 (+2pp·54%) 대 자기 merge 교사 (– 31pp·21%) 와도 부호가 같다.

핵심 replay 타킷을 현재 모델로 다시 만들지 마라. self replay 는 replace 레짐이고, 같은 예산에서 gold replay 보다 항상 먼저 무너진다. 이송연산자를 자기 자신에게 겨누는 설계는 이 증거에 정면으로 걸린다.

그런데 둘의 관계는 우열이 아니다. 같은 실험이 **이중 해리**를 보인다 — gold replay 는 **사실 유지**를 사고 일반 역량은 사지 못한다. self replay 는 정확히 반대다. 현재 동작에 앵커하므로 역량은 지키지만 이미 잃은 내용을 되살리지 못한다.

이 이중 해리가 [Continual Facts] 의 두 관측과 같은 자리에 있다 — § 7 의 별점은 현재 모델에 앵커해 역량만 되살렸고, § 5 의 통합은 원본으로 되돌리고도 역량만 회복시켰다. **“replay 를 넣는다” 는 하나의 처방이 아니라 서로 다른 것을 사는 두 처방이다.**

마지막으로 § 9 와 이어지는 관측이 하나 있다. self replay 의 타킷에서 **크기 성분만 제거하고 방향만 남겨도** 손해의 상당 부분이 되돌아온다. 퍼짐이 죽는 것이 손해의 한 통로라는 뜻이고, PART A 의 2 차모멘트 발견이 여기서도 작동한다는 뜻이다.

자세한 것은 ch22 § 22.6.4, 실험 X4 PART B.

12. 이 모형이 재현하지 못한 것

축소 모형의 가치는 재현하지 못한 것에도 있다. 재현 실패는 원 논문의 반박이 아니라 **기제 배제**로 읽는다 — “그 효과는 일반적 선형 덮어쓰기로는 나오지 않는다” 는 뜻이다. 셋이다.

첫째, 간섭의 소재는 재현되고 방향은 재현되지 않는다. [Continual Facts] 의 2×2 설계는 이후 쓰기 효과 +37.6pp 대 저장 방식 효과 – 2.4pp 를 얻었다 — **간섭은 들어오는 쓰기가 만들고, 앞의 사실을 어떻게 저장했는가는 거의 무관하다.** 이 비대칭 자체는 최소 모형에서도 그대로 나오므로 특별한 설명이 필요 없다. 그런데 어느 쪽 쓰기가 더 파괴적인지의 부호는 반대로 나온다. 그러므로 “좁은 데이터로 쓴 이후 쓰기가 더 파괴적” 이라는 결과는 선형 간섭으로 설명되지 않고, 좁은 집합 위의 과최적화가 모델을 퇴화한 해로 끌고 가는 LLM 고유 기제를 요구한다.

둘째, 역량과 유지의 해리는 재현되지 않는다. 최소 모형에서는 둘이 같은 속도로 함께 무너진다. 그러므로 그 해리는 **순차 덮어쓰기의 일반 성질이 아니다.**

셋째, 저장-접근 해리는 방향으로만 재현된다. 의미론이 0 인 이 모형에서도 과제 지표가 바닥에 닿은 라운드에서 연속 신호는 0 이 아니다. 그러므로 “저장은 남았는데 접근이 실패한다” 는 패턴의 존재 자체는 특별한 접근 기제의 증거가 아니다 — 매끄럽게 감쇠하는 저장 위에 임계판독을 얹으면 자동으로 생긴다. 그러나 [Continual Facts] 가 보고한 크기 (중앙값 69–79% 잔존, 소거 바닥에 닿은 사실 0 개) 는 이 기제로 설명되지 않는다.

자세한 것은 ch22 § 22.6.4·§ 22.8.3, 실험 X4.

13. 그래서 무엇을 지켜야 하는가 — 다섯조건

이 권은 판정을 하지 않는다. 경로별 판정은 ch27 이, 반증 조건의 정식화는 ch30 이 소유한다. 이 권이 넘기는 것은 조건이다.

핵심 Θ -경로가 살아남으려면 다섯을 동시에 만족해야 한다.

(1) 폭을 늘리되 결론을 대신 적어 주지 마라. 인과 변수는 프롬프트의 폭이고, use-bearing 예시는 단순한 다양 반복보다 8.7pp 낮았다. (2) 원본을 버리지 말고, 교사와 replay 타깃을 원본에 앵커하라. 자기 merge 결과를 교사로 쓰는 순차 증류가 12 개 조건 중 최악이었고 (- 31pp·21%), 최소 모형에서 self replay 는 모든 ω 에서 gold 보다 먼저 무너졌다. (3) 별점은 걸되 KL 을 조종간으로 삼지 마라. 별점이 역량을 60pp 넘게 되살리는 동안 원본으로부터의 KL 은 움직이지 않았다. KL 은 배포 카나리아다. (4) 주소를 가중치 밖에 두어라. 이 증거가 지지하는 유일한 합성은 가중치를 기록 매체가 아니라 정본이 다른 곳에 있는 write-through cache 로 쓰는 것이다. 그 구성에서 E -경로와 Θ -경로는 경쟁자가 아니라 보완재다. (5) 계기를 셋 세워라. ρ 가 아니라 K^* 를 SLA 로 쓰고, 1 차 모멘트가 아니라 생성 분포의 퍼짐을 감시하며, 과제지표만이 아니라 연속 신호를 함께 본다. 앞의 둘만 보면 경보가 늦고, 셋째만 보면 무너진 것을 모른다.

그리고 이 다섯을 다 지켜도 K^* 는 유한하다. 서비스가 요구하는 라운드 수를 넘는지는 corpus 의 어느 논문도 답하지 않는다 — sleep 라운드를 100 회 넘게 돌린 논문이 0 편이기 때문이다.

핵심 이것이 반증 조건이다. Θ -경로를 지지하려면 100 라운드를 넘겨, 원본 보존 replay 와 함께, K^* 를 측정한 실험이 필요하다. 현재 corpus 에 그 실험은 없다.

자세한 것은 ch22 § 22.8.4 와 ch30.

요약

- [Continual Facts] 는 발명 사실을 하나씩 adapter 로 학습해 merge 하기를 20 회 · 100 회 반복하고, 같은 내용을 프롬프트에 넣은 대조군을 나란히 세운다. 이 논문은 sleep-time compute 라인을 한 편도 인용하지 않는다 — 가장 강한 반증 후보가 반증 대상을 읽지 않고 쓰였고, 그래서 수렴이 독립적이다.
- 무너지는 것은 하나가 아니라 넷이다 — 회수-사용 분리 (gap 22 - 42pp), 역량 침식 (KL 로 정렬), 주소 상실 (내용은 남는데 닿지 않음), 합성 불능 (가중치 32% 대 프롬프트 91%). 뒤의 둘에는 이 논문이 시도한 어떤 처방도 듣지 않았다.
- 데이터의 폭이 생성과 생존을 모두 정한다 (20 회 뒤 46% 대 1%). 그러나 인과 변수는 폭이지 명시적 추론 단계가 아니다 — use-bearing 예시는 단순 다양 반복보다 8.7pp 낮았다. self-edit·dreaming 설계는 이 통제군을 갖고 있지 않다.
- 망각은 소거가 아니다. 문항을 전부 틀린 사실도 쓰기가 만든 신호의 중앙값 69 - 79% 를 갖고 있고, 잊힌 사실 재학습이 처음 배우는 것보다 비싸다. 가중치는 넣을 자리가 없어서 지는 것이 아니라 부를 이름이 없어서 진다.
- 평평한 손실 곡선은 안정의 증거가 아니다. 원 정리는 라운드마다 분산을 상수로 재주입해 그 좌표를 원리적으로 볼 수 없게 만들어 두었다. 가정을 풀면 replace 에서 퍼짐

이 기하 붕괴하고, 추정량 한 칸 차이로 같은루프가 포화하거나 선형 발산한다. 그리고 바로 그 좌표가 원 논문 자신의 이미지 실험이 실패한 좌표다.

- “라운드당 몇 %” 는 지표가 될 수 없다. 같은 루프에서 연속신호는 1 라운드부터 꾸준히 깎이는데 과제 지표는 스물몇 라운드 동안 0.00pp 로 가만히 있다가 절벽으로 떨어진다. 보고해야 할 양은 ρ 가 아니라 K^* — 기준선을 유지하는 마지막라운드이며, 비율은 상수가 아니어도 crossover 위치는 시드 간에 안정적이다.
- replay 는 하나의 처방이 아니다. gold(보존 원본) 는 사실 유지를 사고, self(현재 모델 재생성) 는 역량을 산다. K^* 로 보면 gold 가 모든 ω 에서 1.5–2.5 배 오래 버틴다.
- 최소 모형이 재현하지 못한 것 셋은 반박이 아니라 기제 배제다 — 좁은 이후 쓰기가 더 파괴적이라는 부호, 역량과 유지의 해리, 저장 잔존의 크기. 셋 다 LLM 고유의 무언가를 요구한다.
- 최종 판정은 하지 않는다. 넘기는 것은 다섯 조건과, 100 라운드를 넘겨 원본 보존 replay 와 함께 K^* 를 켜 실험이 corpus 에 없다는 사실이다.

자가 점검

- 반증 조건 셋 (생성 · 역량 · 도달) 을 진술하고 각각에 대한 판정과 근거 수치를 하나씩 딸 수 있다.
- 실패 양상 네 가지를 구분하고, 통합이 역량은 12pp 회복시키면서 유지율은 25% 대 28%로 두는 결과가 왜 “이것들은 하나의 catastrophic forgetting 이 아니다” 를 뜻하는지 설명할 수 있다.
- entailment gap 을 정의하고, strict 에서는 study 가 이기는데 lenient 에서는 bare 가 이기는 부호 반전이 무엇을 뜻하는지 말할 수 있다. 그리고 use-bearing 예시가 – 8.7pp 였다는 사실이 self-edit·dreaming 설계에 무엇을 요구하는지 한 문장으로 옮길 수 있다.
- “평평한 손실 곡선은 안정의 증거가 아니다” 를 두 단계로 설명할 수 있다 — 왜 그 정리가 그 좌표를 볼 수 없는지, 그리고 추정량 한 칸 차이가 왜 포화와 발산을 가르는지.
- 표 E10-1 의 네 행을 근거로, “라운드당 열화 x%” 라는 SLA 문장이 왜 계약서에 쓸 수 없는 문장인지 설명할 수 있다.
- ρ 와 ρ_S , K^* 와 k , ω 와 r 을 각각 구분해 쓸 수 있고, gold replay 와 self replay 가 서로 다른 것을 산다는 결과를 [Continual Facts] 의 어느 두 관측과 부호가 맞는지까지 짚어 설명할 수 있다.
- (Rosetta) merge 된 가중치의 사실당 한계 decode 비용이 0 인데도 “context wins” 가 서빙 결론이 되지 못하는 이유를, 자기 서빙 스택의 prefill·KV 항목으로 설명할 수 있다.

다음 권으로

이 권은 Θ -경로를 겨누는 가장 강한 증거를 정리했고, 그 증거가 판정이 아니라 조건을 낳는다는 데서 멈췄다. 그런데 조건 (4) 가 열려 둔 자리가 크다 — 정본을 다른 곳에 두고 가중치를 cache 로 쓴다면, 그 “다른 곳” 의 비용은 누가 재는가.

지금까지 지나온 모든 권에서 같은 칸이 비어 있었다. E -경로는 상각의 분자를 인쇄하지 않았고, Θ -경로는 FLOPs 도 지연도 바이트도 재지 않은 채 두 채널을 비교했다. 다음 권들은 그 칸을 하나의 회계표로 모은다 — 같은 자로 재고, 켤 수 없는 칸은 켤 수 없다고 적는 것. 그 표가 완성되어야 “미리 계산해 두면 이득인가” 가 비로소 답할 수 있는 질문이 된다.