

E11 · 그래서 유망한가 — 판정

이 권은 본문 ch25(통일 비용 회계), ch26(상태 용량과 정보 밀도), ch27(유망한가 — 경로별 판정), ch28(scaling law), ch29(system·infra와 memory-device 기회)를 수식과 증명 없이 다시 설명한다. 다섯 장이 하는 일은 하나다. **앞 권들이 모아 온 사실 위에서 답을 낸다.**

이 시리즈를 시작하게 한 질문은 다섯이었다. 이 방법들은 무슨 문제를 푸는가. 그 해법은 유망한가. 그것이 최선인가. 대안 대비 우월한가. 주류가 될 것인가. 이 권은 그 다섯에 답하고, 답이 어떤 모양으로 나오는지 함께 보인다 — **어떤 질문에는 답이 나오고, 어떤 질문에는 “현재 문헌으로 판정 불가”가 나오며, 그 판정 불가가 회피가 아니라 결과다.**

미리 말해 둘 것이 하나 있다. 이 권에는 “sleep-time compute은 유망하다”도 “유망하지 않다”도 나오지 않는다. 그 문장이 세 개의 서로 다른 명제를 하나로 뭉čen 문장이기 때문이다. 왜 그런지가 §1과 §7의 내용이다.

1. 다섯 질문 앞에 세울 세 개의 금지

판정을 시작하기 전에 **답이 될 수 없는 것**을 먼저 못 박아야 한다. 그러지 않으면 답처럼 생긴 문장이 답의 자리에 앉는다.

기호 풀이 Θ (slow weights) = 배포되는 가중치. .safetensors로 굵고 HBM에 올리는 바로 그것이다. W (fast weights) = 요청을 처리하는 동안만 살아 있는 고정 크기 상태. KV cache와 달리 길이에 따라 자라지 않고, 새 항목이 오면 옛 항목 위에 겹쳐 쓴다. E (external store) = 모델 밖의 텍스트·벡터·그래프 저장소. 세 층 각각을 건드리는 방식이 Θ -경로 · W -경로 · E -경로다.

금지 1 — 하나의 답은 답이 아니다. 이 책의 판별식을 정면으로 통과한 논문은 9편이고 E 6편 · W 1편 · Θ 2편으로 갈린다. 세 경로는 갱신하는 층이 다르고, 상태가 사는 메모리 계층이 다르며, 상각 계산이 각각 다른 방식으로 무너진다. 셋을 하나로 묶어 예/아니오를 답하는 문장은 세 명제를 뭉čen문장이다.

금지 2 — 성능 순위표는 답이 아니다. 세 경로는 서로를 baseline으로 돌리지 않는다. 공유 벤치마크의 교집합이 공집합이고 예산축과 품질 축이 둘 다 깨져 있으므로, 순위표를 만들려면 없는 표를 지어내야 한다. 그래서 이 권은 “어느 경로가 1등인가”에 답하지 않고 **각 경로가 무엇을 사고 무엇을 지불하는가**에 답한다.

금지 3 — 예측은 단정이 아니다. “주류가 될까”는 미래에 대한 진술이므로 증거로 결정되지 않는다. **조건부로만** 답한다 — 무엇이 참이면 어느 경로가 이기는지를 적고, 각 조건이 어디까지 확인되었는지를 함께 적는다.

그러면 답이 될 수 있는 것은 셋이다. 경로별 판정, 조건을 명시한 조건부 판정, 그리고 **“현재 문헌으로 판정 불가”**라는 판정.

비유 셋째가 회피처럼 보인다면 형사 재판의 두 결말을 떠올리면 된다. 심리를 연기하는 것과 증거불충분으로 판단을 내리는 것은 다른 일이다. 앞의 것은 아무 말도 하지 않는 것이고, 뒤의 것은 “제출된 증거로는 이 명제가 결정되지 않는다”는 확정된 진술이다. — **비유가 깨지는 곳:** 재판은 증거불충분이면 피고에게 유리한 쪽으로 확정되지만, 이 책의 판정 불가는 어느 쪽으로도 기울지 않는다. “우월하다”도 “우월하지 않다”도 주장

하지 않는다.

다섯 질문을 답하는 순서로 다시 놓는다. Q1 각 경로가 실제로 푸는문제는 무엇인가. Q2 그 해법은 유망한가. Q3 같은 경로안에서 최선인가. Q4 경로 밖의 대안 대비 우월한가. Q5 주류가 될까. Q1 이 먼저인 이유는 나머지 넷이 전부 Q1 의 답에 상대적이기때문이다 — 무슨 문제를 푸는지 정하지 않으면 “최선” 도 “우월” 도 정의되지않는다.

자세한 것은 ch27 § 27.1, ch24 § 24.3.

2. 상각 논증에는 항이 하나 빠져있다

이 라인의 경제 논증은 한 줄이다. 미리 계산해 두는 값이 비싸도, 그 결과를여러 질의가 나눠 쓰면 질의당으로는 싸진다.

$$C_{\text{avg}} = C_{\text{wake}} + \frac{C_{\text{sleep}}}{N_q} \quad (\text{A})$$

기호 풀이 C_{wake} = 질의가 도착한 뒤 그 질의 하나를 처리하는 비용. C_{sleep} = 질의 도착 전에 미리 태운 비용. N_q = 한 문맥을 공유하는 질의 수 — 같은 대화이력·저장소·코드 베이스를 놓고 사용자가 몇 번 물어보는가다.

이 식이 말하는 것은 미리 낸 값이 N_q 로 나뉜다는 것뿐이다. N_q 를 키우면 둘째 항이 0 으로 가고, 그러면 미리 계산하는 쪽이 언제나이긴다.

여기까지가 논문들의 논증이다. 그런데 이 식에는 **매 질의마다 내는비용이 하나 빠져 있다.**

E-경로에서 sleep 국면의 산출물은 $\hat{c}$ (learned context) — 질의를 보기 전에 미리 수행한 추론의 결과물인 자연어 문자열이다. 그 문자열은 wake 국면에서 **프롬프트에 실려 다시 처리되므로** $\hat{c}$ 의 prefill 비용은 질의마다 다시 발생하고 N_q 로 나뉘지않는다. 그런데 이 라인의 대표 논문이 인쇄한 비용모델은 **test time 에 생성된 토큰만 센다** — 입력 토큰의 가중치를 0 으로 놓은 것이다.

비유 회사를 도심 밖으로 옮기는 결정을 생각하자. 이사 비용은 한 번 내고근무일수로 나뉜다. 그런데 직원들의 매일 출퇴근 시간은 나뉘지 않는다. 이사 비용만 세는 회계는 “오래 다닐수록 이득” 이라는 결론을 언제나 낸다. — **비유가 깨지는 곳:** 이사 비용과 출퇴근 시간은 서로독립이지만, sleep 예산과 $\hat{c}$ 길이는 독립이 아니다. **더오래 생각할수록 $\hat{c}$ 가 길어지므로**, 나뉘는 항을 키우면 나뉘지 않는항이 함께 커진다. 이 결합이 다음 문단의 결론을 만든다.

빠진 항을 되살려 계산하면 두 값이 나온다. 이 책은 그것을 **통일비용 회계**라고 부른다.

기호 풀이 $|c|$ = 원 문맥의 토큰 수. $|\hat{c}|$ = learned context 의 토큰 수. L^* = 임계 길이 — $|\hat{c}|$ 가 이 값을 넘으면 N_q 를 아무리 키워도 baseline 을 이길 수 없다. N_q^* = 손익분기, 몇 개 질의부터 이득이 나는가. κ_{cost} = wake 생성 토큰이 sleep 토큰보다 몇 배 비싼가. $\kappa_{\parallel}$ = 같은 문맥을 몇 벌로 병렬 재표현해 프롬프트에 이어붙이는가. w_{in} = 입력 토큰 하나에 매기는 상대 가중치. **이 회계의 손잡이가 w_{in} 이고, 논문의 회계는 $w_{\text{in}} = 0$ 이다.**

$w_{\text{in}} = 0$ 이면 L^* 가 무한대가 된다. 논문의 회계에는 “이길 수 없는 영역”의 경계가 존재하지 않는다. 항을 되살리면 그 경계는 언제나 유한하다. 그리고 붕괴의 모양이 중요하다 — 손익분기는 $|\hat{c}|$ 가 L^* 에 다가갈수록 **발산한다**. 경계에서 갑자기 지는 것이 아니라 경계에 닿기 한참 전부터 필요한 질의 수가 실무적으로 도달 불가능해진다. **절벽이 아니라 점근이다.**

핵심 이것은 실험적 반례가 아니라 **식의 성질**이다. 한 번 내는 비용만 N_q 로 나뉘고 매 질의 내는 비용은 나뉘지 않는데, 논문의 회계는 후자를 향으로 갖고 있지 않다. 미보고 값을 어떻게 골라도 이 결론은 바뀌지 않는다.

그러나 $5\times$ 는 반박되지 않는다. $5\times$ 는 생성 토큰 축에서 관측된 사실이고, 짧은 문맥과 큰 절감률이 함께 있는 레짐에서는 prefill 항을 되살려도 임계 안쪽에 머문다. 반박되는 것은 “**생성 토큰 축 = 비용 축**”이라는 암묵 등식이며, 그 등식의 유효 범위가 유한하다는 것이다.

레짐 간 순서 하나는 단정할 수 있다. 실제 코드베이스를 문맥으로 쓰는 레짐의 여유가 세 레짐 중 최하위이고, 여유가 큰 두 레짐과의 간격은 자릿수 규모다. 두 방향이 같은 쪽으로 작용하기 때문이다 — 절감률이 떨어지면 임계의 분자가 줄고, 문맥이 몇 문장에서 코드베이스로 커지면 분모가 커진다. **그리고 이 방향이 실무 워크로드 쪽이다.** 문맥이 짧고 절감률이 큰 레짐은 저자 제작 벤치마크의 성질이 코드베이스·문서고·대화 이력의 성질이 아니다.

회계 전체를 위아래로 움직이는 상수도 하나 짚는다. κ_{cost} 는 임계 길이에 정비례하는데 그 값의 근거가 측정이 아니라 벤더 문서 인용 한 줄이고, 틀리는 방향이 예측 가능하다 — wake 국면도 배치로 묶어 처리량 위주로 돌리면 κ_{cost} 가 1 에 가까워져 임계가 10 분의 1 로 줄어든다. **이 방향의 민감도 분석이 원문 어디에도 없다.**

시스템 모델링 관점 w_{in} 은 서빙 엔지니어의 어휘로 옮기면 **prefill 을 회계에 넣을지 말지의 스위치**다. $w_{\text{in}} = 0$ 은 “prefill 이 공짜”라는 뜻이고 그것이 참인 구성이 실제로 있다 — $\hat{c}$ 가 프롬프트 접두사로 고정되어 prefix cache 에 완전히 적중하면 매 질의의 추가 prefill 이 0 에 수렴한다. 그러나 prefix cache 의 적중 조건은 **문자열 동일성**이므로 $\kappa_{\parallel}$ 개의 재표현이 질의마다 다르게 뽑히거나 질의 토큰이 앞에 오면 적중이 깨진다. 게다가 적중하더라도 그 캐시는 KV 바이트를 점유하므로 프롬프트가 길어지는 만큼 동시 배치 크기의 상한이 내려간다 — **시간 축에서 지운 비용이 바이트 축에서 다시 나타난다.** 즉 $w_{\text{in}} = 0$ 은 회계상의 단순화가 아니라 특정 서빙 구성에 대한 가정이고, 논문은 그 가정을 명시하지 않는다. 실무 항목은 하나다 — **E -경로 시스템을 도입할 때 첫 번째로 재야 할 값은 품질이 아니라 $\hat{c}$ 접두사의 캐시 적중률이다.**

자세한 것은 ch25 § 25.2.3 – § 25.3.5.

3. 비용 4 종의 빈칸 — 자를 대야 할 자리가 비어있다

앞의 계산은 한 논문에 대한 것이다. 세 경로를 같은 자로 재려면 논문마다네 값이 있어야 한다.

기호 풀이 B_s = sleep 계산 예산 (FLOPs 또는 tokens), 미리 태우는 양. L_w = wake 지연 기여 (ms, TTFT/ITL), 사용자가 실제로 기다리는 시간. C_{cap} = 상태 용량 (bytes/세션 또는 bytes/사용자), 남겨 두는 양. ρ = 망각 · 열화율, 라운드를 반복했을 때 라운드당 잃는 성능.

본문 Part II는 이 네 칸을 논문 21 편에 대해 원문 대조로 채웠다. 채웠다고 인정하는 기준은 **단위가 붙은 수치가 원문에 인쇄되어 있을 것** 하나이고, 개수 · rank · step 수 · 비율은 그 칸의 단위가 아니다.

표 E11-1. 21 편에 대한 비용 4 종 집계. “요구 단위대로 인쇄” 열이 이 표의 전부다.

칸	요구 단위	요구 단위대로 인쇄	대용치만	완전 침묵
B_s	FLOPs 또는 토큰	1 편	6 편	14 편
L_w	ms · TTFT · ITL	0 편	5 편	16 편
C_{cap}	dtype 명시 바이트	0 편	13 편	8 편
ρ	라운드당 손실률	0 편	4 편	17 편

네 줄이 각각 다른 것을 말한다.

B_s — 상각 논증의 분자가 corpus 전체에서 딱 한 번 인쇄되었고, 그 한 번은 상각을 주장하지 않는 논문에서 나왔다 (과제당 3748.4 토큰). **상각을 주장하는 논문 중 분자를 숫자로 인쇄한 논문은 0 편이다.** L_w — 이 라인이 systems 독자에게 파는 성질이 정확히 지연인데 지연의 단위로 잔 값이 없고, 자리마다 **구조적 논증으로 대체되어 있다** (“고정 크기 상태임으로 decode 가문맥 길이에 무관하다”, “merge 뒤에는 추가 지연이 0 이다”). 둘 다 아키텍처의 보장이자 잔 값이 아니다.

C_{cap} — dtype 이 붙은 바이트가 세션당 · 사용자당으로 인쇄된 곳이 없다. 바이트가 등장하는 두 자리는 단위가 다르다 (과제당 체크포인트 35MB, corpus 당 index 수십 GB). **상태의 단위가 corpus 당에서 사용자당으로 바뀌는 바로 그 논문에서 숫자가 사라진다.** ρ — 반복 sleep 의 지속가능성에 대한 정량 근거가 없고 이유가 논문마다 구조적이다. 대표 논문의 모든 실험은 라운드가 정확히 1 회이고, W-경로의 유일한 논문은 상태가 시퀀스마다 0 으로 초기화되어 라운드를 넘길 상태가 만들어지지 않는다. **측정되지 않은 것이 아니라 측정될 실험이 설계되지 않았다.**

그리고 이 절의 결론을 만드는 명단이 하나 있다. **네 칸이 전부 비어있는 논문이 여섯이고, 그중 셋이 세 경로의 대표 논문이다.** 세 경로를 같은 자로 재려고 자를 들이대면 자를 대야 할 세 지점이 모두 비어 있다.

핵심 비용 칸이 비어 있다는 것은 그 방법이 비싸다는 뜻이 아니다. 비어 있으면 비어 있다고 쓴다. 그러므로 이 절의 판정은 “sleep-time compute 은 비싸다”가 아니라 **“현재 문헌 상태에서 썬지 비싼지가 결정되지 않는다”**이다.

자세한 것은 ch25 § 25.2.1.

4. 같은 자를 세 경로에 대면 자가부러진다

식 (A) 로 손익분기 N_q^* 를 계산하라고 요구받은 장이 21 개였고, **계산에 성공한 장이 하나도 없다**. 중요한 것은 실패의 이유가 한종류가 아니라는 점이다.

표 E11-2. 식 (A) 가 닫히지 않는 이유 여섯 유형. 오른쪽 열이 이 표의요점이다.

유형	뜻	값을 인쇄하면 해소되는가
I. 분자 부재	B_s 가 숫자로 없다	해소된다
II. 분모 부재	B_s 는 있으나 N_q 가 없다	해소된다
III. 분자가 구조적으로 0	오프라인 pass 가 없어 상각할 것이 없다	해소되지 않는다
IV. 식의 모양이 안 맞음	분모가 질의 수가 아니다	해소되지 않는다
V. 질의 스트림이 없음	문맥 · 사용자 · 질의라는대상이 정의되지 않는다	해소되지 않는다
VI. 상각이 아니라 재배치	$N_q = 1$ 이라 식이 단순 합으로 붕괴	해소되지 않는다

유형 I-II 는 보고 관행의 문제다. 유형 III-VI 는 다르다. 식 (A) 자체가 “한 문맥을 여러 질의가 공유한다” 는 E -경로의모양을 전제하기 때문이고, 다른 두 경로는 그 전제를 받지 않는다.

W -경로에서는 상각이 재배치로 바뀐다. 유일한 논문의 헤드라인설정에서 $N_q = 1$ 이므로 식 (A) 가 $C_{avg} = C_{wake} + C_{sleep}$ 으로 붕괴한다. wake 에서 뺀 계산이 같은 요청의 다른 국면으로 옮겨 갈 뿐이고 요청 전체의계산량은 오히려 **늘어난다**. 팔리는 것은 총비용 절감이 아니라**비용의 시간 배치**이며, 그 이득을 재려면 L_w 가 필요한데 그칸이 비어 있다. Θ -경로에서는 분모가 질의 수가 아니다 —직접 편집에서는 한 라운드에 묶어 넣은 편집 수이고, 배포가중치에 능력을증류하는 방식에서는 “앞으로의 전 트래픽” 이 된다. 후자에서 상각식은이기는 것이 아니라 **퇴화한다**. 분모가 무한하면 그 식은 아무것도말하지 않는다.

핵심 통일 회계의 첫 결과는 통일된 숫자가 아니라 **하나의 회계 틀이 세경로에 대해 각각 다른 방식으로 무너진다는 관측**이다. 그리고 부러지는지점이 곧 구속력 있는 질문이 옮겨가는 지점이다. Θ -경로에서 식 (A) 가 퇴화하는 순간 질문은 ρ 와 C_{cap} 으로 옮겨가는데, 표 E11-1 이 보이듯 그 두 칸은 각각 0 편과 0 편이다. **경로를 갈아타면질문이 옮겨가는데, 옮겨간 자리의 증거가 더 비어 있다.**

Θ -경로에는 다른 경로에 없는 항도 하나 있다 — **쓰기 검증비용**이다. 편집 연산의 시간은 인쇄되어 있지만 올바르게 썼는지 확인하는비용은 어떤 수치에도 없다. E -경로에서 쓰기가 틀리면 그 항목을 지우면되지만, Θ -경로에서 쓰기가 틀리면 **배포 아티팩트가 이미바뀐 뒤다**.

자세한 것은 ch25 § 25.2.2, § 25.3.6.

5. 자를 바꿔 본다 — 바이트로 재면 자릿수가벌어진다

시간 축에서 비교가 안 되면 다른 축을 대 본다. 세 경로가 한 사용자에게 대해실제로 몇 바이트를 남기는가.

여기서도 문헌은 답을 갖고 있지 않다. **판별식을 통과한 논문 중상태 용량을 사용자당 바이트로 보고한 논문이 0편이다.** 그래서 이 책은논문이 인쇄하지 않은 바이트를 구성 파라미터에서 복원하는 결정론적 회계를돌렸다. 측정이 아니라 회계이며, 그 등급이 아래 모든 문장의 상한을 정한다— **단정하는 것은 자릿수와 모양이고, 절대 바이트는 방향성으로만읽는다.**

표 E11-3. 앵커 두 종에서 경로별 상태 바이트와 그 수명. LoRA 설정은 rank 16, query-value 두 행렬, bf16 이다. dense-8B 의 W 행은**반사실**이다 — 그 앵커에는 W 층이 없다.

경로	1.3B 앵커	dense-8B 앵커	수명	상주 위치
E (텍스트)	56.0 KB	56.0 KB	세션~사용자	콜드/벡터 스토어
Θ delta (LoRA)	6.29 MB	16.78 MB	사용자 (영속)	웜 → 요청 시 로드
Θ 직접 편집 + 개 인화	2.6 GB	16.0 GB	배포본 (영속)	체크포인트 전체
W fast weights	3.22 GB	17.18 GB (반 사실)	세션 (transient)	HBM 상주, 토큰 마다 갱신

dense-8B 앵커에서 양 끝의 비가 약 30 만 배, 즉 **약 5.5 자릿수**이고 1.3B 앵커에서는 약 4.8 자릿수다. 두 앵커에서 순서가 같고 **큰앵커에서 격차가 더 벌어진다.** 우연이 아니라 세 경로가 서로 다른 변수를타기 때문이다.

$$C_{\text{cap}}^{(E)} \propto n, \quad C_{\text{cap}}^{(\Theta)} \propto r d |\mathcal{S}| L_{\text{layer}} \cdot b, \quad C_{\text{cap}}^{(W)} \propto d^2 L_{\text{layer}} \cdot b$$

기호 풀이 n = 저장된 항목 수. r = LoRA rank(변화량 행렬에 건 랭크 제한). d = 모델 폭. $|\mathcal{S}|$ = delta 를 붙인 행렬의 개수. L_{layer} = 층 수. b = 저장 dtype 의 바이트 폭.
이 세 식이 말하는 것은 변수 집합이 겹치지 않는다는 것뿐이다. E 는 **모델과 무관**하다 — 폭을 두 배로 늘려도 저장한 텍스트는그대로다. Θ delta 는 d 에 **선형**이고, W 는 d 에 **제곱**이다. 그래서 모델이 커질수록 세 경로의 상태는 서로멀어진다.

W -경로에는 두 번째 성장 축이 있다. 고정 크기 상태라는 이 경로의간판은 **recall** 을 얻는 대가로 포기된다 — 세그먼트를 나눠 캐시를여러 개 두면 상태 바이트가 문맥 길이에 선형으로 자란다.

수명과 상주 위치를 곱하면 **각 경로가 실제로 무엇에 제약되는지가갈린다.** W 는 **transient** × **핫**이므로 **총량이 아니라 동시성에결린다** — 세션과 함께 사라져 누적되지 않는 대신 활성 세션 하나하나가 HBM 을 GB 단위로 점유하므로 동시 세션 수가 상태 바이트로 제한된다. Θ delta 는 **영속** × **웜**이므로 **총량과 스테이징 지연 둘 다에결리고**, E 는 **영속** × **콜드**이므로 **총량에만 결린다.**

세 제약의 종류가 다르므로 셋을 같은 예산 항목으로 합산할 수없다. “어느 경로의 용량이 큰가” 는 답할 수 없는 질문이고, 답할 수 있는질문은 “어느 경로가 어느 계층에 얼마를 얼마 동안 두는가” 다.

시스템 모델링 관점 그러므로 경로 선택은 알고리즘 선택이면서 동시에 메모리 계층선택이고, 후자는 전자가 정한다. W 는 핫이다 — 세션당 GB 단위이고토큰마다 전 상태를 읽고 쓰므로 HBM 밖에 둘 수 없다. Θ delta 는웜이다 — 사용자당 수 MB 이고 요청 지연 안에 한 번 스테이징되면충분하다. E 는 콜드다 — 사용자당 수십 KB 이고 질의당 한 번 읽히며검색 index 는 host DRAM 에 산다. 트래픽의 축도 갈린다: W 의**비용**은

생성 길이에 비례하고, Θ 의 비용은 요청 수에 비례하며, E 의 비용은 바이트가 아니라 **prefill 토큰으로 나타난다**. 1.3B 앵커에서 512 토큰짜리 요청 하나면 W 는 약 3.3 TB를 움직이고 Θ 는 6.29 MB를 한 번 움직이는데, **이 배수를 “ Θ 가 싸다”로 읽으면 안 된다** — Θ 가 지불하지 않는것은 sleep 라운드에서 미리 지불했기 때문이다.

자세한 것은 ch26 § 26.3.1 – § 26.3.2, ch18 § 18.7.

6. 개인화를 요구하는 순간 갈림길이 생긴다

Θ -경로에는 두 가지 구현이 있고, 걸보기에는 뒤의 것이 유리하다.

직접 편집은 특정 층의 가중치에 같은 shape의 값을 제자리에서 더한다. 편집을 10개 하든 10,000개 하든 체크포인트 크기가 같다. **상태량이 0이라는 것이 이 방식의 걸보기 장점**이고, 편집이 **전역**이면 — 그 사실들이 모든 사용자에게 같은 사실이면 — 그장점은 진짜다. 가중치 1벌을 계속 공유하므로 batching이 살아남고 “한 번 지불하고 무한히 상각”이 성립한다.

개인화를 요구하는 순간 그 0이 전체 사본으로 바뀐다. 분리 가능한 아티팩트가 애초에 생기지 않으므로 사용자마다 다른 사실을 넣으려면 사용자마다 모델 하나가 필요하다.

표 E11-4. 사용자 10^6 명 기준 웹 스토리지 총량. 선형 외삽이며 **모양과 자릿수만 읽는다**.

방식	총량
E 텍스트	0.056 TB
LoRA delta, $r=16$, int4	4.194 TB
LoRA delta, $r=16$, bf16	16.777 TB
LoRA delta, $r=64$, bf16	67.109 TB
직접 편집 + 개인화 (전체 사본)	16,000 TB

세 자릿수의 점프가 한 문장에서 나온다. 함께 사라지는 것이 둘 더 있다 — **되돌리기** (편집 취소 연산이 어느 논문에도 없다)와 **다중배포본의 분리**. 상각의 구조도 뒤집힌다. 편집이 전역이면 편집 시간은 전사용자에게 상각되지만 개인화하면 사용자마다 따로 지불되고 분모가 1이 된다. **분리 가능한 아티팩트가 없다는 것은 저장이 없다는 뜻이 아니라 상각이 없다는 뜻이다**.

이 갈림길은 서빙 쪽에서 batching 파손의 종류로 나타난다. “ Θ -경로는 batching을 깬다”는 문장은 그대로는 틀린다. 파손은 이분법이 아니라 다섯 단계다.

표 E11-5. 구조별 shared-weight batching의 파손 지점과 완화 가능성.

구조	batching	깨지는 단위	완화
E -경로	유지	—	해당 없음
W -경로	부분 파손	세션	부분적. 상태 페이징으로 완화되나 대역폭하한은 남는다
Θ delta, 인구 수준	유지	—	해당 없음

구조	batching	깨지는 단위	완화
Θ delta, 사용자 수준	delta 단위 파손	사용자	가능. 같은 delta 를 쓰는 요청을 모으는 라우팅
Θ 직접 편집 + 개인화	완전 파손	사용자당 체크포인트	불가능. 분리 가능한 아티팩트가 없다

넷째 행의 파손은 **라우팅 문제**다 — 같은 delta 를 쓰는 요청을 한배치에 모으면 배치 안에서 가중치가 다시 공유되고, 실패하면 서로 다른가중치를 한 커널 호출로 묶어 처리하는 grouped-GEMM 경로로 내려간다. 다섯째 행의 파손은 **용량 문제**이며 완화 수단이 구조적으로 없다. **완화 가능한 대가와 완화 불가능한 대가를 같은 저울에 올리지 않는것이** 이 표의 요점이다.

다만 넷째 행의 완화에는 상한이 있다. 개인화는 정의상 delta 가 사용자마다 다르다는 뜻이므로 **같은 delta 를 모으는 전략의 효과는 사용자당동시 요청 수에 묶인다** — 대화형 워크로드에서는 배치 폭이 1에 가까워지고, 그때 batch 는 형성되지만 가중치 바이트의 재사용은 늘지 않는다.

셋째 행도 강조한다. **인구 수준 Θ -경로는 이 권이 말하는기회를 만들지 않는다**. 전역 편집도 이어서 하는 사전학습도 공유 memory layer 도 가중치 1 벌을 유지하므로 웹 계층도 delta 라우팅도 생기지 않는다. **새 요구를 만드는 것은 Θ -경로 자체가 아니라 Θ -경로의 개인화다**. 이 조건절을 빼면 뒤의 판정 전체가 과장된다.

자세한 것은 ch26 § 26.3.6, ch29 § 29.3.3.

7. Q1 — 세 경로는 같은 문제를 풀지않는다

여기서부터 다섯 질문에 답한다. 첫째 질문의 답이 나머지 넷의 모양을정한다.

“유망한가” 의 답이 하나일 수 없는 첫 번째 이유는 셋이 서로 다른 문제를풀기 때문이고, 이 사실은 판정이 아니라 각 경로의 갱신식에서 곧바로읽힌다.

표 E11-6. 세 경로가 실제로 푸는 문제와 지불하는 것. “**풀지 않는문제**” 열이 **이 권의 나머지**를 규정한다 — 어느 경로도 그 열의 항목에대해서는 대안이 아니다.

경로	실제로 푸는 문제	지불하는 것	풀지 않는 문제
E	긴 문맥을 매 질의 프롬프트에 다시 신는 비용	매 질의의 검색과 $\hat{c}$ 프롬프트 항, 파괴적 쓰기의 손상 위험, 세지 않은 B_s .	모델이 모르는 것을 알게 만드는 문제. Θ 와 W 가불변이므로 저장은 모델 밖에 남는다
W	문맥 길이에 선형인 KV cache 를 고정 크기 상태로 접는 문제	경계마다의 prefill 버스트, 손실 압축, 되돌릴 수 없는 요약	요청을 넘는 지속성. 상태가 시퀀스마다 0으로 초기화되어 세션과함께 죽는다
Θ	사실과 능력을 배포 아티팩트에 넣어 질의당 한계 비용을 0 으로만 드는 문제	shared-weight batching, 사용자당 웹 스토리지, 반복라운드의 열화, 롤백 단위	즉시성. 갱신이 라운드단위이므로방금 도착한 사실을 지금 쓸 수 없다

세 행의 “풀지 않는 문제”가 서로의 “푸는 문제”와 겹치지 않는다는 점이 결정적이다. E 는 지속성을 주지만 모델을 바꾸지 않고, Θ 는 모델을 바꾸지만 즉시성을 주지 못하며, W 는 문맥 비용을 접지만 요청을 넘지 못한다. 그러므로 “ E 대신 Θ 를 쓰면 되는가”는 성립하는 질문이 아니다 — 두 경로는 같은 자리를 놓고 경쟁하지 않는다.

비유 세 경로는 같은 종목의 세 선수가 아니라 서로 다른 종목의 선수다. 기록을 나란히 놓아 순위를 매기는 행위 자체가 성립하지 않는다. — **비유가 깨지는 곳**: 서로 다른 종목의 선수는 한 팀에 있어도 자원을 거의 나눠 쓰지 않지만, 세 경로를 한 배포에 얹으면 요구가 상쇄되지 않고 합쳐진다. 이 합산이 § 12의 마지막 항목이다.

Θ -경로를 쓴다는 것은 배포 아티팩트를 바꾼다는 것이고, 그 절차는 아무리 빨라도 요청 하나의 지연 안에 들어가지 않는다. 같은 이유로 E -경로를 쓴다는 것은 배포 아티팩트를 건드리지 않겠다는 선택이고, 그대가가 “모델은 여전히 모른다”이다.

자세한 것은 ch27 § 27.3.1.

8. Q2 — 경로별 로유망한가

E -경로 — 주장의 종류가 바뀌어 있다

E -경로에는 판별식 통과 9편 중 6편이 있다. 문헌의 무게 중심이고 이라인의 이름도 여기서 나왔다. 그런데 그 논문들의 자기 표를 읽으면 품질 1위가 반복적으로 기억 시스템이 없는 구성이다.

- 문맥 전부를 넣는 구성이 $72.90 \pm 0.19\%$ 로 제안 시스템 $68.44 \pm 0.17\%$ 와 $66.88 \pm 0.15\%$ 를 이긴다. 격차 4.46 점 · 6.02 점은 그 논문이 인쇄한 표준편차의 20배를 넘는다.
- 다른 시스템에서는 자명한 full-conversation baseline 이 이미 비교 대상을 이긴다 (94.4% 대 93.4%). 제안 시스템이 남기는 마진은 0.4 점, 작은 모델에서는 0.2 점 — 500 개 대화에서 0.2 점은 대화 한 건이며 신뢰 구간도 시드도 유의검정도 없다.
- 또 다른 시스템에서는 forgetting 없는 그래프 baseline 이 22/22로 동률이고, 여덟 테스트 전부가 1.00 이어서 헤드룸이 0이다. 에이전트 기억 시스템에서는 검색 항목이 하나를 넘어가면 성공률이 단조로 나빠지고 ($49.7 \rightarrow 46.0 \rightarrow 45.5 \rightarrow 44.4$), 기억 baseline 이 No Memory 보다 나쁜 칸도 여럿이다 (3.4 대 10.3).

이 넷은 이 책의 재구성이 아니라 논문들 자신의 수치다.

그 위에 평가 결함이 없힌다. 본문은 다섯 시스템의 결함을 아홉 유형으로 묶었다 — 자기 표가 자기 주장을 반증하고, 인쇄된 산술이 맞지 않고, 만들어놓은 계층이 어느 수치에도 기여하지 않고, 초록이 약속한 능력에 실험이 0 건이고, 결정적 파라미터가 시연 가능성으로 정해진다. 아홉 중 여섯이 다섯 시스템 중 셋 이상에 나타난다.

핵심 그리고 결함의 방향이 한쪽이다. 어떤 유형은 헤드라인을 실제보다 크게 만들고, 어떤 유형은 기여를 넓게 만들며, 어떤 유형은 범위를 멀리 밀고, 어떤 유형은 비용을 세지 않아 이득을 싸게 만든다. 반대방향으로 기운 결함 — 방법을 실제보다 나쁘게 보이게 하는 오류 — 은 한행도 없다.

비유 계측기의 오차가 무작위면 그것은 잡음이고 평균이 참값에 수렴한다. 오차가전부 한 방향이면 잡음이 아니라 **눈금 자체가 밀린 것이다**. — **비유가 깨지는 곳**: 밀린 눈금은 밀린 양을 알면 보정할 수 있지만여기서는 방향만 알고 크기를 모른다. 그래서 단정할 수 있는 것은 “실제이득이 보고치보다 작다”가 아니라 “**보고치보다 클 가능성에는근거가 없다**”이다.

그럼에도 **비용과 지연의 이득은 실재한다**. 그 방향은 측정이 아니라구조에서 나온다 — 26k 토큰의 대화 이력 대신 수백 토큰의 $\hat{c}$ 를심는다면 prefill 이 준다. 반박되는 것은 **이득의 크기**뿐이다. 보고된 91%·92%·약 90%는 상대방에게 prefix cache 를 켜 주지 않은 비교이고 (한 시스템은 전문에 ‘cache’가 한 번도나오지 않는다), 다른 시스템의 두 팔은 115k 대 1.6k 토큰으로 71.9 배차이다.

판정. E -경로는 유망하다. 단 **비용 방법**으로서다. 품질 방법으로는 현재 문헌이 지지하지 않으며, 그 반증은 이 책이 아니라논문들 자신의 표에서 나온다.

그러므로 이 경로에서 일어난 일은 **주장의 종류가 바뀐 것이다**. 초록들은 품질 주장의 문법으로 쓰여 있는데 (“outperform”, “state-of-the-art”) 자기 표가 지지하는 것은 비용 주장이다. **종류가 바뀌면 방어 부담도 바뀐다** — 품질 주장은 정확도 표로방어되지만 비용 주장은 **총비용**으로 방어되고, 총비용에는추출·갱신·요약에 쓴 LLM 호출, 즉 B_s 가들어간다. 그런데 B_s 가 이 경로에서 가장 비어 있는 칸이다. **이경로는 자기 주장을 성능 표로 방어하려다 지고, 비용 표로 방어하려면 세지않은 칸을 세어야 한다**.

반대편 사실도 함께 심는다. E -경로는 상태가 가중치에 내려앉지않으므로 **shared-weight batching**을 그대로 보존하고, 사용자당 워스트리지도 delta 스테이징 지연도 만들지 않는다. Θ -경로 대비결정적인 서빙 이점이다. 그런데 **다섯 논문 중 아무도 이 이점을 주장하지 않는다** — 실제로 가진 가장 강한 논거를 쓰지 않고 가지지 않은품질 논거를 쓰고 있다.

W-경로 — 표본 1의판정

W -경로는 판별식을 정면으로 통과하는 논문이 **한 편**이다. 그 한편의 증거 상태를 그대로 옮긴다.

- **비용 4종이 전부 논문에 없다**. C_{cap} 은 상태차원·head 수·dtype이 없어 유도조차되지 않는다. 헤드라인 지연 주장도 측정이 아니다 — 고정 크기상태이므로 decode가 문맥 길이에 무관하다는 것은 아키텍처의 보장이지 잔값이 아니다.
- **계산량을 맞춘 baseline이 없다**. 캐시를 유지한 full attention은어느 과제·어느 스케일에서도 실행되지 않았다. 여러 번재귀하는 실행이 이미 쓴 계산을 상대방에게 주지 않은 비교다.
- **판별식 통과 자체가 설정 의존이다**. 질의보다 consolidation 이앞서는 것은 한 설정 뿐이고, 수치가 나오는 헤드라인 설정은 질문을 문맥앞에 놓아 $N_q = 1$ 이 된다 — 상각이 없다. 그리고 이득은 6·8 연산 꼬리에만 있고 쉬운 문제에서는 폭이 0.3–2.9 백분점이며, 시드는 하나이고 오차막대가 없다.

판정. W -경로는 현재 문헌으로 **판정 불가**이며 그 판정불가 자체가 결과다. 보류가 아니다. 그리고 판정 불가는 아무 말도 하지않는 것이 아니라 두 가지를 말한

다. 첫째, 회계상 가장 유망한 형태를 가진 경로가 증거가 가장 적은 경로다. § 2가 확정한 상각 논증의결함에서 벗어나는 가장 깨끗한 설계는 원 문맥을 실제로 버리는 것이고 그것이 정확히 이 경로가 하는 일이다 — 문맥을 fast weight로 접고 원본을 버리면 매질의 프롬프트가 줄어들어 나뉘지 않는 항이 음의 기여를 한다. 그 이점이 한 번도 측정되지 않았다. 둘째, 판별식 통과가 설정에 달려 있다는 것 자체가 미성숙의 증거다.

⊖-경로 — 용량은 있고 반복이 없다

⊖-경로의 상태는 다른 둘과 다르다. 용량 축에서는 증거가 있다. 가중치는 사실을 실제로 담고, 담긴 것은 쉽게 지워지지 않는다 — 20라운드 뒤 채점 문항을 전부 틀린 사실도 그 사실에 대한 log-probability 상승분의 중앙값 69%·79%를 유지한다. 그리고 담긴 사실의 질의 당 한계 decode 비용은 0이다 — 검색도 프롬프트 증가도 없기 때문이다. 이것은 E-경로가 원리적으로 줄 수 없는 성질이다.

무너지는 곳은 용량이 아니라 반복이다. 넷을 적는다.

첫째, 판별식 통과군에서 sleep 라운드 수를 독립변수로 놓은 실험이 0편이다. 대표 논문의 모든 실험은 라운드가 정확히 1회다. 측정되지 않은 것이 아니라 측정될 실험이 설계되지 않았다.

둘째, 반복을 실제로 돌려 본 유일한 논문이 이 경로를 지지하려는 논문이 아니라 반증하려는 논문이다. 그 논문은 100라운드까지 돌렸고, 유지율이 0으로 가지 않는 대신 25–28%에서 고원을 이룬다는 것과, 20라운드마다 원래 가중치를 기준점으로 삼아 통합을 넣으면 일반역량은 회복되고 유지율은 회복되지 않는다는 해리를 보고한다. 유일한 다라운드 증거가 반증 축에서 나온다는 사실 자체가 문헌 상태에 대한 진술이다.

셋째, 이 책의 최소모형이 그 방향을 독립적으로 재현한다. 언어도의미도 없는 가우시안 위치 모형과 선형 연상기억 위에서 갱신을 여러 라운드 돌린 실험이다. LLM 실험이 아니므로 라운드 수도 유지율도 숫자로 옮기지 않고, 옮기는 것은 부호와 모양뿐이다.

- 이송해야 할 양은 ρ 가 아니라 K^* 다 — 성능이 기준선을 유지하는 마지막 라운드다. “라운드당 몇 %”는 운영 지표가 될 수 없다. 그 비율이 라운드에 대해 상수가 아니기 때문이다.
- replay는 보존된 원본에 앵커되어야 한다. 같은 예산·같은 혼합비에서 replay 타격을 모델 자기 출력으로 만들면 보존된 원본으로 만들 때보다 모든 혼합비에서 먼저 무너진다. 이 부호는 반증 논문의 고정 교사 대비 (역량+2pp·유지율 54% 대 - 31pp·유지율 21%)와 같고, 앞 권에서 본 accumulate 대 replace 대비와도 같다. 세 곳에서 같은 부호가 나온다.
- 과제 지표는 저장이 이미 깎이는 동안 움직이지 않다가 절벽으로 떨어진다. 연속 신호는 첫 라운드부터 꾸준히 감소하는데 과제 정확도는 한동안 반응하지 않다가 좁은 구간에서 무너진다.

넷째, 서빙에 도달하기 위한 두 전제가 미논의다. 하나는 delta 양자화 — 사용자당 바이트를 정하는 1차 변수가 rank도 적용행렬도 아니라 저장 dtype인데, 양자화한 상태에서 회수율을 측정한 논문이 0편이다. 다른 하나는 쓰기 검증 — 무엇을 학습 집합에 넣을지 판정하는 절차가 두 논문 모두 외부 신호에 의존한다. 한쪽은 문맥마다의 정답 라벨을 요구하고, 다른 쪽은 이름도 크기도 밝혀지지 않은 외부 frozen reward model에 의존하는데 그것을 제거하면 점수가 69.0에서 69.2로 오른다.

판정. Θ -경로는 조건부로 유망하다. 용량 측은 통과하고, 반복 측은 미검증이며, 서빙 측은 두 개의 미논의 전제 위에 서있다. 조건 셋 — (i) 원본 앵커 replay 하에서 K^* 가 서비스 요구라운드 수를 넘는 것이 **측정되고**, (ii) delta 를 int8 이하로 양자화해도 회수율이 유지되는 것이 **측정되며**, (iii) 라벨 없이 쓰기를 판정하는 절차가 나오고 그 정확도가 **측정되는 것**. 셋 중 어느 것도 현재 문헌에 없다. 세 조건이 충족되지 않은 상태에서 “유망하다”고 쓰는 것은 이 책이 논문들에게 금지한 서술 방식이다. 이 경로가 사는 거래는 정확히 이것이다 — **질의당 한 계 비용 0** 을 사기 위해 배치 효율과 웹 스토리지를 지불한다.

자세한 것은 ch27 § 27.2 – § 27.3.4, ch22 § 22.6.

9. Q3·Q4 — 최선인가, 대안 대비 우월한가

이 두 질문은 대조군이 있어야만 답이 있다. 그러므로 이 절이 하는 일은 우열을 선언하는 것이 아니라 어느 대조가 실행되었고 어느 대조가 실행되지 않았는지를 세는 것이다.

표 E11-7. 각 경로가 푸는 문제에 대한 가장 강한 대안과 corpus 의 대조상태.

경로	가장 강한 대안	대조 상태	판정
E	문맥 전부 넣기 — 품질 측	실행되었고 방법이 졌다	품질 측에서는 대안이 우월하다
E	문맥 전부 넣기 + prefix cache — 비용 측	실행되지 않았다	비용 측의 우열은 판정 불가
E	질의 전 추론 없는 순수 검색	부분 실행이 되 비대칭. 스왑이 검색 baseline 에만 걸려 있다	방향만. 한 설정의 관측
W	캐시를 유지한 full attention — 계산량 정합	실행되지 않았다	판정 불가
Θ	같은 사실을 문맥에 넣기	실행되었으나 레짐이 어긋난다 — 문맥 채널은 항목 2 개 이하에서만, 가중치 채널은 100 개까지	방향은 대안우세. 크기는 판정 불가
Θ	검색 (E -경로)	실행되지 않았다. 이름 으로부터 두 문장으로 기각되 baseline 으로 한 번도 돌리지 않는다	판정 불가

핵심 여섯 행이 하나의 패턴을 이룬다. 실행된 대조에서는 방법이 지거나 겨우 비기고, 방법이 이기는 측에서는 대조가 실행되지 않았다. 그리고 빠진 대조군이 무작위가 아니다 — 빠진 것은 언제나 표준 서빙 최적화를 켜 full-context, 캐시를 유지한 full attention, 같은 예산의 in-context, 즉 가장 싸고 가장 자명한 baseline 이다. 구현 난이도가 아니

라이기기 어려운 상대라는 성질이 공통이다.

판정. “최선인가” 와 “대안 대비 우월한가” 는 어디에서도 판정되지 않는다. **어정정하게 남기지 않는다** — 이 책은 “ E -경로가 full-context 보다 총비용에서 우월하다” 도 “우월하지 않다” 도 주장하지 않으며, **그 비교를 성립시키는 표가 문헌에 없다고** 주장한다. 문헌상태의 기술이지 비난이 아니며, 그 상태를 바꾸는데 필요한 실험은 전부값이 싸다.

자세한 것은 ch27 § 27.3.5.

10. Q5 — 주류가 될까: 조건으로만 답한다

미래에 대한 진술이므로 단정하지 않는다. 대신 **무엇이 참이면 어느경로가 이기는지**를 조건으로 적고, 조건마다 **그것이 어디서 판정되는지**를 함께 적는다 — 적지 않으면 조건부 판정도 반증 불가능해진다.

표 E11-8. 조건부 예측. “판정되는 자리” 가 문헌 밖이면 그 조건은 이 책의 증거로 닫히지 않는다.

조건	이기는 경로	판정되는 자리
C1. 요구가 지연과 비용이고 품질은 full-context 근방이면 족하다	E	제품 요구. 문헌이 아님
C2. 워크로드의 N_q 중앙값이 손익분기 위쪽에 안정적으로 있고 문맥이 짧다	E	서빙 로그. 새 실험 불필요
C3. 개인화가 요구되고 사용자당 delta 를 요청 지연 안에 웹 계층에서 끌어올수 있다	Θ	실제 서빙 스택의 측정
C4. 원본 앵커 replay 하에서 반복 sleep 이 서비스가 요구하는 라운드 수를 버틴다	Θ	아직 실행되지 않은 실험
C5. 문맥 처리 비용이 워크로드를 지배하고, 고정 크기 상태가 recall 을 지킨다	W	아키텍처. 현재 증거는 반대 방향
C6. 세 경로가 합성 가능하고 합이 부분보다 낮다	셋 다	없음. 합성 실험 0 건

두 가지가 읽힌다.

첫째, E -경로의 주류화 여부는 이 문헌의 품질과 거의 무관하게 결정된다. C1 과 C2 는 제품 요구와 서빙 로그가 정하는 조건이지 논문이 정하는 조건이 아니고, E -경로 시스템들은 이미 프로덕션에 배포되어 있다. 배포를 정당화한 것은 성능 표가 아니라 **프롬프트 길이의 산술**이다 — 26k 토큰을 수백 토큰으로 줄이면 싸진다는, 아홉 결함 유형 어느 것으로도 흔들리지 않는 사실이다. **이 경로는 문헌이 약한 채로 주류가 될 수 있고, 이미 그렇게 되고 있다.**

둘째, 구조가 가장 강하게 가리키는 미래가 증거가 가장 없는미래다. C6 — 세 경로를 합성한 시스템 — 은 표 E11-6의 구조로부터 곧바로따라 나오고, 세 경로 중 둘을 이미 배포한 조직이 다음으로 붙일 구성이다. 그런데 그 조합을 돌린 실험이 0 건이다. E-경로 논문은 자기 $\hat{c}$ 를 학습 집합으로 삼는 가능성을 언급조차 하지 않고, Θ -경로 논문은 E-경로를 기각한다. 침묵은 인용 예절의문제가 아니라 가장 유망한 설계 공간을 비워 둔 원인이다.

판정. “주류가 될까”는 조건부로만 답하고, **조건 성격이 경로마다 다르다**. E-경로의 조건은 **제품 요구와 서빙 로그가정한다**. Θ -경로의 조건은 **실험이 정한다** — 아직 실행되지 않았지만 실행 가능하고 값이 싸다. W-경로의 조건은 **아키텍처가정한다** — 고정 크기 상태가 recall을 지키는지가 관건이고, 현재 증거는반대 방향이다.

자세한 것은 ch27 § 27.3.6, § 27.4.

11. scaling law — 지금은 그릴 수 없고, 무엇이 인쇄되면 그릴수있다

B_s 를 x축에, 품질을 y축에 놓은 곡선이 있으면 “예산을 얼마 태울것인가”가 공학 문제가 된다. 그 곡선을 그릴 수 있는지부터 센다.

기호 풀이 N = 고전 scaling law의 파라미터 수. D = 학습 토큰 수. 둘 다 이절에서만 쓰며, 특히 N 은 질의 수 N_q 와 다른 양이다.

x축이 여섯 단위로 흩어져 있다. 이 책이 정독한 29편에서 B_s 를 절대 FLOPs 또는 토큰으로 인쇄한 논문은 1 편이고, 5편은 optimizer step 수로, 2편은 벽시계로, 2편은 눈금 없는 서수 손잡이로만보고하며, 19편은 침묵한다. 그 19편을 한 덩어리로 세면 안 된다 — 그 중 9편은 “보고하지 않았다”가 아니라 **질의 전 오프라인 패스자체가 없어 B_s 가 정의되지 않는 경우다**.

단위를 옮길 다리도 없다. step은 batch와 시퀀스 길이가, 벽시계는장치와 달성 효율이 정해져야 계산량이 된다. 후보 8편 중 FLOPs 환산이달하는 것은 1 편이고, MFU 또는 달성 throughput을 보고한 것은 29편 중 1 편인데 **그 1 편은 B_s 가 정의되지도 않는 논문이다**.

y축도 함께 깨져 있다. B_s 축에 3 점 이상을 놓은 논문은 4 편인데 **그 4 편의 벤치마크 교집합이 공집합이고 두 편 이상이공유하는 벤치마크가 하나도 없다**. 게다가 그중 점들이 절대 예산 단위인것은 둘이고 둘 다 sleep-time compute을 제안하는 논문이 아니다. 뒤집어적으면 — **판별식을 통과한 논문 중 B_s 축에 절대 예산 단위로 3 점 이상을 놓은 논문은 0 편이다**. 예산을 눈금 있는 축으로 다룬 곳은 이라인 밖이다. 그리고 이 라인에 이름을 준 논문의 전문에서 숫자뒤에 tokens가 붙은 꼴은 두 번 나오는데 **둘 다 문제 속의 게임말이고 'FLOP'은 0 회** 나온다. 상각 논증의 분자에 숫자가 없다.

그런데 x축을 복원해도 문제가 남는다. B_s 는 (N, D) 와 같은종류의 축이 아니다. 세 가지가 다르다.

- **분모**. (N, D) 는 배포본 하나에 지불되고 그 배포본의 전트래픽에 나뉜다 — 분모가 사실상 무한하므로 상각이 자명하고, 그래서고전 법칙은 상각을 회계에서 지운 채 두 축만으로 성립한다. B_s 는문맥·세션·사용자 하나에 지불되고**유한한 N_q 로 나뉜다** — 같은 FLOPs가 워크로드에 따라 다른비용이 된다.

- **반복.** D 는 한 번 쓰고 끝나지만 B_s 는 라운드마다 다시낸다. “이 방법의 B_s ”는 라운드 수를 지정하지 않으면 정의되지 않는다.
- **결합.** D 를 늘려도 추론 비용은 그대로고 N 을 늘리면 토큰마다 는다 — 부호가 정해져 있다. B_s 는 그렇지 않다. E 에서는 B_s 를 키우면 $\hat{c}$ 가 길어져 wake가 늘고, Θ 에서는 merge 뒤 토큰당 계산이 그대로이며, W 에서는 총계산이 재귀 횟수에 비례해 는다.

비유 B_s 를 축으로 쓰는 것은 눈금 간격이 재는 대상마다 늘었다 줄었다 하는 고무자로 길이를 재는 일과 같다. — **비유가 깨지는 곳:** 고무자는 늘려도 순서는 보존하지만, B_s 축은 경로마다 wake 결합의 부호가 달라 순서조차 보존되지 않는다. y 축을 품질로 놓으면 세 경로를 같은 평면에 겹칠 수 있고, y 축을 비용으로 놓는 순간 겹칠 수 없다. **하나의 곡선이 아니라 세 곡선이다.**

포화점에도 함정이 있다. 곡선에서 실무적으로 값어치 있는 특징은 지수가 아니라 **예산을 더 넣어도 오르지 않는 지점**인데, sleep의 산출물은 어딘가에 담기고 그 그릇의 크기가 C_{cap} 이다. 같은 예산이라도 그릇이 다르면 천장이 다르므로 **포화가 관측되어도 예산의 포화인지 그릇의 포화인지 구별되지 않는다.** 반증 논문의 사례가 그 위험을 보여준다 — 예산을 그대로 둔 채 **데이터의 폭만 넓히면** 세 문항 유형이 각각 +21·+18·+29 백분점 오르는 반면, 단순 진술에 예산을 더 붓는 것은 그 셋 중 어느 것도 개선하지 않는다. 같은 **x 좌표에서 결과를 정한 것은 예산이 아니라 무엇을 쓰는가였다.**

판정. 현재 문헌으로 B_s -품질 곡선은 **그릴 수 없다.** 다만 범위를 명시한다 — 이것은 **문헌의 보고 상태**에 대한 판정이지 “그런 곡선이 존재하지 않는다”는 주장이 아니다. 곡선은 있을 수 있고 다만 지금 그것을 그리는 사람이 없다. **없는 곡선을 지어내지 않는 것이 이판정의 실행이다.**

그래서 본문이 내놓는 산출물은 곡선이 아니라 **목록**이다. 아홉이 인쇄되면 축이 복원된다 — B_s 를 절대 FLOPs로 (R1), 못 하면 환산 입력을 함께 (R2), 최소 3 점으로 스윙하고 각 점의 품질을 인쇄 (R3), 품질은 공개 벤치마크에서 같은 지표·같은 baseline으로 (R4), B_s 가 무엇당 예산인지와 나눠 값을 N_q 의 분포 (R5), 각 점에서 wake 쪽 델타 $|\hat{c}|$ 와 $|c|$ (R6), 저장소 크기와 질의당 주입량을 분리해서 (R7), 라운드 수와 라운드마다 내는지 여부 (R8), 그림 축이 아니라 표에 숫자로 (R9).

최소 실행 집합은 R1(또는 R2)·R3·R4 셋이다. 이 셋만 갖춰지면 **한 경로 안에서** 첫 곡선이 그려진다. R5·R6이 붙으면 y 축을 품질에서 총비용으로 옮길 수 있고, 그때 §2의 상각 회계와 같은 평면에서 만난다.

시스템 모델링 관점 독자의 어휘로 옮기면 (N, D) 는 **빌드 타임 파라미터**이고 B_s 는 **런타임 정책 파라미터**다. 앞의 것은 아티팩트에 박혀 모든 요청에 같게 적용되므로 하나의 수로 축에 놓이지만, 뒤의 것은 요청 흐름의 통계를 함께 고정해야 축이 된다. 그리고 이 목록의 실행 비용이 낮다는 사실이 판정의 일부다 — **아홉 중 새 실험을 요구하는 것은 R3 하나뿐이고, 그마저 “이미 돌린 설정을 두 점 더 돌린다”에 해당한다.** 나머지 여덟은 이미 존재하는 실행 로그의 인쇄다. 침묵의 원인은 측정난이도가 아니라 **비교하려는 의도의 부재**이며 근거가 하나 더 있다 — 어떤 논문은 outer-loop 학습의 벽시계와 step을 정확히 인쇄하면서 sleep 국면의 계산은 한 줄도 적지 않는다. **계산량을 세는 능력이 없는 것이 아니라 세는 습관이 sleep 국면으로 확장되지 않았다.**

자세한 것은 ch28 §28.2 – §28.3.7.

12. memory device 회사에는 무슨 기회가있는가

이 절은 조건부다. 조건을 먼저 적는다 — Θ -경로가 사용자수준 개인화로 갈 때만 아래의 요구가 생긴다. 인구 수준 Θ -경로는가중치 1 벌을 유지하므로 아무것도 새로 만들지 않는다 (§ 6).

기회의 자리를 정하는 것은 총량이 아니다. 사용자 10^6 명에 16.777 TB는 오늘의 데이터센터에서 문제가 아니다. 문제는 그안의 16.78 MB 하나를 어떤 입도로, 어떤 마감 안에, 얼마나 자주 다시 쓰면서 다루느냐다.

좌표 1 — 읽기 입도. 읽기는 요청당 한 번이고 크기는 사용자당 delta 하나 — 8B 앵커에서 구성에 따라 4.19 MB에서 134.22 MB다. KV cache의 스트리밍 접근도 아니고 벡터 index의 작은 무작위 gather도 아닌, 수 MB 짜리 객체 하나에 대한 무작위접근이며 접근키는 사용자 ID다.

좌표 2 — 마감. 그 읽기는 요청 지연 안에 끝나야 한다.

$$t_{\text{load}}(C_{\text{cap}}) + t_{\text{merge}}(C_{\text{cap}}) \leq L_w$$

이 식이 말하는 것은 사용자 delta를 읽 계층에서 끌어와 base가중치에 적용하는 시간이 wake 지연 예산 안에 들어가야 한다는 것뿐이다. 그런데 **좌변의 두 항도, 우변의 예산도 문헌이 인쇄한 적이 없다.** 그래서 이 부등식은 값이 아니라 구조로만 쓸 수 있다 — 이것이 존재한다는것, 그리고 좌변이 C_{cap} 에 비례한다는것.

좌표 3 — 쓰기 주기. sleep 라운드마다 사용자 delta가 새로만들어지므로 읽 계층은 주기적으로 다시 쓰인다. 라운드당 쓰기량은 사용자수 N_u 에 선형이고 라운드 간격 T_k 에 반비례한다. 그런데 여기서나오는 비가 이 절에서 가장 쓸모 있는 수다.

$$\text{DWPD} = \frac{1 \text{ day}}{T_k}$$

기호 풀이 DWPD(drive writes per day) = 저장 매체의 상주 용량 전체를하루에 몇 번 덮어쓰는가. 소자의 쓰기 내구성 사양이 이 단위로 팔린다.

이 식이 말하는 것은 매체의 하루당 전체 재기록 횟수가**용량 · 사용자 수 · dtype**과 무관하게 **라운드주기 하나로 정해진다**는 것이다. 하루에 한 번 자면 1 이고 한 시간에 한 번 자면 24다. 셋 다 약분되어 사라지고 남는 것은 주기뿐이다.

그러므로 “얼마나 자주 자는가” 라는 알고리즘 다이어리가 저장 매체의수명 사양을 직접 정한다. 이 권이 소자를 지목하지 않으면서도 요구를 쓸수 있는 이유가 이 식이다 — 매체가 무엇이든 이 비는 같은 형태로 걸린다.

그리고 **대역폭은 문제가 아니다.** 8B 모델을 bf16으로 서빙하면 decode step마다 base가중치 16.0 GB가 읽히는데 같은 요청에 붙는 delta는 16.78 MB, 그 0.105%다. delta가

문제가 되는 이유는 크기가 아니라 **그 바이트가 첫 토큰 이전에도착해야** 한다는 것이고, 그래서 이 자리의 지표는 GB/s 가 아니라 접근 지연과 꼬리 분위수다.

핵심 기회의 자리는 HBM 대역폭이 아니라 **요청 지연 안에 delta 를스테이징하는 웹 계층과 그 계층의 쓰기 내구성**이다. 제약은 용량이 아니라 배치와 마감과 수명이다.

이 자리는 **Neural Memory** 판이 지목한 자리와 다르다. 그 책은 W -경로에서 fast weight 가 토큰마다 전 상태를 읽고 다시 쓰기때문에 decode 임계 경로 위에서 HBM 대역폭이 소진된다는 것을 memory-centric 기회로 지목했다. 여기서는 병목 자원이 대역폭이 아니라 접근 마감과 쓰기 수명이고, 시간 입도가 토큰당이 아니라 읽기는 요청당 · 쓰기는 라운드당이며, 상태 수명이 세션이 아니라 사용자다. **두 결론을 하나의 서사로 잊지 않는다.** 더 중요한 것은 **공존할 때 두 요구가 상쇄되지 않고 합쳐진다는** 점이다 — fast weight 모델에 사용자별 delta 를 없으면 HBM 은 여전히 토큰당 갱신으로 포화하고 그 위에 요청당 웹 스테이징이 얹힌다.

기회를 실재하게 만드는 것은 **반복**이다. delta 가 한 번 만들어지고 끝이면 쓰기 내구성 문제 자체가 없다. 그런데 반복이 성립하려면 **replay** 가 보존된 원본에 **앵커되어야** 한다 (§ 8). 저장 계층으로 번역하면 결론이 하나다 — **웹 delta 계층 옆에 콜드 원본 아카이브가 상시 필요하고 그 아카이브가 곧 E 다.** Θ -경로는 E -경로를 대체하지 않고 요구한다.

비유 사용자 delta 는 무한히 누적되는 자산이 아니라 **수명을 가진 캐시엔트리**다. K^* 가 유한하다는 것은 언젠가 원래 가중치에서 다시 쌓아야 한다는 뜻이고, 그래서 재기준화 주기가 서비스 설계 변수가 된다. — **비유가 깨지는 곳:** 만료된 캐시 엔트리는 원본을 한 번 읽어다시 채우면 되지만 delta 의 재구축은 sleep 라운드 전체를 다시 도는 일이다. 그것은 정기 쓰기가 아니라 **버스트 쓰기**이고, 재기준화시점이 사용자 집단에서 겹치면 웹 계층은 정기 부하가 아니라 그 버스트로 사이징된다.

양자화가 이 절 전체의 지렛대다. 저장 폭을 절반으로 내리면 **총량 · 마감 여유 · 쓰기 수명이 같은 배수로 동시에 움직인다** — bf16 에서 int4 로 내리면 사용자당 16.78 MB 가 4.19 MB 가 되고 마감 여유가 네 배 넓어지며 라운드당 쓰기가 4 분의 1 이 된다. **알고리즘을 하나도 바꾸지 않고 얻어진다.** 그런데 양자화한 상태에서 회수율을 측정한 논문이 0 편이다. 이 분야가 웹 계층 소자를 논하기 전에 지불하지 않은 것은 자본이 아니라 실험 한 편이다.

시스템 모델링 관점 세 경로를 한 배포에 겹치면 요구가 계층별로 갈린다. **가속기 HBM** 에는 E 의 KV 증가, W 의 세션당 GB 상태와 토큰당 갱신, Θ 의 base 가중치. **노드 DRAM** 에는 검색 index 와 상태 오프로드와 delta 로컬 캐시. **웹 계층** 에는 Θ 만 — 사용자당 수 MB, 요청 마감 안 스테이징, 라운드 주기 교체. **콜드 계층** 에는 E 의 원문 저장소와 Θ 의 replay 앵커용 원본 아카이브. **계산 plane** 에는 세 종류의 sleep 워크로드가 얹히는데 성격이 전혀 다르다 — E 의 sleep 은 **오프라인 batch inference** 잡이라 유틸슬롯에 끼워 넣기 쉽고 (이 경로가 오늘 당장 배포되는 이유의 절반이다), Θ 의 sleep 은 optimizer 상태와 backward 활성값을 요구하는 **fine-tuning** 잡이며, W 의 sleep 은 요청 안에서 일어나므로 **선점 불가능한 요청 내부 단계**다. 앞의 둘은 기존 스케줄러의 일급 객체이고 셋째는 아니다. 그리고 다섯 계층 중 오늘의 서빙 스택에 자리가 **아예 준비되어 있지 않은 것은 웹 행 하나뿐이다** — KV cache 도 벡터 index 도 체크포인트 저장소도 일급 객체지만 “요청 지연 안에 끌어와야 하는 사용자당 수 MB 가중치 객체” 는 그렇지 않다. “**sleep-time compute 이 메모리 계층을 바꾼다**” 는 문장은 다섯 행 중 한

행에 대해서만 참이고, 그 한 행조차 Θ -경로가 개인화로 갈때만 생긴다.

기회를 사기 전에 필요한 것은 소자가 아니라 인쇄값 셋이다 — delta 스테이징의 L_w , 양자화된 delta 의 회수율, 100 라운드를 넘긴 K^* . 셋 다 현재 0 편이고 셋 다 새 하드웨어를 요구하지 않는다.

자세한 것은 ch29 § 29.3.1 – § 29.3.8, ch26 § 26.3.5.

13. 이 판정들이 틀렸음을보이려면

판정은 반증 가능해야 한다. 각 판정을 무너뜨리는 관측을 관측의형태로 적는다.

- E -경로가 비용 방법으로 유망하다는 판정은, B_s 를포함한 총비용을 상대방에 prefix cache 를 켜 full-context 와 같은서빙 스택에서 비교한 표로 결정된다. 이기면 강화되고 지면 무너지며, 양방향으로 열려 있고 새 실험을 요구하지 않는다. 품질방법이 아니다는 판정은 full-context 팔 · 신뢰구간과시드 · 최소 세 수준의 대화 길이 스왑을 함께 갖춘 표에서 E -경로가 이기면 무너진다.
- W -경로가 판정 불가라는 판정은 판별식 통과 논문이 두 편이상 추가되거나 계산량 정합 대조와 L_w 실측이 나오면 해소된다. Θ -경로가 조건부라는 판정은 세 실험이 결정한다 — 원본앵커 replay 하의 K^* 측정, 저장 dtype 만 내리며 그리는 회수율곡선, 라벨 없는 쓰기 판정 절차의 정확도.
- 경로별로 판정한다는 분해 자체는, 세 경로를 합성한 시스템이 각경로 단독보다 같은 표에서 낫다는 결과로 무너진다. 그러면 이 권은역사적 진술로 물러난다. 이 책은 그 결과가 나오기를 요구하는쪽에 서 있다.

반증이 아닌 것도 적는다. 개별 시스템의 성능 수치가 오르내려도판정 대부분은 바뀌지 않는다. 판정이 기대는 것은 수치의 크기가 아니라대조의 구성이기 때문이다 — 새 수치가 아니라 새 표만이이 권을 무너뜨린다. 반증이 되는 것은 자릿수 순서 · 성장지수 · 계층 배치 · 파손 분류가 어긋나는 경우다.

자세한 것은 ch27 § 27.5, ch28 § 28.5, ch29 § 29.5.

요약

- 다섯 질문에 하나의 답은 없다. 세 경로가 푸는 문제의 집합이 겹치지않으므로 순위표가 성립하지 않는다 — E 는 지속성을 주되모델을 바꾸지 않고, Θ 는 모델을 바꾸되 즉시성을 주지 못하며, W 는 문맥 비용을 접되 요청을 넘지 못한다.
- 상각 논증에는 항이 하나 빠져 있다. 한 번 내는 비용만 N_q 로 나뉘고매 질의 내는 $\hat{c}$ 프롭트 항은 나뉘지 않는데 논문의 회계는후자를 갖고 있지 않다. 그래서 “이길 수 없는 영역”의 경계가 무한대로가고 표현조차 되지 않는다. 다만 $5\times$ 는 반박되지 않는다 — 반박대상은 “생성 토큰 축 = 비용 축” 이라는 암묵 등식이다.
- 비용 4 종에서 요구 단위대로 인쇄된 칸은 21 편에서 B_s 1 편뿐이고나머지 셋은 각각 0 편이다. 네 칸이 전부 빈 논문이 여섯이고 그중셋이 세 경로의 대표 논문이다. 그리고 상각식 자체가 경로마다 다르게되화하므로 값을 인쇄해도 해소되지 않는 실패가 여섯 유형 중 넷이다.

- 세 경로의 상태는 8B 앵커에서 E 56.0 KB $\rightarrow$ Θ delta 16.78 MB $\rightarrow$ W 17.18 GB 로 약 5.5 자릿수 벌어지고 격차는 모델이 커질수록 커진다. 셋이 서로 다른 변수를타기 때문이다 — E 는 항목 수, Θ 는 d 에 선형, W 는 d 에 제곱. **그러므로 경로 선택은 곧 메모리 계층 선택이다**: W 는 핫, Θ 는 웜, E 는 콜드. 그리고 개인화를 요구하면 Θ -경로는 delta 형태여야 한다.
- E -경로는 **비용 방법으로서 유망하고 품질 방법으로서는 아니다**. 품질 1위가 반복적으로 기억 시스템 없는 구성이고 그 반증은 논문들 자신의 표에서 나온다. 평가 결함 아홉 유형은 **전부 이득을크게 만드는 한 방향으로 기울어 있다**. 그리고 이 경로가 실제로 가진가장 강한 논거 — shared-weight batching 보존 — 를 주장하는 논문이 0편이다.
- W -경로는 판정 불가이며 그것이 결과다. **상각의구조적 결함에서 벗어나는 가장 깨끗한 설계가 이 경로의 기제이므로, 회계상 가장 유리한 형태를 가진 경로가 증거가 가장 적은 경로다**. Θ -경로는 조건부다 — 용량 축은 통과하지만 반복 축은미검증이고, 서빙에 도달하려면 delta 양자화와 라벨 없는 쓰기 검증이먼저 채워져야 한다.
- “최선인가”와 “우월한가”는 어디에서도 판정되지 않는다. **실행대조에서는 방법이 지거나 겨우 비겼고, 방법이 이기는 축에서는 대조가실행되지 않았으며, 빠진 대조군은 매번 가장 싸고 가장 자명한 baseline 이다**. “주류가 될까”도 조건부로만 답한다 — E -경로의 조건은제품 요구와 서빙 로그가 정하므로 **문헌이 약한 채로 주류가 될 수있고 이미 그렇게 되고 있다**. 반면 경로 분해에서 곧바로 따라 나오는결말인 **경로 합성에는 실험이 0 건이다**.
- B_s -품질 곡선은 지금 그럴 수 없다. x 축이 여섯 단위로 흩어져 있고웁길 다리가 없으며, 3점 이상을 놓은 4 편의 벤치마크 교집합이공집합이다. 게다가 B_s 는 (N, D) 와 같은 종류의 축이아니다 — 유한한 N_q 로 나뉘고, 라운드마다 재소비되며, 산출물이 wake 비용을 경로마다 다른 부호로 바꾼다. 산출물은 곡선이 아니라 최소보고 요구 아홉이고 **그중 새 실험을 요구하는 것은 하나뿐이다**.
- memory device 기회는 Θ -경로가 **개인화로 갈 때만실재한다**. 자리는 HBM 대역폭이 아니라 **요청 지연 안의 delta 스테이징 웜 계층과 그 계층의 쓰기 내구성**이며, 매체의 하루당 재기록횟수는 용량 · 사용자 수 · dtype 과 무관하게라운드 주기 하나로 정해진다. 웜 계층 옆에는 replay 앵커용콜드 원본 아카이브가 상시 필요하다.

자가 점검

- “sleep-time compute 은 유망한가”에 예/아니오로 답하면 안되는 이유를 표 E11-6의 “풀지 않는 문제” 열로 설명할 수 있다.
- 상각식에서 나뉘는 항과 나뉘지 않는 항을 각각 말할 수 있고, 후자를 0으로 놓으면 임계 길이가 어떻게 되는지 설명할 수 있다. 그리고 이 책이 $5\times$ 를 반박하지 **않는다는 것**과 무엇을 반박하는지를 구분할 수 있다.
- 세 경로의 상태 바이트가 왜 자릿수로 벌어지는지를 세 비례식으로 대고, 거기서 핫 · 웜 · 콜드 배치가 어떻게 따라나오는지 설명할 수 있다.
- 개인화 요구가 Θ -경로의 구현을 강제하는 과정을 batching 파손다섯 단계로 설명할 수 있고, 완화 가능한 파손과 불가능한 파손을 가릴 수 있다.
- B_s 가 (N, D) 와 다른 종류의 축인 이유셋 (분모 · 반복 · 결함)을 대고, 그래서 왜 하나가아니라 세 곡선인지 말할 수 있다.
- 매체의 하루당 전체 재기록 횟수가 라운드 주기만으로 정해진다는 것을유도 없이 설명할 수 있고, 그것이 왜 소자 선택보다 알고리즘 다이얼의문제인지 말할 수 있다.
- (Rosetta) “모델 재배포 $\leftrightarrow$ 갱신 1회”행과 “batch로 weight 공유 $\leftrightarrow$ Θ -경로에서 깨

짐” 행을 이 권의 판정으로 채울 수 있다 — 전자는즉시성의 부재로, 후자는 개인화 조건절로.

닫으며

이 시리즈는 다섯 질문으로 시작했고, 답의 모양이 세 번 다르게 나왔다 — E 는 종류를 바꾼 유망, W 는 표본 1의 판정 불가, Θ 는 세 조건이 붙은 조건부다.

세 답에 공통으로 걸린 것이 하나 있다. 어느 경로에서도 “예산을얼마 썼는가”가 세어지지 않았다는 것이다. E -경로에서는 그것이 총비용방어를 막았고, W -경로에서는 계산량 정합 대조를 불가능하게 했으며, Θ -경로에서는 라운드를 늘렸을 때 무엇을 지불하는지 알 수 없게만들었다. “최선인가”의 판정 불가도 절반은 이 결측에서 나온다 — 비용을세지 않으면 같은 예산에서의 비교가 성립하지 않기 때문이다.

그래서 이 시리즈가 남기는 마지막 문장은 비관이 아니다. 이 분야의상태를 바꾸는 데 필요한 비용이 낮다. 총비용 대조는 스위치 하나와 이미있는 로그로 되고, 최소 보고 요구 아홉 중 여덟은 인쇄뿐이며, 웹 계층설계를 막고 있는 것도 자본이 아니라 실험 셋이다. 그리고 구조가 가장강하게 가리키는 방향 — 세 경로를 합성하는 설계 — 에는 아직 아무도들어가지 않았다.

이 책이 스스로 틀릴 수 있는 방식의 전체 목록은 본문 ch30이 갖는다.