

무엇을 측정하면 이 가설을 믿거나 버릴 수 있는가

어려운 Study paper 를 그림과 예로 다시 읽는 안내서

읽는 법 이 문서는 원 Study 의 결론을 바꾸지 않고, 질문→세 문장→직관→예/반례→그림→대안→미증명 지점 순서로 풀어 쓴다. 파란색 training 용어는 별도 Background paper 의 해당 개념으로 연결된다. 주장 ID 와 figure ID 는 원 Study 와 동일하다.

Contents

E12 · 무엇을 측정하면 이 가설을 믿거나 버릴 수 있는가	2
이 권이 답할질문	2
먼저 세 문장	2
직관	2
예와 반례	3
그림 읽기	4
대안과 비교	5
아직 모르는것	5
더 깊이 읽기	5
문서 경계와 사용법	6

E12 · 무엇을 측정하면 이 가설을 믿거나 버릴 수 있는가

이 권이 답할질문

Sleep-time compute 를 research program 으로 밀기 전에 어떤 실험이 성공해야하고, 어떤 결과가 나오면 방향을 버리거나 축소해야 하는가? Promising 한가설은 반증 조건을 가져야 한다. 이 권은 benchmark, staged roadmap, failure control, go/no-go rule 을 하나로 묶는다.

원문 경로는 benchmark roadmap, limitations and falsifiers, conclusion 이다. 근거는 **STC-C035** · author_claim · confidence high, **STC-C036** · author_claim · confidence high, **STC-C037** · synthesis · confidence high, **STC-C039** · synthesis · confidence medium, **STC-C041** · synthesis · confidence high, **STC-C057** · hypothesis · confidence medium 이다.

먼저 세 문장

1. Benchmark 는 current accuracy 가 아니라 retention, access, provenance, deletion, poisoning, cost, wake-SLA 를 함께 재야 한다.
2. 연구는 external synthesis baseline → selective adapter promotion → learned cadence → long-horizon fleet simulation 순으로 단계화한다. 앞 단계가실패하면 뒤 단계로 가지 않는다.
3. Sleep 이 동일 budget 의 retrieval/replay/adapter baseline 보다 utility per cost 에서 이기지 못하거나 rollback·delete 를 만족하지 못하면 broad deployment 가설은 반증된다.

직관

Benchmark unit 은 “기억 하나” 가아니다

하나의 memory record 가 여러 future query 에 다른 방식으로 쓰인다. 따라서 benchmark episode 에는 source, valid time, sensitivity, expected reuse, contradiction, delete event 가 함께 있어야 한다. Evaluation 은 write 직후가 아니라 여러 sleep cycle 뒤에도 반복한다.

Metric family

- **Utility**: future task success, answer accuracy, strategy reuse
- **Retention**: old episode/task performance, backward transfer
- **Access**: encoded information 이 실제 answer 에서 회수되는 비율
- **Freshness**: change 후 stale answer 지속 시간
- **Provenance**: answer/derived memory 가 source 로 연결되는 비율
- **Deletion**: source delete 후 external·parametric leakage
- **Robustness**: poisoned memory 의 spread 와 containment
- **Systems**: sleep joule, bytes moved, write amplification, TTFT/ITL impact
- **Recovery**: rollback time, rebuild time, lost generation 수

관측가능성은 이 metric 을 state generation 과 연결하는 telemetry 다. “평균 score 가 내려갔다” 가 아니라 어느 sleep job 과 evidence 가 원인인지 찾아야한다.

Four-stage roadmap

Stage 1 — External baseline. Immutable episode, temporal graph, vector index, background synthesis 를 구현한다. Provenance·delete·correction 이 되는 기준선을 만든다.

Stage 2 — Selective promotion. High-reuse stable subset 만 adapter 로 compile 하고 RAG 와 break-even 을 비교한다. Adapter 는 external record 에서 재현 가능해야 한다.

Stage 3 — Adaptive cadence. Fixed schedule sweep 으로 utility/staleness/cost curve 를 얻은 뒤 event-triggered 또는 learned scheduler 를 시험한다.

Stage 4 — Long-horizon simulation. 수백 generation, user churn, concept drift, poisoning, deletion 을 포함해 capacity knee 와 lifecycle economics 를 측정한다.

예와 반례

최소 viable benchmark stream

1. 10 만 episode 를 시간순으로 흘린다.
2. 일부는 stable fact, 일부는 preference, 일부는 transient request, 일부는 poison 이다.
3. Fact change 와 delete request 를 중간에 넣는다.
4. 매 interval 에 future query 와 unrelated control task 를 평가한다.
5. External-only, replay, EWC/GEM, adapter, hybrid sleep 을 같은 byte/compute budget 으로 비교한다.
6. 100 회 이상 generation 에서 cumulative error 와 recovery 를 기록한다.

숫자는 illustrative benchmark scale 이며 universal requirement 가 아니다. 핵심은 short static test 가 아니라 time-ordered lifecycle 을 만드는것이다.

Go condition

Hybrid sleep 이 external-only 보다 같은 quality 에서 later-query cost 를 줄이고, adapter-only 보다 provenance·delete 를 유지하며, wake SLA 영향없이 positive net utility 를 보이면 다음 단계로 간다.

No-go condition

- Derived memory error 가 cycle 마다 누적되고 correction 으로 회복되지 않는다.
- 동일 budget 의 RAG/replay baseline 보다 retained utility 가 낮다.
- Delete request 후 parametric leakage 를 허용 기준 아래로 내릴 수 없다.
- Adapter/version fragmentation 이 serving gain 을 상쇄한다.
- Sleep job 이 wake peak 와 경쟁해 SLO 를 지속적으로 위반한다.

반례 — Synthetic collapse 는 항상일어난다

STC-C035 · author_claim · confidence high 는 real-data support 가 사라진 recursive training 의 위험을 보여 주지만, STC-C036 · author_claim · confidence high 은 적절한 real/synthetic accumulation 에서 collapse 가 필연은 아님을 한정한다. 따라서 benchmark 는 “synthetic 인가 아닌가” 보다 recursive depth, anchor ratio, tail retention 을 sweep 해야 한다.

Failure mode마다 lifecycle control을 붙인다




Figure 1: STC-F013. Failure modes and lifecycle controls. 원 Study 의 저자작성 합성 figure 이며, 사실 주장의 인용은 원 Study 와 figure ledger 를따른다.

반증 가능한 research → system → device agenda




Figure 2: STC-F015. Falsifiable research and benchmark agenda. 원 Study 의저자 작성 합성 figure 이며, 사실 주장의 인용은 원 Study 와 figure ledger 를따른다.

반례 — 한 번의 delete test 통과

External record 에서 삭제됐어도 summary cache, graph edge, adapter, backup generation 에 남아 있을 수 있다. 머신러닝과 lineage-driven rebuild 를 함께 검증해야 한다. Delete completeness 는 artifact 전체의 property 다.

그림 읽기

Failure-mode map 은 benchmark injection point 를 준다. Ingest poisoning, summary hallucination, replay collapse, adapter interference, version mismatch, stale serve, incomplete delete 를 각각 의도적으로 넣고 detection · containment · recovery 를 측정한다.

Research agenda 는 질문을 measurement 와 falsifier 로 연결한다. “주류가될까?” 같은 큰 질문 을 capacity knee, break-even reuse, cadence frontier, delete leakage, state migration 으로 분해한다. 각 연구 package 는 성공 score 와 중단 threshold 를 가져야 한다.

대안과 비교

연구 package	baseline	핵심 metric	go	stop/falsifier
external synthesis	raw RAG/KG	utility, correction	conflict 감소	hallucinated merge 증가
adapter	RAG, LoRA-only	break-even	net cost 절감	delete/locality 실패
promotion	fixed intervals	reuse	interior gain	boundary 가항 상 우세
cadence	larger store	staleness+cost	knee 이동	noise 가 gain 상쇄
capacity	flat HBM/SSD	utility/byte	migration 감소	software overhead 우세
device tiering	short benchmark	bytes, WA, SLA	stable 100+ gen	error 단조 누적
long horizon		cycle drift		

오프폴리시평가는 cadence 후보를 싸게 거를 수 있지만 final go/no-go 에는 live or controlled intervention 이 필요하다. 출판게이트는 claim 을 direct fact, synthesis, hypothesis 로 표시하고 falsifier 가 없는 scaling-law 표현을 막는다.

아직 모르는것

- Human correction cost 를 automated metric 과 어떻게 합칠지 모른다.
- User privacy 와 personalization utility 를 동일 benchmark 에서 비교할 consent framework 가 없다.
- Parametric delete completeness 를 black-box behavior 만으로 증명할 수있는지 불명확하다.
- Long-horizon simulation 이 실제 user behavior drift 를 얼마나 대표하는지모른다.
- Device trace 가 공개되지 않으면 infra scaling hypothesis 를 independent 하게 검증하기 어렵다.

핵심

Sleep-time compute 를 믿는 가장 좋은 방법은 멋진 sleep metaphor 가 아니라, strongest baseline 과의 시간순 benchmark 에서 이길 조건과 질 조건을 미리적어 두는 것이다.

더 깊이 읽기

- 원 분석: benchmark roadmap, limitations·falsifiers, 조건부결론
- Training Background: 검증세트, 오프폴리시평가, 머신언러닝, 출판게이트, 관측가능성, 출처추적성
- Claim route: **STC-C035** · author_claim · confidence high · **STC-C036** · author_claim · confidence high · **STC-C037** · synthesis · confidence high · **STC-C039** · synthesis · confidence medium · **STC-C041** · synthesis · confidence high · **STC-C057** · hypothesis · confidence medium

문서 경계와 사용법

이 문서는 쉬운 설명본이지 새로운 증거원이 아니다. 수치 · 인용 · claim status 는 원 Study paper 와 claim map 이 우선한다. 학습 개념은 Training Background paper 를 함께 읽고, 논문 재현이나 외부 배포 판단에는 고정 source 와 rights audit 를 사용한다.